

扩散模型在成像与视觉中的教程

Stanley Chan¹

March 16, 2025

摘要. 近年来，生成工具的惊人增长推动了文本到图像生成和文本到视频生成中许多令人兴奋的应用。这些生成工具背后的基本原理是扩散的概念，这是一种特定的采样机制，克服了之前方法中的一些长期存在的缺点。本教程的目标是讨论这些扩散模型背后的基本思想。本教程的目标受众包括对扩散模型研究感兴趣或应用这些工具解决其他问题的本科生和研究生。

Contents

1 变分自编码器 (VAE)	2
1.1 VAE 的构建模块	2
1.2 证据下界	5
1.3 VAE 中的优化	9
1.4 结语	16
2 去噪扩散概率模型 (DDPM)	17
2.1 构建模块	18
2.2 证据下界	23
2.3 反向过程的分布	28
2.4 训练与推断	32
2.5 预测噪声	35
2.6 去噪扩散隐式模型 (DDIM)	37
2.7 结语	40
3 分数匹配朗之万动力学 (SMLD)	41
3.1 从分布中采样	41
3.2 (斯坦因的) 得分函数	44
3.3 分数匹配技术	46
3.4 结论性评述	50
4 随机微分方程 (SDE)	51
4.1 从迭代算法到常微分方程	51
4.2 什么是 SDE?	53
4.3 DDPM 与 SMLD 的随机微分方程	54
4.4 常微分方程与随机微分方程的数值解法	59
4.5 结论性评述	61
5 Langevin 方程与 Fokker-Planck 方程	62
5.1 布朗运动	62
5.2 主方程	68
5.3 Kramers-Moyal 展开	72
5.4 Fokker-Planck 方程	75
5.5 结论性评述	80
6 结论	81

¹普渡大学电气与计算机工程学院，西拉法叶，IN 47907。
电子邮件: stanchan@purdue.edu.

1 变分自编码器 (VAE)

很久以前，在一个遥远的星系，我们想要构建一个生成器——一个能够根据我们提供给计算机的输入生成文本、语音或图像的生成器。虽然这听起来可能有些神奇，但这个问题实际上已经被研究了很长时间。为了开启本教程的讨论，我们首先应考虑**变分自编码器 (VAE)**。VAE 由 Kingma 和 Welling 于 2014 年提出 [23]。根据他们 2019 年的教程 [24]，VAE 的灵感来源于 Helmholtz Machine[10]，是图模型与深度学习的结合。接下来，我们将讨论 VAE 的问题设定、其构建模块以及训练过程中相关的优化工具。

1.1 VAE 的构建模块

我们首先讨论 VAE 的示意图。如下图所示，VAE 由一对模型（通常由深度神经网络实现）组成。靠近输入端的模型称为**编码器**，而靠近输出端的模型称为**解码器**。我们将输入（通常是一幅图像）表示为向量 $\mathbf{x}$ ，输出（通常是另一幅图像）表示为向量 $\hat{\mathbf{x}}$ 。位于编码器和解码器之间的向量称为**潜变量**，记为 $\mathbf{z}$ 。编码器的任务是为 $\mathbf{x}$ 提取有意义的表示，而解码器的任务是从潜变量 $\mathbf{z}$ 生成新的图像。




Figure 1.1: 变分自编码器由一个将输入 $\mathbf{x}$ 转换为潜变量 $\mathbf{z}$ 的编码器和一个从潜变量合成输出 $\hat{\mathbf{x}}$ 的解码器组成。

在这个设置中，潜变量 $\mathbf{z}$ 有两个特殊的作用。对于输入，潜变量封装了可用于描述 $\mathbf{x}$ 的信息。编码过程可能是有损的，但我们的目标是尽可能保留 $\mathbf{x}$ 的重要内容。对于输出，潜变量作为“种子”，从中可以生成图像 $\hat{\mathbf{x}}$ 。理论上，两个不同的 $\mathbf{z}$ 应该生成两个不同的图像。

下面给出了潜变量的一个稍微更正式的定义。

Definition 1.1. 潜变量 [24]. 在概率模型中，潜变量 $\mathbf{z}$ 是我们未观察到的变量，因此不属于训练数据集，尽管它们是模型的一部分。

Example 1.1. 获取图像的潜表示并不是什么陌生的事情。早在 JPEG 压缩时代（可以说是一个古老的技术），我们使用离散余弦变换 (DCT) 基函数 φ_n 来编码图像的底层图像/图像块。通过将图像 $\mathbf{x}$ 投影到基函数所张成的空间，得到系数向量 $\mathbf{z} = [z_1, \dots, z_N]^T$ ，即 $z_n = \langle \varphi_n, \mathbf{x} \rangle$ 。因此，给定一幅图像 $\mathbf{x}$ ，我们可以生成一个系数向量 $\mathbf{z}$ 。从 $\mathbf{z}$ 中，我们可以使用逆变换来恢复（即解码）图像。

Figure 1.2: 在离散余弦变换 (DCT) 中，我们可以将编码器视为将图像 $\mathbf{x}$ 投影到基函数上生成潜变量 $\mathbf{z}$ 。

在这个例子中，系数向量 $\mathbf{z}$ 就是潜变量。编码器是 DCT 变换，解码器是逆 DCT 变换。

VAE 中的“变分”一词与变分法相关，变分法研究函数的优化。在 VAE 中，我们感兴趣的是寻找描述 $\mathbf{x}$ 和 $\mathbf{z}$ 的最优概率分布。鉴于此，我们需要考虑几个分布：

- $p(\mathbf{x})$: $\mathbf{x}$ 的真实分布。这是永远未知的。扩散模型的整个宇宙就是寻找从 $p(\mathbf{x})$ 中抽取样本的方法。如果我们知道 $p(\mathbf{x})$ （比如说，我们有一个描述 $p(\mathbf{x})$ 的公式），我们就可以直接抽取一个使 $\log p(\mathbf{x})$ 最大化的样本 $\mathbf{x}$ 。

- $p(\mathbf{z})$: 潜在变量的分布。通常，我们将其设为零均值单位方差的高斯分布 $\mathcal{N}(0, \mathbf{I})$ 。一个原因是高斯分布的线性变换仍然是高斯分布，这使得数据处理更加容易。Doersch [12] 也有一个很好的解释。提到任何分布都可以通过一个足够复杂的函数映射高斯分布来生成。例如，在单变量设置中，逆累积分布函数（CDF）技术 [7, Chapter 4] 可以用于任何具有可逆 CDF 的连续分布。一般来说，只要我们有一个足够强大的函数（例如，神经网络），我们就可以学习它并将 i.i.d. 高斯映射到我们问题所需的任何潜在变量。
- $p(\mathbf{z}|\mathbf{x})$: 与**编码器**相关的条件分布，它告诉我们给定 $\mathbf{x}$ 时 $\mathbf{z}$ 的可能性。我们无法访问它。 $p(\mathbf{z}|\mathbf{x})$ 本身不是编码器，但编码器必须做一些事情，使其行为与 $p(\mathbf{z}|\mathbf{x})$ 一致。
- $p(\mathbf{x}|\mathbf{z})$: 与**解码器**相关的条件分布，它告诉我们给定 $\mathbf{z}$ 时得到 $\mathbf{x}$ 的后验概率。同样，我们无法访问它。

当我们从经典的参数模型转向深度神经网络时，潜在变量的概念被改变为深度潜在变量。Kingma 和 Welling [24] 给出了一个很好的定义。

Definition 1.2. 深度潜在变量 [24]。深度潜在变量是其分布 $p(\mathbf{z})$ 、 $p(\mathbf{x}|\mathbf{z})$ 或 $p(\mathbf{z}|\mathbf{x})$ 由神经网络参数化的潜在变量。

深度潜在变量的优势在于，即使先验分布和条件分布的结构相对简单（例如高斯分布），它们也可以建模非常复杂的数据分布 $p(\mathbf{x})$ 。一种思考方式是，神经网络可以用来估计高斯的均值。虽然高斯本身很简单，但均值是输入数据的函数，它通过神经网络生成一个依赖于数据的均值。因此，高斯的表达能力得到了显著提高。

让我们回到上面的四个分布。这里有一个有点琐碎但有教育意义的例子，可以说明这个想法：

Example 1.2. 考虑一个随机变量 $\mathbf{X}$ ，它根据一个高斯混合模型分布，潜在变量 $z \in \{1, \dots, K\}$ 表示簇标识，使得 $p_Z(k) = \mathbb{P}[Z = k] = \pi_k$ ，其中 $k = 1, \dots, K$ 。我们假设 $\sum_{k=1}^K \pi_k = 1$ 。然后，如果我们被告知只需要查看第 k 个簇，给定 Z 的 $\mathbf{X}$ 的条件分布是

$$p_{\mathbf{X}|Z}(\mathbf{x}|k) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \sigma_k^2 \mathbf{I}).$$

$\mathbf{x}$ 的边际分布可以使用全概率定律找到，得到

$$p_{\mathbf{X}}(\mathbf{x}) = \sum_{k=1}^K p_{\mathbf{X}|Z}(\mathbf{x}|k) p_Z(k) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \sigma_k^2 \mathbf{I}). \quad (1.1)$$

因此，如果我们从 $p_{\mathbf{X}}(\mathbf{x})$ 开始，编码器的设计问题就是构建一个神奇的编码器，使得对于每个样本 $\mathbf{x} \sim p_{\mathbf{X}}(\mathbf{x})$ ，潜在代码将是 $z \in \{1, \dots, K\}$ ，其分布为 $z \sim p_Z(k)$ 。

为了说明编码器和解码器的工作原理，我们假设均值和方差是已知且固定的。否则，我们将需要通过期望最大化（EM）算法来估计均值和方差。这是可行的，但繁琐的方程会破坏这个例子的教育目的。

编码器：如何从 $\mathbf{x}$ 得到 z ？这很简单，因为在编码器端，我们知道 $p_{\mathbf{X}}(\mathbf{x})$ 和 $p_Z(k)$ 。想象一下，你只有两个类别 $z \in \{1, 2\}$ 。实际上，你只是在做一个二元决策，决定样本 $\mathbf{x}$ 应该属于哪个类别。有很多方法可以进行这种二元决策。如果你喜欢最大后验决策规则，你可以检查

$$p_{Z|\mathbf{X}}(1|\mathbf{x}) \geq_{\text{class 2}}^{\text{class 1}} p_{Z|\mathbf{X}}(2|\mathbf{x}),$$

这将返回一个简单的决策：你给我们 $\mathbf{x}$ ，我们告诉你 $z \in \{1, 2\}$ 。

解码器：在解码器端，如果我们给定一个潜在代码 $z \in \{1, \dots, K\}$ ，神奇的解码器只需要返回一个从 $p_{\mathbf{X}|Z}(\mathbf{x}|k) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \sigma_k^2 \mathbf{I})$ 中抽取的样本 $\mathbf{x}$ 。不同的 z 将给我们 K 个混合成分中的一个。如果我们有足够的样本，整体分布将遵循高斯混合分布。这个例子当然过于简化了，因为现实世界的问题可能比已知均值和方差的高斯混合模型要复杂得多。但我们意识到的一点是，如果我们想找到神奇的编码器和解码器，我们必须有一种方法来找到两个条件分布 $p(\mathbf{z}|\mathbf{x})$ 和 $p(\mathbf{x}|\mathbf{z})$ 。然而，它们都是高维的。

为了让我们能够说一些更有意义的东西，我们需要施加额外的结构，以便我们可以将这个概念推广到更复杂的问题。为此，我们考虑以下两个代理分布：

- $q_{\phi}(\mathbf{z}|\mathbf{x})$: $p(\mathbf{z}|\mathbf{x})$ 的代理，也是与编码器相关联的分布。 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 可以是任何有向图模型，并且可以使用深度神经网络进行参数化 [24, Section 2.1]。例如，我们可以定义

$$\begin{aligned} (\boldsymbol{\mu}, \sigma^2) &= \text{EncoderNetwork}_{\phi}(\mathbf{x}), \\ q_{\phi}(\mathbf{z}|\mathbf{x}) &= \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}, \text{diag}(\sigma^2)). \end{aligned} \quad (1.2)$$

由于其易处理性和计算效率，该模型被广泛使用。

- $p_{\theta}(\mathbf{x}|\mathbf{z})$: $p(\mathbf{x}|\mathbf{z})$ 的代理，也是与解码器相关联的分布。与编码器类似，解码器可以通过深度神经网络进行参数化。例如，我们可以定义

$$\begin{aligned} f_{\theta}(\mathbf{z}) &= \text{DecoderNetwork}_{\theta}(\mathbf{z}), \\ p_{\theta}(\mathbf{x}|\mathbf{z}) &= \mathcal{N}(\mathbf{x} | f_{\theta}(\mathbf{z}), \sigma_{\text{dec}}^2 \mathbf{I}), \end{aligned} \quad (1.3)$$

其中 σ_{dec} 是一个可以预先确定或学习的超参数。

输入 $\mathbf{x}$ 与潜在变量 $\mathbf{z}$ 之间的关系以及条件分布在 Figure 1.3 中进行了总结。有两个节点 $\mathbf{x}$ 和 $\mathbf{z}$ 。“正向”关系由 $p(\mathbf{z}|\mathbf{x})$ 指定（并由 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 近似），而“反向”关系由 $p(\mathbf{x}|\mathbf{z})$ 指定（并由 $p_{\theta}(\mathbf{x}|\mathbf{z})$ 近似）。




Figure 1.3: 在变分自编码器中，变量 $\mathbf{x}$ 和 $\mathbf{z}$ 通过条件分布 $p(\mathbf{x}|\mathbf{z})$ 和 $p(\mathbf{z}|\mathbf{x})$ 连接。为了使模型工作，我们引入了代理分布 $p_{\theta}(\mathbf{x}|\mathbf{z})$ 和 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 。

Example 1.3. 假设我们有一个随机变量 $\mathbf{x} \in \mathbb{R}^d$ 和一个潜在变量 $\mathbf{z} \in \mathbb{R}^d$ ，使得

$$\begin{aligned} \mathbf{x} &\sim p(\mathbf{x}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \sigma^2 \mathbf{I}), \\ \mathbf{z} &\sim p(\mathbf{z}) = \mathcal{N}(\mathbf{z} | 0, \mathbf{I}). \end{aligned}$$

我们想要构建一个 VAE。这意味着我们想要构建两个映射 $\text{Encoder}(\cdot)$ 和 $\text{Decoder}(\cdot)$ 。编码器将获取样本 $\mathbf{x}$ 并将其映射到潜在变量 $\mathbf{z}$ ，而解码器将获取潜在变量 $\mathbf{z}$ 并将其映射到生成变量 $\hat{\mathbf{x}}$ 。如果我们知道 $p(\mathbf{x})$ 是什么，那么有一个简单的解决方案，其中 $\mathbf{z} = (\mathbf{x} - \boldsymbol{\mu})/\sigma$ 且 $\hat{\mathbf{x}} = \boldsymbol{\mu} + \sigma\mathbf{z}$ 。在这种情况下，可以确定真实分布，并且它们可以用 delta 函数表示：

$$\begin{aligned} p(\mathbf{x}|\mathbf{z}) &= \delta(\mathbf{x} - (\sigma\mathbf{z} + \boldsymbol{\mu})), \\ p(\mathbf{z}|\mathbf{x}) &= \delta(\mathbf{z} - (\mathbf{x} - \boldsymbol{\mu})/\sigma). \end{aligned}$$

现在假设我们不知道 $p(\mathbf{x})$ ，因此我们需要构建一个编码器和一个解码器来估计 $\mathbf{z}$ 和 $\hat{\mathbf{x}}$ 。首先定义编码器。在这个例子中，我们的编码器获取输入 $\mathbf{x}$ 并生成一对参数 $\hat{\boldsymbol{\mu}}(\mathbf{x})$ 和 $\hat{\sigma}(\mathbf{x})^2$ ，表示高斯的参数。然后，我们将 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 定义为高斯分布：

$$\begin{aligned} (\hat{\boldsymbol{\mu}}(\mathbf{x}), \hat{\sigma}(\mathbf{x})^2) &= \text{Encoder}_{\phi}(\mathbf{x}), \\ q_{\phi}(\mathbf{z}|\mathbf{x}) &= \mathcal{N}(\mathbf{z} | \hat{\boldsymbol{\mu}}(\mathbf{x}), \hat{\sigma}(\mathbf{x})^2 \mathbf{I}). \end{aligned}$$

为了讨论的目的，我们假设 $\hat{\boldsymbol{\mu}}$ 是 $\mathbf{x}$ 的仿射函数，使得 $\hat{\boldsymbol{\mu}}(\mathbf{x}) = a\mathbf{x} + \mathbf{b}$ ，其中 a 和 $\mathbf{b}$ 是参数。同样，我们假设 $\hat{\sigma}(\mathbf{x})^2 = t^2$ ，其中 t 是标量。这将给出

$$q_{\phi}(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z} | a\mathbf{x} + \mathbf{b}, t^2 \mathbf{I}).$$

对于解码器，我们采用类似的结构，考虑

$$\begin{aligned} (\tilde{\boldsymbol{\mu}}(\mathbf{z}), \tilde{\sigma}(\mathbf{z})^2) &= \text{Decoder}_{\theta}(\mathbf{z}), \\ p_{\theta}(\mathbf{x}|\mathbf{z}) &= \mathcal{N}(\mathbf{x} | \tilde{\boldsymbol{\mu}}(\mathbf{z}), \tilde{\sigma}(\mathbf{z})^2 \mathbf{I}). \end{aligned}$$

同样，为了讨论的目的，我们假设 $\tilde{\boldsymbol{\mu}}$ 是仿射的，使得 $\tilde{\boldsymbol{\mu}}(\mathbf{z}) = c\mathbf{z} + \mathbf{v}$ ，其中 c 和 $\mathbf{v}$ 是参数，且 $\tilde{\sigma}(\mathbf{z})^2 = s^2$ ，其中 s 是标量。因此， $p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})$ 的形式为：

$$p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mathbf{z} | c\mathbf{x} + \mathbf{v}, s^2\mathbf{I}).$$

我们稍后将讨论如何确定这些参数。

1.2 证据下界

我们如何利用这两个代理分布来实现确定编码器和解码器的目标？如果我们将 ϕ 和 θ 视为优化变量，那么我们需要一个目标函数（或损失函数），以便通过训练样本来优化 ϕ 和 θ 。我们在这里使用的损失函数称为证据下界（ELBO）[24]：

Definition 1.3. (证据下界) 证据下界定义为

$$\text{ELBO}(\mathbf{x}) \stackrel{\text{def}}{=} \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} \right]. \quad (1.4)$$

你肯定很困惑，人们究竟是如何想出这个损失函数的！？让我们看看 ELBO 的含义以及它是如何推导的。

简而言之，ELBO 是先验分布 $\log p(\mathbf{x})$ 的一个下界，因为我们可以证明

$$\begin{aligned} \log p(\mathbf{x}) &= \text{some magical steps to be derived} \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} \right] + \mathbb{D}_{\text{KL}}(q_{\phi}(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}|\mathbf{x})) \\ &\geq \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} \right] \\ &\stackrel{\text{def}}{=} \text{ELBO}(\mathbf{x}), \end{aligned} \quad (1.5)$$

其中不等式成立是因为 KL 散度总是非负的。因此，ELBO 是 $\log p(\mathbf{x})$ 的一个有效下界。由于我们从未直接访问 $\log p(\mathbf{x})$ ，如果我们能以某种方式访问 ELBO，并且 ELBO 是一个良好的下界，那么我们可以有效地最大化 ELBO，以实现最大化 $\log p(\mathbf{x})$ 的目标，这是黄金标准。现在的问题是，这个下界有多好。正如你从方程和 Figure 1.4 中看到的，当我们的代理 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 能够完全匹配真实分布 $p(\mathbf{z}|\mathbf{x})$ 时，不等式将变为等式。因此，游戏的一部分是确保 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 接近 $p(\mathbf{z}|\mathbf{x})$ 。




Figure 1.4: $\log p(\mathbf{x})$ 和 ELBO 的可视化。两者之间的差距由 KL 散度 $\mathbb{D}_{\text{KL}}(q_{\phi}(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}|\mathbf{x}))$ 决定。

Eqn (1.5)的推导如下。

Theorem 1.1. 对数似然分解. 对数似然 $\log p(\mathbf{x})$ 可以分解为

$$\log p(\mathbf{x}) = \underbrace{\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} \right]}_{\stackrel{\text{def}}{=} \text{ELBO}(\mathbf{x})} + \mathbb{D}_{\text{KL}}(q_{\phi}(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}|\mathbf{x})). \quad (1.6)$$

证明. 技巧是使用我们神奇的代理 $q_\phi(\mathbf{z}|\mathbf{x})$ 来探索 $p(\mathbf{x})$ 并推导出下界。

$$\begin{aligned}
 \log p(\mathbf{x}) &= \log p(\mathbf{x}) \times \underbrace{\int q_\phi(\mathbf{z}|\mathbf{x}) d\mathbf{z}}_{=1} && \text{(乘以 1)} \\
 &= \int \underbrace{\log p(\mathbf{x})}_{\text{关于 } \mathbf{z} \text{ 的常数}} \times \underbrace{q_\phi(\mathbf{z}|\mathbf{x})}_{\text{关于 } \mathbf{z} \text{ 的分布}} d\mathbf{z} && \text{(将 } \log p(\mathbf{x}) \text{ 移入积分)} \\
 &= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p(\mathbf{x})], && (1.7)
 \end{aligned}$$

其中最后一个等式是对于任何随机变量 Z 和标量 a , $\int a \times p_Z(z) dz = \mathbb{E}[a] = a$ 的事实。

看, 我们已经得到了 $\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\cdot]$ 。只需再几步。让我们使用贝叶斯定理, 它指出 $p(\mathbf{x}, \mathbf{z}) = p(\mathbf{z}|\mathbf{x})p(\mathbf{x})$:

$$\begin{aligned}
 \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p(\mathbf{x})] &= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{p(\mathbf{z}|\mathbf{x})} \right] && \text{(贝叶斯定理)} \\
 &= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{p(\mathbf{z}|\mathbf{x})} \times \frac{q_\phi(\mathbf{z}|\mathbf{x})}{q_\phi(\mathbf{z}|\mathbf{x})} \right] && \text{(乘以 } \frac{q_\phi(\mathbf{z}|\mathbf{x})}{q_\phi(\mathbf{z}|\mathbf{x})} \text{)} \\
 &= \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z}|\mathbf{x})} \right]}_{\text{ELBO}} + \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{q_\phi(\mathbf{z}|\mathbf{x})}{p(\mathbf{z}|\mathbf{x})} \right]}_{\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}|\mathbf{x}))}, && (1.8)
 \end{aligned}$$

我们认识到第一项正是 ELBO, 而第二项正是 KL 散度。将 Eqn (1.8) 与 Eqn (1.5) 进行比较, 我们完成了证明。

Example 1.4. 使用前面的例子, 如果我们知道 $p(\mathbf{z}|\mathbf{x})$, 我们可以最小化 $\log p(\mathbf{x})$ 和 $\text{ELBO}(\mathbf{x})$ 之间的差距。为了看到这一点, 我们注意到 $\log p(\mathbf{x})$ 是

$$\log p(\mathbf{x}) = \text{ELBO}(\mathbf{x}) + \mathbb{D}_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}|\mathbf{x})) \geq \text{ELBO}(\mathbf{x}).$$

等式成立当且仅当 KL 散度项为零。为了使 KL 散度为零, 必须有 $q_\phi(\mathbf{z}|\mathbf{x}) = p(\mathbf{z}|\mathbf{x})$ 。然而, 由于 $p(\mathbf{z}|\mathbf{x})$ 是一个 delta 函数, 唯一可能是

$$\begin{aligned}
 q_\phi(\mathbf{z}|\mathbf{x}) &= \mathcal{N}(\mathbf{z} \mid \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}, 0) \\
 &= \delta(\mathbf{z} - \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}), && (1.9)
 \end{aligned}$$

即, 我们将标准差设为 $t = 0$ 。为了确定 $p_\theta(\mathbf{x}|\mathbf{z})$, 我们需要一些额外的步骤来简化 ELBO。

我们现在有了 ELBO。但这个 ELBO 仍然不太有用, 因为它涉及到 $p(\mathbf{x}, \mathbf{z})$, 这是我们无法访问的。所以, 我们需要再做一点工作。

Theorem 1.2. ELBO 的解释. ELBO 可以分解为

$$\text{ELBO}(\mathbf{x}) = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log \overbrace{p_\theta(\mathbf{x}|\mathbf{z})}^{\text{a Gaussian}}]}_{\text{how good your decoder is}} - \underbrace{\mathbb{D}_{\text{KL}}\left(\overbrace{q_\phi(\mathbf{z}|\mathbf{x})}^{\text{a Gaussian}} \parallel \overbrace{p(\mathbf{z})}^{\text{a Gaussian}}\right)}_{\text{how good your encoder is}}. \quad (1.10)$$

证明。让我们仔细看看 ELBO

$$\begin{aligned}
\text{ELBO}(\mathbf{x}) &\stackrel{\text{def}}{=} \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}, \mathbf{z})}{q_\phi(\mathbf{z}|\mathbf{x})} \right] && \text{(定义)} \\
&= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{x}|\mathbf{z})p(\mathbf{z})}{q_\phi(\mathbf{z}|\mathbf{x})} \right] && (p(\mathbf{x}, \mathbf{z}) = p(\mathbf{x}|\mathbf{z})p(\mathbf{z})) \\
&= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log p(\mathbf{x}|\mathbf{z})] + \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{p(\mathbf{z})}{q_\phi(\mathbf{z}|\mathbf{x})} \right] && \text{(拆分期望)} \\
&= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log p_\theta(\mathbf{x}|\mathbf{z})] - \mathbb{D}_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z})), && \text{(KL 的定义)}
\end{aligned}$$

其中我们将无法访问的 $p(\mathbf{x}|\mathbf{z})$ 替换为其代理 $p_\theta(\mathbf{x}|\mathbf{z})$ 。

这是一个美妙的结果。我们刚刚展示了一些非常容易理解的东西。让我们看看 Eqn (1.10) 中的两项：

- **重建。** 第一项与解码器有关。我们希望当我们将一个潜在变量 $\mathbf{z}$ 输入解码器时，解码器能生成一个好的图像 $\mathbf{x}$ (当然!!)。因此，我们希望最大化 $\log p_\theta(\mathbf{x}|\mathbf{z})$ 。这类似于最大似然估计，我们希望找到模型参数以最大化观察到图像的可能性。这里的期望是针对样本 $\mathbf{z}$ (以 $\mathbf{x}$ 为条件) 进行的。这并不奇怪，因为样本 $\mathbf{z}$ 用于评估解码器的质量。它不能是任意的噪声向量，而是一个有意义的潜在向量。因此， $\mathbf{z}$ 需从 $q_\phi(\mathbf{z}|\mathbf{x})$ 中采样。
- **先验匹配。** 第二项是编码器的 KL 散度。我们希望编码器将 $\mathbf{x}$ 转换为潜在向量 $\mathbf{z}$ ，使得潜在向量遵循我们选择的分布，例如 $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I})$ 。稍微一般化一点，我们将 $p(\mathbf{z})$ 写为目标分布。因为 KL 散度是一种距离 (当两个分布变得更不相似时增加)，我们需要在前面加上负号，以便当两个分布变得更相似时它增加。

Example 1.5. 继续前面的例子，我们继续假设我们知道 $p(\mathbf{z}|\mathbf{x})$ 。那么 ELBO 中的重建项将给我们

$$\begin{aligned}
\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log p_\theta(\mathbf{x}|\mathbf{z})] &= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log \mathcal{N}(\mathbf{x} | c\mathbf{z} + \mathbf{v}, s^2\mathbf{I})] \\
&= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[-\frac{1}{2} \log 2\pi - \log s - \frac{\|\mathbf{x} - (c\mathbf{z} + \mathbf{v})\|^2}{2s^2} \right] \\
&= -\frac{1}{2} \log 2\pi - \log s - \frac{c^2}{2s^2} \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\|\mathbf{z} - \frac{\mathbf{x}-\mathbf{v}}{c}\|^2] \\
&= -\frac{1}{2} \log 2\pi - \log s - \frac{c^2}{2s^2} \mathbb{E}_{\delta\left(\mathbf{z} - \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}\right)} [\|\mathbf{z} - \frac{\mathbf{x}-\mathbf{v}}{c}\|^2] \\
&= -\frac{1}{2} \log 2\pi - \log s - \frac{c^2}{2s^2} [\|\frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma} - \frac{\mathbf{x}-\mathbf{v}}{c}\|^2] \\
&\leq -\frac{1}{2} \log 2\pi - \log s,
\end{aligned}$$

其中上界紧当且仅当范数平方项为零，这在 $\mathbf{v} = \boldsymbol{\mu}$ 和 $c = \sigma$ 时成立。对于其余项，显然 $-\log s$ 是 s 的单调递减函数，当 $s \rightarrow 0$ 时 $-\log s \rightarrow \infty$ 。因此，当 $\mathbf{v} = \boldsymbol{\mu}$ 和 $c = \sigma$ 时， $\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\log p_\theta(\mathbf{x}|\mathbf{z})]$ 在 $s = 0$ 时达到最大值。这意味着

$$\begin{aligned}
p_\theta(\mathbf{x}|\mathbf{z}) &= \mathcal{N}(\mathbf{x} | \sigma\mathbf{z} + \boldsymbol{\mu}, 0) \\
&= \delta(\mathbf{x} - (\sigma\mathbf{z} + \boldsymbol{\mu})).
\end{aligned} \tag{1.11}$$

ELBO 的局限性。 ELBO 在实际中很有用，但它并不等同于真实似然 $\log p(\mathbf{x})$ 。正如我们提到的，ELBO 仅在 $\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}|\mathbf{x})) = 0$ 时完全等于 $\log p(\mathbf{x})$ ，这发生在 $q_\phi(\mathbf{z}|\mathbf{x}) = p(\mathbf{z}|\mathbf{x})$ 时。在下面的例子中，我们将展示一个通过最大化 ELBO 得到的 $q_\phi(\mathbf{z}|\mathbf{x})$ 与 $p(\mathbf{z}|\mathbf{x})$ 不同的情况。

Example 1.6. (ELBO 的局限性) 在前面的例子中，如果我们对 $p(\mathbf{z}|\mathbf{x})$ 一无所知，我们需要通过最大化 ELBO 来训练 VAE。然而，由于 ELBO 只是真实分布 $\log p(\mathbf{x})$ 的下界，最大化 ELBO 不会返回我们希望的 delta 函数。相反，我们将获得一些非常有意但不完全是 delta 函数的东西。

为了简单起见，让我们考虑那些会返回我们无偏均值估计但方差未知的分布：

$$\begin{aligned} q_\phi(\mathbf{z}|\mathbf{x}) &= \mathcal{N}(\mathbf{z} \mid \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}, t^2\mathbf{I}), \\ p_\theta(\mathbf{x}|\mathbf{z}) &= \mathcal{N}(\mathbf{x} \mid \sigma\mathbf{z} + \boldsymbol{\mu}, s^2\mathbf{I}). \end{aligned}$$

这在某种程度上是“作弊”，因为理论上我们不应该对均值的估计做任何假设。但从直观的角度来看，由于 $q_\phi(\mathbf{z}|\mathbf{x})$ 和 $p_\theta(\mathbf{x}|\mathbf{z})$ 是 $p(\mathbf{z}|\mathbf{x})$ 和 $p(\mathbf{x}|\mathbf{z})$ 的代理，它们必须类似于 delta 函数的某些属性。最近的选择是将 $q_\phi(\mathbf{z}|\mathbf{x})$ 和 $p_\theta(\mathbf{x}|\mathbf{z})$ 定义为均值与两个 delta 函数一致的高斯分布。方差未知，它们是本例中感兴趣的主体。

我们的重点在于最大化 ELBO，它由先验匹配项和重构项组成。对于先验匹配误差，我们希望最小化 KL 散度：

$$\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p(\mathbf{z})) = \mathbb{D}_{\text{KL}}(\mathcal{N}(\mathbf{z} \mid \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}, t^2\mathbf{I}) \parallel \mathcal{N}(\mathbf{z} \mid 0, \mathbf{I})).$$

两个多元高斯分布 $\mathcal{N}(\mathbf{z}|\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)$ 和 $\mathcal{N}(\mathbf{z}|\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)$ 的 KL 散度有一个闭式表达式，可以在维基百科上找到：

$$\begin{aligned} \mathbb{D}_{\text{KL}}(\mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)\|\mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)) \\ = \frac{1}{2} \left(\text{Tr}(\boldsymbol{\Sigma}_1^{-1}\boldsymbol{\Sigma}_0) - d + (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^T \boldsymbol{\Sigma}_1^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) + \log \frac{\det \boldsymbol{\Sigma}_1}{\det \boldsymbol{\Sigma}_0} \right). \end{aligned}$$

利用这个结果（并通过一些代数运算），我们可以证明

$$\mathbb{D}_{\text{KL}}(\mathcal{N}(\mathbf{z} \mid \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}, t^2\mathbf{I}) \parallel \mathcal{N}(\mathbf{z} \mid 0, \mathbf{I})) = \frac{1}{2} [t^2 d - d + \|\frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}\|^2 - 2d \log t],$$

其中 d 是 $\mathbf{x}$ 和 $\mathbf{z}$ 的维度。为了最小化 KL 散度，我们对 t 求导并证明

$$\frac{\partial}{\partial t} \left\{ \frac{1}{2} [t^2 d - d + \|\frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}\|^2 - 2d \log t] \right\} = t \cdot d - \frac{d}{t}.$$

将其设为零将得到 $t = 1$ 。因此，我们可以证明

$$q_\phi(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\mathbf{z} \mid \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}, \mathbf{I}).$$

对于重构项，我们可以证明

$$\begin{aligned} \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}|\mathbf{z})] &= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\log \frac{1}{(\sqrt{2\pi}s^2)^d} \exp \left\{ -\frac{\|\mathbf{x} - (\sigma\mathbf{z} + \boldsymbol{\mu})\|^2}{2s^2} \right\} \right] \\ &= \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[-\frac{d}{2} \log 2\pi - d \log s - \frac{\|\mathbf{x} - (\sigma\mathbf{z} + \boldsymbol{\mu})\|^2}{2s^2} \right] \\ &= -\frac{d}{2} \log 2\pi - d \log s - \frac{\sigma^2}{2s^2} \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} [\|\mathbf{z} - \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma}\|^2] \\ &= -\frac{d}{2} \log 2\pi - d \log s - \frac{\sigma^2}{2s^2} \text{Trace} \left\{ \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \left[\left(\mathbf{z} - \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma} \right) \left(\mathbf{z} - \frac{\mathbf{x}-\boldsymbol{\mu}}{\sigma} \right)^T \right] \right\} \\ &= -\frac{d}{2} \log 2\pi - d \log s - \frac{\sigma^2}{2s^2} \cdot d, \end{aligned}$$

因为 $\mathbf{z} \sim q_\phi(\mathbf{z}|\mathbf{x})$ 的协方差是 $\mathbf{I}$ ，所以迹将给出 d 。对 s 求导将得到

$$\frac{d}{ds} \left\{ -\frac{d}{2} \log 2\pi - d \log s - \frac{d\sigma^2}{2s^2} \right\} = -\frac{d}{s} + \frac{d\sigma^2}{s^3} = 0.$$

将其设为零将得到 $s = \sigma$ 。因此，

$$p_\theta(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mathbf{x} \mid \sigma\mathbf{z} + \boldsymbol{\mu}, \sigma^2\mathbf{I}).$$

正如我们在这个例子和前面的例子中所看到的，虽然理想分布是狄拉克函数，但我们得到的代理分布具有有限的方差。这个有限的方差为 VAE 生成的样本增加了额外的随机性。这个 VAE 没有任何问题——我们通过最大化 ELBO 正确地做到了这一点。只是最大化 ELBO 并不等同于最大化 $\log p(\mathbf{x})$ 。

1.3 VAE 中的优化

在前两小节中，我们介绍了 VAE 和 ELBO 的基本构建模块。本小节的目标是讨论如何训练 VAE 以及如何进行推断。

VAE 是一个旨在近似真实分布 $p(\mathbf{x})$ 的模型，以便我们可以从中抽取样本。VAE 由 (ϕ, θ) 参数化。因此，训练 VAE 等同于解决一个封装了 $p(\mathbf{x})$ 本质且易于处理的优化问题。然而，由于 $p(\mathbf{x})$ 不可直接访问，自然的替代方案是优化 ELBO，即 $\log p(\mathbf{x})$ 的下界。这意味着，VAE 的学习目标是解决以下问题。

Definition 1.4. VAE 的优化目标是最大化 ELBO：

$$(\phi, \theta) = \operatorname{argmax}_{\phi, \theta} \sum_{\mathbf{x} \in \mathcal{X}} \text{ELBO}(\mathbf{x}), \quad (1.12)$$

其中 $\mathcal{X} = \{\mathbf{x}^{(\ell)} \mid \ell = 1, \dots, L\}$ 是训练数据集。

ELBO 梯度的不可处理性。与上述优化相关的挑战是，ELBO 关于 (ϕ, θ) 的梯度是不可处理的。由于当今大多数神经网络优化器使用一阶方法并通过反向传播梯度来更新网络权重，不可处理的梯度将在训练 VAE 时带来困难。

让我们进一步阐述梯度的不可处理性。我们首先将定义 1.3 代入上述目标函数。ELBO 的梯度为：²

$$\begin{aligned} \nabla_{\theta, \phi} \text{ELBO}(\mathbf{x}) &= \nabla_{\theta, \phi} \left\{ \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\log \frac{p_{\theta}(\mathbf{x}, \mathbf{z})}{q_{\phi}(\mathbf{z}|\mathbf{x})} \right] \right\} \\ &= \nabla_{\theta, \phi} \left\{ \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}) \right] \right\}. \end{aligned} \quad (1.13)$$

梯度包含两个参数。我们先来看 θ 。我们可以证明

$$\begin{aligned} \nabla_{\theta} \text{ELBO}(\mathbf{x}) &= \nabla_{\theta} \left\{ \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}) \right] \right\} \\ &= \nabla_{\theta} \left\{ \int \left[\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}) \right] \cdot q_{\phi}(\mathbf{z}|\mathbf{x}) d\mathbf{z} \right\} \\ &= \int \nabla_{\theta} \left\{ \log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}) \right\} \cdot q_{\phi}(\mathbf{z}|\mathbf{x}) d\mathbf{z} \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\nabla_{\theta} \left\{ \log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}) \right\} \right] \\ &= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\nabla_{\theta} \left\{ \log p_{\theta}(\mathbf{x}, \mathbf{z}) \right\} \right] \\ &\approx \frac{1}{L} \sum_{\ell=1}^L \nabla_{\theta} \left\{ \log p_{\theta}(\mathbf{x}, \mathbf{z}^{(\ell)}) \right\}, \end{aligned} \quad (\text{其中 } \mathbf{z}^{(\ell)} \sim q_{\phi}(\mathbf{z}|\mathbf{x})) \quad (1.14)$$

其中最后一个等式是期望的蒙特卡罗近似。

在上述方程中，如果 $p_{\theta}(\mathbf{x}, \mathbf{z})$ 由可计算的模型（如神经网络）实现，则其梯度 $\nabla_{\theta} \{\log p_{\theta}(\mathbf{x}, \mathbf{z})\}$ 可以通过

²ELBO 的原始定义使用了真实的联合分布 $p(\mathbf{x}, \mathbf{z})$ 。在实践中，由于 $p(\mathbf{x}, \mathbf{z})$ 不可访问，我们将其替换为可计算的代理分布 $p_{\theta}(\mathbf{x}, \mathbf{z})$ 。

自动微分计算。因此，可以通过反向传播梯度来实现最大化。关于 ϕ 的梯度更为复杂。我们可以证明

$$\begin{aligned}
\nabla_{\phi} \text{ELBO}(\mathbf{x}) &= \nabla_{\phi} \left\{ \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})] \right\} \\
&= \nabla_{\phi} \left\{ \int [\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})] \cdot q_{\phi}(\mathbf{z}|\mathbf{x}) d\mathbf{z} \right\} \\
&= \int \nabla_{\phi} \left\{ [\log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x})] \cdot q_{\phi}(\mathbf{z}|\mathbf{x}) \right\} d\mathbf{z} \\
&\neq \int \nabla_{\phi} \left\{ \log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}) \right\} \cdot q_{\phi}(\mathbf{z}|\mathbf{x}) d\mathbf{z} \\
&= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\nabla_{\phi} \left\{ \log p_{\theta}(\mathbf{x}, \mathbf{z}) - \log q_{\phi}(\mathbf{z}|\mathbf{x}) \right\} \right] \\
&= \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} \left[\nabla_{\phi} \left\{ -\log q_{\phi}(\mathbf{z}|\mathbf{x}) \right\} \right] \\
&\approx \frac{1}{L} \sum_{\ell=1}^L \nabla_{\phi} \left\{ -\log q_{\phi}(\mathbf{z}^{(\ell)}|\mathbf{x}) \right\}, \quad (\text{其中 } \mathbf{z}^{(\ell)} \sim q_{\phi}(\mathbf{z}|\mathbf{x})). \quad (1.15)
\end{aligned}$$

正如我们所看到的，尽管我们希望保持与 θ 相似的结构，但上述推导中的期望和梯度算子无法交换。这阻止了我们通过梯度反向传播来最大化 ELBO。

重参数化技巧。 ELBO 梯度的不可行性源于我们需要从分布 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 中抽取样本 $\mathbf{z}$ ，而该分布本身是 ϕ 的函数。正如 Kingma 和 Welling [23] 所指出的，对于连续潜在变量，可以计算 $\nabla_{\theta, \phi} \text{ELBO}(\mathbf{x})$ 的无偏估计，从而近似计算梯度并最大化 ELBO。其思想是采用一种称为重参数化技巧的技术 [23]。

回想一下，潜在变量 $\mathbf{z}$ 是从分布 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 中抽取的样本。重参数化技巧的思想是将 $\mathbf{z}$ 表示为另一个随机变量 ϵ 的可微且可逆的变换，该随机变量的分布与 $\mathbf{x}$ 和 ϕ 无关。也就是说，我们定义一个可微且可逆的函数 $\mathbf{g}$ ，使得

$$\mathbf{z} = \mathbf{g}(\epsilon, \phi, \mathbf{x}), \quad (1.16)$$

对于某个随机变量 $\epsilon \sim p(\epsilon)$ 。为了使讨论更简单，我们提出一个额外的要求

$$q_{\phi}(\mathbf{z}|\mathbf{x}) \cdot \left| \det \left(\frac{\partial \mathbf{z}}{\partial \epsilon} \right) \right| = p(\epsilon), \quad (1.17)$$

其中 $\frac{\partial \mathbf{z}}{\partial \epsilon}$ 是雅可比矩阵， $\det(\cdot)$ 是矩阵行列式。这个要求与多元微积分中的变量变换有关。以下示例将使其更加清晰。

Example 1.7. 假设 $\mathbf{z} \sim q_{\phi}(\mathbf{z}|\mathbf{x}) \stackrel{\text{def}}{=} \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2))$ 。我们可以定义

$$\mathbf{z} = \mathbf{g}(\epsilon, \phi, \mathbf{x}) \stackrel{\text{def}}{=} \epsilon \odot \boldsymbol{\sigma} + \boldsymbol{\mu}, \quad (1.18)$$

其中 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ ，且“ $\odot$ ”表示逐元素乘法。参数 ϕ 为 $\phi = (\boldsymbol{\mu}, \boldsymbol{\sigma}^2)$ 。对于这种分布选择，我们可以通过让 $\epsilon = \frac{\mathbf{z} - \boldsymbol{\mu}}{\boldsymbol{\sigma}}$ 来证明：

$$\begin{aligned}
q_{\phi}(\mathbf{z}|\mathbf{x}) \cdot \left| \det \left(\frac{\partial \mathbf{z}}{\partial \epsilon} \right) \right| &= \prod_{i=1}^d \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp \left\{ -\frac{(z_i - \mu_i)^2}{2\sigma_i^2} \right\} \cdot \prod_{i=1}^d \sigma_i \\
&= \frac{1}{(\sqrt{2\pi})^d} \exp \left\{ -\frac{\|\epsilon\|^2}{2} \right\} = \mathcal{N}(0, \mathbf{I}) = p(\epsilon).
\end{aligned}$$

通过对 $\mathbf{z}$ 进行重新参数化，将其表示为 ϵ 的函数，我们可以考察 $\nabla_{\phi} \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [f(\mathbf{z})]$ 对于某个一般函数 $f(\mathbf{z})$ 的情况。（稍后我们将考虑 $f(\mathbf{z}) = -\log q_{\phi}(\mathbf{z}|\mathbf{x})$ 。）为了符号简洁，我们写作 $\mathbf{g}(\epsilon)$ 而非 $\mathbf{g}(\epsilon, \phi, \mathbf{x})$ ，尽管我们理

解 $\mathbf{g}$ 有三个输入。通过变量替换，我们可以证明

$$\begin{aligned}
\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[f(\mathbf{z})] &= \int f(\mathbf{z}) \cdot q_\phi(\mathbf{z}|\mathbf{x}) d\mathbf{z} \\
&= \int f(\mathbf{g}(\epsilon)) \cdot q_\phi(\mathbf{g}(\epsilon)|\mathbf{x}) d\mathbf{g}(\epsilon), & (\mathbf{z} = \mathbf{g}(\epsilon)) \\
&= \int f(\mathbf{g}(\epsilon)) \cdot q_\phi(\mathbf{g}(\epsilon)|\mathbf{x}) \cdot \left| \det \left(\frac{\partial \mathbf{g}(\epsilon)}{\partial \epsilon} \right) \right| d\epsilon & (\text{变量替换的雅可比行列式}) \\
&= \int f(\mathbf{z}) \cdot p(\epsilon) d\epsilon & (\text{使用 Eqn (1.17)}) \\
&= \mathbb{E}_{p(\epsilon)}[f(\mathbf{z})].
\end{aligned} \tag{1.19}$$

因此，如果我们想对 ϕ 求梯度，可以证明

$$\begin{aligned}
\nabla_\phi \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[f(\mathbf{z})] &= \nabla_\phi \mathbb{E}_{p(\epsilon)}[f(\mathbf{z})] = \nabla_\phi \left\{ \int f(\mathbf{z}) \cdot p(\epsilon) d\epsilon \right\} \\
&= \int \nabla_\phi \{f(\mathbf{z}) \cdot p(\epsilon)\} d\epsilon \\
&= \int \{\nabla_\phi f(\mathbf{z})\} \cdot p(\epsilon) d\epsilon \\
&= \mathbb{E}_{p(\epsilon)}[\nabla_\phi f(\mathbf{z})],
\end{aligned} \tag{1.20}$$

这可以通过蒙特卡洛方法近似。将 $f(\mathbf{z}) = -\log q_\phi(\mathbf{z}|\mathbf{x})$ 代入，我们可以证明

$$\begin{aligned}
\nabla_\phi \mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[-\log q_\phi(\mathbf{z}|\mathbf{x})] &= \mathbb{E}_{p(\epsilon)}[-\nabla_\phi \log q_\phi(\mathbf{z}|\mathbf{x})] \\
&\approx -\frac{1}{L} \sum_{\ell=1}^L \nabla_\phi \log q_\phi(\mathbf{z}^{(\ell)}|\mathbf{x}), & (\text{where } \mathbf{z}^{(\ell)} = \mathbf{g}(\epsilon^{(\ell)}, \phi, \mathbf{x})) \\
&= -\frac{1}{L} \sum_{\ell=1}^L \nabla_\phi \left[\log p(\epsilon^{(\ell)}) - \log \left| \det \frac{\partial \mathbf{z}^{(\ell)}}{\partial \epsilon^{(\ell)}} \right| \right] \\
&= \frac{1}{L} \sum_{\ell=1}^L \nabla_\phi \left[\log \left| \det \frac{\partial \mathbf{z}^{(\ell)}}{\partial \epsilon^{(\ell)}} \right| \right].
\end{aligned}$$

因此，只要行列式对 ϕ 可微，蒙特卡洛近似就可以数值计算。

Example 1.8. 假设参数和分布 q_ϕ 定义如下：

$$\begin{aligned}
(\boldsymbol{\mu}, \boldsymbol{\sigma}^2) &= \text{EncoderNetwork}_\phi(\mathbf{x}) \\
q_\phi(\mathbf{z}|\mathbf{x}) &= \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}^2)).
\end{aligned}$$

我们可以定义 $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ 。然后，我们可以证明

$$\begin{aligned}
\log \left| \det \frac{\partial \mathbf{z}}{\partial \epsilon} \right| &= \log \left| \det \left(\frac{\partial (\boldsymbol{\mu} + \boldsymbol{\sigma} \odot \epsilon)}{\partial \epsilon} \right) \right| \\
&= \log \left| \det \left(\text{diag} \{ \boldsymbol{\sigma} \} \right) \right| \\
&= \log \prod_{i=1}^d \sigma_i = \sum_{i=1}^d \log \sigma_i.
\end{aligned}$$

因此，我们可以证明

$$\begin{aligned}
\nabla_{\phi} \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})} [-\log q_{\phi}(\mathbf{z}|\mathbf{x})] &\approx \frac{1}{L} \sum_{\ell=1}^L \nabla_{\phi} \left[\log \left| \det \frac{\partial \mathbf{z}^{(\ell)}}{\partial \boldsymbol{\epsilon}^{(\ell)}} \right| \right] \\
&= \frac{1}{L} \sum_{\ell=1}^L \nabla_{\phi} \left[\sum_{i=1}^d \log \sigma_i \right] \\
&= \nabla_{\phi} \left[\sum_{i=1}^d \log \sigma_i \right] \\
&= \frac{1}{\boldsymbol{\sigma}} \odot \nabla_{\phi} \{ \boldsymbol{\sigma}_{\phi}(\mathbf{x}) \},
\end{aligned}$$

这里我们强调 $\boldsymbol{\sigma}_{\phi}(\mathbf{x})$ 是编码器的输出，它是一个神经网络。

正如我们在上述例子中看到的，对于某些特定的分布选择（例如高斯分布），ELBO 的梯度可以显著更容易推导。

VAE 编码器。在讨论了重新参数化技巧之后，我们现在可以讨论 VAE 中编码器的具体结构。为了使讨论集中，我们假设编码器的一个相对常见选择：

$$\begin{aligned}
(\boldsymbol{\mu}, \sigma^2) &= \text{EncoderNetwork}_{\phi}(\mathbf{x}) \\
q_{\phi}(\mathbf{z}|\mathbf{x}) &= \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}, \sigma^2 \mathbf{I}).
\end{aligned}$$

参数 $\boldsymbol{\mu}$ 和 σ 在技术上是神经网络，因为它们是 $\text{EncoderNetwork}_{\phi}(\cdot)$ 的输出。因此，如果我们将它们表示为

$$\begin{aligned}
\boldsymbol{\mu} &= \underbrace{\boldsymbol{\mu}_{\phi}}_{\text{neural network}}(\mathbf{x}), \\
\sigma^2 &= \underbrace{\sigma_{\phi}^2}_{\text{neural network}}(\mathbf{x}),
\end{aligned}$$

我们的符号稍微复杂一些，因为我们想强调 $\boldsymbol{\mu}$ 是 $\mathbf{x}$ 的函数；你给我们一个图像 $\mathbf{x}$ ，我们的工作返回高斯的参数（即均值和方差）。如果你给我们一个不同的 $\mathbf{x}$ ，那么高斯的参数也应该不同。参数 ϕ 指定 $\boldsymbol{\mu}$ 由 ϕ 控制（或参数化）。

假设我们得到了第 ℓ 个训练样本 $\mathbf{x}^{(\ell)}$ 。从这个 $\mathbf{x}^{(\ell)}$ 我们想要生成一个潜在变量 $\mathbf{z}^{(\ell)}$ ，它是 $q_{\phi}(\mathbf{z}|\mathbf{x})$ 的一个样本。由于高斯结构，这等价于说

$$\mathbf{z}^{(\ell)} \sim \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}_{\phi}(\mathbf{x}^{(\ell)}), \sigma_{\phi}^2(\mathbf{x}^{(\ell)}) \mathbf{I}). \quad (1.21)$$

这个方程的有趣之处在于，我们使用神经网络 $\text{EncoderNetwork}_{\phi}(\cdot)$ 来估计高斯的均值和方差。然后，从这个高斯中我们抽取一个样本 $\mathbf{z}^{(\ell)}$ ，如 Figure 1.5 所示。




Figure 1.5: VAE 编码器的实现。我们使用神经网络获取图像 $\mathbf{x}$ 并估计高斯分布的均值 $\boldsymbol{\mu}_{\phi}$ 和方差 σ_{ϕ}^2 。

表达 Eqn (1.21) 的一种更方便的方式是认识到采样操作 $\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 \mathbf{I})$ 可以通过重参数化技巧完成。

高维高斯分布的重参数化技巧:

$$\mathbf{z} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 \mathbf{I}) \iff \mathbf{z} = \boldsymbol{\mu} + \sigma \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}). \quad (1.22)$$

使用重参数化技巧, Eqn (1.21) 可以写成

$$\mathbf{z}^{(\ell)} = \boldsymbol{\mu}_\phi(\mathbf{x}^{(\ell)}) + \sigma_\phi(\mathbf{x}^{(\ell)}) \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}).$$

证明. 我们将证明一个任意协方差矩阵 $\boldsymbol{\Sigma}$ 的一般情况, 而不是对角矩阵 $\sigma^2 \mathbf{I}$ 。

对于任何高维高斯分布 $\mathbf{z} \sim \mathcal{N}(\mathbf{z}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 采样过程可以通过白噪声的变换完成

$$\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\Sigma}^{\frac{1}{2}} \boldsymbol{\epsilon}, \quad (1.23)$$

其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I})$ 。半矩阵 $\boldsymbol{\Sigma}^{\frac{1}{2}}$ 可以通过特征分解或 Cholesky 分解获得。如果 $\boldsymbol{\Sigma}$ 有特征分解 $\boldsymbol{\Sigma} = \mathbf{U} \mathbf{S} \mathbf{U}^T$, 那么 $\boldsymbol{\Sigma}^{\frac{1}{2}} = \mathbf{U} \mathbf{S}^{\frac{1}{2}} \mathbf{U}^T$ 。特征值矩阵 $\mathbf{S}$ 的平方根是良定义的, 因为 $\boldsymbol{\Sigma}$ 是一个半正定矩阵。

我们可以计算 $\mathbf{z}$ 的期望和协方差:

$$\begin{aligned} \mathbb{E}[\mathbf{z}] &= \mathbb{E}[\boldsymbol{\mu} + \boldsymbol{\Sigma}^{\frac{1}{2}} \boldsymbol{\epsilon}] = \boldsymbol{\mu} + \underbrace{\boldsymbol{\Sigma}^{\frac{1}{2}} \mathbb{E}[\boldsymbol{\epsilon}]}_{=0} = \boldsymbol{\mu}, \\ \text{Cov}(\mathbf{z}) &= \mathbb{E}[(\mathbf{z} - \boldsymbol{\mu})(\mathbf{z} - \boldsymbol{\mu})^T] = \mathbb{E}\left[\boldsymbol{\Sigma}^{\frac{1}{2}} \boldsymbol{\epsilon} \boldsymbol{\epsilon}^T (\boldsymbol{\Sigma}^{\frac{1}{2}})^T\right] = \boldsymbol{\Sigma}^{\frac{1}{2}} \underbrace{\mathbb{E}[\boldsymbol{\epsilon} \boldsymbol{\epsilon}^T]}_{=\mathbf{I}} (\boldsymbol{\Sigma}^{\frac{1}{2}})^T = \boldsymbol{\Sigma}. \end{aligned}$$

因此, 对于对角矩阵 $\boldsymbol{\Sigma} = \sigma^2 \mathbf{I}$, 上述表达式简化为

$$\mathbf{z} = \boldsymbol{\mu} + \sigma \boldsymbol{\epsilon}, \quad \text{where } \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}). \quad (1.24)$$

给定 VAE 编码器结构和 $q_\phi(\mathbf{z}|\mathbf{x})$, 我们可以回到 ELBO。回想一下, ELBO 由先验匹配项和重构项组成。先验匹配项通过 KL 散度 $\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z}))$ 来衡量。让我们评估这个 KL 散度。

为了评估 KL 散度, 我们 (重新) 使用一个结果, 我们总结如下:

Theorem 1.3. 两个高斯分布的 KL 散度.

两个 d 维高斯分布 $\mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0)$ 和 $\mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)$ 的 KL 散度为

$$\begin{aligned} \mathbb{D}_{\text{KL}}(\mathcal{N}(\boldsymbol{\mu}_0, \boldsymbol{\Sigma}_0) \| \mathcal{N}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_1)) \\ = \frac{1}{2} \left(\text{Tr}(\boldsymbol{\Sigma}_1^{-1} \boldsymbol{\Sigma}_0) - d + (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0)^T \boldsymbol{\Sigma}_1^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) + \log \frac{\det \boldsymbol{\Sigma}_1}{\det \boldsymbol{\Sigma}_0} \right). \end{aligned} \quad (1.25)$$

通过考虑

$$\begin{aligned} \boldsymbol{\mu}_0 &= \boldsymbol{\mu}_\phi(\mathbf{x}), \quad \boldsymbol{\Sigma}_0 = \sigma_\phi^2(\mathbf{x}) \mathbf{I} \\ \boldsymbol{\mu}_1 &= 0, \quad \boldsymbol{\Sigma}_1 = \mathbf{I}, \end{aligned}$$

我们可以证明 KL 散度有一个解析表达式

$$\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z})) = \frac{1}{2} \left(\sigma_\phi^2(\mathbf{x}) d - d + \|\boldsymbol{\mu}_\phi(\mathbf{x})\|^2 - 2d \log \sigma_\phi(\mathbf{x}) \right), \quad (1.26)$$

其中 d 是向量 $\mathbf{z}$ 的维度。KL 散度关于 ϕ 的梯度没有闭式解, 但可以数值计算:

$$\nabla_\phi \mathbb{D}_{\text{KL}}(q_\phi(\mathbf{z}|\mathbf{x}) \| p(\mathbf{z})) = \frac{1}{2} \nabla_\phi \left(\sigma_\phi^2(\mathbf{x}) d - d + \|\boldsymbol{\mu}_\phi(\mathbf{x})\|^2 - 2d \log \sigma_\phi(\mathbf{x}) \right). \quad (1.27)$$

关于 $\boldsymbol{\theta}$ 的梯度为零, 因为没有依赖于 $\boldsymbol{\theta}$ 的内容。

VAE 解码器. 解码器通过神经网络实现。为了符号简洁，我们将其定义为 $\text{DecoderNetwork}_{\boldsymbol{\theta}}(\cdot)$ ，其中 $\boldsymbol{\theta}$ 表示网络参数。解码器网络的工作是获取一个潜在变量 $\mathbf{z}$ 并生成一个图像 $f_{\boldsymbol{\theta}}(\mathbf{z})$ ：

$$f_{\boldsymbol{\theta}}(\mathbf{z}) = \text{DecoderNetwork}_{\boldsymbol{\theta}}(\mathbf{z}). \quad (1.28)$$

分布 $p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})$ 可以定义为

$$p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z}) = \mathcal{N}(\mathbf{x} | f_{\boldsymbol{\theta}}(\mathbf{z}), \sigma_{\text{dec}}^2 \mathbf{I}), \quad \text{for some hyperparameter } \sigma_{\text{dec}}. \quad (1.29)$$

$p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})$ 的解释是我们通过网络估计 $f_{\boldsymbol{\theta}}(\mathbf{z})$ 并将其作为高斯的均值。如果我们从 $p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})$ 中抽取一个样本 $\mathbf{x}$ ，那么通过重参数化技巧，我们可以将生成的图像 $\hat{\mathbf{x}}$ 写成

$$\hat{\mathbf{x}} = f_{\boldsymbol{\theta}}(\mathbf{z}) + \sigma_{\text{dec}} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}).$$

此外，如果我们取似然的对数，我们可以证明

$$\begin{aligned} \log p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z}) &= \log \mathcal{N}(\mathbf{x} | f_{\boldsymbol{\theta}}(\mathbf{z}), \sigma_{\text{dec}}^2 \mathbf{I}) \\ &= \log \frac{1}{\sqrt{(2\pi\sigma_{\text{dec}}^2)^d}} \exp \left\{ -\frac{\|\mathbf{x} - f_{\boldsymbol{\theta}}(\mathbf{z})\|^2}{2\sigma_{\text{dec}}^2} \right\} \\ &= -\frac{\|\mathbf{x} - f_{\boldsymbol{\theta}}(\mathbf{z})\|^2}{2\sigma_{\text{dec}}^2} - \underbrace{\log \sqrt{(2\pi\sigma_{\text{dec}}^2)^d}}_{\text{independent of } \boldsymbol{\theta} \text{ so we can drop it}}. \end{aligned} \quad (1.30)$$

回到 ELBO，我们希望计算 $\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})]$ 。如果我们直接计算期望，将需要计算一个积分

$$\begin{aligned} \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})] &= \int \log [\mathcal{N}(\mathbf{x} | f_{\boldsymbol{\theta}}(\mathbf{z}), \sigma_{\text{dec}}^2 \mathbf{I})] \cdot \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}_{\phi}(\mathbf{x}), \sigma_{\phi}^2(\mathbf{x})) d\mathbf{z} \\ &= - \int \frac{\|\mathbf{x} - f_{\boldsymbol{\theta}}(\mathbf{z})\|^2}{2\sigma_{\text{dec}}^2} \cdot \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}_{\phi}(\mathbf{x}), \sigma_{\phi}^2(\mathbf{x})) d\mathbf{z} + C, \end{aligned}$$

其中高斯分布对数的常数 C 可以省略。通过使用重参数化技巧，我们写出 $\mathbf{z} = \boldsymbol{\mu}_{\phi}(\mathbf{x}) + \sigma_{\phi}(\mathbf{x})\boldsymbol{\epsilon}$ 并将其代入上述方程。这将给出³

$$\begin{aligned} \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})] &= - \int \frac{\|\mathbf{x} - f_{\boldsymbol{\theta}}(\mathbf{z})\|^2}{2\sigma_{\text{dec}}^2} \cdot \mathcal{N}(\mathbf{z} | \boldsymbol{\mu}_{\phi}(\mathbf{x}), \sigma_{\phi}^2(\mathbf{x})) d\mathbf{z} \\ &\approx -\frac{1}{M} \sum_{m=1}^M \frac{\|\mathbf{x} - f_{\boldsymbol{\theta}}(\mathbf{z}^{(m)})\|^2}{2\sigma_{\text{dec}}^2} \\ &= -\frac{1}{M} \sum_{m=1}^M \frac{\|\mathbf{x} - f_{\boldsymbol{\theta}}(\boldsymbol{\mu}_{\phi}(\mathbf{x}) + \sigma_{\phi}(\mathbf{x})\boldsymbol{\epsilon}^{(m)})\|^2}{2\sigma_{\text{dec}}^2}. \end{aligned} \quad (1.31)$$

上述近似源于蒙特卡洛方法，其随机性基于 $\boldsymbol{\epsilon} \sim \mathcal{N}(\boldsymbol{\epsilon} | 0, \mathbf{I})$ 的采样。索引 M 指定了我们用于近似期望的蒙特卡洛样本数量。注意，输入图像 $\mathbf{x}$ 是固定的，因为 $\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})]$ 是 $\mathbf{x}$ 的函数。

关于 $\boldsymbol{\theta}$ 的 $\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})]$ 梯度相对容易计算。由于只有 $f_{\boldsymbol{\theta}}$ 依赖于 $\boldsymbol{\theta}$ ，我们可以进行自动微分。关于 ϕ 的梯度稍难一些，但由于我们使用了链式法则并深入到 $\boldsymbol{\mu}_{\phi}(\mathbf{x})$ 和 $\sigma_{\phi}(\mathbf{x})$ ，它仍然是可计算的。

检查 Eqn (1.31)，我们注意到一个有趣的现象，即损失函数仅仅是重构图像 $f_{\boldsymbol{\theta}}(\mathbf{z})$ 与真实图像 $\mathbf{x}$ 之间的 ℓ_2 范数。这意味着如果我们有生成图像 $f_{\boldsymbol{\theta}}(\mathbf{z})$ ，我们可以通过常规的 ℓ_2 损失与真实图像 $\mathbf{x}$ 直接比较，如图 Figure 1.6 所示。

训练 VAE. 给定一个干净图像的训练数据集 $\mathcal{X} = \{(\mathbf{x}^{(\ell)})\}_{\ell=1}^L$ ，VAE 的训练目标是最大化 ELBO

$$\operatorname{argmax}_{\boldsymbol{\theta}, \phi} \sum_{\mathbf{x} \in \mathcal{X}} \text{ELBO}_{\phi, \boldsymbol{\theta}}(\mathbf{x}),$$

³这里的负号并非错误。我们希望最大化 $\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\boldsymbol{\theta}}(\mathbf{x}|\mathbf{z})]$ ，这等同于最小化 ℓ_2 范数的负数。




Figure 1.6: VAE 解码器的实现。我们使用神经网络接收潜在向量 $\mathbf{z}$ 并生成图像 $f_{\theta}(\mathbf{z})$ 。如果我们假设高斯分布，对数似然将给出一个二次方程。

其中求和是对整个训练数据集进行的。单个 ELBO 基于我们上面推导的项之和

$$\text{ELBO}_{\phi, \theta}(\mathbf{x}) = \mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\theta}(\mathbf{x}|\mathbf{z})] - \mathbb{D}_{\text{KL}}(q_{\phi}(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z})). \quad (1.32)$$

这里，重构项为：

$$\mathbb{E}_{q_{\phi}(\mathbf{z}|\mathbf{x})}[\log p_{\theta}(\mathbf{x}|\mathbf{z})] \approx -\frac{1}{M} \sum_{m=1}^M \frac{\|\mathbf{x} - f_{\theta}(\mu_{\phi}(\mathbf{x}) + \sigma_{\phi}(\mathbf{x})\epsilon^{(m)})\|^2}{2\sigma_{\text{dec}}^2}, \quad (1.33)$$

而先验匹配项为

$$\mathbb{D}_{\text{KL}}(q_{\phi}(\mathbf{z}|\mathbf{x}) \parallel p(\mathbf{z})) = \frac{1}{2}(\sigma_{\phi}^2(\mathbf{x})d - d + \|\mu_{\phi}(\mathbf{x})\|^2 - 2\log \sigma_{\phi}(\mathbf{x})). \quad (1.34)$$

为了优化 θ 和 ϕ ，我们可以运行随机梯度下降。梯度可以基于神经网络的张量图计算。在计算机上，这是通过自动微分自动完成的。

让我们总结一下这些内容。

Theorem 1.4. (VAE 训练)。要训练 VAE，我们需要解决优化问题

$$\operatorname{argmax}_{\theta, \phi} \sum_{\mathbf{x} \in \mathcal{X}} \text{ELBO}_{\phi, \theta}(\mathbf{x}),$$

其中

$$\begin{aligned} \text{ELBO}_{\phi, \theta}(\mathbf{x}) = & -\frac{1}{M} \sum_{m=1}^M \frac{\|\mathbf{x} - f_{\theta}(\mu_{\phi}(\mathbf{x}) + \sigma_{\phi}(\mathbf{x})\epsilon^{(m)})\|^2}{2\sigma_{\text{dec}}^2} \\ & + \frac{1}{2}(\sigma_{\phi}^2(\mathbf{x})d - d + \|\mu_{\phi}(\mathbf{x})\|^2 - 2d\log \sigma_{\phi}(\mathbf{x})). \end{aligned} \quad (1.35)$$

VAE 推断。VAE 的推断相对简单。一旦 VAE 被训练，我们可以丢弃编码器，只保留解码器，如 Figure 1.7 所示。要从模型生成新图像，我们选择一个随机潜在向量 $\mathbf{z} \in \mathbb{R}^d$ 。通过将这个 $\mathbf{z}$ 发送到解码器 f_{θ} ，我们将能够生成一个新图像 $\hat{\mathbf{x}} = f_{\theta}(\mathbf{z})$ 。




Figure 1.7: 使用 VAE 生成图像就像通过解码器发送潜在噪声代码 $\mathbf{z}$ 一样简单。

1.4 结语

对于寻求更多参考文献的读者，我们强烈推荐 Kingma 和 Welling 基于他们原始 VAE 论文的教程 [24]。Doersch 等人提供的简短教程 [12] 也可能有所帮助。[24] 包含了一份优秀论文的长列表，其中包括 Rezende 和 Mohamed 关于归一化流的论文 [32]，该论文与 Kingma 和 Welling 的 VAE 论文几乎同时发表。

VAE 与经典变分推断和图模型有着诸多联系 [45]。VAE 也与 Goodfellow 等人提出的生成对抗网络 (GAN) 相关 [15]。Kingma 和 Welling 在 [24] 中评论道，VAE 与 GAN 具有互补特性；尽管 GAN 生成的图像感知质量更佳，但其与数据似然的联系较弱。VAE 能更好地满足数据似然标准，但有时样本的感知质量不如 GAN。

2 去噪扩散概率模型 (DDPM)

在本节中，我们将讨论扩散模型。关于如何推导扩散模型，有许多不同的视角，例如得分匹配、微分方程等。我们将遵循 Ho 等人关于去噪扩散概率模型的原始论文中概述的方法 [16]。

在讨论数学细节之前，让我们从 VAE 扩展的角度总结一下 DDPM：

扩散模型是增量更新，整体的组合为我们提供了编码器-解码器结构。

为什么要增量？这就像调整一艘巨轮的方向。你需要慢慢地将船转向你期望的方向，否则你会失去控制。同样的原则适用于你公司的 HR 和大学的管理层。

一次弯曲一英寸。

好了，哲学讲够了。让我们回到正题。

DDPM 与 Sohl-Dickstein 等人在 2015 年的一项早期工作有很多联系 [38]。Sohl-Dickstein 等人提出了如何从一个分布转换到另一个分布的问题。VAE 提供了一种方法：参考前一节，我们可以将源分布视为潜在变量 $\mathbf{z} \sim p(\mathbf{z})$ ，目标分布视为输入变量 $\mathbf{x} \sim p(\mathbf{x})$ 。然后通过设置代理分布 $p_\theta(\mathbf{x}|\mathbf{z})$ 和 $q_\phi(\mathbf{z}|\mathbf{x})$ ，我们可以训练编码器和解码器，使解码器服务于生成图像的目标。但 VAE 主要是一个一步生成——如果你给我们一个潜在代码 $\mathbf{z}$ ，我们要求神经网络 $f_\theta(\cdot)$ 立即返回生成的信号 $\mathbf{x} \sim \mathcal{N}(\mathbf{x} | f_\theta(\mathbf{z}), \sigma_{\text{dec}}^2 \mathbf{I})$ 。在某种意义上，这对神经网络要求太高了。我们要求它用几层神经元立即从一个分布 $p(\mathbf{z})$ 转换到另一个分布 $p(\mathbf{x})$ 。这太过分了。

Sohl-Dickstein 等人提出的想法是构建一个转换链，而不是一步过程。为此，他们定义了与 VAE 中的编码器和解码器类似的两个过程。他们将编码器称为前向过程，解码器称为反向过程。在这两个过程中，他们考虑了一系列变量 $\mathbf{x}_0, \dots, \mathbf{x}_T$ ，其联合分布分别表示为前向过程的 $q_\phi(\mathbf{x}_{0:T})$ 和反向过程的 $p_\theta(\mathbf{x}_{0:T})$ 。为了使这两个过程易于处理（同时也灵活），他们施加了一个马尔可夫链结构（即无记忆），其中

$$\begin{aligned} \text{从 } \mathbf{x}_0 \text{ 到 } \mathbf{x}_T \text{ 的前向过程: } \quad q_\phi(\mathbf{x}_{0:T}) &= q(\mathbf{x}_0) \prod_{t=1}^T q_\phi(\mathbf{x}_t | \mathbf{x}_{t-1}), \\ \text{从 } \mathbf{x}_T \text{ 到 } \mathbf{x}_0 \text{ 的反向过程: } \quad p_\theta(\mathbf{x}_{0:T}) &= p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t). \end{aligned}$$

在这两个方程中，转移分布仅依赖于其直接前一个阶段。因此，如果每个转移通过某种形式的神经网络实现，整个生成过程就被分解为许多较小的任务。这并不意味着我们需要 T 倍的神经网络。我们只是重复使用一个网络 T 次。将整个过程分解为较小的步骤，使我们能够在每一步使用简单的分布。正如接下来的小节将讨论的那样，我们可以使用高斯分布来进行转换。由于高斯的特性，如果似然和先验都是高斯分布，后验也将保持为高斯分布。因此，如果上述每个转换分布都是高斯分布，联合分布也是高斯分布。由于高斯分布完全由前两个矩（均值和方差）表征，计算非常容易处理。在 Sohl-Dickstein 等人的原始论文中，还有一个二项扩散过程的案例研究。

在提供了概念的高级概述之后，让我们讨论一些细节。扩散模型的起点是考虑 VAE 结构，并将其转化为一组增量更新，如 Figure 2.1 所示。这种特定结构被称为**变分扩散模型**，这是 Kingma 等人在 2021 年给出的名称 [22]。变分扩散模型具有一系列状态 $\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_T$ ，其解释如下：

- $\mathbf{x}_0$: 这是原始图像，与 VAE 中的 $\mathbf{x}$ 相同。
- $\mathbf{x}_T$: 这是潜在变量，与 VAE 中的 $\mathbf{z}$ 相同。如上所述，为了简单性、可处理性和计算效率，我们选择 $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$ 。
- $\mathbf{x}_1, \dots, \mathbf{x}_{T-1}$: 它们是中间状态。它们也是潜在变量，但不是白高斯分布。

变分扩散模型的结构由两条路径组成。前向路径和反向路径类似于单步变分自编码器的路径。不同之处在于编码器和解码器的输入输出维度相同。所有前向构建块的组合将为我们提供编码器，所有反向构建块的组合将为我们提供解码器。




Figure 2.1: Kingma 等人提出的变分扩散模型 [22]。在此模型中，输入图像为 x_0 ，白噪声为 x_T 。中间变量（或状态） $x_1, \dots, x_{T-1}$ 是潜在变量。从 x_{t-1} 到 x_t 的过渡类似于 VAE 中的前向步骤（编码器），而从 x_t 到 x_{t-1} 的过渡则类似于 VAE 中的反向步骤（解码器）。在变分扩散模型中，编码器/解码器的输入维度和输出维度是相同的。




Figure 2.2: 变分扩散模型的转移模块由三个节点组成。转移分布 $p(x_t|x_{t+1})$ 和 $p(x_t|x_{t-1})$ 无法直接访问，但我们可以用高斯分布来近似它们。

2.1 构建模块

让我们来谈谈变分扩散模型的构建模块。构建模块分为三类：转移模块、初始模块和最终模块。

转移模块 第 t 个转移模块由三个状态 x_{t-1} 、 x_t 和 x_{t+1} 组成。到达状态 x_t 有两条可能的路径，如 Figure 2.2 所示。

- 第一条路径是从 x_{t-1} 到 x_t 的正向转移。相关的转移分布为 $p(x_t|x_{t-1})$ 。简单来说，如果你告诉我们 x_{t-1} ，我们可以根据 $p(x_t|x_{t-1})$ 抽取一个样本 x_t 。然而，就像 VAE 一样，转移分布 $p(x_t|x_{t-1})$ 是不可直接访问的。我们可以通过一些简单的分布（如高斯分布）来近似它。近似分布记为 $q_\phi(x_t|x_{t-1})$ 。我们稍后将讨论 q_ϕ 的具体形式。
- 第二条路径是从 x_{t+1} 到 x_t 的反向转移。同样，我们不知道 $p(x_t|x_{t+1})$ ，因此我们有另一个代理分布（例如高斯分布）来近似真实分布。这个代理分布记为 $p_\theta(x_t|x_{t+1})$ 。

初始块 变分扩散模型的初始块关注状态 x_0 。由于我们从 x_0 开始，我们只需要从 x_1 到 x_0 的反向转移。从 x_{-1} 到 x_0 的正向转移可以省略。因此，我们只需要考虑 $p(x_0|x_1)$ 。但由于 $p(x_0|x_1)$ 无法直接访问，我们通过一个高斯分布 $p_\theta(x_0|x_1)$ 来近似它，其中均值通过神经网络计算。参见 Figure 2.3 以获取图示。

最终块 最终块关注状态 x_T 。记住， x_T 应该是我们的最终潜在变量，它是一个白高斯噪声向量。因为这是最终块，我们只需要从 x_{T-1} 到 x_T 的正向转移，而不需要诸如 x_{T+1} 到 x_T 的转移。正向转移通过 $q_\phi(x_T|x_{T-1})$ 来近似，这是一个高斯分布。参见 Figure 2.4 以获取图示。

理解转移分布。在我们继续之前，我们需要解释转移分布 $q_\phi(x_t|x_{t-1})$ 。我们知道它是一个高斯分布。但这个高斯分布的均值和方差是什么？

Definition 2.1. 转移分布 $q_\phi(x_t|x_{t-1})$ 。 在变分扩散模型（以及我们稍后将讨论的 DDPM）中，转移




Figure 2.3: 变分扩散模型的初始块关注节点 $\mathbf{x}_0$ 。由于在时间 $t = 0$ 之前没有状态，我们只有从 $\mathbf{x}_1$ 到 $\mathbf{x}_0$ 的反向转移。




Figure 2.4: 变分扩散模型的最终块关注节点 $\mathbf{x}_T$ 。由于在时间 $t = T$ 之后没有状态，我们只有从 $\mathbf{x}_{T-1}$ 到 $\mathbf{x}_T$ 的正向转移。

分布 $q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})$ 定义为

$$q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1}) \stackrel{\text{def}}{=} \mathcal{N}(\mathbf{x}_t | \sqrt{\alpha_t}\mathbf{x}_{t-1}, (1 - \alpha_t)\mathbf{I}). \quad (2.1)$$

换句话说， $q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})$ 是一个高斯分布。均值为 $\sqrt{\alpha_t}\mathbf{x}_{t-1}$ ，方差为 $1 - \alpha_t$ 。选择缩放因子 $\sqrt{\alpha_t}$ 是为了确保方差幅度得以保持，从而不会在多次迭代后爆炸或消失。

Example 2.1. 让我们考虑一个高斯混合模型

$$\mathbf{x}_0 \sim p_0(\mathbf{x}) = \pi_1 \mathcal{N}(\mathbf{x}|\mu_1, \sigma_1^2) + \pi_2 \mathcal{N}(\mathbf{x}|\mu_2, \sigma_2^2).$$

给定转移概率，我们知道如果 $\mathbf{x}_t \sim q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})$ ，那么

$$\mathbf{x}_t = \sqrt{\alpha_t}\mathbf{x}_{t-1} + \sqrt{(1 - \alpha_t)}\epsilon, \quad \text{where } \epsilon \sim \mathcal{N}(0, \mathbf{I}).$$

我们的目标是看看这个迭代过程（使用上述转移概率）是否会在平衡状态下（即当 $t \rightarrow \infty$ 时）给我们一个白高斯分布。对于混合模型，不难证明 $\mathbf{x}_t$ 的概率分布可以通过以下算法递归计算，其中 $t = 1, 2, \dots, T$ ：（证明将在后面展示）

$$\begin{aligned} \mathbf{x}_t \sim p_t(\mathbf{x}) = & \pi_1 \mathcal{N}(\mathbf{x} | \sqrt{\alpha_t}\mu_{1,t-1}, \alpha_t\sigma_{1,t-1}^2 + (1 - \alpha_t)) \\ & + \pi_2 \mathcal{N}(\mathbf{x} | \sqrt{\alpha_t}\mu_{2,t-1}, \alpha_t\sigma_{2,t-1}^2 + (1 - \alpha_t)), \end{aligned} \quad (2.2)$$

其中 $\mu_{1,t-1}$ 是时间 $t-1$ 时类别 1 的均值， $\mu_{1,0} = \mu_1$ 为初始均值。类似地， $\sigma_{1,t-1}^2$ 是时间 $t-1$ 时类别 1 的方差， $\sigma_{1,0}^2 = \sigma_1^2$ 为初始方差。

在下图中，我们展示了一个数值例子，其中 $\pi_1 = 0.3$ ， $\pi_2 = 0.7$ ， $\mu_1 = -2$ ， $\mu_2 = 2$ ， $\sigma_1 = 0.2$ ， $\sigma_2 = 1$ 。速率定义为 $\alpha_t = 0.97$ ，对所有 t 。我们绘制了不同 t 时的概率分布函数。




Figure 2.5: 分布 $p_t(\mathbf{x})$ 的演化。随着时间 t 的推移，双峰分布逐渐变为高斯分布。

Eqn (2.2)的证明。对于那些想了解我们如何推导 Eqn (2.2)中混合模型的概率密度的人，我们可以展示一个简单的推导。考虑一个混合模型

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \underbrace{\mathcal{N}(\mathbf{x} | \mu_k, \sigma_k^2 \mathbf{I})}_{p(\mathbf{x}|k)}.$$

如果我们考虑一个新变量 $\mathbf{y} = \sqrt{\alpha}\mathbf{x} + \sqrt{1-\alpha}\epsilon$ ，其中 $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ ，则 $\mathbf{y}$ 的分布可以通过全概率定律推导：

$$p(\mathbf{y}) = \sum_{k=1}^K p(\mathbf{y}|k)p(k) = \sum_{k=1}^K \pi_k p(\mathbf{y}|k).$$

由于 $\mathbf{y}|k = \sqrt{\alpha}\mathbf{x}|k + \sqrt{1-\alpha}\epsilon$ 是（条件）高斯随机变量 $\mathbf{x}|k$ 和另一个高斯随机变量 ϵ 的线性组合， $\mathbf{y}|k$ 的和仍为高斯分布。均值和方差为

$$\begin{aligned} \mathbb{E}[\mathbf{y}|k] &= \sqrt{\alpha}\mathbb{E}[\mathbf{x}|k] + \sqrt{1-\alpha}\mathbb{E}[\epsilon] = \sqrt{\alpha}\mu_k, \\ \text{Var}[\mathbf{y}|k] &= \alpha\text{Var}[\mathbf{x}|k] + (1-\alpha)\text{Var}[\epsilon] = \alpha\sigma_k^2 + (1-\alpha), \end{aligned}$$

其中我们使用了 $\mathbb{E}[\epsilon] = 0$ 和 $\text{Var}[\epsilon] = 1$ 的事实。既然我们刚刚论证了 $\mathbf{y}|k$ 是高斯分布，一旦我们知道均值和方差， $\mathbf{y}|k$ 的分布就完全确定了。代入上述推导结果，我们知道 $p(\mathbf{y}|k) = \mathcal{N}(\mathbf{y} | \sqrt{\alpha}\mu_k, \alpha\sigma_k^2 + (1-\alpha))$ 。这就完成了推导。

神奇的标量 $\sqrt{\alpha_t}$ 和 $1-\alpha_t$ 。你可能会好奇那些天才（去噪扩散论文的作者）是如何想出上述转移概率率中的神奇标量 $\sqrt{\alpha_t}$ 和 $(1-\alpha_t)$ 的。为了揭开这个谜团，让我们考虑两个不相关的标量 $a \in \mathbb{R}$ 和 $b \in \mathbb{R}$ ，并定义转移分布为

$$q_\phi(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t | a\mathbf{x}_{t-1}, b^2 \mathbf{I}). \quad (2.3)$$

以下是发现：

Theorem 2.1. (为什么是 $\sqrt{\alpha}$ 和 $1-\alpha$?) 假设 $q_\phi(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t | a\mathbf{x}_{t-1}, b^2 \mathbf{I})$ ，其中 a 和 b 为常数。如果我们希望选择 a 和 b 使得 $\mathbf{x}_t$ 的分布变为 $\mathcal{N}(0, \mathbf{I})$ ，则必须满足

$$a = \sqrt{\alpha} \quad \text{and} \quad b = \sqrt{1-\alpha}.$$

因此，转移分布为

$$q_\phi(\mathbf{x}_t | \mathbf{x}_{t-1}) \stackrel{\text{def}}{=} \mathcal{N}(\mathbf{x}_t | \sqrt{\alpha}\mathbf{x}_{t-1}, (1-\alpha)\mathbf{I}). \quad (2.4)$$

备注：如果你更喜欢噪声调度，可以将 α 替换为 α_t 。

证明。我们希望证明 $a = \sqrt{\alpha}$ 和 $b = \sqrt{1 - \alpha}$ 。对于 Eqn (2.3) 中所示的分布，等效的采样步骤为：

$$\mathbf{x}_t = a\mathbf{x}_{t-1} + b\boldsymbol{\epsilon}_{t-1}, \quad \text{where} \quad \boldsymbol{\epsilon}_{t-1} \sim \mathcal{N}(0, \mathbf{I}). \quad (2.5)$$

我们可以继续进行递归以展示

$$\begin{aligned} \mathbf{x}_t &= a\mathbf{x}_{t-1} + b\boldsymbol{\epsilon}_{t-1} \\ &= a(a\mathbf{x}_{t-2} + b\boldsymbol{\epsilon}_{t-2}) + b\boldsymbol{\epsilon}_{t-1} && \text{(代入 } \mathbf{x}_{t-1} = a\mathbf{x}_{t-2} + b\boldsymbol{\epsilon}_{t-2} \text{)} \\ &= a^2\mathbf{x}_{t-2} + ab\boldsymbol{\epsilon}_{t-2} + b\boldsymbol{\epsilon}_{t-1} && \text{(重新组合项)} \\ &= \vdots \\ &= a^t\mathbf{x}_0 + b \underbrace{[\boldsymbol{\epsilon}_{t-1} + a\boldsymbol{\epsilon}_{t-2} + a^2\boldsymbol{\epsilon}_{t-3} + \dots + a^{t-1}\boldsymbol{\epsilon}_0]}_{\stackrel{\text{def}}{=} \mathbf{w}_t}. \end{aligned} \quad (2.6)$$

上述有限和是独立高斯随机变量的和。均值向量 $\mathbb{E}[\mathbf{w}_t]$ 保持为零，因为每个变量均值均为零。协方差矩阵（对于零均值向量）为

$$\begin{aligned} \text{Cov}[\mathbf{w}_t] &\stackrel{\text{def}}{=} \mathbb{E}[\mathbf{w}_t \mathbf{w}_t^T] \\ &= b^2(\text{Cov}(\boldsymbol{\epsilon}_{t-1}) + a^2\text{Cov}(\boldsymbol{\epsilon}_{t-2}) + \dots + (a^{t-1})^2\text{Cov}(\boldsymbol{\epsilon}_0)) \\ &= b^2(1 + a^2 + a^4 + \dots + a^{2(t-1)})\mathbf{I} \\ &= b^2 \cdot \frac{1 - a^{2t}}{1 - a^2} \mathbf{I}. \end{aligned}$$

当 $t \rightarrow \infty$ 时，对于任何 $0 < a < 1$ ， $a^t \rightarrow 0$ 。因此，在极限 $t = \infty$ 时，

$$\lim_{t \rightarrow \infty} \text{Cov}[\mathbf{w}_t] = \frac{b^2}{1 - a^2} \mathbf{I}.$$

所以，如果我们希望 $\lim_{t \rightarrow \infty} \text{Cov}[\mathbf{w}_t] = \mathbf{I}$ （使得 $\mathbf{x}_t$ 的分布趋近于 $\mathcal{N}(0, \mathbf{I})$ ），那么我们需要

$$1 = \frac{b^2}{1 - a^2},$$

或者等价地 $b = \sqrt{1 - a^2}$ 。现在，如果我们令 $a = \sqrt{\alpha}$ ，则 $b = \sqrt{1 - \alpha}$ 。这将给我们

$$\mathbf{x}_t = \sqrt{\alpha}\mathbf{x}_{t-1} + \sqrt{1 - \alpha}\boldsymbol{\epsilon}_{t-1}. \quad (2.7)$$

分布 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$ 。理解了这些神奇的标量后，我们可以讨论分布 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$ 。也就是说，我们想知道如果给定 $\mathbf{x}_0$ ， $\mathbf{x}_t$ 将如何分布。

Theorem 2.2. (条件分布 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$)。条件分布 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$ 由下式给出

$$q_\phi(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I}), \quad (2.8)$$

其中 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ 。

证明。要了解 Eqn (2.8) 是如何推导的，我们可以重新进行递归，但这次我们使用 $\sqrt{\alpha_t}\mathbf{x}_{t-1}$ 和 $(1 - \alpha_t)\mathbf{I}$

分别作为均值和协方差。这将给我们

$$\begin{aligned}
 \mathbf{x}_t &= \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1} \\
 &= \sqrt{\alpha_t} (\sqrt{\alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_{t-1}} \boldsymbol{\epsilon}_{t-2}) + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1} \\
 &= \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \underbrace{\sqrt{\alpha_t} \sqrt{1 - \alpha_{t-1}} \boldsymbol{\epsilon}_{t-2} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1}}_{\mathbf{w}_1}.
 \end{aligned} \tag{2.9}$$

因此，我们有两个高斯分布的和。但由于两个高斯分布的和仍然是高斯分布，我们只需计算其新的协方差（因为均值保持为零）。新的协方差为

$$\begin{aligned}
 \mathbb{E}[\mathbf{w}_1 \mathbf{w}_1^T] &= [(\sqrt{\alpha_t} \sqrt{1 - \alpha_{t-1}})^2 + (\sqrt{1 - \alpha_t})^2] \mathbf{I} \\
 &= [\alpha_t(1 - \alpha_{t-1}) + 1 - \alpha_t] \mathbf{I} = [1 - \alpha_t \alpha_{t-1}] \mathbf{I}.
 \end{aligned}$$

回到 Eqn (2.9)，我们可以展示递归变为 $\mathbf{x}_{t-2}$ 和噪声向量 $\boldsymbol{\epsilon}_{t-2}$ 的线性组合：

$$\begin{aligned}
 \mathbf{x}_t &= \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_t \alpha_{t-1}} \boldsymbol{\epsilon}_{t-2} \\
 &= \sqrt{\alpha_t \alpha_{t-1} \alpha_{t-2}} \mathbf{x}_{t-3} + \sqrt{1 - \alpha_t \alpha_{t-1} \alpha_{t-2}} \boldsymbol{\epsilon}_{t-3} \\
 &= \vdots \\
 &= \left(\sqrt{\prod_{i=1}^t \alpha_i} \right) \mathbf{x}_0 + \left(\sqrt{1 - \prod_{i=1}^t \alpha_i} \right) \boldsymbol{\epsilon}_0.
 \end{aligned} \tag{2.10}$$

所以，如果我们定义 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ ，我们可以展示

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}_0. \tag{2.11}$$

换句话说，分布 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$ 为

$$\mathbf{x}_t \sim q_\phi(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}). \tag{2.12}$$

新分布 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$ 的实用性在于其一步前向扩散步骤，与链 $\mathbf{x}_0 \rightarrow \mathbf{x}_1 \rightarrow \dots \rightarrow \mathbf{x}_{T-1} \rightarrow \mathbf{x}_T$ 相比。在前向扩散模型的每一步中，由于我们已经知道 $\mathbf{x}_0$ 并且假设所有后续转移都是高斯的，我们将知道任何 t 时的 $\mathbf{x}_t$ 。这种情况可以从 Figure 2.6 中理解。




Figure 2.6: $q_\phi(\mathbf{x}_t | \mathbf{x}_{t-1})$ 和 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$ 之间的区别。

Example 2.2. 对于高斯混合模型，使得 $\mathbf{x}_0 \sim p_0(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \sigma_k^2 \mathbf{I})$ ，我们可以展示在时间 t

的分布为

$$\begin{aligned}\mathbf{x}_t \sim p_t(\mathbf{x}) &= \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \sqrt{\bar{\alpha}_t} \boldsymbol{\mu}_k, (1 - \bar{\alpha}_t) \mathbf{I} + \bar{\alpha}_t \sigma_k^2 \mathbf{I}) \\ &= \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} \mid \sqrt{\alpha^t} \boldsymbol{\mu}_k, (1 - \alpha^t) \mathbf{I} + \alpha^t \sigma_k^2 \mathbf{I}), \quad \text{if } \alpha_t = \alpha \text{ so that } \bar{\alpha}_t = \prod_{i=1}^t \alpha = \alpha^t.\end{aligned}\tag{2.13}$$

如果你对概率分布 p_t 如何随时间 t 演化感到好奇，我们可以可视化我们在例 2.1 中讨论的高斯混合分布的轨迹。我们使用 Eqn (2.13) 来绘制热图。你可以看到，当 $t = 0$ 时，初始分布是两个高斯分布的混合。随着我们按照 Eqn (2.13) 中定义的转移进行，我们可以看到分布逐渐变为单一的高斯分布 $\mathcal{N}(0, \mathbf{I})$ 。




Figure 2.7: 由 $\mathbf{x}_t$ 生成的随机轨迹的实现。背景中的颜色图表示概率分布 $p_t(\mathbf{x})$ 。

在同一图中，我们叠加并展示了一些随机样本 $\mathbf{x}_t$ 作为时间 t 的函数的瞬时轨迹。我们用于生成样本的方程是

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}).$$

如你所见， $\mathbf{x}_t$ 的轨迹或多或少遵循分布 $p_t(\mathbf{x})$ 。

许多读者感到困惑的一点是，如果目标是从图像 $p(\mathbf{x}_0)$ 转换为白噪声 $p(\mathbf{x}_T)$ ，那么推导 $q_\phi(\mathbf{x}_t | \mathbf{x}_{t-1})$ 和 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$ 的意义何在？答案是，到目前为止我们一直在讨论的是前向过程。在扩散模型中，前向过程被选择为可以以封闭形式表达。更有趣的部分是反向过程。正如将要讨论的，反向过程通过一系列去噪操作实现。每个去噪步骤应与前向过程中的相应步骤耦合。 $q_\phi(\mathbf{x}_t | \mathbf{x}_0)$ 只是为我们提供了一种稍微更方便的方式来实现前向过程。

2.2 证据下界

既然我们已经理解了变分扩散模型的结构，就可以写出 ELBO 并训练模型了。

Theorem 2.3. (变分扩散模型的 ELBO). 变分扩散模型的 ELBO 为

$$\begin{aligned}\text{ELBO}_{\phi, \theta}(\mathbf{x}) &= \mathbb{E}_{q_\phi(\mathbf{x}_1 | \mathbf{x}_0)} \left[\underbrace{\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)}_{\text{how good the initial block is}} \right] \\ &\quad - \mathbb{E}_{q_\phi(\mathbf{x}_{T-1} | \mathbf{x}_0)} \left[\underbrace{\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{x}_T | \mathbf{x}_{T-1}) \| p(\mathbf{x}_T))}_{\text{how good the final block is}} \right] \\ &\quad - \sum_{t=1}^{T-1} \mathbb{E}_{q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_{t+1} | \mathbf{x}_0)} \left[\underbrace{\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{x}_t | \mathbf{x}_{t-1}) \| p_\theta(\mathbf{x}_t | \mathbf{x}_{t+1}))}_{\text{how good the transition blocks are}} \right],\end{aligned}\tag{2.14}$$

其中 $\mathbf{x}_0 = \mathbf{x}$ ，且 $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$ 。

如果你是本教程的休闲读者，我们希望这个方程不会让你望而却步。虽然它看起来复杂，但它确实有结构。我们只需要在理解它时保持耐心。

重建（初始块）。首先来看这一项

$$\mathbb{E}_{q_\phi(\mathbf{x}_1|\mathbf{x}_0)} \left[\log p_\theta(\mathbf{x}_0|\mathbf{x}_1) \right].$$

这一项基于初始块，类似于 Eqn (??)。期望内的主题是对数似然 $\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)$ 。这个对数似然衡量了神经网络（与 p_θ 相关联）从潜在变量 $\mathbf{x}_1$ 恢复 $\mathbf{x}_0$ 的能力。

期望是对从 $q_\phi(\mathbf{x}_1|\mathbf{x}_0)$ 抽取的样本进行的。回想一下， $q_\phi(\mathbf{x}_1|\mathbf{x}_0)$ 是生成 $\mathbf{x}_1$ 的分布。我们要求 $\mathbf{x}_1$ 从这个分布中抽取，因为 $\mathbf{x}_1$ 不是凭空而来，而是由前向转移 $q_\phi(\mathbf{x}_1|\mathbf{x}_0)$ 创造的。这里需要以 $\mathbf{x}_0$ 为条件，因为我们知道原始图像是什么。

这里使用期望的原因是 $p_\theta(\mathbf{x}_0|\mathbf{x}_1)$ 是 $\mathbf{x}_1$ 的函数（因此如果 $\mathbf{x}_1$ 是随机的，那么 $p_\theta(\mathbf{x}_0|\mathbf{x}_1)$ 也是随机的）。对于不同的中间状态 $\mathbf{x}_1$ ，概率 $p_\theta(\mathbf{x}_0|\mathbf{x}_1)$ 会不同。期望消除了对 $\mathbf{x}_1$ 的依赖。

先验匹配（最终块）。先验匹配项为

$$-\mathbb{E}_{q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)} \left[\mathbb{D}_{\text{KL}} \left(q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1}) \| p(\mathbf{x}_T) \right) \right], \quad (2.15)$$

它基于最终块。我们使用 KL 散度来衡量 $q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})$ 和 $p(\mathbf{x}_T)$ 之间的差异。分布 $q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})$ 是从 $\mathbf{x}_{T-1}$ 到 $\mathbf{x}_T$ 的前向转移。这描述了 $\mathbf{x}_T$ 是如何生成的。第二个分布是 $p(\mathbf{x}_T)$ 。由于我们的懒惰，我们假设 $p(\mathbf{x}_T) = \mathcal{N}(0, \mathbf{I})$ 。我们希望 $q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})$ 尽可能接近 $\mathcal{N}(0, \mathbf{I})$ 。

在计算 KL 散度时，变量 $\mathbf{x}_T$ 是一个虚拟变量。然而，由于 q_ϕ 是以 $\mathbf{x}_{T-1}$ 为条件的，这里计算的 KL 散度是条件变量 $\mathbf{x}_{T-1}$ 的函数。 $\mathbf{x}_{T-1}$ 从哪里来？它是由 $q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)$ 生成的。我们使用条件分布 $q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)$ 是因为 $\mathbf{x}_{T-1}$ 首先依赖于我们使用的 $\mathbf{x}_0$ 。对 $q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)$ 的期望表示，对于由 $q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)$ 生成的每一个 $\mathbf{x}_{T-1}$ ，我们都会有一个 KL 散度的值。我们对所有可能生成的 $\mathbf{x}_{T-1}$ 取期望，以消除依赖。

一致性（转移块）。一致性项为

$$-\sum_{t=1}^{T-1} \mathbb{E}_{q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_{t+1}|\mathbf{x}_0)} \left[\mathbb{D}_{\text{KL}} \left(q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1}) \| p_\theta(\mathbf{x}_t|\mathbf{x}_{t+1}) \right) \right], \quad (2.16)$$

它基于转移块。如果你回想一下 Figure ??，有两个方向。前向转移由分布 $q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})$ 决定，而反向转移由另一个分布 $p_\theta(\mathbf{x}_t|\mathbf{x}_{t+1})$ 决定。一致性项使用 KL 散度来衡量偏差。

期望是对从 $q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_{t+1}|\mathbf{x}_0)$ 抽取的样本对 $(\mathbf{x}_{t-1}, \mathbf{x}_{t+1})$ 进行的。原因是上述 KL 散度是 $\mathbf{x}_{t-1}$ 和 $\mathbf{x}_{t+1}$ 的函数。（你可以忽略 $\mathbf{x}_t$ ，因为它是一个虚拟变量，在我们计算期望的积分过程中会被消除。）由于对 $\mathbf{x}_{t-1}$ 和 $\mathbf{x}_{t+1}$ 的依赖，我们需要取期望。

定理 ??的证明. 我们定义以下符号： $\mathbf{x}_{0:T} = \{\mathbf{x}_0, \dots, \mathbf{x}_T\}$ 表示从 $t=0$ 到 $t=T$ 的所有状态变量的集合。我们还回顾一下，先验分布 $p(\mathbf{x})$ 是图像 $\mathbf{x}_0$ 的分布，因此它等同于 $p(\mathbf{x}_0)$ 。有了这些，我们可以证明

$$\begin{aligned} \log p(\mathbf{x}) &= \log p(\mathbf{x}_0) \\ &= \log \int p(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T} && \text{(通过对 } \mathbf{x}_{1:T} \text{ 积分进行边缘化)} \\ &= \log \int p(\mathbf{x}_{0:T}) \frac{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)}{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} d\mathbf{x}_{1:T} && \text{(乘以并除以 } q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)) \\ &= \log \int q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0) \left[\frac{p(\mathbf{x}_{0:T})}{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] d\mathbf{x}_{1:T} && \text{(重新排列项)} \\ &= \log \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\frac{p(\mathbf{x}_{0:T})}{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] && \text{(期望的定义).} \end{aligned}$$

现在，我们需要使用 Jensen 不等式，该不等式指出对于任何随机变量 X 和任何凹函数 f ，都有 $f(\mathbb{E}[X]) \geq \mathbb{E}[f(X)]$ 。通过识别 $f(\cdot) = \log(\cdot)$ ，我们可以证明

$$\log p(\mathbf{x}) = \log \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\frac{p(\mathbf{x}_{0:T})}{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] \geq \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_{0:T})}{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] \quad (2.17)$$

让我们仔细看看 $p(\mathbf{x}_{0:T})$ 。检查 Figure 2.2，我们注意到如果我们想要解耦 $p(\mathbf{x}_{0:T})$ ，我们应该对 $\mathbf{x}_{t-1}|\mathbf{x}_t$

进行条件化。这导致：

$$p(\mathbf{x}_{0:T}) = p(\mathbf{x}_T) \prod_{t=1}^T p(\mathbf{x}_{t-1}|\mathbf{x}_t) = p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1) \prod_{t=2}^T p(\mathbf{x}_{t-1}|\mathbf{x}_t). \quad (2.18)$$

至于 $q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)$ ，Figure 2.2 表明我们需要对 $\mathbf{x}_t|\mathbf{x}_{t-1}$ 进行条件化。然而，由于序列关系，我们可以写成

$$q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0) = \prod_{t=1}^T q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1}) = q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1}) \prod_{t=1}^{T-1} q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1}). \quad (2.19)$$

将 Eqn (2.18) 和 Eqn (2.19) 代入 Eqn (2.17)，我们可以证明

$$\begin{aligned} \log p(\mathbf{x}) &\geq \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_{0:T})}{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] \\ &= \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1) \prod_{t=2}^T p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1}) \prod_{t=1}^{T-1} q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] \\ &= \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1) \prod_{t=1}^{T-1} p(\mathbf{x}_t|\mathbf{x}_{t+1})}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1}) \prod_{t=1}^{T-1} q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] \quad (\text{将 } t \text{ 移至 } t+1) \\ &= \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})} \right] + \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \prod_{t=1}^{T-1} \frac{p(\mathbf{x}_t|\mathbf{x}_{t+1})}{q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] \quad (\text{拆分期望}) \end{aligned}$$

上面的第一项可以进一步分解为两个期望

$$\mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})} \right] = \underbrace{\mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log p(\mathbf{x}_0|\mathbf{x}_1) \right]}_{\text{Reconstruction}} + \underbrace{\mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})} \right]}_{\text{Prior Matching}}.$$

重建项可以简化为

$$\mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log p(\mathbf{x}_0|\mathbf{x}_1) \right] = \mathbb{E}_{q_\phi(\mathbf{x}_1|\mathbf{x}_0)} \left[\log p(\mathbf{x}_0|\mathbf{x}_1) \right],$$

其中我们使用了条件 $\mathbf{x}_{1:T}|\mathbf{x}_0$ 等同于 $\mathbf{x}_1|\mathbf{x}_0$ 的事实，当感兴趣的项（即 $\log p(\mathbf{x}_0|\mathbf{x}_1)$ ）仅涉及 $\mathbf{x}_0$ 和 $\mathbf{x}_1$ 时。先验匹配项为

$$\mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})} \right] = \mathbb{E}_{q_\phi(\mathbf{x}_T, \mathbf{x}_{T-1}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})} \right],$$

其中我们注意到，条件期望可以简化为仅依赖于样本 $\mathbf{x}_T$ 和 $\mathbf{x}_{T-1}$ ，因为 $\log \frac{p(\mathbf{x}_T)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})}$ 仅依赖于 $\mathbf{x}_T$ 和 $\mathbf{x}_{T-1}$ 。对于期望项，概率链式法则告诉我们 $q_\phi(\mathbf{x}_T, \mathbf{x}_{T-1}|\mathbf{x}_0) = q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1}, \mathbf{x}_0)q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)$ 。由于 q_ϕ 是马尔可夫的，我们可以进一步写成 $q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1}, \mathbf{x}_0) = q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})$ 。因此，联合期望 $\mathbb{E}_{q_\phi(\mathbf{x}_T, \mathbf{x}_{T-1}|\mathbf{x}_0)}$ 可以写成两个期望的乘积 $\mathbb{E}_{q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)} \mathbb{E}_{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})}$ 。这将给出

$$\begin{aligned} \mathbb{E}_{q_\phi(\mathbf{x}_T, \mathbf{x}_{T-1}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})} \right] &= \mathbb{E}_{q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)} \left\{ \mathbb{E}_{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})} \left[\log \frac{p(\mathbf{x}_T)}{q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1})} \right] \right\} \\ &= -\mathbb{E}_{q_\phi(\mathbf{x}_{T-1}|\mathbf{x}_0)} \left[\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{x}_T|\mathbf{x}_{T-1}) \| p(\mathbf{x}_T)) \right]. \end{aligned}$$

最后，我们来看乘积项。我们可以证明

$$\begin{aligned}\mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \prod_{t=1}^{T-1} \frac{p(\mathbf{x}_t|\mathbf{x}_{t+1})}{q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] &= \sum_{t=1}^{T-1} \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_t|\mathbf{x}_{t+1})}{q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] \\ &= \sum_{t=1}^{T-1} \mathbb{E}_{q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_t, \mathbf{x}_{t+1}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_t|\mathbf{x}_{t+1})}{q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})} \right],\end{aligned}$$

其中我们再次利用了期望仅需要 $\mathbf{x}_{t-1}$ 、 $\mathbf{x}_t$ 和 $\mathbf{x}_{t+1}$ 的事实。然后，通过使用相同的条件独立性论证，我们可以证明

$$\begin{aligned}\sum_{t=1}^{T-1} \mathbb{E}_{q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_t, \mathbf{x}_{t+1}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_t|\mathbf{x}_{t+1})}{q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] &= \sum_{t=1}^{T-1} \mathbb{E}_{q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_{t+1}|\mathbf{x}_0)} \left\{ \mathbb{E}_{q_\phi(\mathbf{x}_t|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_t|\mathbf{x}_{t+1})}{q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] \right\} \\ &= - \sum_{t=1}^{T-1} \mathbb{E}_{q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_{t+1}|\mathbf{x}_0)} \left[\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1}) \| p(\mathbf{x}_t|\mathbf{x}_{t+1})) \right].\end{aligned}$$

通过将 $p(\mathbf{x}_0|\mathbf{x}_1)$ 替换为 $p_\theta(\mathbf{x}_0|\mathbf{x}_1)$ ，并将 $p(\mathbf{x}_t|\mathbf{x}_{t+1})$ 替换为 $p_\theta(\mathbf{x}_t|\mathbf{x}_{t+1})$ ，我们就完成了。

重写一致性项。上述变分扩散模型的噩梦在于，我们需要从联合分布 $q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_{t+1}|\mathbf{x}_0)$ 中抽取样本 $(\mathbf{x}_{t-1}, \mathbf{x}_{t+1})$ 。我们不知道 $q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_{t+1}|\mathbf{x}_0)$ 是什么！根据我们的选择，它是一个高斯分布，但我们仍然需要使用未来的样本 $\mathbf{x}_{t+1}$ 来抽取当前样本 $\mathbf{x}_t$ 。这很奇怪。

检查一致性项时，我们注意到 $q_\phi(\mathbf{x}_t|\mathbf{x}_{t-1})$ 和 $p_\theta(\mathbf{x}_t|\mathbf{x}_{t+1})$ 沿着两个相反的方向移动。因此，不可避免地我们需要使用 $\mathbf{x}_{t-1}$ 和 $\mathbf{x}_{t+1}$ 。我们需要问的问题是：我们能否想出一些办法，使得我们不需要处理两个相反的方向，同时又能检查一致性？

所以，这里有一个简单的技巧叫做贝叶斯定理，它将给出

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_t)q(\mathbf{x}_t)}{q(\mathbf{x}_{t-1})} \xrightarrow{\text{condition on } \mathbf{x}_0} q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0) = \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)q(\mathbf{x}_t|\mathbf{x}_0)}{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}. \quad (2.20)$$

通过这种条件顺序的改变，我们可以通过添加一个额外的条件变量 $\mathbf{x}_0$ ，将 $q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0)$ 切换到 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 。(如果你不以 $\mathbf{x}_0$ 为条件，我们无法从 $q(\mathbf{x}_{t-1})$ 中抽取样本，例如，因为 $\mathbf{x}_{t-1}$ 的具体状态依赖于初始图像 $\mathbf{x}_0$ 。)方向 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 现在与 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 平行，如 Figure 2.8所示。因此，如果我们想重写一致性项，一个自然的选择是计算 $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 和 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 之间的 KL 散度。




Figure 2.8: 如果我们考虑 Eqn (2.20)中的贝叶斯定理，我们可以定义一个分布 $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ ，其方向与 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 平行。

如果我们设法通过一些（无聊的）代数推导，我们可以证明 ELBO 现在是：

Theorem 2.4. (变分扩散模型的 ELBO). 设 $\mathbf{x} = \mathbf{x}_0$ ，且 $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$ 。定理 ??中的变分扩散模型

的 ELBO 可以等价地写成

$$\begin{aligned} \text{ELBO}_{\phi, \theta}(\mathbf{x}) &= \mathbb{E}_{q_{\phi}(\mathbf{x}_1|\mathbf{x}_0)} \left[\underbrace{\log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1)}_{\text{same as before}} \right] - \underbrace{\mathbb{D}_{\text{KL}}(q_{\phi}(\mathbf{x}_T|\mathbf{x}_0) \| p(\mathbf{x}_T))}_{\text{new prior matching}} \\ &\quad - \sum_{t=2}^T \mathbb{E}_{q_{\phi}(\mathbf{x}_t|\mathbf{x}_0)} \left[\underbrace{\mathbb{D}_{\text{KL}}(q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \| p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{\text{new consistency}} \right]. \end{aligned} \quad (2.21)$$

让我们快速做出三个解释：

- **重建**. 新的重建项与之前相同。我们仍然在最大化对数似然。
- **先验匹配**. 新的先验匹配简化为 $q_{\phi}(\mathbf{x}_T|\mathbf{x}_0)$ 和 $p(\mathbf{x}_T)$ 之间的 KL 散度。这一变化是因为我们现在以 $\mathbf{x}_0$ 为条件。因此，不需要从 $q_{\phi}(\mathbf{x}_{T-1}|\mathbf{x}_0)$ 中抽取样本并取期望。
- **一致性**. 新的一致性项与之前的有两点不同。首先，运行索引 t 从 $t=2$ 开始，到 $t=T$ 结束。之前是从 $t=1$ 到 $t=T-1$ 。伴随这一点的是分布匹配，现在是在 $q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 和 $p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 之间。因此，我们不再要求前向转移与反向转移匹配，而是使用 q_{ϕ} 构建一个反向转移，并用它与 p_{θ} 匹配。

定理 2.4 的证明。 我们从 Eqn (2.17) 开始，通过展示

$$\begin{aligned} \log p(\mathbf{x}) &\geq \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_{0:T})}{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] && \text{(由 Eqn (2.17))} \\ &= \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1) \prod_{t=2}^T p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_{\phi}(\mathbf{x}_1|\mathbf{x}_0) \prod_{t=2}^T q_{\phi}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0)} \right] && \text{(拆分链)} \\ &= \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1)}{q_{\phi}(\mathbf{x}_1|\mathbf{x}_0)} \right] + \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_{\phi}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0)} \right] \end{aligned} \quad (2.22)$$

让我们考虑第二项：

$$\begin{aligned} \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_{\phi}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0)} &= \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{\frac{q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)q_{\phi}(\mathbf{x}_t|\mathbf{x}_0)}{q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_0)}} && \text{(贝叶斯规则, Eqn (2.20))} \\ &= \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \times \prod_{t=2}^T \frac{q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_0)}{q_{\phi}(\mathbf{x}_t|\mathbf{x}_0)} && \text{(重新排列分母)} \\ &= \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \times \frac{q_{\phi}(\mathbf{x}_1|\mathbf{x}_0)}{q_{\phi}(\mathbf{x}_T|\mathbf{x}_0)}, && \text{(递归消去项)} \end{aligned}$$

其中最后一个等式利用了对于任何序列 $a_1, \dots, a_T$ ，我们有 $\prod_{t=2}^T \frac{a_{t-1}}{a_t} = \frac{a_1}{a_2} \times \frac{a_2}{a_3} \times \dots \times \frac{a_{T-1}}{a_T} = \frac{a_1}{a_T}$ 。回到 Eqn (2.22)，我们可以看到

$$\begin{aligned} &\mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1)}{q_{\phi}(\mathbf{x}_1|\mathbf{x}_0)} \right] + \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_{\phi}(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0)} \right] \\ &= \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1)}{q_{\phi}(\mathbf{x}_1|\mathbf{x}_0)} + \log \frac{q_{\phi}(\mathbf{x}_1|\mathbf{x}_0)}{q_{\phi}(\mathbf{x}_T|\mathbf{x}_0)} \right] + \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \right] \\ &= \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1)}{q_{\phi}(\mathbf{x}_T|\mathbf{x}_0)} \right] + \mathbb{E}_{q_{\phi}(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \right], \end{aligned}$$

其中我们消去了分子和分母中的 $q_{\phi}(\mathbf{x}_1|\mathbf{x}_0)$ ，因为对于任何正数 a, b 和 c ， $\log \frac{a}{b} + \log \frac{b}{c} = \log \frac{a}{c}$ 。这将

给我们

$$\begin{aligned}\mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)p(\mathbf{x}_0|\mathbf{x}_1)}{q_\phi(\mathbf{x}_T|\mathbf{x}_0)} \right] &= \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} [\log p(\mathbf{x}_0|\mathbf{x}_1)] + \mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)}{q_\phi(\mathbf{x}_T|\mathbf{x}_0)} \right] \\ &= \underbrace{\mathbb{E}_{q_\phi(\mathbf{x}_1|\mathbf{x}_0)} [\log p(\mathbf{x}_0|\mathbf{x}_1)]}_{\text{reconstruction}} - \underbrace{\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{x}_T|\mathbf{x}_0) \| p(\mathbf{x}_T))}_{\text{prior matching}}.\end{aligned}$$

最后一项是

$$\begin{aligned}\mathbb{E}_{q_\phi(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \prod_{t=2}^T \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \right] &= \sum_{t=2}^T \mathbb{E}_{q_\phi(\mathbf{x}_t, \mathbf{x}_{t-1}|\mathbf{x}_0)} \log \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \\ &= \sum_{t=2}^T \iint \log \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \cdot q_\phi(\mathbf{x}_t, \mathbf{x}_{t-1}|\mathbf{x}_0) d\mathbf{x}_{t-1} d\mathbf{x}_t \\ &= \sum_{t=2}^T \iint \log \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \cdot q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) q_\phi(\mathbf{x}_t|\mathbf{x}_0) d\mathbf{x}_{t-1} d\mathbf{x}_t \\ &= \sum_{t=2}^T \int \left\{ \int \log \frac{p(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \cdot q_\phi(\mathbf{x}_{t-1}, \mathbf{x}_t|\mathbf{x}_0) d\mathbf{x}_{t-1} \right\} q_\phi(\mathbf{x}_t|\mathbf{x}_0) d\mathbf{x}_t \\ &= \underbrace{- \sum_{t=2}^T \mathbb{E}_{q_\phi(\mathbf{x}_t|\mathbf{x}_0)} \mathbb{D}_{\text{KL}}(q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \| p(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{\text{consistency}}.\end{aligned}$$

最后，将 $p(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 替换为 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ ，并将 $p(\mathbf{x}_0|\mathbf{x}_1)$ 替换为 $p_\theta(\mathbf{x}_0|\mathbf{x}_1)$ 。完成！

2.3 反向过程的分佈

既然我们已经了解了变分扩散模型的新 ELBO, 接下来应该花些时间讨论其核心组成部分, 即 $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 。简而言之, 我们想要展示的是

- $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 仍然是一个高斯分布。
- 由于它是高斯分布, 它完全由均值和协方差表征。事实证明,

$$q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1} | \heartsuit \mathbf{x}_t + \spadesuit \mathbf{x}_0, \clubsuit \mathbf{I}), \quad (2.23)$$

对于一些下面定义的魔法标量 $\heartsuit$ 、 $\spadesuit$ 和 $\clubsuit$ 。

Theorem 2.5. 分布 $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 的形式为

$$q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1} | \boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0), \boldsymbol{\Sigma}_q(t)), \quad (2.24)$$

其中

$$\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0) = \frac{(1 - \bar{\alpha}_{t-1})\sqrt{\alpha_t}}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{(1 - \alpha_t)\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_t} \mathbf{x}_0 \quad (2.25)$$

$$\boldsymbol{\Sigma}_q(t) = \frac{(1 - \alpha_t)(1 - \sqrt{\bar{\alpha}_{t-1}})}{1 - \bar{\alpha}_t} \mathbf{I} \stackrel{\text{def}}{=} \sigma_q^2(t) \mathbf{I}, \quad (2.26)$$

其中 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ 。

Eqn (2.25) 揭示了一个有趣的事实, 即均值 $\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0)$ 是 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 的线性组合。几何上, $\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0)$ 位于连接 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 的直线上, 如 Figure 2.9 所示。




Figure 2.9: 根据 Eqn (2.25), 均值 $\mu_q(\mathbf{x}_t, \mathbf{x}_0)$ 是 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 的线性组合。

定理 2.5 的证明。 使用 Eqn (2.20) 中所述的贝叶斯定理, 如果我们评估以下高斯分布的乘积, 则可以确定 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \frac{\mathcal{N}(\mathbf{x}_t|\sqrt{\alpha_t}\mathbf{x}_{t-1}, (1-\alpha_t)\mathbf{I})\mathcal{N}(\mathbf{x}_{t-1}|\sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0, (1-\bar{\alpha}_{t-1})\mathbf{I})}{\mathcal{N}(\mathbf{x}_t|\sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1-\bar{\alpha}_t)\mathbf{I})}. \quad (2.27)$$

为简单起见, 我们将向量视为标量。那么上述高斯分布的乘积将变为

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \propto \exp \left\{ \frac{(\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_{t-1})^2}{2(1-\alpha_t)} + \frac{(\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0)^2}{2(1-\bar{\alpha}_{t-1})} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t}\mathbf{x}_0)^2}{2(1-\bar{\alpha}_t)} \right\}. \quad (2.28)$$

我们考虑以下映射:

$$\begin{aligned} x &= \mathbf{x}_t, & a &= \alpha_t \\ y &= \mathbf{x}_{t-1}, & b &= \bar{\alpha}_{t-1} \\ z &= \mathbf{x}_0, & c &= \bar{\alpha}_t. \end{aligned}$$

考虑一个二次函数

$$f(y) = \frac{(x - \sqrt{a}y)^2}{2(1-a)} + \frac{(y - \sqrt{b}z)^2}{2(1-b)} - \frac{(x - \sqrt{c}z)^2}{2(1-c)}. \quad (2.29)$$

我们知道, 无论我们如何重新排列项, 结果函数仍然是一个二次方程。 $f(y)$ 的最小值是结果高斯的均值。因此, 我们可以计算 f 的导数并证明

$$f'(y) = \frac{1-ab}{(1-a)(1-b)}y - \left(\frac{\sqrt{a}}{1-a}x + \frac{\sqrt{b}}{1-b}z \right).$$

设 $f'(y) = 0$ 得到

$$y = \frac{(1-b)\sqrt{a}}{1-ab}x + \frac{(1-a)\sqrt{b}}{1-ab}z. \quad (2.30)$$

我们注意到 $ab = \alpha_t \bar{\alpha}_{t-1} = \bar{\alpha}_t$ 。所以,

$$\mu_q(\mathbf{x}_t, \mathbf{x}_0) = \frac{(1-\bar{\alpha}_{t-1})\sqrt{\alpha_t}}{1-\bar{\alpha}_t}\mathbf{x}_t + \frac{(1-\alpha_t)\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_t}\mathbf{x}_0. \quad (2.31)$$

同样, 对于方差, 我们可以检查曲率 $f''(y)$ 。我们可以很容易地证明

$$f''(y) = \frac{1-ab}{(1-a)(1-b)} = \frac{1-\bar{\alpha}_t}{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}.$$

取其倒数将得到

$$\Sigma_q(t) = \frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\mathbf{I}. \quad (2.32)$$

上述定理中的组合权重值得研究。回想一下

$$\mu_q(\mathbf{x}_t, \mathbf{x}_0) = \frac{(1-\bar{\alpha}_{t-1})\sqrt{\alpha_t}}{1-\bar{\alpha}_t}\mathbf{x}_t + \frac{(1-\alpha_t)\sqrt{\bar{\alpha}_{t-1}}}{1-\bar{\alpha}_t}\mathbf{x}_0.$$

我们可以问的一个问题是，当 t 从 T 变为 1 时，这两个系数如何表现？我们在 Figure 2.10 中展示了一个例子。对于这个特定的例子，我们对所有 t 使用 $\alpha_t = 0.9$ 。我们将系数作为 t 的函数绘制出来。Figure 2.10 表明，当 t 从 $t = T$ 减少到 $t = 1$ 时， $\mathbf{x}_t$ 的系数缩小，而 $\mathbf{x}_0$ 的系数增长。




Figure 2.10: $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 的系数随 t 增长的轨迹。

当 t 从 T 变为 1 时，方差 $\sigma_q^2(t)$ 也会发生变化。Figure 2.11 显示了 $\mathbf{x}_t$ 的轨迹，通过根据 $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 采样 $\mathbf{x}_t$ 作为 t 的函数。在同一图中，我们显示了由 $\sigma_q^2(t)$ 定义的高斯半径。我们的图表明，当 $t = T$ 时，方差 $\sigma_q^2(t)$ 相当大，因此 $\mathbf{x}_t$ 更接近白高斯噪声。当 t 下降到 $t = 1$ 时，方差 $\sigma_q^2(t)$ 也下降到零。这是有道理的，因为最终我们希望 $\mathbf{x}_0$ 是无噪声的干净图像。




Figure 2.11: $\mathbf{x}_t$ 的轨迹及其相关的高斯半径 $\sigma_q^2(t)$ 。

构建 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 。 Eqn (2.24) 的有趣之处在于， $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 完全由 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 决定。不需要神经网络来估计均值和方差！（你可以将其与需要网络的 VAE 进行比较。）由于不需要网络，实际上没有什么需要“学习”的。如果我们知道 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ ，分布 $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 就会自动确定。

这里的认识很重要。让我们看看 Eqn (2.21) 中的一致性项：

$$\begin{aligned} \text{ELBO}_{\phi, \theta}(\mathbf{x}) = & \mathbb{E}_{q_\phi(\mathbf{x}_1|\mathbf{x}_0)} \left[\underbrace{\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)}_{\text{same as before}} \right] - \underbrace{\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{x}_T|\mathbf{x}_0) \| p(\mathbf{x}_T))}_{\text{new prior matching}} \\ & - \sum_{t=2}^T \mathbb{E}_{q_\phi(\mathbf{x}_t|\mathbf{x}_0)} \left[\underbrace{\mathbb{D}_{\text{KL}}(q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \| p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{\text{new consistency}} \right], \end{aligned} \quad (\text{from Eqn (2.21)})$$

我们刚刚展示了

$$q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1} | \boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0), \boldsymbol{\Sigma}_q(t)).$$

对于 $q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 没有“学习”过程，因为一旦超参数 α_t 定义好，它就被定义了。因此，一致性项是许多 KL 散度项的和，其中第 t 项是

$$\mathbb{D}_{\text{KL}} \left(\underbrace{q_\phi(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)}_{\text{nothing to learn}} \parallel \underbrace{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}_{\text{need to do something}} \right). \quad (2.33)$$

所以，为了计算 KL 散度，我们需要对 $p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 进行处理。

这里的核心思想是 $q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 是高斯分布。如果我们想快速计算 KL 散度，那么如果 $p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 也是高斯分布，那就更好了。因此，我们选择 $p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 为高斯分布。此外，我们应该匹配均值和方差的形式！因此，我们定义

$$p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}\left(\mathbf{x}_{t-1} \mid \underbrace{\boldsymbol{\mu}_{\theta}(\mathbf{x}_t)}_{\text{neural network}}, \sigma_q^2(t)\mathbf{I}\right), \quad (2.34)$$

其中我们假设均值向量可以通过神经网络确定。至于方差，我们选择方差为 $\sigma_q^2(t)$ 。这与 Eqn (2.26) 完全相同！因此，如果我们将 Eqn (2.24) 与 $p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 并排放置，我们会注意到两者之间的平行关系：

$$q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_{t-1} \mid \underbrace{\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0)}_{\text{known}}, \underbrace{\sigma_q^2(t)\mathbf{I}}_{\text{known}}\right), \quad (2.35)$$

$$p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}\left(\mathbf{x}_{t-1} \mid \underbrace{\boldsymbol{\mu}_{\theta}(\mathbf{x}_t)}_{\text{neural network}}, \underbrace{\sigma_q^2(t)\mathbf{I}}_{\text{known}}\right). \quad (2.36)$$

因此，KL 散度被简化为

$$\begin{aligned} & \mathbb{D}_{\text{KL}}\left(q_{\phi}(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t)\right) \\ &= \mathbb{D}_{\text{KL}}\left(\mathcal{N}(\mathbf{x}_{t-1} \mid \boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0), \sigma_q^2(t)\mathbf{I}) \parallel \mathcal{N}(\mathbf{x}_{t-1} \mid \boldsymbol{\mu}_{\theta}(\mathbf{x}_t), \sigma_q^2(t)\mathbf{I})\right) \\ &= \frac{1}{2\sigma_q^2(t)} \|\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_{\theta}(\mathbf{x}_t)\|^2, \end{aligned} \quad (2.37)$$

其中我们使用了两个相同方差的高斯分布之间的 KL 散度只是两个均值向量之间的欧几里得距离平方这一事实。

将 Eqn (2.37) 代入 Eqn (2.21) 中的 ELBO 定义，我们可以将 ELBO 重写如下。

Theorem 2.6. Eqn (2.21) 中的 **变分扩散模型的 ELBO** 可以简化为

$$\begin{aligned} \text{ELBO}_{\theta}(\mathbf{x}) &= \mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)}[\log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1)] - \underbrace{\mathbb{D}_{\text{KL}}\left(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T)\right)}_{\text{nothing to train}} \\ &\quad - \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \|\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_{\theta}(\mathbf{x}_t)\|^2 \right], \end{aligned} \quad (2.38)$$

其中 $\mathbf{x} = \mathbf{x}_0$ ，且 $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$ 。

关于定理 2.6 的一个备注是，下标 ϕ 被去掉了，因为定理 2.5 中定义的分 q_{ϕ} 完全由 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 决定。没有什么需要学习的，因此优化不需要包括 ϕ 。因此，我们可以去掉 Eqn (2.38) 中的 KL 散度项。这给我们留下了重建项 $\mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)}[\log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1)]$ 和转移项 $\sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \|\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_{\theta}(\mathbf{x}_t)\|^2 \right]$ 。

重建项可以简化，因为

$$\begin{aligned} \log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1) &= \log \mathcal{N}(\mathbf{x}_0 | \boldsymbol{\mu}_{\theta}(\mathbf{x}_1), \sigma_q^2(1)\mathbf{I}) \\ &= \log \frac{1}{(\sqrt{2\pi\sigma_q^2(1)})^d} \exp \left\{ -\frac{\|\mathbf{x}_0 - \boldsymbol{\mu}_{\theta}(\mathbf{x}_1)\|^2}{2\sigma_q^2(1)} \right\} \\ &= -\frac{\|\mathbf{x}_0 - \boldsymbol{\mu}_{\theta}(\mathbf{x}_1)\|^2}{2\sigma_q^2(1)} - \frac{d}{2} \log(2\pi\sigma_q^2(1)). \end{aligned}$$

所以，一旦我们知道 $\mathbf{x}_1$ ，我们就可以将其发送到网络 $\boldsymbol{\mu}_{\theta}(\mathbf{x}_1)$ 以返回均值估计。然后，均值估计将用于计算似然。

2.4 训练与推断

本节我们将讨论如何训练一个变分扩散模型，并将其转化为一个去噪扩散概率模型。

我们从定理 2.6 中定义的 ELBO 开始。Eqn (2.38) 表明，我们需要找到一个网络 μ_θ ，能够以某种方式最小化损失：

$$\frac{1}{2\sigma_q^2(t)} \left\| \underbrace{\mu_q(\mathbf{x}_t, \mathbf{x}_0)}_{\text{known}} - \underbrace{\mu_\theta(\mathbf{x}_t)}_{\text{network}} \right\|^2. \quad (2.39)$$

回顾 Eqn (2.25)，我们有

$$\mu_q(\mathbf{x}_t, \mathbf{x}_0) = \frac{(1 - \bar{\alpha}_{t-1})\sqrt{\alpha_t}}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{(1 - \alpha_t)\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_t} \mathbf{x}_0. \quad (2.40)$$

可以看出，它是 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 的函数。因此，一旦知道 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ ， $\mu_q(\mathbf{x}_t, \mathbf{x}_0)$ 就是已知且确定的。

我们关注的对象是 μ_θ 。由于 μ_θ 是我们的设计，没有理由不能将其定义为更便利的形式。这里给出一个选择，我们定义

$$\underbrace{\mu_\theta(\mathbf{x}_t)}_{\text{a network}} \stackrel{\text{def}}{=} \frac{(1 - \bar{\alpha}_{t-1})\sqrt{\alpha_t}}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{(1 - \alpha_t)\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_t} \underbrace{\hat{\mathbf{x}}_\theta(\mathbf{x}_t)}_{\text{another network}}. \quad (2.41)$$

将 Eqn (2.40) 和 Eqn (2.41) 代入 Eqn (2.39)，得到

$$\begin{aligned} \frac{1}{2\sigma_q^2(t)} \left\| \mu_q(\mathbf{x}_t, \mathbf{x}_0) - \mu_\theta(\mathbf{x}_t) \right\|^2 &= \frac{1}{2\sigma_q^2(t)} \left\| \frac{(1 - \alpha_t)\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_t} (\hat{\mathbf{x}}_\theta(\mathbf{x}_t) - \mathbf{x}_0) \right\|^2 \\ &= \frac{1}{2\sigma_q^2(t)} \frac{(1 - \alpha_t)^2 \bar{\alpha}_{t-1}}{(1 - \bar{\alpha}_t)^2} \left\| \hat{\mathbf{x}}_\theta(\mathbf{x}_t) - \mathbf{x}_0 \right\|^2. \end{aligned} \quad (2.42)$$

因此，ELBO 可以写成

$$\text{ELBO}_\theta(\mathbf{x}) = \mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)] - \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \frac{(1 - \alpha_t)^2 \bar{\alpha}_{t-1}}{(1 - \bar{\alpha}_t)^2} \left\| \hat{\mathbf{x}}_\theta(\mathbf{x}_t) - \mathbf{x}_0 \right\|^2 \right], \quad (2.43)$$

其中我们省略了项 $\mathbb{D}_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \| p(\mathbf{x}_T))$ 。

接下来，我们希望简化 ELBO，以便将 $\mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)]$ 吸收到求和式中。以下是结果。

Theorem 2.7. 去噪扩散概率模型的 ELBO 为

$$\text{ELBO}_\theta(\mathbf{x}) = - \sum_{t=1}^T \frac{1}{2\sigma_q^2(t)} \frac{(1 - \alpha_t)^2 \bar{\alpha}_{t-1}}{(1 - \bar{\alpha}_t)^2} \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\left\| \hat{\mathbf{x}}_\theta(\mathbf{x}_t) - \mathbf{x}_0 \right\|^2 \right]. \quad (2.44)$$

证明。 将 Eqn (2.42) 代入 Eqn (2.38)，我们可以看到

$$\begin{aligned} \text{ELBO}_\theta(\mathbf{x}) &= \mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)] - \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \left\| \mu_q(\mathbf{x}_t, \mathbf{x}_0) - \mu_\theta(\mathbf{x}_t) \right\|^2 \right] \\ &= \mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)] - \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \frac{(1 - \alpha_t)^2 \bar{\alpha}_{t-1}}{(1 - \bar{\alpha}_t)^2} \left\| \hat{\mathbf{x}}_\theta(\mathbf{x}_t) - \mathbf{x}_0 \right\|^2 \right]. \end{aligned} \quad (2.45)$$

第一项为

$$\begin{aligned}
\log p_{\theta}(\mathbf{x}_0|\mathbf{x}_1) &= \log \mathcal{N}(\mathbf{x}_0|\boldsymbol{\mu}_{\theta}(\mathbf{x}_1), \sigma_q^2(1)\mathbf{I}) \propto -\frac{1}{2\sigma_q^2(1)} \|\boldsymbol{\mu}_{\theta}(\mathbf{x}_1) - \mathbf{x}_0\|^2 && \text{(定义)} \\
&= -\frac{1}{2\sigma_q^2(1)} \left\| \frac{(1-\bar{\alpha}_0)\sqrt{\alpha_1}}{1-\bar{\alpha}_1} \mathbf{x}_1 + \frac{(1-\alpha_1)\sqrt{\bar{\alpha}_0}}{1-\bar{\alpha}_1} \hat{\mathbf{x}}_{\theta}(\mathbf{x}_1) - \mathbf{x}_0 \right\|^2 && \text{(回忆 } \alpha_0 = 1) \\
&= -\frac{1}{2\sigma_q^2(1)} \left\| \frac{(1-\alpha_1)}{1-\bar{\alpha}_1} \hat{\mathbf{x}}_{\theta}(\mathbf{x}_1) - \mathbf{x}_0 \right\|^2 \\
&= -\frac{1}{2\sigma_q^2(1)} \|\hat{\mathbf{x}}_{\theta}(\mathbf{x}_1) - \mathbf{x}_0\|^2. && \text{(回忆 } \bar{\alpha}_1 = \alpha_1) \quad (2.46)
\end{aligned}$$

将 Eqn (2.46) 代入 Eqn (2.45), ELBO 简化为

$$\text{ELBO}_{\theta}(\mathbf{x}) = -\sum_{t=1}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \frac{(1-\alpha_t)^2 \bar{\alpha}_{t-1}}{(1-\bar{\alpha}_t)^2} \|\hat{\mathbf{x}}_{\theta}(\mathbf{x}_t) - \mathbf{x}_0\|^2 \right].$$

Eqn (2.44) 中定义的损失函数非常直观。忽略常数和期望, 对于特定的 $\mathbf{x}_t$, 主要关注的对象是

$$\underset{\theta}{\operatorname{argmin}} \quad \|\hat{\mathbf{x}}_{\theta}(\mathbf{x}_t) - \mathbf{x}_0\|^2.$$

这不过是一个去噪问题, 因为我们需要找到一个网络 $\hat{\mathbf{x}}_{\theta}$, 使得去噪后的图像 $\hat{\mathbf{x}}_{\theta}(\mathbf{x}_t)$ 接近真实图像 $\mathbf{x}_0$ 。使其不同于典型去噪器的原因如下:

- $\mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)}$: 我们并非试图对任意随机噪声图像进行去噪。相反, 我们精心选择噪声图像为

$$\begin{aligned}
\mathbf{x}_t &\sim q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1-\bar{\alpha}_t)\mathbf{I}) \\
\Leftrightarrow \quad \mathbf{x}_t &= \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{(1-\bar{\alpha}_t)} \boldsymbol{\epsilon}_t, \quad \text{其中} \quad \boldsymbol{\epsilon}_t \sim \mathcal{N}(0, \mathbf{I}).
\end{aligned}$$

- $\frac{1}{2\sigma_q^2(t)} \frac{(1-\alpha_t)^2 \bar{\alpha}_{t-1}}{(1-\bar{\alpha}_t)^2}$: 我们并未对所有步骤的去噪损失赋予相同权重。相反, 有一个调度器来控制每个去噪损失的相对重要性。考虑到这一点, 并使用蒙特卡洛方法来近似期望, 我们可以将优化问题写作

$$\begin{aligned}
&\underset{\theta}{\operatorname{argmax}} \sum_{\mathbf{x}_0 \in \mathcal{X}} \text{ELBO}(\mathbf{x}_0) \\
&= \underset{\theta}{\operatorname{argmin}} \sum_{\mathbf{x}_0 \in \mathcal{X}} \sum_{t=1}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \frac{(1-\alpha_t)^2 \bar{\alpha}_{t-1}}{(1-\bar{\alpha}_t)^2} \left\| \hat{\mathbf{x}}_{\theta} \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{(1-\bar{\alpha}_t)} \boldsymbol{\epsilon}_t \right) - \mathbf{x}_0 \right\|^2 \right] \\
&= \underset{\theta}{\operatorname{argmin}} \sum_{\mathbf{x}_0 \in \mathcal{X}} \sum_{t=1}^T \frac{1}{M} \sum_{m=1}^M \frac{1}{2\sigma_q^2(t)} \frac{(1-\alpha_t)^2 \bar{\alpha}_{t-1}}{(1-\bar{\alpha}_t)^2} \left\| \hat{\mathbf{x}}_{\theta} \left(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{(1-\bar{\alpha}_t)} \boldsymbol{\epsilon}_t^{(m)} \right) - \mathbf{x}_0 \right\|^2, \quad (2.47)
\end{aligned}$$

其中 $\boldsymbol{\epsilon}_t^{(m)} \sim \mathcal{N}(0, \mathbf{I})$, 而对 $\mathbf{x}_0 \in \mathcal{X}$ 的求和意味着我们考虑了训练集 $\mathcal{X}$ 中的所有样本。如你所见, 该模型的训练涉及训练一个去噪器 $\hat{\mathbf{x}}_{\theta}(\cdot)$ 。因此, 所得模型被称为去噪扩散概率模型 (DDPM)。

DDPM 中的前向扩散。 DDPM 的训练涉及两个并行分支。第一个分支是前向扩散。前向扩散的目标是通过使用

$$\mathbf{x}_t \sim q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1-\bar{\alpha}_t)\mathbf{I}), \quad t = 1, \dots, T-1.$$

生成中间变量 $\mathbf{x}_1, \dots, \mathbf{x}_{T-1}$ 。前向扩散不需要任何训练。如果你给我们干净的图像 $\mathbf{x}_0$, 我们可以运行前向扩散并准备图像 $\mathbf{x}_1, \dots, \mathbf{x}_T$ 。图示见 Figure 2.12。

训练 DDPM。 一旦准备好训练样本 $\mathbf{x}_0, \dots, \mathbf{x}_T$, 我们就可以训练 DDPM。DDPM 的训练总结为 Eqn (2.47) 和 Figure 2.13 中的优化。目标是训练一个适用于所有噪声水平的去噪器。之所以是一个适用于所有噪




Figure 2.12: 前向扩散过程。




Figure 2.13: 去噪扩散概率模型的训练。对于同一个神经网络 $\hat{\mathbf{x}}_{\theta}$ ，我们将噪声输入 $\mathbf{x}_t$ 送入网络。损失的梯度被反向传播以更新网络。注意，噪声图像并非任意生成，而是根据前向采样过程生成的。

声水平的去噪器，是因为每个 $\mathbf{x}_t$ 都有不同的方差 $1 - \bar{\alpha}_t$ 。我们不感兴趣于训练多个去噪器，因为这在计算上不可行。

去噪器的训练与任何传统的监督学习并无不同。给定一对干净和噪声图像，在我们的例子中是 $\mathbf{x}_0$ 和 $\mathbf{x}_t$ ，我们训练去噪器 $\hat{\mathbf{x}}_{\theta}(\cdot)$ 。Eqn (2.47) 中的训练损失有三个求和项。如果我们运行随机梯度下降，我们可以将上述优化简化为以下过程。

DDPM 的训练算法。 对于训练数据集中的每张图像 $\mathbf{x}_0$ ：

- 重复以下步骤直至收敛。
- 随机选取一个时间戳 $t \sim \text{Uniform}[1, T]$ 。
- 从 $\mathcal{N}(\mathbf{x}_t | \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$ 中抽取样本 $\mathbf{x}_t^{(m)}$ ，即，

$$\mathbf{x}_t^{(m)} = \bar{\alpha}_t\mathbf{x}_0 + \sqrt{(1 - \bar{\alpha}_t)}\boldsymbol{\epsilon}_t^{(m)}, \quad \boldsymbol{\epsilon}_t^{(m)} \sim \mathcal{N}(0, \mathbf{I}).$$

- 对以下目标进行梯度下降步骤：

$$\nabla_{\theta} \left\{ \frac{1}{M} \sum_{m=1}^M \left\| \hat{\mathbf{x}}_{\theta}(\mathbf{x}_t^{(m)}) - \mathbf{x}_0 \right\|^2 \right\}.$$

你可以像训练其他神经网络一样，分批次进行此操作。注意，这里你是在为**所有**噪声条件训练**一个**去噪网络 $\hat{\mathbf{x}}_{\theta}$ 。

DDPM 的推理——反向扩散。一旦去噪器 $\hat{\mathbf{x}}_\theta$ 训练完成，我们就可以用它来进行推理。推理涉及从状态序列 $\mathbf{x}_T, \mathbf{x}_{T-1}, \dots, \mathbf{x}_1$ 上的分布 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 中采样图像。由于这是反向扩散过程，我们需要递归地进行：

$$\mathbf{x}_{t-1} \sim p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}|\boldsymbol{\mu}_\theta(\mathbf{x}_t), \sigma_q^2(t)\mathbf{I}).$$

通过重参数化，我们得到

$$\begin{aligned} \mathbf{x}_{t-1} &= \boldsymbol{\mu}_\theta(\mathbf{x}_t) + \sigma_q(t)\boldsymbol{\epsilon}, & \text{where } \boldsymbol{\epsilon} &\sim \mathcal{N}(0, \mathbf{I}) \\ &= \frac{(1 - \bar{\alpha}_{t-1})\sqrt{\alpha_t}}{1 - \bar{\alpha}_t}\mathbf{x}_t + \frac{(1 - \alpha_t)\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_t}\hat{\mathbf{x}}_\theta(\mathbf{x}_t) + \sigma_q(t)\boldsymbol{\epsilon}. \end{aligned}$$

这引出了以下推理算法。简单来说，我们从白噪声向量 $\mathbf{x}_T$ 开始，依次运行去噪器 T 次，回到生成的图像 $\hat{\mathbf{x}}_0$ 。图示见 Figure ??。

DDPM 的推理。

- 你给我们一个白噪声向量 $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$ 。
- 对 $t = T, T-1, \dots, 1$ 重复以下步骤。
- 我们使用训练好的去噪器计算 $\hat{\mathbf{x}}_\theta(\mathbf{x}_t)$ 。
- 根据以下更新：

$$\mathbf{x}_{t-1} = \frac{(1 - \bar{\alpha}_{t-1})\sqrt{\alpha_t}}{1 - \bar{\alpha}_t}\mathbf{x}_t + \frac{(1 - \alpha_t)\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_t}\hat{\mathbf{x}}_\theta(\mathbf{x}_t) + \sigma_q(t)\boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}). \quad (2.48)$$

2.5 预测噪声

我们推导的最后一步是将结果与 Ho 等人 [16] 的原始论文联系起来，以便符号与文献更加一致。

训练。如果你熟悉去噪文献，你可能知道预测噪声而非信号的残差型算法。同样的精神适用于去噪扩散，我们可以学习预测噪声。为了理解这一点，我们考虑 Eqn (2.11)。如果我们重新排列项，我们将得到

$$\begin{aligned} \mathbf{x}_t &= \sqrt{\alpha_t}\mathbf{x}_0 + \sqrt{1 - \alpha_t}\boldsymbol{\epsilon}_0 \\ \Rightarrow \quad \mathbf{x}_0 &= \frac{\mathbf{x}_t - \sqrt{1 - \alpha_t}\boldsymbol{\epsilon}_0}{\sqrt{\alpha_t}}. \end{aligned}$$

将其代入 $\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0)$ ，我们可以证明

$$\begin{aligned} \boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0) &= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})\mathbf{x}_t + \sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)\mathbf{x}_0}{1 - \bar{\alpha}_t} \\ &= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})\mathbf{x}_t + \sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t) \cdot \frac{\mathbf{x}_t - \sqrt{1 - \alpha_t}\boldsymbol{\epsilon}_0}{\sqrt{\alpha_t}}}{1 - \bar{\alpha}_t} \\ &= \text{a few more algebraic steps which we shall skip} \\ &= \frac{1}{\sqrt{\alpha_t}}\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}\sqrt{\alpha_t}}\boldsymbol{\epsilon}_0. \end{aligned} \quad (2.49)$$

换句话说，我们已经将 $\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0)$ 从 $\mathbf{x}_0$ 的函数转换为 $\boldsymbol{\epsilon}_0$ 的函数。

由于我们进行了这种修改，自然我们也应该修改均值估计器 $\boldsymbol{\mu}_\theta$ 。为了使 $\boldsymbol{\mu}_\theta$ 的形式与 $\boldsymbol{\mu}_q(\mathbf{x}_t, \mathbf{x}_0)$ 的形式匹配，我们选择

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t) = \frac{1}{\sqrt{\alpha_t}}\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}\sqrt{\alpha_t}}\hat{\boldsymbol{\epsilon}}_\theta(\mathbf{x}_t). \quad (2.50)$$

将 Eqn (2.49)和 Eqn (2.50)代入 Eqn (2.39)，我们将得到一个新的 ELBO

$$\begin{aligned}\text{ELBO}_{\theta}(\mathbf{x}_0, \epsilon_0) &= - \sum_{t=1}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \frac{(1-\alpha_t)^2}{(1-\bar{\alpha}_t)\alpha_t} \|\hat{\epsilon}_{\theta}(\mathbf{x}_t) - \epsilon_0\|^2 \right] \\ &= - \sum_{t=1}^T \mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma_q^2(t)} \frac{(1-\alpha_t)^2}{(1-\bar{\alpha}_t)\alpha_t} \left\| \hat{\epsilon}_{\theta} \left(\sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1-\alpha_t} \epsilon_0 \right) - \epsilon_0 \right\|^2 \right]\end{aligned}$$

我们注意到这个 ELBO 是 $\mathbf{x}_0$ 和 ϵ_0 的函数。因此，为了训练去噪器，我们需要解决优化问题

$$\begin{aligned}\argmin_{\theta} \mathbb{E}_{\mathbf{x}_0, \epsilon_0} \text{ELBO}_{\theta}(\mathbf{x}_0, \epsilon_0) \\ \approx \argmin_{\theta} \sum_{\mathbf{x}_0 \sim \mathcal{X}} \frac{1}{M} \sum_{m=1}^M \text{ELBO}_{\theta}(\mathbf{x}_0, \epsilon_0^{(m)}),\end{aligned}$$

其中上标表示第 m 个初始噪声项。如果我们运行随机梯度下降，我们可以将上述描述简化为以下过程。

使用 $\hat{\epsilon}_{\theta}(\mathbf{x}_t)$ 训练 DDPM。 对于训练数据集中的每个图像 $\mathbf{x}_0$ ：

- 重复以下步骤直到收敛。
- 选择一个随机时间戳 $t \sim \text{Uniform}[1, T]$ 。
- 抽取一个样本 $\epsilon_0 \sim \mathcal{N}(0, \mathbf{I})$ 。
- 抽取一个样本 $\mathbf{x}_t \sim \mathcal{N}(\mathbf{x}_t | \sqrt{\alpha_t} \mathbf{x}_0, (1-\alpha_t)\mathbf{I})$ ，即，

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1-\alpha_t} \epsilon_0.$$

- 对以下梯度下降步骤进行更新

$$\nabla_{\theta} \|\hat{\epsilon}_{\theta}(\mathbf{x}_t) - \epsilon_0\|^2.$$

推理。 对于推理，我们知道

$$\mathbf{x}_{t-1} \sim p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1} | \boldsymbol{\mu}_{\theta}(\mathbf{x}_t), \sigma_q(t)^2 \mathbf{I}).$$

使用重参数化，我们可以证明

$$\begin{aligned}\mathbf{x}_{t-1} &= \boldsymbol{\mu}_{\theta}(\mathbf{x}_t) + \sigma_q(t) \mathbf{z}, \quad \text{where } \mathbf{z} \sim \mathcal{N}(0, \mathbf{I}) \\ &= \left(\frac{1}{\sqrt{\alpha_t}} \mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t} \sqrt{\alpha_t}} \hat{\epsilon}_{\theta}(\mathbf{x}_t) \right) + \sigma_q(t) \mathbf{z} \\ &= \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \hat{\epsilon}_{\theta}(\mathbf{x}_t) \right) + \sigma_q(t) \mathbf{z}.\end{aligned}\tag{2.51}$$

总结如下，我们有

使用 $\hat{\epsilon}_{\theta}(\mathbf{x}_t)$ 进行 DDPM 推理。

- 你给我们一个白噪声向量 $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$ 。
- 对 $t = T, T-1, \dots, 1$ 重复以下步骤。
- 我们使用训练好的去噪器计算 $\hat{\mathbf{x}}_{\theta}(\mathbf{x}_t)$ 。
- 根据以下更新

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \hat{\epsilon}_{\theta}(\mathbf{x}_t) \right) + \sigma_q(t) \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(0, \mathbf{I}).\tag{2.52}$$

2.6 去噪扩散隐式模型 (DDIM)

从 DDPM 到 DDIM。 DDPM 最普遍的缺点之一是它们需要大量的迭代次数才能生成看起来相当不错的图像。正如 Song 等人在 [39] 中提到的, DDPM 在标准 GPU 上生成 50k 张 (大小为 256×256) 图像需要超过 1000 小时。原因在于运行反向扩散步骤时, 我们需要进行去噪。如果反向扩散过程本质上需要许多步骤才能收敛, 那么我们将需要进行许多去噪步骤。因此, 为了加快计算速度, 减少迭代次数是必要的。DDIM 就是为了克服这一困难而发明的。

回顾 Eqn (2.1), 原始 DDPM 的转移概率形式为

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) \stackrel{\text{def}}{=} \mathcal{N}(\mathbf{x}_t | \sqrt{\alpha_t} \mathbf{x}_{t-1}, (1 - \alpha_t) \mathbf{I}).$$

此外, Eqn (2.8) 显示, 给定 $\mathbf{x}_0$ 的 $\mathbf{x}_t$ 的概率为

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}),$$

其中 $\bar{\alpha}_t = \prod_{i=0}^t \alpha_i$, 对于任何递减序列 $0 < \alpha_t \leq 1$ 。这里的一个重要观察是, 转移概率 $q(\mathbf{x}_t | \mathbf{x}_{t-1})$ 遵循马尔可夫链, 意味着 $\mathbf{x}_t$ 的概率仅依赖于 $\mathbf{x}_{t-1}$, 而不依赖于之前的状态 $\mathbf{x}_{t-2}$ 等。马尔可夫结构的优势在于系统是无记忆的。一旦我们知道 $\mathbf{x}_{t-1}$, 我们就会知道 $\mathbf{x}_t$ 。但缺点是马尔可夫链可能需要许多步骤才能收敛。DDIM 通过从马尔可夫结构转向非马尔可夫结构来克服这一问题。

DDIM 中的概率分布。 为了开始我们的讨论, 让我们按照 [39] 选择一个特殊的参数选择, 其中我们用比率 α_t / α_{t-1} 替换 α_t 。这意味着

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) \stackrel{\text{def}}{=} \mathcal{N}(\mathbf{x}_t | \sqrt{\frac{\alpha_t}{\alpha_{t-1}}} \mathbf{x}_{t-1}, (1 - \frac{\alpha_t}{\alpha_{t-1}}) \mathbf{I}).$$

这个选择没有特别强的物理意义, 除了它使符号更简单。通过这个选择, 乘积项简化为 $\bar{\alpha}_t = \prod_{i=1}^t \frac{\alpha_i}{\alpha_{i-1}} = \alpha_t$, 假设 $\alpha_0 = 1$ 。因此,

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t | \sqrt{\alpha_t} \mathbf{x}_0, (1 - \alpha_t) \mathbf{I}). \quad (2.53)$$

通过重新参数化表达 Eqn (2.53), 我们注意到 Eqn (2.53) 中的 $\mathbf{x}_t$ 可以用 $\mathbf{x}_0$ 表示如下

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}, \quad \text{where } \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}).$$

通过同样的论证, 我们可以写出

$$\mathbf{x}_{t-1} = \sqrt{\alpha_{t-1}} \mathbf{x}_0 + \sqrt{1 - \alpha_{t-1}} \boldsymbol{\epsilon}, \quad \text{where } \boldsymbol{\epsilon} \sim \mathcal{N}(0, \mathbf{I}). \quad (2.54)$$

所以这里有一个有趣的技巧。让我们用某些东西替换 $\boldsymbol{\epsilon}$, 使得 $\mathbf{x}_{t-1}$ 不再是 $\mathbf{x}_0$ 被白噪声扰动的结果。也许我们可以考虑以下推导

$$\begin{aligned} \mathbf{x}_t &= \sqrt{\alpha_t} \mathbf{x}_0 + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon} \\ \Rightarrow \sqrt{1 - \alpha_t} \boldsymbol{\epsilon} &= \mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_0 \\ \Rightarrow \boldsymbol{\epsilon} &= \frac{\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_0}{\sqrt{1 - \alpha_t}}. \end{aligned}$$

因此, 将 $\boldsymbol{\epsilon}$ 代入 Eqn (2.54), 我们得到

$$\begin{aligned} \mathbf{x}_{t-1} &= \sqrt{\alpha_{t-1}} \mathbf{x}_0 + \sqrt{1 - \alpha_{t-1}} \boldsymbol{\epsilon} \\ &= \sqrt{\alpha_{t-1}} \mathbf{x}_0 + \sqrt{1 - \alpha_{t-1}} \left(\frac{\mathbf{x}_t - \sqrt{\alpha_t} \mathbf{x}_0}{\sqrt{1 - \alpha_t}} \right). \end{aligned} \quad (2.55)$$

Eqn (2.55) 和 Eqn (2.54) 之间的区别在于, 在 Eqn (2.54) 中, 噪声项是 $\boldsymbol{\epsilon}$, 即 $\mathcal{N}(0, \mathbf{I})$ 。正是这个高斯分布使得 DDPM 的推导变得容易, 但也是这个高斯分布使得反向扩散变慢。相比之下, Eqn (2.55) 用估

计值替换了高斯分布。这个估计值使用了之前的信号 $\mathbf{x}_t$ 与初始信号 $\mathbf{x}_0$ 的组合。当然，有人可能会争辩说，在 DDPM 中（例如，Eqn (2.24)）也使用了 $\mathbf{x}_t$ 和 $\mathbf{x}_0$ 的组合。区别在于，Eqn (2.55) 中的组合允许我们做一些 Eqn (2.24) 无法做到的事情，即推导边际分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_0)$ 并将其转化为所需的形式。让我们更详细地阐述边际分布。参考 Eqn (2.55)，我们注意到我们可以选择

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}\left(\sqrt{\alpha_{t-1}}\mathbf{x}_0 + \sqrt{1 - \alpha_{t-1}}\left(\frac{\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_0}{\sqrt{1 - \alpha_t}}\right), \text{ something}\right).$$

其中 “something” 代表高斯的方差，可以设为某个超参数 σ_t^2 的 $\sigma_t^2\mathbf{I}$ 。DDIM 中一个重要的（可能是最重要的）论点是，我们希望边际分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_0)$ 与 $q(\mathbf{x}_t|\mathbf{x}_0)$ 具有相同的形式：

$$q(\mathbf{x}_{t-1}|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_{t-1}}\mathbf{x}_0, (1 - \alpha_{t-1})\mathbf{I}).$$

之所以追求这种分布，是因为我们最终关心的是边际分布 $q(\mathbf{x}_t|\mathbf{x}_0)$ ，我们希望当 $t = T$ 时它变成纯白噪声，而当 $t = 0$ 时它是原始图像。因此，尽管我们可以有数百万种不同的过渡分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 的选择，但只有一些非常特殊的过渡概率才能确保 $q(\mathbf{x}_{t-1}|\mathbf{x}_0)$ 呈现出我们喜欢的形式。

过渡分布的推导。带着这个目标，我们现在陈述我们的数学问题。假设

$$\begin{aligned} q(\mathbf{x}_t|\mathbf{x}_0) &= \mathcal{N}(\sqrt{\alpha_t}\mathbf{x}_0, (1 - \alpha_t)\mathbf{I}), \\ q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) &= \mathcal{N}\left(\sqrt{\alpha_{t-1}}\mathbf{x}_0 + \sqrt{1 - \alpha_{t-1}}\left(\frac{\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_0}{\sqrt{1 - \alpha_t}}\right), \sigma_t^2\mathbf{I}\right), \end{aligned} \quad (2.56)$$

我们能否确保 $q(\mathbf{x}_{t-1}|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_{t-1}}\mathbf{x}_0, (1 - \alpha_{t-1})\mathbf{I})$ ？如果不能，我们需要做哪些额外的改变？

这个数学问题的答案需要一些教科书中的工具。我们回忆一下 Bishop 教科书中的以下结果 [4]。

Theorem 2.8. Bishop [4, Eqn 2.115] 假设我们有两个随机变量 $\mathbf{x}$ 和 $\mathbf{y}$ ，它们遵循分布

$$\begin{aligned} p(\mathbf{x}) &= \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}), \\ p(\mathbf{y}|\mathbf{x}) &= \mathcal{N}(\mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1}). \end{aligned}$$

那么我们可以证明边际分布是

$$p(\mathbf{y}) = \int p(\mathbf{y}|\mathbf{x})p(\mathbf{x})d\mathbf{x} = \mathcal{N}(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Lambda}^{-1}\mathbf{A}^{-1}).$$

让我们看看如何将这个结果应用到我们的问题中。查看 Eqn (2.56)，我们可以识别以下特性：

$$\mathbf{A} = \sqrt{\frac{1 - \alpha_{t-1}}{1 - \alpha_t}}, \quad \boldsymbol{\mu} = \sqrt{\alpha_t}\mathbf{x}_0, \quad \mathbf{b} = \sqrt{\alpha_{t-1}}\mathbf{x}_0 - \sqrt{\frac{1 - \alpha_{t-1}}{1 - \alpha_t}}\sqrt{\alpha_t}\mathbf{x}_0.$$

假设 $q(\mathbf{x}_{t-1}|\mathbf{x}_0) = \mathcal{N}(\boldsymbol{\mu}_{t-1}, \sigma_{t-1}^2\mathbf{I})$ ，其中均值 $\boldsymbol{\mu}_{t-1}$ 和方差 σ_{t-1}^2 是未知的选择。如果我们能证明 $\boldsymbol{\mu}_{t-1} = \sqrt{\alpha_{t-1}}\mathbf{x}_0$ 且 $\sigma_{t-1}^2 = (1 - \alpha_{t-1})$ ，那么我们就完成了。为此，我们证明

$$\begin{aligned} \boldsymbol{\mu}_{t-1} &= \mathbf{A}\boldsymbol{\mu} + \mathbf{b} \\ &= \sqrt{\frac{1 - \alpha_{t-1}}{1 - \alpha_t}} \cdot \sqrt{\alpha_t}\mathbf{x}_0 + \sqrt{\alpha_{t-1}}\mathbf{x}_0 - \sqrt{\frac{1 - \alpha_{t-1}}{1 - \alpha_t}}\sqrt{\alpha_t}\mathbf{x}_0 \\ &= \sqrt{\alpha_{t-1}}\mathbf{x}_0. \end{aligned}$$

哦，好消息！我们已经证明 $\boldsymbol{\mu}_{t-1} = \sqrt{\alpha_{t-1}}\mathbf{x}_0$ 。这意味着对于我们选择的过渡分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ ，边际分布具有所需的均值。

所以剩下的就是检查方差。我们证明

$$\begin{aligned}\sigma_{t-1}^2 &= \mathbf{L}^{-1} + \mathbf{A}\mathbf{A}^{-1}\mathbf{A}^T \\ &= \sigma_t^2 + \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \cdot (1-\alpha_t) \cdot \sqrt{\frac{1-\alpha_{t-1}}{1-\alpha_t}} \\ &= \sigma_t^2 + (1-\alpha_{t-1}).\end{aligned}$$

哦，不！我们无法证明 $\sigma_{t-1}^2 = 1 - \alpha_{t-1}$ 。这里有一个额外的项 σ_t^2 。但这并不是什么大问题。我们如何通过添加 σ_t^2 到 $\mathbf{A}$ 中进行快速修复：

$$\begin{aligned}\sigma_{t-1}^2 &= \sigma_t^2 + \sqrt{\frac{1-\alpha_{t-1}-\sigma_t^2}{1-\alpha_t}} \cdot (1-\alpha_t) \cdot \sqrt{\frac{1-\alpha_{t-1}-\sigma_t^2}{1-\alpha_t}} \\ &= \sigma_t^2 + 1 - \alpha_{t-1} - \sigma_t^2 \\ &= 1 - \alpha_{t-1}.\end{aligned}$$

啊哈！ σ_{t-1}^2 现在呈现出所需的形式，使得 $\sigma_{t-1}^2 = 1 - \alpha_{t-1}$ 。让我们快速检查一下，确保这个额外的 σ_t^2 不会影响均值：

$$\begin{aligned}\mu_{t-1} &= \mathbf{A}\mu + \mathbf{b} \\ &= \sqrt{\frac{1-\alpha_{t-1}-\sigma_t^2}{1-\alpha_t}} \cdot \sqrt{\alpha_t}\mathbf{x}_0 + \sqrt{\alpha_{t-1}}\mathbf{x}_0 - \sqrt{\frac{1-\alpha_{t-1}-\sigma_t^2}{1-\alpha_t}}\sqrt{\alpha_t}\mathbf{x}_0 \\ &= \sqrt{\alpha_{t-1}}\mathbf{x}_0.\end{aligned}$$

所以，尽管我们改变了方差项，均值仍然保持所需的形式。

总结一下，我们可以选择 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 为以下形式。

Theorem 2.9. DDIM 过渡分布。 在 DDIM 中，过渡分布定义为

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}\left(\sqrt{\alpha_{t-1}}\mathbf{x}_0 + \sqrt{1-\alpha_{t-1}-\sigma_t^2}\left(\frac{\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_0}{\sqrt{1-\alpha_t}}\right), \sigma_t^2\mathbf{I}\right). \quad (2.57)$$

如果 $q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_t}\mathbf{x}_0, (1-\alpha_t)\mathbf{I})$ ，那么根据我们的推导， $q(\mathbf{x}_{t-1}|\mathbf{x}_0) = \mathcal{N}(\sqrt{\alpha_{t-1}}\mathbf{x}_0, (1-\alpha_{t-1})\mathbf{I})$ 。

DDIM 的推断。 DDIM 的推断是基于转移分布推导的。从前向过程开始，如果我们想要执行反向过程，我们需要从以下方程中找出 $\mathbf{x}_0$ ：

$$\underbrace{\mathbf{x}_t}_{\text{given}} = \underbrace{\sqrt{\alpha_t}\mathbf{x}_0}_{\text{want to find}} + \underbrace{\sqrt{1-\alpha_t}\boldsymbol{\epsilon}}_{\text{estimated by network}}.$$

通过重新排列项，我们看到

$$\begin{aligned}\mathbf{x}_0 &= \frac{1}{\sqrt{\alpha_t}}(\mathbf{x}_t - \sqrt{1-\alpha_t}\boldsymbol{\epsilon}) \\ \implies f_{\boldsymbol{\theta}}^{(t)}(\mathbf{x}_t) &\stackrel{\text{def}}{=} \frac{1}{\sqrt{\alpha_t}}(\mathbf{x}_t - \sqrt{1-\alpha_t}\boldsymbol{\epsilon}_{\boldsymbol{\theta}}^{(t)}(\mathbf{x}_t)).\end{aligned}$$

这个方程中有两个新项。第一个是 $\boldsymbol{\epsilon}_{\boldsymbol{\theta}}^{(t)}(\mathbf{x}_t)$ ，它取代了 $\boldsymbol{\epsilon}$ 。它是基于当前输入 $\mathbf{x}_t$ 的噪声估计。第二项是 $f_{\boldsymbol{\theta}}^{(t)}(\mathbf{x}_t)$ ，它被定义为方程 $\frac{1}{\sqrt{\alpha_t}}(\mathbf{x}_t - \sqrt{1-\alpha_t}\boldsymbol{\epsilon}_{\boldsymbol{\theta}}^{(t)}(\mathbf{x}_t))$ 。我们可以将其视为真实信号 $\mathbf{x}_0$ 的估计。

回到转移分布，我们记得它由 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 表示。如果我们无法访问 $\mathbf{x}_0$ ，我们可以用 $f_{\boldsymbol{\theta}}^{(t)}(\mathbf{x}_t)$ 替

换它。这意味着

$$\begin{aligned}
p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) &= q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \\
\Rightarrow p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) &\stackrel{\text{def}}{=} q(\mathbf{x}_{t-1}|\mathbf{x}_t, f_{\theta}^{(t)}(\mathbf{x}_t)) \\
&= \mathcal{N}\left(\sqrt{\alpha_{t-1}}f_{\theta}^{(t)}(\mathbf{x}_t) + \sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\alpha_t}f_{\theta}^{(t)}(\mathbf{x}_t)}{\sqrt{1 - \alpha_t}}, \quad \sigma_t^2 \mathbf{I}\right) \\
&= \mathcal{N}\left(\sqrt{\alpha_{t-1}} \cdot \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \sqrt{1 - \alpha_t} \epsilon_{\theta}^{(t)}(\mathbf{x}_t)\right) + \right. \\
&\quad \left. + \sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \frac{\mathbf{x}_t - \sqrt{\alpha_t} \left(\frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \sqrt{1 - \alpha_t} \epsilon_{\theta}^{(t)}(\mathbf{x}_t)\right)\right)}{\sqrt{1 - \alpha_t}}, \quad \sigma_t^2 \mathbf{I}\right) \\
&= \mathcal{N}\left(\sqrt{\alpha_{t-1}} \left(\frac{\mathbf{x}_t - \sqrt{1 - \alpha_t} \epsilon_{\theta}^{(t)}(\mathbf{x}_t)}{\sqrt{\alpha_t}}\right) + \sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \epsilon_{\theta}^{(t)}(\mathbf{x}_t), \quad \sigma_t^2 \mathbf{I}\right). \tag{2.58}
\end{aligned}$$

对于 $t = 1$ 的特殊情况，我们定义 $p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(f_{\theta}^{(1)}(\mathbf{x}_1), \sigma_1^2 \mathbf{I})$ ，以便反向过程在任何地方都得到支持。查看 Eqn (2.58)，我们使用重参数化将其写成如下形式，并根据 [39] 解释该方程。

$$\text{(DDIM)} \quad \mathbf{x}_{t-1} = \underbrace{\sqrt{\alpha_{t-1}} \left(\frac{\mathbf{x}_t - \sqrt{1 - \alpha_t} \epsilon_{\theta}^{(t)}(\mathbf{x}_t)}{\sqrt{\alpha_t}}\right)}_{\text{predicted } \mathbf{x}_0} + \underbrace{\sqrt{1 - \alpha_{t-1} - \sigma_t^2} \cdot \epsilon_{\theta}^{(t)}(\mathbf{x}_t)}_{\text{direction pointing to } \mathbf{x}_t} + \underbrace{\sigma_t \epsilon_t}_{\sim \mathcal{N}(0, \mathbf{I})}. \tag{2.59}$$

将这个方程与 Eqn (2.52) 中的 DDPM 方程进行比较会有所帮助：

$$\text{(DDPM)} \quad \mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_{\theta}^{(t)}(\mathbf{x}_t)\right) + \sigma_t \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, \mathbf{I}). \tag{2.60}$$

DDPM 和 DDIM 之间的主要区别是微妙的。虽然它们都在更新中使用 $\mathbf{x}_t$ 和 $\epsilon_{\theta}^{(t)}(\mathbf{x}_t)$ ，但具体的更新公式导致了不同的收敛速度。事实上，在后来的微分方程文献中，人们将 DDIM 和 DDPM 与随机微分方程联系起来时，观察到 DDIM 在求解微分方程时采用了一些特殊的一阶加速数值方案。

2.7 结语

DDPM（去噪扩散概率模型）的文献正在迅速增长。要理解这一主题，Sohl-Dickstein 等人 [38] 和 Ho 等人 [16] 的原始论文是必读材料。对于更“用户友好”的版本，我们发现 Luo 的教程非常有用 [27]。一些后续工作被高度引用，包括 Song 等人提出的去噪扩散隐式模型 [39]。在应用方面，人们已将 DDPM 用于各种图像合成应用，例如 [34, 35]。

3 分数匹配朗之万动力学 (SMLD)

基于分数的生成模型 [42] 是从期望分布生成数据的替代方法。有几个核心要素：朗之万方程、(Stein) 分数函数和分数匹配损失。本节的重点更多在于后两者。我们将对朗之万方程进行一些粗略的讨论，并解释如何使其在计算上可行以完成我们的生成任务。关于朗之万方程的更深入讨论将推迟到下一节。

3.1 从分布中采样

想象我们被给定一个分布 $p(\mathbf{x})$ ，并且我们想要从 $p(\mathbf{x})$ 中抽取样本。如果 $\mathbf{x}$ 是一维变量，我们可以通过反转累积分布函数 (CDF) [7, 第 4 章] 并将一个均匀 $[0, 1]$ 随机变量通过这个反转的 CDF 来轻松实现目标。对于高维分布，同样的 CDF 技术不适用。然而，给高概率样本赋予更高权重的直觉仍然有效。例如，如果我们想从橙色数据集中抽取一个样本，几乎可以肯定我们想要的是一个球形的橙子而不是一个立方体的橙子。

因此，以一种非严格的方式，我们可以认为，如果我们被给定 $p(\mathbf{x})$ ，我们应该从 $p(\mathbf{x})$ 值较高的位置抽取样本。这种寻找更高概率的想法可以转化为一个优化问题

$$\mathbf{x}^* = \operatorname{argmax}_{\mathbf{x}} \log p(\mathbf{x}),$$

其中目标是最大化分布 $p(\mathbf{x})$ 的对数似然。当然，这种最大化并没有提供任何关于如何抽取低概率样本的线索，我们将通过朗之万方程的视角来解释这一点。现在，我们想对这里的最大化与最大似然估计之间的差异做一个说明。在最大似然估计中，数据点 $\mathbf{x}$ 是固定的，但模型参数在变化。在这里，模型参数是固定的，但数据点在变化。我们被给定一个固定的模型。我们的目标是从这个模型中抽取最可能的样本。下表显示了我们的采样问题与最大似然估计之间的差异。

让我们继续讨论最大化的问题。如果 $p(\mathbf{x})$ 是一个简单的参数模型，最大化将有解析解。然而，一般来说，高维空间中的优化问题是病态的，存在许多局部最小值。因此，没有一种算法在所有情况下都能全局收敛。在计算复杂度、内存需求、实现难度和解质量之间，一个合理的折衷是梯度下降算法，这是一种一阶方法。对于我们的优化问题，目标函数是 $\log p(\mathbf{x})$ ，梯度下降算法通过更新规则定义了一系列迭代

$$\mathbf{x}_{t+1} = \mathbf{x}_t + \tau \nabla_{\mathbf{x}} \log p(\mathbf{x}_t),$$

其中 $\nabla_{\mathbf{x}} \log p(\mathbf{x}_t)$ 表示在 $\mathbf{x}_t$ 处评估的 $\log p(\mathbf{x})$ 的梯度， τ 是步长。这里我们使用“+”而不是通常的“-”，因为我们正在解决一个最大化问题。如果您同意上述方法，我们现在可以提供关于朗之万方程的信息介绍。不必过多担心其在物理学中的根源，我们可以将朗之万方程视为一种迭代过程，使我们能够抽取样本。

Definition 3.1. 从已知分布 $p(\mathbf{x})$ 中采样的（离散时间）朗之万方程是一个迭代过程，对于 $t = 1, \dots, T$:

$$\mathbf{x}_{t+1} = \mathbf{x}_t + \tau \nabla_{\mathbf{x}} \log p(\mathbf{x}_t) + \sqrt{2\tau} \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(0, \mathbf{I}), \quad (3.1)$$

其中 τ 是用户可以控制的步长， $\mathbf{x}_0$ 是白噪声。

Example 3.1. 考虑一个高斯分布 $p(x) = \mathcal{N}(x | \mu, \sigma^2)$ ，我们可以证明朗之万方程为

$$\begin{aligned} x_{t+1} &= x_t + \tau \cdot \nabla_x \log \left\{ \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_t - \mu)^2}{2\sigma^2}} \right\} + \sqrt{2\tau} z \\ &= x_t - \tau \cdot \frac{x_t - \mu}{\sigma^2} + \sqrt{2\tau} z, \end{aligned} \quad z \sim \mathcal{N}(0, 1),$$

其中初始状态可以设置为 $x_0 \sim \mathcal{N}(0, 1)$ 。

如果我们忽略噪声项 $\sqrt{2\tau}\mathbf{z}$, Eqn (3.1) 中的朗之万方程正是 **梯度下降**, 但针对一个特定的函数——随机变量 $\mathbf{x}$ 的对数似然。因此, 虽然梯度下降是适用于任何目标函数的通用一阶优化算法, 但朗之万方程在生成模型的背景下更关注分布。梯度下降算法加上一个小的噪声扰动, 为我们提供了一个简单的总结。

在生成模型中,

$$\text{朗之万方程} = \text{梯度下降} + \text{噪声}$$

应用于对数似然函数。

但为什么我们需要梯度下降加噪声, 而不是单纯的梯度下降? 一种解释是我们并不关心解决优化问题。相反, 我们更感兴趣的是从分布中采样。通过在梯度下降步骤中引入随机噪声, 我们随机选择一个样本, 该样本遵循目标函数的轨迹, 但不会停留在原地。如果我们接近峰值, 我们会稍微左右移动。如果我们远离峰值, 梯度方向会将我们拉向峰值。如果峰值周围的曲率很陡, 我们将在那里集中大部分稳态点 $\mathbf{x}_T$ 。如果峰值周围的曲率平坦, 我们将分散开来。因此, 通过在均匀分布的位置重复初始化梯度下降 (加噪声) 算法, 我们最终将收集到遵循我们指定分布的样本。

一个稍微更正式的方式来证明朗之万方程是福克-普朗克方程。福克-普朗克方程是随机过程的一个基本结果。对于任何马尔可夫过程 (例如, 维纳过程和布朗运动), 解 $\mathbf{x}_t$ 的动力学由随机微分方程 (即朗之万方程) 描述。然而, 由于 $\mathbf{x}_t$ 在任何时间 t 都是一个随机变量, 因此每个 $\mathbf{x}_t$ 都有一个潜在的概率分布 $p(\mathbf{x}, t)$ 。福克-普朗克方程提供了关于该分布的数学陈述。该分布必须满足一个偏微分方程。粗略地说, 在我们问题的背景下, 福克-普朗克方程可以描述如下。

Theorem 3.1. 在我们问题的背景下, 朗之万方程的解 $\mathbf{x}_t$ 在时间 t 将具有满足 **福克-普朗克方程** 的概率分布 $p(\mathbf{x}, t)$

$$\partial_t p(\mathbf{x}, t) = -\partial_{\mathbf{x}} \left\{ [\partial_{\mathbf{x}}(\log p(\mathbf{x}))] p(\mathbf{x}, t) \right\} + \partial_{\mathbf{x}}^2 p(\mathbf{x}, t), \quad (3.2)$$

其中 $\log p(\mathbf{x})$ 是真实分布的对数似然。

推导福克-普朗克方程将需要大量的努力。然而, 如果我们有一个候选解, 验证它是否满足福克-普朗克方程并不困难。

定理验证。 假设我们已经运行了足够长时间的 Langevin 方程, 以至于达到了一个收敛解 $\mathbf{x}_t$, 当 $t \rightarrow \infty$ 时。我们论证这个极限分布是 $p(\mathbf{x})$ 。实际上, 我们可以证明

$$\partial_{\mathbf{x}} \left\{ \log p(\mathbf{x}) \right\} = \frac{\partial_{\mathbf{x}} p(\mathbf{x})}{p(\mathbf{x})}.$$

然后, 当 $t \rightarrow \infty$ 时, 用 $p(\mathbf{x})$ 替换 $p(\mathbf{x}, t)$, 我们可以证明

$$\begin{aligned} -\partial_{\mathbf{x}} \left\{ [\partial_{\mathbf{x}}(\log p(\mathbf{x}))] p(\mathbf{x}) \right\} + \partial_{\mathbf{x}}^2 p(\mathbf{x}) &= \partial_{\mathbf{x}} \left\{ [-\partial_{\mathbf{x}}(\log p(\mathbf{x}))] p(\mathbf{x}) + \partial_{\mathbf{x}} p(\mathbf{x}) \right\} \\ &= \partial_{\mathbf{x}} \left\{ -\frac{\partial_{\mathbf{x}} p(\mathbf{x})}{p(\mathbf{x})} p(\mathbf{x}) + \partial_{\mathbf{x}} p(\mathbf{x}) \right\} \\ &= \partial_{\mathbf{x}} \left\{ -\partial_{\mathbf{x}} p(\mathbf{x}) + \partial_{\mathbf{x}} p(\mathbf{x}) \right\} = 0. \end{aligned}$$

另一方面, 当 $t \rightarrow \infty$ 时, $\partial_t p(\mathbf{x}) = 0$ 成立。因此, Fokker-Planck 方程得到验证。

Example 3.2. 考虑一个高斯混合 $p(x) = \pi_1 \mathcal{N}(x | \mu_1, \sigma_1^2) + \pi_2 \mathcal{N}(x | \mu_2, \sigma_2^2)$ 。我们可以解析或数值计算梯度 $\nabla_x \log p(x)$ 。为了演示，我们选择 $\pi_1 = 0.6$, $\mu_1 = 2$, $\sigma_1 = 0.5$, $\pi_2 = 0.4$, $\mu_2 = -2$, $\sigma_2 = 0.2$ 。我们初始化 $x_0 = 0$ 。选择 $\tau = 0.05$ 。我们运行上述梯度下降迭代 $T = 500$ 次，并绘制 $p(x_t)$ 在 $t = 1, \dots, T$ 时的轨迹。如下图所示，序列 $\{x_1, x_2, \dots, x_T\}$ 简单地遵循高斯的形状并爬升到其中一个峰值。

更有趣的是当我们加入噪声项时。序列 x_t 不会停留在峰值，而是在峰值附近移动并最终停在峰值附近。（备注：为了终止算法，我们可以逐渐减小 τ 或提前停止。）




Figure 3.2: 确定性算法旨在选择最大化似然的样本，与每次迭代添加噪声的随机算法对比。

Figure ??展示了样本轨迹的有趣描述。从任意位置开始，数据点 $\mathbf{x}_t$ 将根据 Langevin 动力学方程进行随机游走。随机游走的方向并非完全随机。每一步都有一定程度的预定义漂移，同时也有一定程度的随机性。漂移由 $\nabla_x \log p(\mathbf{x})$ 决定，而随机性来自 $\mathbf{z}$ 。

Example 3.3. 继续前面的例子，我们再次考虑一个高斯混合

$$p(x) = \pi_1 \mathcal{N}(x | \mu_1, \sigma_1^2) + \pi_2 \mathcal{N}(x | \mu_2, \sigma_2^2)$$

我们选择 $\pi_1 = 0.6$, $\mu_1 = 2$, $\sigma_1 = 0.5$, $\pi_2 = 0.4$, $\mu_2 = -2$, $\sigma_2 = 0.2$ 。假设我们初始化 $M = 10000$ 个均匀分布的样本 $x_0 \sim \text{Uniform}[-3, 3]$ 。我们运行 Langevin 更新 $t = 100$ 步。生成样本的直方图如下图所示。




Figure 3.4: 通过朗之万动力学生成的样本。最初样本是均匀分布的。随着时间的推移，样本的分布逐渐趋近于期望的分布。

备注 1: 随机梯度朗之万动力学。由朗之万方程控制的 $\mathbf{x}_t$ 的动态行为通常被称为朗之万动力学。朗之万动力学使用梯度下降加噪声。这与随机梯度下降 (SGD) 不同。SGD 使用小批量来近似全梯度。SGD 中没有噪声。SGD 的随机性来自于从训练数据集中均匀采样的小批量。SGD 可以与朗之万动力学结合, 形成随机梯度朗之万动力学, 如 [46] 中所述, 该文献在经典的最大后验 (MAP) 估计背景下提供了清晰的比较。

$$\text{随机梯度下降} \quad \Delta \theta_t = \frac{\epsilon_t}{2} \left(\nabla_{\theta} \log p(\theta_t) + \frac{N}{n} \sum_{i=1}^n \nabla \log p(\mathbf{y}_{t_i} | \theta_t) \right)$$

$$\text{朗之万动力学} \quad \Delta \theta_t = \frac{\epsilon}{2} \left(\nabla_{\theta} \log p(\theta_t) + \sum_{i=1}^N \nabla \log p(\mathbf{y}_i | \theta_t) \right) + \eta_t$$

$$\text{随机梯度朗之万动力学} \quad \Delta \theta_t = \frac{\epsilon_t}{2} \left(\nabla_{\theta} \log p(\theta_t) + \frac{N}{n} \sum_{i=1}^n \nabla \log p(\mathbf{y}_{t_i} | \theta_t) \right) + \eta_t,$$

其中 ϵ_t 是满足 $\sum_{t=1}^{\infty} \epsilon_t = \infty$ 和 $\sum_{t=1}^{\infty} \epsilon_t^2 < \infty$ 性质的步长序列, $\eta_t \sim \mathcal{N}(0, \mathbf{I})$ 是白噪声。集合 $\{\mathbf{y}_1, \dots, \mathbf{y}_N\}$ 表示训练集。常数 N 和 n 分别表示完整训练集和小批量中的训练样本数量。

3.2 (斯坦因的) 得分函数

抛开朗之万动力学和基础的福克-普朗克方程不谈, 迭代过程的关键是对数似然函数的梯度 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 。它有一个正式的名称, 称为**斯坦因得分函数**, 记作

$$\mathbf{s}_{\theta}(\mathbf{x}) \stackrel{\text{def}}{=} \nabla_{\mathbf{x}} \log p_{\theta}(\mathbf{x}). \quad (3.3)$$

我们应当注意, 不要将斯坦因得分函数与**普通得分函数**混淆, 后者定义为

$$\mathbf{s}_{\mathbf{x}}(\theta) \stackrel{\text{def}}{=} \nabla_{\theta} \log p_{\theta}(\mathbf{x}). \quad (3.4)$$

普通得分函数是对数似然关于 θ 的梯度。相反, 斯坦因得分函数是关于数据点 $\mathbf{x}$ 的梯度。最大似然估计使用普通得分函数, 而朗之万动力学则使用斯坦因得分函数。然而, 由于扩散文献中大多数人将斯坦因得分函数简称为得分函数, 我们遵循这一习惯。


Example 3.4. 若 $p(x)$ 为高斯分布, 即 $p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, 则

$$s(x) = \nabla_x \log p(x) = -\frac{(x - \mu)}{\sigma^2}.$$

Example 3.5. 若 $p(x)$ 为高斯混合分布, 即 $p(x) = \sum_{i=1}^N \pi_i \frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{(x-\mu_i)^2}{2\sigma_i^2}}$, 则

$$s(x) = \nabla_x \log p(x) = -\frac{\sum_{j=1}^N \pi_j \frac{1}{\sqrt{2\pi\sigma_j^2}} e^{-\frac{(x-\mu_j)^2}{2\sigma_j^2}} \frac{(x-\mu_j)}{\sigma_j^2}}{\sum_{i=1}^N \pi_i \frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{(x-\mu_i)^2}{2\sigma_i^2}}}.$$

上述两例的概率密度函数及其对应的得分函数展示于 Figure 3.5。



得分函数的几何解释。理解得分函数的方式是记住它是关于数据 $\mathbf{x}$ 的梯度。对于任何高维分布 $p(\mathbf{x})$ ，梯度将给出一个向量场。得分函数有几种有用的解释：

- 向量的大小在 $\log p(\mathbf{x})$ 变化最大的地方最强。因此，在 $\log p(\mathbf{x})$ 接近峰值的区域，梯度大多非常弱。
- 向量场指示了数据点在等高线图中应如何移动。在 Figure ?? 中，我们展示了一个高斯混合分布（包含两个高斯分布）的等高线图。我们绘制箭头以指示向量场。现在，如果我们考虑一个存在于该空间的数据点，朗之万动力学方程将基本上使数据点沿着向量场指向的方向向盆地移动。
- 在物理学中，得分函数等同于“漂移”。这一名称暗示了扩散粒子应如何流向最低能量状态。

3.3 分数匹配技术

在朗之万动力学中，最困难的问题是如何获得 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ ，因为我们无法直接访问 $p(\mathbf{x})$ 。在本节中，我们简要讨论几种已知的技术。

显式分数匹配 [43]。假设我们有一个数据集 $\mathcal{X} = \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(M)}\}$ 。人们提出的解决方案是通过定义一个分布来考虑经典核密度估计

$$q_h(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M \frac{1}{h} K\left(\frac{\mathbf{x} - \mathbf{x}^{(m)}}{h}\right), \quad (3.5)$$

其中 h 是核函数 $K(\cdot)$ 的某个超参数， $\mathbf{x}^{(m)}$ 是训练集中的第 m 个样本。Figure ?? 展示了核密度估计的思想。在左侧的卡通图中，我们展示了以不同数据点 $\mathbf{x}^{(m)}$ 为中心的多个核函数 $K(\cdot)$ 。所有这些单个核的总和给出了整体的核密度估计 $q(\mathbf{x})$ 。在右侧，我们展示了一个真实的直方图及其对应的核密度估计。我们注意到 $q(\mathbf{x})$ 最多只是对真实数据分布 $p(\mathbf{x})$ 的近似，而真实分布是永远未知的。

由于 $q(\mathbf{x})$ 是对 $p(\mathbf{x})$ 的近似，而 $p(\mathbf{x})$ 永远无法直接访问，我们可以基于 $q(\mathbf{x})$ 来学习 $\mathbf{s}_{\theta}(\mathbf{x})$ 。这导致了以下损失函数的定义，该函数可用于训练网络。

Theorem 3.2. 显式分数匹配损失为

$$\begin{aligned} J_{\text{ESM}}(\theta) &\stackrel{\text{def}}{=} \frac{1}{2} \mathbb{E}_{p(\mathbf{x})} \|\mathbf{s}_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log p(\mathbf{x})\|^2 \\ &\approx \frac{1}{2} \mathbb{E}_{q_h(\mathbf{x})} \|\mathbf{s}_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log q_h(\mathbf{x})\|^2. \end{aligned} \quad (3.6)$$

通过代入核密度估计，我们可以证明损失为

$$\begin{aligned} J_{\text{ESM}}(\theta) &= \mathbb{E}_{q_h(\mathbf{x})} \|\mathbf{s}_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log q_h(\mathbf{x})\|^2 \\ &= \int \|\mathbf{s}_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log q_h(\mathbf{x})\|^2 q_h(\mathbf{x}) d\mathbf{x} \\ &\approx \frac{1}{M} \sum_{m=1}^M \int \|\mathbf{s}_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log q_h(\mathbf{x})\|^2 \frac{1}{h} K\left(\frac{\mathbf{x} - \mathbf{x}^{(m)}}{h}\right) d\mathbf{x}. \end{aligned} \quad (3.7)$$

因此，我们推导出了一个可用于训练网络的损失函数。一旦我们训练了网络 $\mathbf{s}_{\theta}$ ，我们就可以将其替换到朗之万动力学方程中，得到递归：

$$\mathbf{x}_{t+1} = \mathbf{x}_t + \tau \mathbf{s}_{\theta}(\mathbf{x}_t) + \sqrt{2\tau} \mathbf{z}. \quad (3.8)$$

显式分数匹配的问题在于，核密度估计是对真实分布的一种相当差的非参数估计。特别是当我们有有限数量的样本且样本存在于高维空间时，核密度估计的性能可能会很差。

隐式分数匹配 [18]。在隐式分数匹配中，显式分数匹配损失被隐式损失所取代。

$$J_{\text{ISM}}(\boldsymbol{\theta}) \stackrel{\text{def}}{=} \mathbb{E}_{p(\mathbf{x})} \left[\text{Tr}(\nabla_{\mathbf{x}} \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})) + \frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})\|^2 \right], \quad (3.9)$$

其中 $\nabla_{\mathbf{x}} \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})$ 表示 $\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})$ 的雅可比矩阵。隐式分数匹配损失可以通过蒙特卡罗方法近似

$$J_{\text{ISM}}(\boldsymbol{\theta}) \approx \frac{1}{M} \sum_{m=1}^M \sum_i \left(\partial_i \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}^{(m)}) + \frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}^{(m)})\|_i^2 \right),$$

其中 $\partial_i \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}^{(m)}) = \frac{\partial}{\partial x_i} [\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})]_i = \frac{\partial^2}{\partial x_i^2} \log p(\mathbf{x})$ 。如果分数函数的模型由深度神经网络实现，迹算子可能难以计算，因此使得隐式分数匹配不可扩展 [40]。

去噪分数匹配。鉴于显式和隐式分数匹配的潜在缺点，我们现在介绍一种更流行的分数匹配方法，称为去噪分数匹配 (DSM)，由 Vincent 提出 [43]。在 DSM 中，损失函数定义如下。

$$J_{\text{DSM}}(\boldsymbol{\theta}) \stackrel{\text{def}}{=} \mathbb{E}_{q(\mathbf{x}, \mathbf{x}')} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}) - \nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')\|^2 \right] \quad (3.10)$$

这里的关键区别在于，我们将分布 $q(\mathbf{x})$ 替换为条件分布 $q(\mathbf{x}|\mathbf{x}')$ 。前者需要近似，例如通过核密度估计，而后者则不需要。在特殊情况下，当 $q(\mathbf{x}|\mathbf{x}') = \mathcal{N}(\mathbf{x} | \mathbf{x}', \sigma^2)$ 时，我们可以设 $\mathbf{x} = \mathbf{x}' + \sigma \mathbf{z}$ 。这将给出

$$\begin{aligned} \nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}') &= \nabla_{\mathbf{x}} \log \frac{1}{(\sqrt{2\pi}\sigma^2)^d} \exp \left\{ -\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\sigma^2} \right\} \\ &= \nabla_{\mathbf{x}} \left\{ -\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\sigma^2} - \log(\sqrt{2\pi}\sigma^2)^d \right\} \\ &= -\frac{\mathbf{x} - \mathbf{x}'}{\sigma^2} = -\frac{\mathbf{z}}{\sigma}. \end{aligned}$$

因此，去噪分数匹配的损失函数变为

$$\begin{aligned} J_{\text{DSM}}(\boldsymbol{\theta}) &\stackrel{\text{def}}{=} \mathbb{E}_{q(\mathbf{x}, \mathbf{x}')} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}) - \nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')\|^2 \right] \\ &= \mathbb{E}_{q(\mathbf{x}')} \left[\frac{1}{2} \left\| \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}' + \sigma \mathbf{z}) + \frac{\mathbf{z}}{\sigma} \right\|^2 \right]. \end{aligned}$$

如果我们用 $\mathbf{x}$ 替换虚拟变量 $\mathbf{x}'$ ，并且注意到在给定训练数据集时，从 $q(\mathbf{x})$ 采样可以替换为从 $p(\mathbf{x})$ 采样，我们可以得出以下结论。

Theorem 3.3. 去噪分数匹配的损失函数定义为

$$J_{\text{DSM}}(\boldsymbol{\theta}) = \mathbb{E}_{p(\mathbf{x})} \left[\frac{1}{2} \left\| \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x} + \sigma \mathbf{z}) + \frac{\mathbf{z}}{\sigma} \right\|^2 \right] \quad (3.11)$$

Eqn (??) 的美妙之处在于其高度可解释性。量 $\mathbf{x} + \sigma \mathbf{z}$ 实际上是在干净图像 $\mathbf{x}$ 上添加噪声 $\sigma \mathbf{z}$ 。分数函数 $\mathbf{s}_{\boldsymbol{\theta}}$ 应该接收这个带噪图像并预测噪声 $\frac{\mathbf{z}}{\sigma}$ 。预测噪声等同于去噪，因为任何去噪后的图像加上预测的噪声将给出带噪的观测结果。因此，Eqn (??) 是一个去噪步骤。

以下定理由 Vincent [43] 证明，确立了 DSM 与 ESM 之间的等价性。正是这种等价性使我们能够使用 DSM 来估计分数函数。

Theorem 3.4. [Vincent [43]] 对于与变量 $\boldsymbol{\theta}$ 无关的常数 C ，成立

$$J_{\text{DSM}}(\boldsymbol{\theta}) = J_{\text{ESM}}(\boldsymbol{\theta}) + C. \quad (3.12)$$

定理 3.4的证明这里的证明基于 [43]。我们从显式分数匹配损失函数开始，其定义为

$$\begin{aligned} J_{\text{ESM}}(\boldsymbol{\theta}) &= \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}) - \nabla_{\mathbf{x}} \log q(\mathbf{x})\|^2 \right] \\ &= \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})\|^2 - \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \log q(\mathbf{x}) + \underbrace{\frac{1}{2} \|\nabla_{\mathbf{x}} \log q(\mathbf{x})\|^2}_{\stackrel{\text{def}}{=} C_1, \text{与 } \boldsymbol{\theta} \text{ 无关}} \right]. \end{aligned}$$

让我们放大第二项。我们可以证明

$$\begin{aligned} \mathbb{E}_{q(\mathbf{x})} [\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \log q(\mathbf{x})] &= \int (\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \log q(\mathbf{x})) q(\mathbf{x}) d\mathbf{x}, \quad (\text{期望}) \\ &= \int \left(\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \frac{\nabla_{\mathbf{x}} q(\mathbf{x})}{q(\mathbf{x})} \right) q(\mathbf{x}) d\mathbf{x}, \quad (\text{梯度}) \\ &= \int \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} q(\mathbf{x}) d\mathbf{x}. \end{aligned}$$

接下来，我们通过回顾 $q(\mathbf{x}) = \int q(\mathbf{x}') q(\mathbf{x}|\mathbf{x}') d\mathbf{x}'$ 来考虑条件化。这将给出

$$\begin{aligned} \int \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} q(\mathbf{x}) d\mathbf{x} &= \int \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \underbrace{\left(\int q(\mathbf{x}') q(\mathbf{x}|\mathbf{x}') d\mathbf{x}' \right)}_{=q(\mathbf{x})} d\mathbf{x} \quad (\text{条件化}) \\ &= \int \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \left(\int q(\mathbf{x}') \nabla_{\mathbf{x}} q(\mathbf{x}|\mathbf{x}') d\mathbf{x}' \right) d\mathbf{x} \quad (\text{移动梯度}) \\ &= \int \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \left(\int q(\mathbf{x}') \nabla_{\mathbf{x}} q(\mathbf{x}|\mathbf{x}') \times \frac{q(\mathbf{x}|\mathbf{x}')}{q(\mathbf{x}|\mathbf{x}')} d\mathbf{x}' \right) d\mathbf{x} \quad (\text{乘除}) \\ &= \int \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \int q(\mathbf{x}') \underbrace{\left(\frac{\nabla_{\mathbf{x}} q(\mathbf{x}|\mathbf{x}')}{q(\mathbf{x}|\mathbf{x}')} \right)}_{=\nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')} q(\mathbf{x}|\mathbf{x}') d\mathbf{x}' d\mathbf{x} \quad (\text{重排项}) \\ &= \int \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \left(\int q(\mathbf{x}') (\nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')) q(\mathbf{x}|\mathbf{x}') d\mathbf{x}' \right) d\mathbf{x} \\ &= \int \int \underbrace{q(\mathbf{x}|\mathbf{x}') q(\mathbf{x}')}_{=q(\mathbf{x}, \mathbf{x}')} (\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')) d\mathbf{x}' d\mathbf{x} \quad (\text{移动积分}) \\ &= \mathbb{E}_{q(\mathbf{x}, \mathbf{x}')} [\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')]. \end{aligned}$$

因此，如果我们将此结果代回 ESM 的定义，可以证明

$$J_{\text{ESM}}(\boldsymbol{\theta}) = \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})\|^2 \right] - \mathbb{E}_{q(\mathbf{x}, \mathbf{x}')} [\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')] + C_1.$$

将此与 DSM 的定义进行比较，可以观察到

$$\begin{aligned} J_{\text{DSM}}(\boldsymbol{\theta}) &\stackrel{\text{def}}{=} \mathbb{E}_{q(\mathbf{x}, \mathbf{x}')} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}) - \nabla_{\mathbf{x}} q(\mathbf{x}|\mathbf{x}')\|^2 \right] \\ &= \mathbb{E}_{q(\mathbf{x}, \mathbf{x}')} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})\|^2 - \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}') + \underbrace{\frac{1}{2} \|\nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')\|^2}_{\stackrel{\text{def}}{=} C_2, \text{independent of } \boldsymbol{\theta}} \right] \\ &= \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})\|^2 \right] - \mathbb{E}_{q(\mathbf{x}, \mathbf{x}')} [\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})^T \nabla_{\mathbf{x}} \log q(\mathbf{x}|\mathbf{x}')] + C_2. \end{aligned}$$

因此，我们得出结论

$$J_{\text{DSM}}(\boldsymbol{\theta}) = J_{\text{ESM}}(\boldsymbol{\theta}) - C_1 + C_2.$$

训练过程在分数匹配模型中通常通过最小化去噪分数匹配损失函数来完成。如果我们有一个训练数据集 $\{\mathbf{x}^{(m)}\}_{m=1}^M$ ，优化目标是

$$\begin{aligned}\boldsymbol{\theta}^* &= \underset{\boldsymbol{\theta}}{\operatorname{argmin}} \mathbb{E}_{p(\mathbf{x})} \left[\frac{1}{2} \left\| \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x} + \sigma \mathbf{z}) + \frac{\mathbf{z}}{\sigma} \right\|^2 \right] \\ &\approx \underset{\boldsymbol{\theta}}{\operatorname{argmin}} \frac{1}{M} \sum_{m=1}^M \frac{1}{2} \left\| \mathbf{s}_{\boldsymbol{\theta}} \left(\mathbf{x}^{(m)} + \sigma \mathbf{z}^{(m)} \right) + \frac{\mathbf{z}^{(m)}}{\sigma} \right\|^2, \quad \text{where } \mathbf{z}^{(m)} \sim \mathcal{N}(0, \mathbf{I}).\end{aligned}$$

Figure ?? 展示了分数函数 $\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})$ 的训练过程。

上述训练过程假设了一个固定的噪声水平 σ 。将其推广到多个噪声水平并不困难。Song 和 Ermon 的噪声条件分数网络 (NCSN) [40] 认为可以优化以下损失

$$J_{\text{NCSN}}(\boldsymbol{\theta}) = \frac{1}{L} \sum_{i=1}^L \lambda(\sigma_i) \ell(\boldsymbol{\theta}; \sigma_i), \quad (3.13)$$

其中单个损失函数根据噪声水平 $\sigma_1, \dots, \sigma_L$ 定义：

$$\ell(\boldsymbol{\theta}; \sigma) = \mathbb{E}_{p(\mathbf{x})} \left[\frac{1}{2} \left\| \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x} + \sigma \mathbf{z}) + \frac{\mathbf{z}}{\sigma} \right\|^2 \right].$$

系数函数 $\lambda(\sigma_i)$ 通常根据经验选择为 $\lambda(\sigma) = \sigma^2$ [40]。噪声水平序列通常满足 $\frac{\sigma_1}{\sigma_2} = \dots = \frac{\sigma_{L-1}}{\sigma_L} > 1$ 。

对于**推断**，我们假设已经训练了分数估计器 $\mathbf{s}_{\boldsymbol{\theta}}$ 。为了生成图像，我们使用 Langevin 方程通过去噪图像迭代地抽取样本。在 NCSN 的情况下，相应的 Langevin 方程可以通过退火重要性采样实现：

$$\mathbf{x}_{t+1} = \mathbf{x}_t + \frac{\alpha_i}{2} \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}_t, \sigma_i) + \sqrt{\alpha_i} \mathbf{z}_t, \quad \mathbf{z}_t \sim \mathcal{N}(0, \mathbf{I}),$$

其中 $\alpha_i = \sigma_i^2 / \sigma_L^2$ 是步长， $\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}_t, \sigma_i)$ 表示噪声水平 σ_i 的分数匹配函数。迭代 t 依次对每个 σ_i 从 $i = 1$ 到 L 重复。有关实现的更多细节，我们建议读者参考 Song 和 Ermon 原始论文的算法 1 [40]。

3.4 结论性评述

关于分数匹配的进一步阅读，应从 Vincent 的技术报告 [43] 开始。近期文献中非常受欢迎的一篇论文是 Song 和 Ermon 的 [40]，以及他们的后续工作 [41] 和 [42]。在他们的论文中，他们提出了一个重要讨论，即在训练分数函数时，我们需要一个噪声调度，以便更好地训练分数函数。

分数匹配的应用范围广泛，不仅限于图像生成。它们可用于解决许多重要的图像恢复问题，如去模糊、去噪、超分辨率等。Kadkhodaie 和 Simoncellil 的 [19] 是较早明确将分数函数作为图像重建过程一部分的论文之一。Kawar 等人 [21] 提出了类似的概念，他们从包含前向图像形成模型和先验的后验分布中采样。对于具有更好结构前向模型的问题，已证明采用近端映射的思想可以提高性能。这一系列工作可以建立在算子分裂策略的基础上，例如通过将其扩展到即插即用扩散模型的即插即用 ADMM [8]，例如 Zhu 等人 [?] 或 Bouman 和 Buzzard 的生成即插即用模型 [5]。最近，还观察到当我们无法访问退化过程时，可以直接执行回归到均值 [11]。各种应用论文 [9, 17, 37]。

4 随机微分方程 (SDE)

在前两节中，我们通过 DDPM 和 SMLD 的视角研究了扩散模型。在本节中，我们将从微分方程的角度来研究扩散模型。正如我们在讨论朗之万方程时提到的，朗之万方程的稳态解是一个随机变量，其概率分布满足福克-普朗克方程。这种迭代算法与微分方程之间的不寻常联系使得这一主题格外有趣。本节的目的是介绍随机微分方程的基本原理，以及它们如何用于理解扩散模型。

4.1 从迭代算法到常微分方程

首先，也是最重要的问题，至少对于微分方程背景较少的读者来说，是为什么一个迭代算法可以与微分方程相关联。让我们通过两个例子来理解这一点。

Example 4.1. 简单的一阶常微分方程。想象我们有一个离散时间算法，其迭代由递归定义：

$$\mathbf{x}_i = \left(1 - \frac{\beta \Delta t}{2}\right) \mathbf{x}_{i-1}, \quad \text{for } i = 1, 2, \dots, N, \quad (4.1)$$

其中 β 为超参数， Δt 为步长参数。我们可以将这个迭代方案转化为连续时间的微分方程。

假设存在一个连续时间函数 $\mathbf{x}(t)$ 。我们通过令 $\mathbf{x}_i = \mathbf{x}(\frac{i}{N})$ ，其中 $i = 1, \dots, N$ ， $\Delta t = \frac{1}{N}$ ，且 $t \in \{0, \frac{1}{N}, \dots, \frac{N-1}{N}\}$ ，定义一个离散化方案。那么上述递归可以写成

$$\mathbf{x}(t + \Delta t) = \left(1 - \frac{\beta \Delta t}{2}\right) \mathbf{x}(t).$$

重新排列项后，我们得到

$$\frac{\mathbf{x}(t + \Delta t) - \mathbf{x}(t)}{\Delta t} = -\frac{\beta}{2} \mathbf{x}(t),$$

当 $\Delta t \rightarrow 0$ 时，我们可以将离散方程写成一个常微分方程 (ODE)

$$\frac{d\mathbf{x}(t)}{dt} = -\frac{\beta}{2} \mathbf{x}(t). \quad (4.2)$$

不仅如此，我们还可以求解 ODE 的解析解，其解由

$$\mathbf{x}(t) = e^{-\frac{\beta}{2}t}. \quad (4.3)$$

给出。通过将 Eqn (4.3) 代入 Eqn (4.2)，可以验证解的正确性。




Figure 4.1: 解析解与数值方案产生的估计值。

ODE 的强大之处在于它为我们提供了一个解析解。与依赖迭代方案（可能需要数百到数千次迭代）不同，解析解准确地告诉我们在任何时间 t 的解的行为。为了说明这一点，我们在上图中展示了由算法定义的解 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_i, \dots, \mathbf{x}_N$ 的轨迹。这里，我们选择 $\Delta t = 0.1$ 。在同一图中，我们直接绘制了任意 t 的连续时间解 $\mathbf{x}(t) = \exp\{-\beta t/2\}$ 。如图所示，解析解与迭代方案预测的轨迹完全相同。

在这个启发性例子中，我们观察到了两个有趣的事实：

- 离散时间迭代方案可以写成连续时间的常微分方程（ODE）。事实上，许多离散时间算法都有其对应的 ODE。
- 对于简单的 ODE，我们可以写出闭式解析解。更复杂的 ODE 则难以写出解析解，但我们仍可以使用 ODE 工具来分析解的行为。我们还可以推导出极限解 $t \rightarrow 0$ 。

Example 4.2. 梯度下降。回想一下，对于（表现良好的）凸函数 f ，梯度下降算法是以下递归。对于 $i = 1, 2, \dots, N$ ，执行

$$\mathbf{x}_i = \mathbf{x}_{i-1} - \beta_{i-1} \nabla f(\mathbf{x}_{i-1}), \quad (4.4)$$

其中 β_i 为步长参数。使用与前例相同的离散化方法，我们可以证明（通过令 $\beta_{i-1} = \beta(t)\Delta t$ ）：

$$\begin{aligned} \mathbf{x}_i = \mathbf{x}_{i-1} - \beta_{i-1} \nabla f(\mathbf{x}_{i-1}) &\implies \mathbf{x}(t + \Delta t) = \mathbf{x}(t) - \beta(t)\Delta t \nabla f(\mathbf{x}(t)) \\ &\implies \frac{\mathbf{x}(t + \Delta t) - \mathbf{x}(t)}{\Delta t} = -\beta(t) \nabla f(\mathbf{x}(t)) \\ &\implies \frac{d\mathbf{x}(t)}{dt} = -\beta(t) \nabla f(\mathbf{x}(t)). \end{aligned} \quad (4.5)$$

右侧所示的常微分方程有一个解轨迹 $\mathbf{x}(t)$ 。这个 $\mathbf{x}(t)$ 被称为函数 f 的梯度流。

为简化起见，我们可以设 $\beta(t) = \beta$ 对所有 t 成立。那么关于这个 ODE 有两个简单的事实。首先，我们可以证明

$$\begin{aligned} \frac{d}{dt} f(\mathbf{x}(t)) &= \nabla f(\mathbf{x}(t))^T \frac{d\mathbf{x}(t)}{dt} && \text{(链式法则)} \\ &= \nabla f(\mathbf{x}(t))^T [-\beta \nabla f(\mathbf{x}(t))] && \text{(Eqn (4.5))} \\ &= -\beta \nabla f(\mathbf{x}(t))^T \nabla f(\mathbf{x}(t)) \\ &= -\beta \|\nabla f(\mathbf{x}(t))\|^2 \leq 0 && \text{(范数平方)} \end{aligned}$$

因此，当我们从 $\mathbf{x}_{i-1}$ 移动到 $\mathbf{x}_i$ 时，目标值 $f(\mathbf{x}(t))$ 必须下降。这与我们的预期一致，因为梯度下降算法应随着迭代的进行降低代价。其次，在极限 $t \rightarrow \infty$ 时，我们知道 $\frac{d\mathbf{x}(t)}{dt} \rightarrow 0$ 。因此， $\frac{d\mathbf{x}(t)}{dt} = -\beta \nabla f(\mathbf{x}(t))$ 将意味着

$$\nabla f(\mathbf{x}(t)) \rightarrow 0, \quad \text{as } t \rightarrow \infty. \quad (4.6)$$

因此，解轨迹 $\mathbf{x}(t)$ 将接近函数 f 的最小值点。

前向与后向更新。

让我们用梯度下降的例子来说明 ODE 的另一个方面。回到 Eqn (4.4)，我们认识到递归可以等价地写成（假设 $\beta(t) = \beta$ ）：

$$\underbrace{\mathbf{x}_i - \mathbf{x}_{i-1}}_{\Delta \mathbf{x}} = \underbrace{-\beta_{i-1}}_{\beta \Delta t} \nabla f(\mathbf{x}_{i-1}) \Rightarrow d\mathbf{x} = -\beta \nabla f(\mathbf{x}) dt, \quad (4.7)$$

其中连续方程在设 $\Delta t \rightarrow 0$ 和 $\Delta \mathbf{x} \rightarrow 0$ 时成立。这个等式的有趣之处在于，它通过用 dt 表示更新 $\Delta \mathbf{x}$ ，为我们提供了更新的总结。它表示，如果我们沿着时间轴移动 dt ，那么解 $\mathbf{x}$ 将被更新 $d\mathbf{x}$ 。

Eqn (4.7) 定义了变化之间的关系。如果我们考虑一系列迭代 $i = 1, 2, \dots, N$ ，并且如果我们被告知

迭代的进展遵循 Eqn (4.7)，那么我们可以写出

$$\begin{aligned}
 (\text{forward}) \quad \mathbf{x}_i &= \mathbf{x}_{i-1} + \Delta \mathbf{x}_{i-1} \approx \mathbf{x}_{i-1} + d\mathbf{x} \\
 &= \mathbf{x}_{i-1} - \nabla f(\mathbf{x}_{i-1})\beta dt \\
 &\approx \mathbf{x}_{i-1} - \beta_{i-1} \nabla f(\mathbf{x}_{i-1}).
 \end{aligned}$$

我们称之为**前向**方程，因为我们通过 $\mathbf{x} + \Delta \mathbf{x}$ 更新 $\mathbf{x}$ ，假设 $t \leftarrow t + \Delta t$ 。

现在，考虑一系列迭代 $i = N, N-1, \dots, 2, 1$ 。如果我们被告知迭代的进展遵循 Eqn (4.7)，那么时间反转的迭代将是

$$\begin{aligned}
 (\text{reverse}) \quad \mathbf{x}_{i-1} &= \mathbf{x}_i - \Delta \mathbf{x}_i \approx \mathbf{x}_i - d\mathbf{x} \\
 &= \mathbf{x}_i + \beta \nabla f(\mathbf{x}_i) dt \\
 &\approx \mathbf{x}_i + \beta_i \nabla f(\mathbf{x}_i).
 \end{aligned}$$

注意在反转进展方向时符号的变化。我们称之为**反向**方程。

4.2 什么是 SDE ?

随机微分方程 (SDE) 可以被视为常微分方程 (ODE) 的扩展。在本小节中，我们简要介绍符号并解释它们的含义。

ODE。我们考虑以下形式的一阶 ODE：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(t, \mathbf{x}),$$

其中 $\mathbf{f}(t, \mathbf{x})$ 是 t 和 $\mathbf{x}$ 的某个函数。假设初始条件为 $\mathbf{x}(0) = \mathbf{x}_0$ ，解的形式为

$$\mathbf{x}(t) = \mathbf{x}_0 + \int_0^t \mathbf{f}(s, \mathbf{x}(s)) ds.$$

解的积分形式通常伴随着一个简写符号，称为**微分形式**，可以写成

$$d\mathbf{x} = \mathbf{f}(t, \mathbf{x}) dt. \quad (4.8)$$

SDE。在 SDE 中，除了确定性函数 $\mathbf{f}(t, \mathbf{x})$ 外，我们还考虑随机扰动。例如，随机扰动可以采取以下形式：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(t, \mathbf{x}) + \mathbf{g}(t, \mathbf{x})\boldsymbol{\xi}(t), \quad \text{where} \quad \boldsymbol{\xi}(t) \sim \mathcal{N}(0, \mathbf{I}),$$

其中 $\boldsymbol{\xi}(t)$ 是噪声函数，例如白噪声。我们可以定义 $d\mathbf{w} = \boldsymbol{\xi}(t)dt$ ，其中 $d\mathbf{w}$ 通常被称为布朗运动的微分形式。然后，这个 SDE 的微分形式可以写成

$$d\mathbf{x} = \mathbf{f}(t, \mathbf{x})dt + \mathbf{g}(t, \mathbf{x})d\mathbf{w}. \quad (4.9)$$

由于 $\boldsymbol{\xi}(t)$ 是随机的，这个微分方程的解也是随机的。为了明确解的随机性，我们应该通过积分方程来解释微分形式

$$\mathbf{x}(t, \omega) = \mathbf{x}_0 + \int_0^t \mathbf{f}(s, \mathbf{x}(s, \omega)) ds + \int_0^t \mathbf{g}(s, \mathbf{x}(s, \omega)) d\mathbf{w}(s, \omega),$$

其中 ω 表示 $\mathbf{x}$ 状态的索引。因此，当我们选择随机过程 $\mathbf{w}(s, \omega)$ 的某个特定状态时，我们解对应于这个特定 ω 的微分方程。

Example 4.3. 考虑随机微分方程

$$d\mathbf{x} = a d\mathbf{w},$$

对于某些常数 a 。根据我们上面的讨论，解轨迹将采取以下形式

$$\mathbf{x}(t) = \mathbf{x}_0 + \int_0^t a d\mathbf{w}(s) = \mathbf{x}_0 + a \int_0^t \boldsymbol{\xi}(s) ds,$$

其中最后一个等式使用了 $d\mathbf{w} = \boldsymbol{\xi}(t)dt$ 的事实。我们可以通过离散时间迭代数值实现 $d\mathbf{x} = a d\mathbf{w}$ 来可视觉化解轨迹：

$$\mathbf{x}_i - \mathbf{x}_{i-1} = a \underbrace{(\mathbf{w}_i - \mathbf{w}_{i-1})}_{\stackrel{\text{def}}{=} \mathbf{z}_{i-1} \sim \mathcal{N}(0, \mathbf{I})} \Rightarrow \mathbf{x}_i = \mathbf{x}_{i-1} + a \mathbf{z}_{i-1}.$$

例如，如果 $a = 0.05$ ， $\mathbf{x}(t)$ 的一个可能轨迹将如下所示。初始点 $\mathbf{x}_0 = 0$ 用红色标记，表示过程在时间上向前移动。




Figure 4.2: 过程 $d\mathbf{x} = a d\mathbf{w}$ 的轨迹。

Example 4.4. 考虑随机微分方程

$$d\mathbf{x} = -\frac{\alpha}{2}\mathbf{x}dt + \beta d\mathbf{w}.$$

这个问题的解由 [Risken Eqn 3.7] 给出

$$\mathbf{x}(t) = \mathbf{x}_0 e^{-\frac{\alpha}{2}t} + \beta \int_0^t e^{-\frac{\alpha}{2}(t-s)} \boldsymbol{\xi}(s) ds.$$

为了可视化轨迹，我们考虑 $\alpha = 1$ 和 $\beta = 0.1$ 。离散化将给出

$$\mathbf{x}_i - \mathbf{x}_{i-1} = -\frac{\alpha}{2}\mathbf{x}_{i-1} + \beta(\mathbf{w}_i - \mathbf{w}_{i-1}) \Rightarrow \mathbf{x}_i = \left(1 - \frac{\alpha}{2}\right)\mathbf{x}_{i-1} + \beta\mathbf{z}_{i-1}.$$




Figure 4.3: 过程 $d\mathbf{x} = -\frac{\alpha}{2}\mathbf{x}dt + \beta d\mathbf{w}$ 的轨迹。

4.3 DDPM 与 SMLD 的随机微分方程

在不深入探讨 SDE 物理意义的前提下（我们稍后会进行），我们希望将 SDE 与之前章节学习的去噪扩散概率模型（DDPM）及分数匹配朗之万动力学（SMLD）联系起来。

正向与反向扩散。扩散模型涉及一对方程：正向扩散过程与反向扩散过程。以导数形式表达，正向扩散过程可写作

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(\mathbf{x}, t) + g(t)\boldsymbol{\xi}(t), \quad \text{where } \boldsymbol{\xi}(t) \sim \mathcal{N}(0, \mathbf{I}).$$

我们强调，这是基于布朗运动的一种特定扩散过程。随机扰动 $\boldsymbol{\xi}$ 被假设为一个随机过程，其中 $\boldsymbol{\xi}(t)$ 在所有 t 时刻均为独立同分布的高斯随机变量。因此，自相关函数为狄拉克函数 $\mathbb{E}[\boldsymbol{\xi}(t)\boldsymbol{\xi}(t')] = \delta(t - t')$ 。对于此扩散过程，我们可以用微分形式表示：

Definition 4.1. 正向扩散。

$$d\mathbf{x} = \underbrace{\mathbf{f}(\mathbf{x}, t) dt}_{\text{drift}} + \underbrace{g(t) d\mathbf{w}}_{\text{diffusion}}. \quad (4.10)$$

此处，微分为 $d\mathbf{w} = \boldsymbol{\xi}(t)dt$ 。这表明我们可以将 $\boldsymbol{\xi}(t)$ 视为某种变化率（相对于 t ），其积分 $\boldsymbol{\xi}(t)dt$ 将给出 $d\mathbf{w}$ 。

$\mathbf{f}(\mathbf{x}, t)$ 与 $g(t)$ 两项具有物理意义。漂移系数是一个向量值函数 $\mathbf{f}(\mathbf{x}, t)$ ，定义了封闭系统中分子在无随机效应下的运动方式。对于梯度下降算法，漂移由目标函数的负梯度定义，即我们希望解轨迹跟随目标函数的梯度。扩散系数 $g(t)$ 是一个标量函数，描述了分子如何随机从一个位置移动到另一个位置， $g(t)$ 决定了随机运动的强度。

扩散方程的反向是时间上的逆向运动。根据 Anderson [2]，反向时间 SDE 给出如下：

Definition 4.2. 反向扩散。

$$d\mathbf{x} = \underbrace{[\mathbf{f}(\mathbf{x}, t) - g(t)^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{x})] dt}_{\text{drift}} + \underbrace{g(t) d\bar{\mathbf{w}}}_{\text{reverse-time diffusion}}, \quad (4.11)$$

其中 $p_t(\mathbf{x})$ 是 $\mathbf{x}$ 在时间 t 的概率分布， $\bar{\mathbf{w}}$ 是时间倒流时的维纳过程。

简而言之，反向时间扩散不过是一个按时间逆序进行的随机过程。因此，正向扩散定义 $\mathbf{z}_i = \mathbf{w}_{i+1} - \mathbf{w}_i$ ，而反向扩散则定义 $\mathbf{z}_i = \mathbf{w}_{i-1} - \mathbf{w}_i$ 。以下为一例：

Example 4.5. 考虑反向扩散方程

$$d\mathbf{x} = a d\bar{\mathbf{w}}. \quad (4.12)$$

我们可以写出离散时间递归如下。对于 $i = N, N-1, \dots, 1$ ，执行

$$\mathbf{x}_{i-1} = \mathbf{x}_i + \underbrace{a(\mathbf{w}_{i-1} - \mathbf{w}_i)}_{=\mathbf{z}_i} = \mathbf{x}_i + a\mathbf{z}_i, \quad \mathbf{z}_i \sim \mathcal{N}(0, \mathbf{I}).$$

下图展示了此反向时间过程的轨迹。注意，红色标记的初始点位于 $\mathbf{x}_N$ 。过程被追踪回 $\mathbf{x}_0$ 。




Figure 4.4: 反向扩散 $d\mathbf{x} = a d\bar{\mathbf{w}}$ 的轨迹。

DDPM 的随机微分方程。为了建立 DDPM 与 SDE 之间的联系，我们考虑离散时间 DDPM 正向迭代。对于 $i = 1, 2, \dots, N$ ：

$$\mathbf{x}_i = \sqrt{1 - \beta_i} \mathbf{x}_{i-1} + \sqrt{\beta_i} \mathbf{z}_{i-1}, \quad \mathbf{z}_{i-1} \sim \mathcal{N}(0, \mathbf{I}). \quad (4.13)$$

我们可以证明，此方程可由以下正向 SDE 方程导出。

Theorem 4.1. DDPM 的正向采样方程可通过 SDE 表示为

$$d\mathbf{x} = \underbrace{-\frac{\beta(t)}{2} \mathbf{x} dt}_{=\mathbf{f}(\mathbf{x},t)} + \underbrace{\sqrt{\beta(t)} d\mathbf{w}}_{=\mathbf{g}(t)}. \quad (4.14)$$

证明. 我们定义步长 $\Delta t = \frac{1}{N}$ ，并考虑一个辅助噪声水平 $\{\bar{\beta}_i\}_{i=1}^N$ ，其中 $\beta_i = \bar{\beta}_i$ 。然后

$$\beta_i = \underbrace{\beta\left(\frac{i}{N}\right)}_{\bar{\beta}_i} \cdot \frac{1}{N} = \beta(t + \Delta t) \Delta t,$$

其中我们假设在 $N \rightarrow \infty$ 时, $\bar{\beta}_i \rightarrow \beta(t)$ ，这是一个在 $0 \leq t \leq 1$ 上的连续时间函数。类似地，我们定义

$$\mathbf{x}_i = \mathbf{x}\left(\frac{i}{N}\right) = \mathbf{x}(t + \Delta t), \quad \mathbf{z}_i = \mathbf{z}\left(\frac{i}{N}\right) = \mathbf{z}(t + \Delta t).$$

因此，我们有

$$\begin{aligned} \mathbf{x}_i &= \sqrt{1 - \beta_i} \mathbf{x}_{i-1} + \sqrt{\beta_i} \mathbf{z}_{i-1} \\ \Rightarrow \mathbf{x}_i &= \sqrt{1 - \frac{\bar{\beta}_i}{N}} \mathbf{x}_{i-1} + \sqrt{\frac{\bar{\beta}_i}{N}} \mathbf{z}_{i-1} \\ \Rightarrow \mathbf{x}(t + \Delta t) &= \sqrt{1 - \beta(t + \Delta t) \cdot \Delta t} \mathbf{x}(t) + \sqrt{\beta(t + \Delta t) \cdot \Delta t} \mathbf{z}(t) \\ \Rightarrow \mathbf{x}(t + \Delta t) &\approx \left(1 - \frac{1}{2} \beta(t + \Delta t) \cdot \Delta t\right) \mathbf{x}(t) + \sqrt{\beta(t + \Delta t) \cdot \Delta t} \mathbf{z}(t) \\ \Rightarrow \mathbf{x}(t + \Delta t) &\approx \mathbf{x}(t) - \frac{1}{2} \beta(t) \Delta t \mathbf{x}(t) + \sqrt{\beta(t) \cdot \Delta t} \mathbf{z}(t). \end{aligned}$$

因此，当 $\Delta t \rightarrow 0$ 时，我们有

$$d\mathbf{x} = -\frac{1}{2} \beta(t) \mathbf{x} dt + \sqrt{\beta(t)} d\mathbf{w}. \quad (4.15)$$

因此，我们证明了 DDPM 前向更新迭代可以等价地写为一个 SDE。

能够将 DDPM 前向更新迭代写为 SDE 意味着 DDPM 估计可以通过求解 SDE 来确定。换句话说，对于适当定义的 SDE 求解器，我们可以将 SDE 输入求解器。适当选择的求解器返回的解将是 DDPM 估计。当然，我们并不需要使用 SDE 求解器，因为 DDPM 迭代本身就是在求解 SDE。它可能不是最好的 SDE 求解器，因为 DDPM 迭代只是一阶方法。然而，如果我们不感兴趣使用 SDE 求解器，我们仍然可以使用 DDPM 迭代来获得解。以下是一个例子。

Example 4.6. 考虑所有 $i = 0, \dots, N-1$ 的 DDPM 前向方程，其中 $\beta_i = 0.05$ 。我们通过从高斯混合分布中抽取样本来初始化样本 $\mathbf{x}_0$ ，使得

$$\mathbf{x}_0 \sim \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_0 | \boldsymbol{\mu}_k, \sigma_k^2 \mathbf{I}),$$

其中 $\pi_1 = \pi_2 = 0.5$ ， $\sigma_1 = \sigma_2 = 1$ ， $\boldsymbol{\mu}_1 = 3$ 和 $\boldsymbol{\mu}_2 = -3$ 。然后，使用方程

$$\mathbf{x}_i = \sqrt{1 - \beta_i} \mathbf{x}_{i-1} + \sqrt{\beta_i} \mathbf{z}_{i-1}, \quad \mathbf{z}_{i-1} \sim \mathcal{N}(0, \mathbf{I}),$$

我们可以绘制轨迹和分布如下。




Figure 4.5: $\mathbf{x}_t$ 轨迹的实现，从高斯混合开始，最终变为单一高斯。

反向扩散方程通过将适当的量代入 Eqn (4.11) 得到: $\mathbf{f}(\mathbf{x}, t) = -\frac{\beta(t)}{2}$ 和 $g(t) = \sqrt{\beta(t)}$ 。这将给出

$$\begin{aligned} d\mathbf{x} &= [\mathbf{f}(\mathbf{x}, t) - g(t)^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{x})] dt + g(t) d\bar{\mathbf{w}} \\ &= \left[-\frac{\beta(t)}{2} \mathbf{x} - \beta(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right] dt + \sqrt{\beta(t)} d\bar{\mathbf{w}}, \end{aligned}$$

这将给出以下方程:

Theorem 4.2. DDPM 的反向采样方程可以通过以下方式写为 SDE:

$$d\mathbf{x} = -\beta(t) \left[\frac{\mathbf{x}}{2} + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right] dt + \sqrt{\beta(t)} d\bar{\mathbf{w}}. \quad (4.16)$$

证明. 迭代更新方案可以通过考虑 $d\mathbf{x} = \mathbf{x}(t) - \mathbf{x}(t - \Delta t)$ 和 $d\bar{\mathbf{w}} = \mathbf{w}(t - \Delta t) - \mathbf{w}(t) = -\mathbf{z}(t)$ 来写出。然后, 令 $dt = \Delta t$, 我们可以证明

$$\begin{aligned} \mathbf{x}(t) - \mathbf{x}(t - \Delta t) &= -\beta(t) \Delta t \left[\frac{\mathbf{x}(t)}{2} + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) \right] - \sqrt{\beta(t) \Delta t} \mathbf{z}(t) \\ \Rightarrow \quad \mathbf{x}(t - \Delta t) &= \mathbf{x}(t) + \beta(t) \Delta t \left[\frac{\mathbf{x}(t)}{2} + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) \right] + \sqrt{\beta(t) \Delta t} \mathbf{z}(t). \end{aligned}$$

通过将项分组, 并假设 $\beta(t) \Delta t \ll 1$, 我们认识到

$$\begin{aligned} \mathbf{x}(t - \Delta t) &= \mathbf{x}(t) \left[1 + \frac{\beta(t) \Delta t}{2} \right] + \beta(t) \Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) + \sqrt{\beta(t) \Delta t} \mathbf{z}(t) \\ &\approx \mathbf{x}(t) \left[1 + \frac{\beta(t) \Delta t}{2} \right] + \beta(t) \Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) + \frac{(\beta(t) \Delta t)^2}{2} \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) + \sqrt{\beta(t) \Delta t} \mathbf{z}(t) \\ &= \left[1 + \frac{\beta(t) \Delta t}{2} \right] \left(\mathbf{x}(t) + \beta(t) \Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) \right) + \sqrt{\beta(t) \Delta t} \mathbf{z}(t). \end{aligned}$$

然后, 按照离散化方案, 令 $t \in \{0, \dots, \frac{N-1}{N}\}$, $\Delta t = 1/N$, $\mathbf{x}(t - \Delta t) = \mathbf{x}_{i-1}$, $\mathbf{x}(t) = \mathbf{x}_i$, 且 $\beta(t) \Delta t = \beta_i$, 我们可以证明

$$\begin{aligned} \mathbf{x}_{i-1} &= \left(1 + \frac{\beta_i}{2} \right) \left[\mathbf{x}_i + \frac{\beta_i}{2} \nabla_{\mathbf{x}} \log p_i(\mathbf{x}_i) \right] + \sqrt{\beta_i} \mathbf{z}_i \\ &\approx \frac{1}{\sqrt{1-\beta_i}} \left[\mathbf{x}_i + \frac{\beta_i}{2} \nabla_{\mathbf{x}} \log p_i(\mathbf{x}_i) \right] + \sqrt{\beta_i} \mathbf{z}_i, \end{aligned} \quad (4.17)$$

其中 $p_i(\mathbf{x})$ 是时间 i 时 $\mathbf{x}$ 的概率密度函数。对于实际实现, 我们可以用估计的得分函数 $\mathbf{s}_{\theta}(\mathbf{x}_i)$ 替换 $\nabla_{\mathbf{x}} \log p_i(\mathbf{x}_i)$ 。

因此, 我们恢复了与 Song 和 Ermon 在 [42] 中定义的 DDPM 迭代一致的迭代。这是一个有趣的结果, 因为它允许我们使用得分函数连接 DDPM 的迭代。Song 和 Ermon [42] 将 SDE 称为 **方差保持 (VP)** SDE。

Example 4.7. 从前面的例子出发，我们使用以下公式执行反向扩散方程

$$\mathbf{x}_{i-1} = \frac{1}{\sqrt{1-\beta_i}} \left[\mathbf{x}_i + \frac{\beta_i}{2} \nabla_{\mathbf{x}} \log p_i(\mathbf{x}_i) \right] + \sqrt{\beta_i} \mathbf{z}_i,$$

其中 $\mathbf{z}_i \sim \mathcal{N}(0, \mathbf{I})$ 。迭代的轨迹如下所示。




Figure 4.6: $\mathbf{x}_t$ 轨迹的实现，从单个高斯分布开始，到高斯混合结束。

SMLD 的随机微分方程. 得分匹配 Langevin 动力学模型也可以用 SDE 来描述。首先，我们注意到在 SMLD 设置中，并没有真正的“前向扩散步骤”。然而，我们可以大致认为，如果我们将 SMLD 训练中的噪声尺度分为 N 个级别，那么递归应该遵循马尔可夫链

$$\mathbf{x}_i = \mathbf{x}_{i-1} + \sqrt{\sigma_i^2 - \sigma_{i-1}^2} \mathbf{z}_{i-1}, \quad i = 1, 2, \dots, N. \quad (4.18)$$

这并不难看出。如果我们假设 $\mathbf{x}_{i-1}$ 的方差为 σ_{i-1}^2 ，那么我们可以证明

$$\begin{aligned} \text{Var}[\mathbf{x}_i] &= \text{Var}[\mathbf{x}_{i-1}] + (\sigma_i^2 - \sigma_{i-1}^2) \\ &= \sigma_{i-1}^2 + (\sigma_i^2 - \sigma_{i-1}^2) = \sigma_i^2. \end{aligned}$$

因此，给定一系列噪声水平，Eqn (4.18) 确实会生成估计 $\mathbf{x}_i$ ，使得噪声统计量满足所需的属性。

如果我们同意 Eqn (4.18)，那么很容易推导出与 Eqn (4.18) 相关的 SDE。我们将结果总结如下。

Theorem 4.3. SMLD 的前向采样方程可以通过以下 SDE 写出

$$d\mathbf{x} = \sqrt{\frac{d[\sigma(t)^2]}{dt}} d\mathbf{w}. \quad (4.19)$$

证明. 假设在极限 $\{\sigma_i\}_{i=1}^N$ 变为连续时间 $\sigma(t)$ 对于 $0 \leq t \leq 1$ ，且 $\{\mathbf{x}_i\}_{i=1}^N$ 变为 $\mathbf{x}(t)$ ，其中 $\mathbf{x}_i = \mathbf{x}(\frac{i}{N})$ 。如果我们令 $t \in \{0, \frac{1}{N}, \dots, \frac{N-1}{N}\}$ 。那么我们有

$$\begin{aligned} \mathbf{x}(t + \Delta t) &= \mathbf{x}(t) + \sqrt{\sigma(t + \Delta t)^2 - \sigma(t)^2} \mathbf{z}(t) \\ &\approx \mathbf{x}(t) + \sqrt{\frac{d[\sigma(t)^2]}{dt} \Delta t} \mathbf{z}(t). \end{aligned}$$

当 $\Delta t \rightarrow 0$ 时，方程收敛到

$$d\mathbf{x} = \sqrt{\frac{d[\sigma(t)^2]}{dt}} d\mathbf{w}.$$

将此映射到 Eqn (4.11)，我们推导出反向时间扩散方程。

Theorem 4.4. SMLD 的反向采样方程可以通过以下 SDE 表示：

$$d\mathbf{x} = - \left(\frac{d[\sigma(t)^2]}{dt} \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right) dt + \sqrt{\frac{d[\sigma(t)^2]}{dt}} d\bar{\mathbf{w}}. \quad (4.20)$$

证明。我们认识到

$$\mathbf{f}(\mathbf{x}, t) = 0, \quad \text{and} \quad g(t) = \sqrt{\frac{d[\sigma(t)^2]}{dt}}.$$

因此，如果我们写出反向方程 Eqn (4.11)，我们应该有

$$\begin{aligned} d\mathbf{x} &= [\mathbf{f}(\mathbf{x}, t) - g(t)^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{x})] dt + g(t) d\bar{\mathbf{w}} \\ &= - \left(\frac{d[\sigma(t)^2]}{dt} \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) \right) dt + \sqrt{\frac{d[\sigma(t)^2]}{dt}} d\bar{\mathbf{w}}. \end{aligned}$$

对于离散时间迭代，我们首先定义 $\alpha(t) = \frac{d[\sigma(t)^2]}{dt}$ 。然后，使用与 DDPM 情况相同的离散化设置，我们可以证明

$$\begin{aligned} \mathbf{x}(t + \Delta t) - \mathbf{x}(t) &= - \left(\alpha(t) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right) \Delta t - \sqrt{\alpha(t) \Delta t} \mathbf{z}(t) \\ \Rightarrow \quad \mathbf{x}(t) &= \mathbf{x}(t + \Delta t) + \alpha(t) \Delta t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) + \sqrt{\alpha(t) \Delta t} \mathbf{z}(t) \\ \Rightarrow \quad \mathbf{x}_{i-1} &= \mathbf{x}_i + \alpha_i \nabla_{\mathbf{x}} \log p_i(\mathbf{x}_i) + \sqrt{\alpha_i} \mathbf{z}_i \\ \Rightarrow \quad \mathbf{x}_{i-1} &= \mathbf{x}_i + (\sigma_i^2 - \sigma_{i-1}^2) \nabla_{\mathbf{x}} \log p_i(\mathbf{x}_i) + \sqrt{(\sigma_i^2 - \sigma_{i-1}^2)} \mathbf{z}_i, \end{aligned} \quad (4.21)$$

这与 SMLD 反向更新方程相同。Song 和 Ermon [42] 称此 SDE 为**方差爆炸** (VE) SDE。

VP 和 VE 推理的等价性。正如我们刚刚看到的，DDPM 和 SMLD 对应于随机微分方程的两个变体：方差爆炸 (VE) 和方差保持 (VP)。Kawar 等人 [21] 观察到，由 VP 和 VE 确定的推理过程是等价的。因此，如果我们想将扩散模型用作图像恢复等其他任务的一部分，使用 VE 还是 VP 并不重要。但请注意，超参数的具体选择仍会影响训练，从而影响模型本身。

4.4 常微分方程与随机微分方程的数值解法

常微分方程 (ODE) 和随机微分方程 (SDE) 通常难以解析求解。在许多情况下，这些微分方程需要通过数值方法求解。在本小节中，我们简要概述这些方法的总体思路。

为了使讨论更加简单，我们将重点放在一个简单的常微分方程上：

$$\frac{d\mathbf{x}(t)}{dt} = \mathbf{f}(t, \mathbf{x}(t)). \quad (4.22)$$

从几何上看，这个常微分方程意味着 $\mathbf{x}(t)$ 的导数等于函数 $\mathbf{f}(t, \mathbf{x})$ 在 $\mathbf{x}(t)$ 处的值。为了实现这一点，我们需要 $\mathbf{x}(t)$ 的斜率与函数值相匹配。在一维情况下，上述几何解释可以转化为以下方程：

$$\frac{x(t) - x(t_0)}{t - t_0} = f(t_0, x_0),$$

其中 t_0 是一个接近 t 的时间点。通过重新排列项，我们可以看到这个方程等价于

$$x(t) = x(t_0) + f(t_0, x_0)(t - t_0).$$

因此，我们得到了与梯度下降非常相似的结果。这就是欧拉方法。

欧拉方法。欧拉方法是一种用于求解常微分方程的一阶数值方法。给定 $\frac{dx(t)}{dt} = f(t, x)$ 和 $x(t_0) = x_0$ ，欧拉方法通过迭代方案求解问题，对于 $i = 0, 1, \dots, N-1$ ，有

$$x_{i+1} = x_i + \alpha \cdot f(t_i, x_i), \quad i = 0, 1, \dots, N-1,$$

其中 α 是步长。让我们考虑一个简单的例子。

Example 4.8. [3, Example 2.2] 考虑以下常微分方程

$$\frac{dx(t)}{dt} = \frac{x(t) + t^2 - 2}{t + 1}.$$

如果我们应用步长为 α 的欧拉方法，则迭代将采取以下形式

$$x_{i+1} = x_i + \alpha \cdot f(t_i, x_i) = x_i + \alpha \cdot \frac{(x_i + t_i^2 - 2)}{t_i + 1}.$$

龙格-库塔 (RK) 方法。另一种常用的常微分方程求解方法是龙格-库塔 (RK) 方法。经典的 RK-4 算法通过以下迭代求解常微分方程：

$$x_{i+1} = x_i + \frac{\alpha}{6} \cdot (k_1 + 2k_2 + 2k_3 + k_4), \quad i = 1, 2, \dots, N,$$

其中 k_1 、 k_2 、 k_3 和 k_4 定义为

$$\begin{aligned} k_1 &= f(x_i, t_i), \\ k_2 &= f\left(t_i + \frac{\alpha}{2}, x_i + \alpha \frac{k_1}{2}\right), \\ k_3 &= f\left(t_i + \frac{\alpha}{2}, x_i + \alpha \frac{k_2}{2}\right), \\ k_4 &= f(t_i + \alpha, x_i + \alpha k_3). \end{aligned}$$

更多细节可以参考数值方法教科书，如 [3]。

预测-校正算法 [42]。由于不同的数值求解器在近似误差方面表现不同，直接将常微分方程（或随机微分方程）交给现成的数值求解器会导致不同程度的误差 [20]。然而，如果我们特别尝试求解反向扩散方程，可以使用除数值 ODE/SDE 求解器之外的技术来进行适当的校正，如 Figure 4.7 所示。




Figure 3.5: 得分函数示例

让我们以 DDPM 为例。在 DDPM 中，反向扩散方程由下式给出：

$$\mathbf{x}_{i-1} = \frac{1}{\sqrt{1-\beta_i}} \left[\mathbf{x}_i + \frac{\beta_i}{2} \nabla_{\mathbf{x}} \log p_i(\mathbf{x}_i) \right] + \sqrt{\beta_i} \mathbf{z}_i.$$

我们可以将其视为反向扩散的欧拉方法。然而，如果我们已经训练了得分函数 $\mathbf{s}_{\theta}(\mathbf{x}_i, i)$ ，我们可以运行得分匹配方程，即

$$\mathbf{x}_{i-1} = \mathbf{x}_i + \epsilon_i \mathbf{s}_{\theta}(\mathbf{x}_i, i) + \sqrt{2\epsilon_i} \mathbf{z}_i,$$

进行 M 次校正。下面的算法总结了这一思想。（注意，我们已经用估计值替换了得分函数。）

对于 SMLD 算法，两个方程分别为：

$$\begin{aligned} \mathbf{x}_{i-1} &= \mathbf{x}_i + (\sigma_i^2 - \sigma_{i-1}^2) \mathbf{s}_{\theta}(\mathbf{x}_i, \sigma_i) + \sqrt{\sigma_i^2 - \sigma_{i-1}^2} \mathbf{z} && \text{预测,} \\ \mathbf{x}_{i-1} &= \mathbf{x}_i + \epsilon_i \nabla_{\mathbf{x}} \mathbf{s}_{\theta}(\mathbf{x}_i, \sigma_i) + \sqrt{\epsilon_i} \mathbf{z} && \text{校正.} \end{aligned}$$

我们可以像 DDPM 的预测-校正算法那样，通过重复几次校正迭代将它们配对起来。




Figure 4.7: 预测与校正算法。

4.5 结论性评述

迭代算法与随机微分方程之间的联系不仅是一项具有自身科学价值的发现，正如一些论文所评论的那样，这一发现还具有实际应用价值。通过将多种扩散模型统一到相同的 SDE 框架下，人们可以比较这些算法。在某些情况下，通过借鉴 SDE 文献以及概率抽样文献中的思想，可以改进数值方案。例如，[42] 中的预测-校正方案就是一个结合了马尔可夫链蒙特卡洛的混合 SDE 求解器。根据 [1] 等论文，将扩散迭代映射到 SDE 提供了更多的设计灵活性。在扩散算法之外，一般的随机梯度下降算法也有对应的 SDE，如 Fokker-Planck 方程。人们已经展示了如何通过分析一个定义良好的极限分布来理论分析估计的极限分布，这减轻了通过分析随机算法来理解其行为的难度。

开发加速 SDE 求解器的兴趣日益增长。Lu 等人 [26] 展示了我们在扩散模型中遇到的典型 SDE 可以分解为半线性项和非线性项。由于半线性项有闭式解，只需使用专门的数值求解器来处理非线性项。进一步研究表明，DDIM 可以被视为一种加速的 SDE 求解器。其他加速 SDE 求解器的方法包括知识蒸馏 [36, 28]。

5 Langevin 方程与 Fokker-Planck 方程

近年来，许多关于扩散模型的论文要么专注于提高图像生成质量（通过将其推广到更具语义意义的图像），要么将其应用于新领域的问题（例如医学数据）。为了帮助初学者读者更好地理解这些应用的基础，我们希望回溯时间，讨论与扩散模型相关的随机微分方程的物理学。通过研究这些 SDE 的基本原理，我们希望能够更深入地理解这些方程的来源。

更具体地说，我们感兴趣的是研究与扩散相关的两组主要方程：Langevin 方程和 Fokker-Planck 方程。本节有几个目标。首先，我们想讨论 Langevin 方程的起源，并解释为什么它与扩散模型相关。我们想解释马尔可夫过程的一般性质及其相关的微分方程。最后，我们想展示 Fokker-Planck 方程的推导过程，并讨论为什么它在扩散模型中扮演重要角色。

5.1 布朗运动

历史视角。1827 年，植物学家罗伯特·布朗观察到一种现象，即小花粉粒置于水中时会产生不规则运动 [6]。这种花粉粒的运动后来被命名为布朗运动。布朗运动的解释由阿尔伯特·爱因斯坦于 1905 年提出 [14]，同时期玛丽安·斯莫卢霍夫斯基也独立进行了研究 [44]。爱因斯坦的主要论点是，花粉粒的运动是由水分子的撞击引起的。然而，由于系统中有数万亿个分子，且我们无法得知单个分子的初始状态，因此几乎不可能使用经典分析来研究微观状态。爱因斯坦证明了均方位移可以与扩散系数相关联，因此他通过考虑分子的统计行为引入了一种概率方法⁴。爱因斯坦的理论预测随后由让-巴蒂斯特·佩兰通过实验证实，佩兰后来于 1926 年获得了诺贝尔物理学奖。在爱因斯坦论文发表几年后，1908 年，法国物理学家保罗·朗之万构建了一个随机的马尔可夫力来描述粒子的碰撞和相互作用。这随后促使荷兰物理学家阿德里安·福克于 1914 年和德国物理学家马克斯·普朗克于 1917 年发展出了一个偏微分方程，即现在所知的福克-普朗克方程。1940 年，汉斯·克拉默斯和 1949 年何塞·恩里克·莫亚尔引入了克拉默斯-莫亚尔展开，展示了一种泰勒展开技术来描述概率分布的时间演化。

布朗运动的推导。那么，什么是布朗运动，它与扩散模型有何关联？假设有一个粒子悬浮在流体中。斯托克斯定律指出，施加在粒子上的摩擦力由下式给出：

$$F(t) = -\alpha v(t), \quad (5.1)$$

其中 F 为摩擦力， v 为速度， $\alpha = 6\pi\mu R$ 。这里， R 为粒子的半径， μ 为流体的粘度。根据牛顿第二定律，我们进一步知道 $F(t) = m\dot{v}(t)$ ，其中 m 为粒子的质量。将这两个方程相等：

$$\begin{cases} F(t) &= -\alpha v(t) \\ F(t) &= m \frac{dv(t)}{dt}, \end{cases}$$

我们将得到以下微分方程：

$$m \frac{dv(t)}{dt} + \alpha v(t) = 0.$$

通过定义 $\gamma \stackrel{\text{def}}{=} \frac{\alpha}{m}$ ，我们可以将上述方程简化为：

$$\frac{dv(t)}{dt} + \gamma v(t) = 0. \quad (5.2)$$

当粒子质量远大于流体分子时，上述确定性方程是准确的。原因是，根据动量守恒，大质量粒子在与流体分子碰撞时获得的速度很小。然而，由于花粉粒非常轻，水分子的撞击会使它们以微小但不可忽略的方式加速。这将产生随机波动。水分子作用在粒子上的总力因此被修正为：

$$F(t) = -\alpha v(t) + F_f(t),$$

其中 $F_f(t)$ 为随机项。这将给出一个修正后的微分方程：

$$m \frac{dv(t)}{dt} = -\alpha v(t) + F_f(t).$$

⁴这里需要指出的是，安德雷·柯尔莫哥洛夫的概率论著作直到 1933 年才出版 [25]。因此，在 1905 年，概率论的概念尚处于萌芽阶段。

通过定义 $\Gamma(t) = F_f(t)/m$ ，我们得到一个新的微分方程：

$$\frac{dv(t)}{dt} + \gamma v(t) = \Gamma(t), \quad (5.3)$$

可以用简写符号表示为：

$$\dot{v} + \gamma v = \Gamma(t). \quad (5.4)$$

在 Eqn (5.4) 中，随机过程 $\Gamma(t)$ 代表一种随机力，称为**朗之万力**。它满足两个性质：

- (i) $\mathbb{E}[\Gamma(t)] = 0$ 对所有 t 成立，因此其均值函数为零常数；
- (ii) $\mathbb{E}[\Gamma(t)\Gamma(t')] = q\delta(t - t')$ 对所有 t 和 t' 成立，即自相关函数是一个幅度为 q 的 delta 函数。

备注。性质 (i) 和 (ii) 是广义平稳过程的特例。广义平稳过程是指具有常数均值函数（常数不一定为零）的随机过程，且自相关函数 $R(t, t') \stackrel{\text{def}}{=} \mathbb{E}[\Gamma(t)\Gamma(t')]$ 是差值 $t - t'$ 的函数。此函数不一定是 delta 函数。例如， $R(t, t') = e^{-|t-t'|}$ 可以是广义平稳过程的有效自相关函数。

满足性质 (i) 和 (ii) 的随机过程在统计力学文献中有时被称为 delta 相关过程。有多种方法可以构造 delta 相关过程。例如，我们可以假设 $\Gamma(t) \sim \mathcal{N}(0, 1)$ 对于每个 t ，或者任何其他以相同方式定义的独立同分布。高斯分布更常用，因为许多物理现象可以用高斯分布来描述，例如热噪声。满足性质 (i) 和 (ii) 的高斯随机过程称为高斯白噪声。

对于任何广义平稳过程，**维纳-辛钦定理**指出，功率谱密度可以通过自相关函数的傅里叶变换来定义。更具体地说，如果 $R(\tau) = \mathbb{E}[\Gamma(t + \tau)\Gamma(t)]$ 是自相关函数（如果 $\Gamma(t)$ 是广义平稳过程，我们可以将 $R(t, t')$ 写成 $R(\tau)$ ），维纳-辛钦定理指出，功率谱密度为

$$S(\omega) = \int_{-\infty}^{\infty} R(\tau) e^{-j\omega\tau} d\tau. \quad (5.5)$$

因此，如果 $R(\tau)$ 是 delta 函数， $S(\omega)$ 将对所有 ω 具有常数数值。

备注。“高斯白噪声”这一名称来源于功率谱密度 $S(\omega)$ 对于每个频率 ω 都是均匀的（因此它包含了可见光谱中的所有颜色）。白噪声定义为 $\Gamma(t) \sim \mathcal{N}(0, \sigma^2)$ 对所有 t 成立。很容易证明这样的 $\Gamma(t)$ 将满足上述两个标准。

首先， $\mathbb{E}[\Gamma(t)]$ 由构造为 $\mathbb{E}[\Gamma(t)] = 0$ （因为 $\Gamma(t) \sim \mathcal{N}(0, \sigma^2)$ ）。其次，如果 $\Gamma(t) \sim \mathcal{N}(0, \sigma^2)$ ，则 $R(\tau) = \mathbb{E}[\Gamma(t + \tau)\Gamma(t)]$ 必须是 delta 函数。维纳-辛钦定理随后指出，功率谱密度是平坦的，因为它是 delta 函数的傅里叶变换。下图显示了白噪声的随机实现及其自相关函数。




Figure 5.1: (a) 高斯白噪声的自相关函数 $R(\tau)$ 。 (b) 随机过程 $\Gamma(t)$ 的随机实现。

从物理学到生成式人工智能。由于 $\Gamma(t)$ 中表现出的随机性，由 Eqn (5.4) 给出的微分方程是一个随机微分方程 (SDE)。因此，这个 SDE 的解是一个随机过程，其中值 $v(t)$ 在任何时间 t 都是一个随机变量。布朗运动指的是这个随机过程 $v(t)$ 随时间变化的轨迹。Eqn (5.4) 中得到的 SDE 是朗之万方程的一个特例。我们称其为具有 δ 相关朗之万力的线性朗之万方程：

Definition 5.1. 一个具有 δ 相关朗之万力的线性朗之万方程是形如

$$\dot{\xi} + \gamma\xi = \Gamma(t), \quad (5.6)$$

的随机微分方程，其中 $\Gamma(t)$ 是一个满足两个性质的随机过程：(i) 对所有 t ， $\mathbb{E}[\Gamma(t)] = 0$ ；(ii) 对所有 t 和 t' ， $\mathbb{E}[\Gamma(t)\Gamma(t')] = q\delta(t - t')$ 。

此时，我们可以将 Eqn (5.6) 中的朗之万方程与扩散模型（例如 DDPM）联系起来。

Example 5.1. 前向 DDPM. 回想一下，DDPM 前向扩散方程由

$$d\mathbf{x} = \underbrace{-\frac{\beta(t)}{2} \mathbf{x}}_{=f(t)} dt + \underbrace{\sqrt{\beta(t)} d\mathbf{w}}_{=g(t)}.$$

给出。将其表示为朗之万方程的形式，我们可以写成

$$\dot{\xi}(t) + f(t)\xi(t) = g(t)\Gamma(t), \quad \text{where } \Gamma(t) \sim \mathcal{N}(0, \mathbf{I}).$$

Example 5.2. 反向 DDPM. 反向 DDPM 扩散由 Eqn (4.16)

$$d\mathbf{x} = \underbrace{-\beta(t) \left[\frac{\mathbf{x}}{2} + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right]}_{=f(\xi, t)} dt + \underbrace{\sqrt{\beta(t)} d\mathbf{w}}_{=g(t)}.$$

给出。将其表示为朗之万方程的形式，我们可以写成

$$\dot{\xi}(t) = f(\xi, t) + g(t)\Gamma(t), \quad \text{where } \Gamma(t) \sim \mathcal{N}(0, \mathbf{I}).$$

我们可以继续为其他扩散模型（如 SMLD）提供这些例子。我们将这些留给读者作为练习。我们的核心信息是，我们在前几章中看到的扩散方程都可以通过朗之万方程来表述。因此，如果我们想知道这些扩散方程产生的概率分布，我们应该在朗之万方程的文献中寻找工具。

(线性) 朗之万方程的解。 Eqn (5.6) 中给出的线性朗之万方程是一个简单的方程。可以在任何时间 t 解析地推导出解 $\xi(t)$ 。

我们首先考虑 $\Gamma(t) = 0$ 的简单问题。在这种情况下，微分方程为

$$\dot{\xi}(t) + \gamma\xi(t) = 0,$$

它被称为一阶齐次微分方程。这个微分方程的解如下。

Theorem 5.1. 考虑以下微分方程

$$\dot{\xi}(t) + \gamma\xi(t) = 0,$$

初始条件为 $\xi(0) = \xi_0$ 。解由

$$\xi(t) = \xi_0 e^{-\gamma t}. \quad (5.7)$$

给出。

证明。通过重新排列项，我们可以证明

$$\frac{\dot{\xi}(t)}{\xi(t)} = -\gamma,$$

其中我们假设对所有 t , $\xi(t) \neq 0$ ，以便我们可以取 $1/\xi(t)$ 。对两边积分将得到

$$\int_0^t \frac{\dot{\xi}(t')}{\xi(t')} dt' = - \int_0^t \gamma dt'.$$

方程的左边将给出 $\log \xi(t) - \log \xi(0)$ ，而右边将给出 $-\gamma t$ 。将它们相等将得到

$$\log \xi(t) - \log \xi(0) = -\gamma t \implies \xi(t) = \xi_0 e^{-\gamma t}.$$

现在我们来考虑 $\Gamma(t)$ 存在的情况。微分方程变为

$$\dot{\xi} + \gamma \xi = \Gamma(t),$$

这被称为一阶非齐次微分方程。为了求解这个微分方程，我们采用一种称为参数变易法或常数变易法的技术 [29, 定理 1.2.3]。其思想可以概括为两个步骤。我们从之前的推导中知道，齐次方程的解是 $\xi(t) = \xi_0 e^{-\gamma t}$ 。因此，我们对非齐次情况的解做一个有根据的猜测，即解的形式为 $s(t) = A(t)e^{-\gamma t}$ ，其中 $A(t)$ 是某个函数。为了简化符号，我们定义 $h(t) = e^{-\gamma t}$ 。如果 $s(t)$ 确实是微分方程的解，那么我们可以计算 $\dot{s}(t) + \gamma s(t) = \Gamma(t)$ 。这个方程的左边是

$$\begin{aligned} \dot{s}(t) + \gamma s(t) &= [A(t)h(t)]' + \gamma[A(t)h(t)] \\ &= A'(t)h(t) + A(t)h'(t) + \gamma A(t)h(t) \\ &= A(t)[h'(t) + \gamma h(t)] + A'(t)h(t) \\ &= A'(t)h(t), \end{aligned}$$

其中最后一个等式成立是因为 $h(t) = e^{-\gamma t}$ 是齐次方程的解，因此 $h'(t) + \gamma h(t) = 0$ 。因此，为了使 $\dot{s}(t) + \gamma s(t) = \Gamma(t)$ 成立，必须通过找到适当的 $A'(t)$ 使得 $A'(t)h(t) = \Gamma(t)$ 。但这并不困难。方程 $A'(t)h(t) = \Gamma(t)$ 可以写成

$$A'(t)e^{-\gamma t} = \Gamma(t) \implies A'(t) = e^{\gamma t}\Gamma(t).$$

对两边积分将得到

$$A(t) = \int_0^t e^{\gamma t'} \Gamma(t') dt',$$

由于 $s(t) = A(t)e^{-\gamma t}$ ，我们可以证明

$$s(t) = e^{-\gamma t} \int_0^t e^{\gamma t'} \Gamma(t') dt' = \int_0^t e^{-\gamma(t-t')} \Gamma(t') dt'.$$

因此，完整的解（即齐次部分和非齐次部分的和）为

$$\xi(t) = \xi_0 e^{-\gamma t} + \int_0^t e^{-\gamma(t-t')} \Gamma(t') dt'.$$

我们将结果总结如下。

Theorem 5.2. 考虑以下微分方程

$$\dot{\xi}(t) + \gamma \xi(t) = \Gamma(t),$$

初始条件为 $\xi(0) = \xi_0$ 。解由下式给出

$$\xi(t) = \xi_0 e^{-\gamma t} + \int_0^t e^{-\gamma(t-t')} \Gamma(t') dt'. \quad (5.8)$$

平衡态分布。前面的结果表明，解 $\xi(t)$ 是一个随机过程 $\Gamma(t)$ 的函数。由于每次运行（布朗运动）实验时我们不知道 $\Gamma(t)$ 的具体实现，因此通过观察 $\xi(t)$ 的概率分布来表征 $\xi(t)$ 通常更有用。接下来，我们遵循 Risken [33] 的方法来分析平衡态下的概率分布，其中 $t \rightarrow \infty$ 且 $\xi(t) \rightarrow x$ 。

Theorem 5.3. 考虑定义 5.1 中的 Langevin 方程，其中

$$\dot{\xi} + \gamma\xi = \Gamma(t), \quad (5.9)$$

且 $\Gamma(t)$ 是高斯白噪声，因此它满足上述性质。设 $\xi(t) = x$ 为该 SDE 在平衡态下的解， $p(x)$ 为 x 的概率分布。则有

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{x^2}{2\sigma^2}}, \quad (5.10)$$

其中 $\sigma = \sqrt{\frac{q}{2\gamma}}$ 。换句话说，平衡态下的解 $\xi(t) = x$ 是一个零均值的高斯随机变量。

证明。 设 $\xi_0 = \xi(0)$ 为初始条件。那么，SDE 解的形式为

$$\xi(t) = \xi_0 e^{-\gamma t} + \int_0^t e^{-\gamma(t-t')} \Gamma(t') dt'. \quad (5.11)$$

在平衡态下，当 $t \rightarrow \infty$ 时，我们可以忽略 $\xi_0 e^{-\gamma t}$ 。此外，通过令 $\tau = t - t'$ ，我们可以将解写成

$$\xi(t) = \int_0^\infty e^{-\gamma(t-t')} \Gamma(t') dt' = \int_0^\infty e^{-\gamma\tau} \Gamma(t - \tau) d\tau.$$

概率密度函数 $p(\xi)$ 可以通过对特征函数进行逆傅里叶变换来确定。回想一下，随机变量 $v(t)$ 的特征函数是

$$C(u) = \mathbb{E}[\exp\{iu \cdot \xi(t)\}] = 1 + \sum_{n=1}^{\infty} \frac{(iu)^n}{n!} \mathbb{E}[\xi(t)^n].$$

因此，为了找到 $C(u)$ ，我们需要确定矩 $\mathbb{E}[\xi(t)^n]$ 。使用 Risken（第 3 章方程 3.26 和 3.27）中的一个结果，我们可以证明

$$\begin{aligned} \mathbb{E}[\xi(t)^{2n+1}] &= 0 \\ \mathbb{E}[\xi(t)^{2n}] &= \frac{(2n)!}{2^n n!} \left[\int_0^\infty \int_0^\infty e^{-\gamma(\tau_1 + \tau_2)} q \delta(\tau_1 - \tau_2) d\tau_1 d\tau_2 \right]^n \end{aligned} \quad (5.12)$$

$$= \frac{(2n)!}{2^n n!} \left[q \int_0^\infty e^{-2\gamma\tau} d\tau \right]^n = \frac{(2n)!}{2^n n!} \left[\frac{q}{2\gamma} \right]^n. \quad (5.13)$$

将这个结果代入特征函数将得到

$$\begin{aligned} C(u) &= 1 + 0 + \frac{2!}{2} \left[\frac{q}{2\gamma} \right] + 0 + \frac{(2 \cdot 2)!}{2^2 2!} \left[\frac{q}{2\gamma} \right]^2 + \dots \\ &= \sum_{n=0}^{\infty} \frac{(iu)^{2n} \mathbb{E}[\xi(t)^{2n}]}{(2n)!} \\ &= \sum_{n=0}^{\infty} \frac{(iu)^{2n}}{(2n)!} \cdot \frac{(2n)!}{2^n n!} \left[\frac{q}{2\gamma} \right]^n \\ &= \sum_{n=0}^{\infty} \frac{1}{n!} \left(-\frac{u^2 q}{4\gamma} \right)^n = e^{-\frac{u^2 q}{4\gamma}}. \end{aligned} \quad (5.14)$$

认识到这是高斯分布的特征函数，我们可以使用逆傅里叶变换来恢复概率密度函数

$$p(x) = \sqrt{\frac{\gamma}{\pi q}} e^{-\frac{\gamma x^2}{q}}.$$

Example 5.3. (前向 DDPM 平衡态分布) 让我们通过将结果应用于前向 DDPM 方程来进行一次合理性检查，看看在平衡状态下我们会得到什么样的概率分布。

为简化起见，假设 DDPM 方程的学习率为常数

$$d\mathbf{x} = -\frac{\beta}{2} \mathbf{x} dt + \sqrt{\beta} d\mathbf{w}.$$

相应的朗之万方程为

$$\dot{\xi}(t) + \frac{\beta}{2} \xi(t) = \sqrt{\beta} \Gamma(t).$$

当 $t \rightarrow \infty$ 时，我们上述定理表明

$$p(x) = \sqrt{\frac{\gamma}{\pi q}} e^{-\frac{\gamma x^2}{q}} = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}},$$

其中我们代入了 $\gamma = \beta/2$ ，且 $q = \sqrt{\beta^2} = \beta$ 。因此，当 $t \rightarrow \infty$ 时， $\xi(t)$ 的概率分布为 $\mathcal{N}(0, 1)$ 。这与我们的预期一致。

维纳过程。在 $\gamma = 0$ 的特殊情况下，线性朗之万方程简化为

$$\dot{\xi} = \Gamma(t).$$

通过在 Eqn (5.11) 中令 $\gamma = 0$ ，我们可以证明

$$\xi(t) = \xi_0 + \int_0^t \Gamma(t') dt',$$

这也被称为维纳过程。维纳过程解的概率分布可以如下推导。

Theorem 5.4. 维纳过程。考虑维纳过程

$$\dot{\xi} = \Gamma(t), \quad (5.15)$$

其中 $\Gamma(t)$ 是高斯白噪声，满足 $\mathbb{E}[\Gamma(t)] = 0$ 和 $\mathbb{E}[\Gamma(t)\Gamma(t')] = q\delta(t - t')$ 。解 $\xi(t)$ 的概率分布 $p(x, t)$ ，其中 $\xi(t) = x$ ，为

$$p(x, t) = \frac{1}{\sqrt{2\pi qt}} e^{-\frac{(x - \xi_0)^2}{2qt}}. \quad (5.16)$$

证明。此结果与定理 5.3 的主要区别在于，这里我们关注的是任意时间 t 的分布。为此，我们注意到 $\xi(t) = \xi_0 + \int_0^t \Gamma(t') dt'$ 。因此，为了消除非零均值，我们可以考虑 $\xi(t) - \xi_0$ 。将其代入 Eqn (5.13)，我们可以证明

$$\begin{aligned} \mathbb{E}[(\xi(t) - \xi_0)^{2n+1}] &= 0 \\ \mathbb{E}[(\xi(t) - \xi_0)^{2n}] &= \frac{(2n)!}{2^n n!} \left[q \int_0^t e^0 d\tau_2 \right]^n = \frac{(2n)!}{2^n n!} (qt)^n. \end{aligned}$$

这意味着 $\xi(t) - \xi_0$ 的特征函数为

$$C(u) = \sum_{n=0}^{\infty} \frac{1}{n!} \left(-\frac{u^2 qt}{2} \right)^n = e^{-\frac{u^2 qt}{2}}. \quad (5.17)$$

进行逆傅里叶变换将给出 $\xi(t)$ 的概率分布：

$$p(x, t) = \frac{1}{\sqrt{2\pi qt}} e^{-\frac{(x-\xi_0)^2}{2qt}}. \quad (5.18)$$

为了深入理解这个方程，假设 $\xi_0 = 0$ 且 $q = 2k$ ，其中 k 为常数。这将给出

$$p(x, t) = \frac{1}{\sqrt{4\pi kt}} e^{-\frac{x^2}{4kt}}.$$

这个结果的一个有趣观察是，上述推导出的概率分布 $p(x, t)$ 实际上是**热方程**的解：

$$\frac{\partial}{\partial t} p(x, t) = k \frac{\partial^2}{\partial x^2} p(x, t), \quad (5.19)$$

假设初始条件为 $p(x, 0) = \delta(x)$ 。为了看到这一点，我们只需将概率分布代入热方程。然后我们可以看到

$$\begin{aligned} \frac{\partial}{\partial t} p(x, t) &= \frac{1}{2t} \cdot \left(\frac{x^2}{2kt} - 1 \right) \cdot \frac{1}{\sqrt{4\pi kt}} e^{-\frac{x^2}{4kt}} \\ \frac{\partial^2}{\partial x^2} p(x, t) &= \frac{1}{2kt} \cdot \left(\frac{x^2}{2kt} - 1 \right) \cdot \frac{1}{\sqrt{4\pi kt}} e^{-\frac{x^2}{4kt}}. \end{aligned}$$

热方程的解表现为从原点开始的高斯分布，并随时间向外扩展。这一结果的意义在于，虽然很难知道由朗之万方程定义的随机过程 $\xi(t)$ 的确切轨迹，但热方程提供了概率分布的完整图景。Figure ??展示了维纳过程 $\xi(t)$ 的随机实现及其对应的概率分布 $p(x, t)$ 。对于更复杂的朗之万方程（涉及非线性项），似乎自然可

Algorithm 1 DDPM 的预测校正算法。[42]

$\mathbf{x}_N = \mathcal{N}(0, \mathbf{I})$ 。

for $i = N - 1, \dots, 0$ **do**

$$\text{(Prediction)} \quad \mathbf{x}_{i-1} = \frac{1}{\sqrt{1-\beta_i}} \left[\mathbf{x}_i + \frac{\beta_i}{2} \mathbf{s}_\theta(\mathbf{x}_i, i) \right] + \sqrt{\beta_i} \mathbf{z}_i. \quad (4.23)$$

for $m = 1, \dots, M$ **do**

$$\text{(校正)} \quad \mathbf{x}_{i-1} = \mathbf{x}_i + \epsilon_i \mathbf{s}_\theta(\mathbf{x}_i, i) + \sqrt{2\epsilon_i} \mathbf{z}_i, \quad (4.24)$$

end for

end for

以预期一个描述概率分布的类似偏微分方程。更具体地说，有理由预期方程的一边会出现 $\partial/\partial t$ ，而另一边则会有 $\partial^2/\partial x^2$ 。正如我们稍后将展示的，福克-普朗克方程将具有与此相似的形式。事实上，可以从福克-普朗克方程导出热传导方程。

备注：对于形如

$$\dot{\xi}_i + \sum_{j=1}^N \gamma_{ij} \xi_j = \Gamma_i(t), \quad i = 1, \dots, N,$$

的齐次微分方程组，其中 $\mathbb{E}[\Gamma_i(t)] = 0$ 且 $\mathbb{E}[\Gamma_i(t)\Gamma_j(t')] = q_{ij}\delta(t-t')$ ，以及 $q_{ij} = q_{ji}$ ，相应的随机过程被称为**奥恩斯坦-乌伦贝克过程**。

5.2 主方程

到目前为止，我们一直在研究线性朗之万方程 $\dot{\xi}(t) + \gamma\xi(t) = \Gamma(t)$ 。这个方程使我们能够处理大多数正向扩散问题，其目标是为样本添加噪声（即将输入分布转换为高斯分布）。对于反向扩散，如反向 DDPM 方程和反向 SMLD 方程，我们需要更一般化的方程。我们现在考虑的是非线性朗之万方程，其表达式如下。

Definition 5.2. 非线性朗之万方程的形式为

$$\dot{\xi} = h(\xi, t) + g(\xi, t)\Gamma(t), \quad (5.20)$$

其中 $h(\xi, t)$ 和 $g(\xi, t)$ 分别表示漂移和扩散的函数。与之前一样，我们假设 $\Gamma(t)$ 是高斯白噪声，因此对于所有 t ， $\mathbb{E}[\Gamma(t)] = 0$ ，且 $\mathbb{E}[\Gamma(t)\Gamma(t')] = 2\delta(t - t')$ 。

读者可以参考例 ??，了解反向 DDPM 如何符合这个方程。

分析非线性朗之万方程的困难在于没有简单的闭式解。因此，我们需要开发一些数学工具来帮助我们理解非线性朗之万方程。

马尔可夫性质。 首先我们定义一个马尔可夫过程。假设 $\xi(t)$ 在时间 t_n 有一个值 $x_n = \xi(t_n)$ ，并且 $t_1 \leq t_2 \leq \dots \leq t_n$ 。我们将使用符号 $p(x_n, t_n)$ 来描述 $\xi(t_n) = x_n$ 的概率密度。我们还引入以下简写符号

$$\mathbf{x}_n = [x_n, \dots, x_1], \quad \text{and} \quad \mathbf{t}_n = [t_n, \dots, t_1].$$

因此， $p(\mathbf{x}_n, \mathbf{t}_n) = p(x_n, t_n, \dots, x_1, t_1)$ 是 $(\xi(t_n), \dots, \xi(t_1))$ 的联合分布。

让我们定义一个马尔可夫过程。我们说一个随机过程 $\xi(t)$ 是马尔可夫的，如果满足以下无记忆条件。

Definition 5.3. 一个随机过程 $\xi(t)$ 被称为**马尔可夫过程**，如果

$$p(x_n, t_n \mid \mathbf{x}_{n-1}, \mathbf{t}_{n-1}) = p(x_n, t_n \mid x_{n-1}, t_{n-1}). \quad (5.21)$$

也就是说，给定所有先前状态的情况下，在 t_n 时刻达到状态 x_n 的概率与仅以 t_{n-1} 时刻的紧邻前状态 x_{n-1} 为条件时的概率相同。

满足定义 5.2 中定义的非线性朗之万方程的随机过程 $\xi(t)$ 是马尔可夫的，只要 $\Gamma(t)$ 是 δ 相关的。这意味着， t_n 时刻的条件概率仅取决于 t_{n-1} 时刻的值。Risken [33] 总结了原因：(i) 一阶微分方程由其初始值唯一确定；(ii) 在较早时间 $t < t_{n-1}$ 的 δ 相关朗之万力 $\Gamma(t)$ 不能改变较晚时间 $t > t_{n-1}$ 的条件概率。Risken 进一步阐述，如果 $\Gamma(t)$ 不再是 δ 相关的，马尔可夫性质将被破坏。例如，如果 $\Gamma(t)$ 满足 $\mathbb{E}[\Gamma(t)\Gamma(t')] = \frac{q}{2\gamma} e^{-\gamma|t-t'|}$ ，那么由 $\dot{\xi}(t) = h(\xi) + \Gamma(t)$ 描述的过程将是非马尔可夫的。从现在开始，我们将只关注马尔可夫过程。

Chapman-Kolmogorov 方程。 考虑一个马尔可夫过程 $\xi(t)$ 。我们可以推导出一个称为 Chapman-Kolmogorov 方程的有用结果。Chapman-Kolmogorov 方程指出， t_3 和 t_1 时刻的联合分布可以通过积分 t_2 给定 t_2 的条件概率，然后 t_2 给定 t_1 的条件概率来找到。这里的两个关键论点是贝叶斯定理加上边缘化的定义，以及马尔可夫过程的无记忆性质。

Theorem 5.5. Chapman-Kolmogorov 方程。 设 $\xi(t)$ 是一个马尔可夫过程， $x_n = \xi(t_n)$ 是 $\xi(t)$ 在时间 t_n 的状态。那么

$$p(x_3, t_3 \mid x_1, t_1) = \int p(x_3, t_3 \mid x_2, t_2) p(x_2, t_2 \mid x_1, t_1) dx_2, \quad (5.22)$$

假设 $t_1 \leq t_2 \leq t_3$ 。

证明。 为了记号的简洁性，我们记 $\mathbf{x}_n = \{x_n, \dots, x_1\}$ 和 $\mathbf{t}_n = \{t_n, \dots, t_1\}$ 。如果 $\xi(t)$ 是马尔可夫的，那么根据马尔可夫的无记忆性，我们有

$$\begin{aligned} p(\mathbf{x}_n, \mathbf{t}_n) &= p(x_n, t_n \mid \mathbf{x}_{n-1}, \mathbf{t}_{n-1}) p(\mathbf{x}_{n-1}, \mathbf{t}_{n-1}) \\ &= p(x_n, t_n \mid x_{n-1}, t_{n-1}) p(\mathbf{x}_{n-1}, \mathbf{t}_{n-1}). \end{aligned}$$

重复上述论证将得到

$$p(\mathbf{x}_n, \mathbf{t}_n) = p(x_n, t_n \mid x_{n-1}, t_{n-1}) \cdots p(x_2, t_2 \mid x_1, t_1) \cdot p(x_1, t_1).$$

因此, 通过对 $p(\mathbf{x}_3, \mathbf{t}_3)$ 关于 x_2 进行边缘化, 我们可以证明

$$\begin{aligned} p(x_3, t_3, x_1, t_1) &= \int p(\mathbf{x}_3, \mathbf{t}_3) dx_2 \\ &= \int p(x_3, t_3 | x_2, t_2) p(x_2, t_2 | x_1, t_1) p(x_1, t_1) dx_2. \end{aligned}$$

通过写出 $p(x_3, t_3, x_1, t_1) = p(x_3, t_3 | x_1, t_1) p(x_1, t_1)$, 我们可以证明

$$p(x_3, t_3 | x_1, t_1) = \int p(x_3, t_3 | x_2, t_2) p(x_2, t_2 | x_1, t_1) dx_2. \quad (5.23)$$

这就完成了证明。

作为 Chapman-Kolmogorov 方程的推论, 我们可以令 $x = x_3$ 为当前状态, $x_0 = x_1$ 为初始状态, $x' = x_2$ 为中间状态。那么方程可以写成

$$p(x, t | x_0, t_0) = \int p(x, t | x', t') p(x', t' | x_0, t_0) dx', \quad (5.24)$$

如果我们进一步去掉对 x_0 的条件, 我们可以写成

$$p(x, t) = \int p(x, t | x', t') p(x', t') dx'.$$

主方程. 基于 Chapman-Kolmogorov 方程, 我们可以推导出马尔可夫过程的一个基本方程。这个方程被称为主方程。

Theorem 5.6. 设 $\xi(t)$ 为马尔可夫过程。主方程表述为

$$\frac{\partial}{\partial t} p(x, t) = \int [W(x | x') p(x', t) - W(x' | x) p(x, t)] dx', \quad (5.25)$$

其中 $W(x | x')$ 是单位时间的概率密度函数。

证明. 回顾 Chapman-Kolmogorov 方程

$$p(x_3, t_3 | x_1, t_1) = \int p(x_3, t_3 | x_2, t_2) p(x_2, t_2 | x_1, t_1) dx_2. \quad (5.26)$$

我们考虑以下映射:

$$\begin{aligned} (x_1, t_1) &\longrightarrow (x_0, t_0) \\ (x_2, t_2) &\longrightarrow (x, t) \\ (x_3, t_3) &\longrightarrow (x, t + \Delta t) \end{aligned}$$

那么, Chapman-Kolmogorov 方程可以写成

$$p(x, t + \Delta t | x_0, t_0) = \int p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx'. \quad (5.27)$$

由于我们的目标是得到时间上的偏导数, 我们考虑 $p(x, t | x_0, t_0)$ 的时间导数:

$$\begin{aligned} \frac{\partial}{\partial t} p(x, t | x_0, t_0) &= \lim_{\Delta t \rightarrow 0} \frac{p(x, t + \Delta t | x_0, t_0) - p(x, t | x_0, t_0)}{\Delta t} \\ &= \lim_{\Delta t \rightarrow 0} \frac{\int p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx' - p(x, t | x_0, t_0)}{\Delta t}. \end{aligned}$$

我们注意到在方程的右侧有一个积分。如果我们交换变量 x 和 x' ，我们可以使用以下观察：

$$\int p(x', t + \Delta t | x, t) dx' = 1.$$

我们可以将其插入上述方程并得到

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \left[\int p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx' - \int p(x', t + \Delta t | x, t) p(x, t | x_0, t_0) dx' \right]$$

接下来，我们可以将极限移入积分。让我们定义

$$W(x, t | x', t) = \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} p(x, t + \Delta t | x', t)$$

$$W(x', t | x, t) = \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} p(x', t + \Delta t | x, t)$$

因此，我们有

$$\frac{\partial}{\partial t} p(x, t | x_0, t_0) = \int \left[W(x, t | x', t) p(x', t | x_0, t_0) - W(x', t | x, t) p(x, t | x_0, t_0) \right] dx' \quad (5.28)$$

如果我们固定 (x_0, t_0) ，那么我们可以去掉条件。这将给出

$$\frac{\partial}{\partial t} p(x, t) = \int \left[W(x, t | x', t) p(x', t) - W(x', t | x, t) p(x, t) \right] dx'. \quad (5.29)$$

在上述推导中，项 $W(x, t | x', t)$ 和 $W(x', t | x, t)$ 被称为**转移率**。它们是单位时间的转移概率，单位为 $[\text{时间}^{-1}]$ 。因此，如果我们对它们进行时间积分，我们将得到

$$\int W(x, t | x', t) dt = p(x, t | x', t)$$

$$\int W(x', t | x, t) dt = p(x', t | x, t).$$

一种可视化主方程的方法是将 $\int W(x, t | x', t) p(x', t) dx'$ 视为**流入**，将 $\int W(x', t | x, t) p(x, t) dx'$ 视为从状态 x' 到 x （以及从 x 到 x' ）的转移概率的**流出**。因此，如果我们把概率看作房间中粒子的密度，那么主方程表示密度变化率是粒子流入和流出的差：

$$\underbrace{\frac{\partial}{\partial t} p(x, t)}_{\text{rate of change}} = \underbrace{\int \left[W(x, t | x', t) p(x', t) \right] dx'}_{\text{in-flow of probability}} - \underbrace{\int \left[W(x', t | x, t) p(x, t) \right] dx'}_{\text{out-flow of probability}} \quad (5.30)$$

主方程在化学、生物学和许多学科中广泛应用。粒子流入和流出的概念对于研究系统动力学特别有用。主方程的另一个重要方面是它将时间 ∂t 与状态 dx' 联系起来。这将在 Fokker-Planck 方程中变得普遍。对于上述证明，我们可以抱怨的一点是，尽管它很严谨，但在证明过程中缺乏物理直觉。接下来，我们将提出一个更直观但不够严谨的替代证明。该证明基于 Luca Donati 的讲义笔记 [13]。

直观证明. 考虑一个只能处于两种状态（1 或 2）的粒子。落在特定状态的概率为 $p(x_1, t)$ 和 $p(x_2, t)$ ，使得对于任何 t ， $p(x_1, t) + p(x_2, t) = 1$ 。现在考虑一个小区间 $(t, t + dt)$ 。在这个区间内，粒子可以保持当前状态，也可以跳到另一个状态。这意味着在 $t + dt$ 结束时，我们可以写出

$$p(x_1, t + dt) = p(x_1, t) \mathbb{P}[\text{stay in } x_1] + p(x_2, t) \mathbb{P}[\text{move from } x_2 \text{ to } x_1]$$

$$= p(x_1, t) \left(1 - \mathbb{P}[\text{move from } x_1 \text{ to } x_2] \right) + p(x_2, t) \mathbb{P}[\text{move from } x_2 \text{ to } x_1]$$

定义速率 $W(x_2|x_1)$ 和 $W(x_1|x_2)$, 使得

$$\begin{aligned}\mathbb{P}[\text{move from } x_1 \text{ to } x_2] &= W(x_2|x_1)dt \\ \mathbb{P}[\text{move from } x_2 \text{ to } x_1] &= W(x_1|x_2)dt.\end{aligned}$$

注意, 这里我们隐含地假设了转移分布是马尔可夫的, 因此当前状态仅依赖于其前一个状态, 而不是整个历史。然后, 上述方程可以写成

$$p(x_1, t + dt) = p(x_1, t)(1 - W(x_2|x_1)dt) + p(x_2, t)W(x_1|x_2)dt + \mathcal{O}(dt^2).$$

高阶项的存在是为了考虑在 $(t, t + dt)$ 期间的多重跳跃, 例如, 在区间内从 x_1 跳到 x_2 , 然后从 x_2 跳回 x_1 。然而, 如果 $dt \rightarrow 0$, 这一项将消失。通过重新排列项, 我们可以写出

$$\frac{dp(x_1, t)}{dt} = -W(x_2|x_1)p(x_1, t) + W(x_1|x_2)p(x_2, t).$$

我们可以将这个结果推广到多个状态, 从 x_1 出发或到达 x_1 。例如,

$$\frac{dp(x_1, t)}{dt} = \sum_{j \neq 1} [-W(x_j|x_1)p(x_1, t) + W(x_1|x_j)p(x_j, t)].$$

为了使其更加一般化, 我们可以考虑 x_j 的连续统。通过重新排列项, 我们将得到

$$\frac{dp(x, t)}{dt} = \int [W(x|x')p(x', t) - W(x'|x)p(x, t)] dx',$$

这就是主方程。

5.3 Kramers-Moyal 展开

随着主方程的建立, 我们现在可以处理非线性朗之万方程了。回想一下, 非线性朗之万方程没有闭式解, 因此我们无法解析地写出解的概率分布。主方程允许我们通过一个称为福克-普朗克方程的偏微分方程来写出概率分布的条件。福克-普朗克方程的推导需要一个称为 Kramers-Moyal 展开的数学结果。

Theorem 5.7. 设 $\xi(t)$ 为马尔可夫过程, $p(x, t)$ 为 $\xi(t)$ 在时间 t 取值为 x 的概率分布。**Kramers-Moyal 展开表明**

$$\frac{\partial}{\partial t} p(x, t) = \sum_{m=1}^{\infty} \left[-\frac{\partial^m}{\partial x^m} D^{(m)}(x, t) p(x, t) \right],$$

其中 Kramers-Moyal 展开系数定义为

$$D^{(m)}(x, t) = \frac{1}{m!} \lim_{\Delta t \rightarrow 0} \left[\frac{1}{\Delta t} \mathbb{E}[(\xi(t + \Delta t) - x)^m] \Big|_{\xi(t)=x} \right].$$

证明。 我们从主方程开始。主方程表明

$$\begin{aligned}\frac{\partial}{\partial t} p(x, t | x_0, t_0) &= \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \left[\int p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx' \right. \\ &\quad \left. - \int p(x', t + \Delta t | x, t) p(x, t | x_0, t_0) dx' \right].\end{aligned}$$

我们可以引入一个测试函数 $\varphi(x)$ ，使得

$$\begin{aligned} \frac{\partial}{\partial t} \int \varphi(x) p(x, t | x_0, t_0) dx &= \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \left\{ \int \varphi(x) \int p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx' dx \right. \\ &\quad \left. - \int \varphi(x) \int p(x', t + \Delta t | x, t) p(x, t | x_0, t_0) dx' dx \right\}. \end{aligned}$$

测试函数的泰勒展开将给出一个无限级数

$$\varphi(x) = \varphi(x') + \sum_{m=1}^{\infty} \frac{(x - x')^m}{m!} \frac{\partial^m}{\partial x^m} \varphi(x) \Big|_{x=x'}.$$

将展开代入主方程将得到

$$\begin{aligned} &\frac{\partial}{\partial t} \int \varphi(x) p(x, t | x_0, t_0) dx \\ &= \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \left[\iint \varphi(x') p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx' dx \right. \\ &\quad + \iint \sum_{m=1}^{\infty} \frac{(x - x')^m}{m!} \frac{\partial^m}{\partial x^m} \varphi(x) \Big|_{x=x'} p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx' dx \\ &\quad \left. - \iint \varphi(x) p(x', t + \Delta t | x, t) p(x, t | x_0, t_0) dx' dx \right] \end{aligned} \quad (5.31)$$

我们注意到上述方程中的最后一个二重积分有哑变量 x' 和 x 。我们可以交换哑变量，并写出

$$\iint \varphi(x) p(x', t + \Delta t | x, t) p(x, t | x_0, t_0) dx' dx = \iint \varphi(x') p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx' dx$$

然后，Eqn (5.31)中的第一个和第三个二重积分可以相消。这将留下

$$\begin{aligned} &\frac{\partial}{\partial t} \int \varphi(x) p(x, t | x_0, t_0) dx \\ &= \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \iint \sum_{m=1}^{\infty} \frac{(x - x')^m}{m!} \frac{\partial^m}{\partial x^m} \varphi(x) \Big|_{x=x'} p(x, t + \Delta t | x', t) p(x', t | x_0, t_0) dx' dx \end{aligned} \quad (5.32)$$

现在让我们定义

$$D^{(m)}(x', t) = \frac{1}{m!} \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \int (x - x')^m p(x, t + \Delta t | x', t) dx.$$

然后，主方程变为

$$\begin{aligned} &\frac{\partial}{\partial t} \int \varphi(x) p(x, t | x_0, t_0) dx \\ &= \int \sum_{m=1}^{\infty} D^{(m)}(x', t) \frac{\partial^m}{\partial x^m} \varphi(x) \Big|_{x=x'} p(x', t | x_0, t_0) dx' \quad \text{代入 } D^{(m)}(x', t) \\ &= \sum_{m=1}^{\infty} \int D^{(m)}(x', t) p(x', t | x_0, t_0) \frac{\partial^m}{\partial x^m} \varphi(x) \Big|_{x=x'} dx' \quad \text{交换求和与积分} \\ &= \sum_{m=1}^{\infty} (-1)^m \int \varphi(x') \frac{\partial^m}{\partial x'^m} \left[D^{(m)}(x, t) p(x, t, x_0, t_0) \right] dx' \quad \text{广义分部积分,} \end{aligned}$$

其中最后一步称为广义分部积分，它表明对于任何连续可微函数 f 和 g ,

$$\int g \cdot \frac{\partial^m f}{\partial x^m} dx = (-1)^m \int f \frac{\partial^m g}{\partial x^m} dx.$$

结合所有这些，并认识到上述结果对任意 $\varphi(x)$ 成立，可以得出

$$\frac{\partial}{\partial t} p(x, t | x_0, t_0) = \sum_{m=1}^{\infty} (-1)^m \frac{\partial^m}{\partial x^m} \left[D^{(m)}(x, t) p(x, t, x_0, t_0) \right]. \quad (5.33)$$

如果我们进一步去掉对 (x_0, t_0) 的条件，我们将得到

$$\frac{\partial}{\partial t} p(x, t) = \sum_{m=1}^{\infty} \frac{1}{m!} (-1)^m \frac{\partial^m}{\partial x^m} \left[D^{(m)}(x, t) p(x, t) \right] \quad (5.34)$$

这就完成了证明。

Kramers-Moyal 展开通过空间导数 ∂x 表达了任何马尔可夫过程（包括非线性朗之万方程的解）的概率分布的时间导数 ∂t 。然而，展开式有无限多项。一个重要的问题是，我们是否可以截断其中的任何项。如果可以，可以截断多少项？Pawula 定理为这个问题提供了一个答案：[30]

Theorem 5.8. Pawula 定理。 Kramers-Moyal 展开可能在以下三种情况之一停止：

- $m = 1$ ：所得的微分方程称为 Liouville 方程，这是一个确定性过程。
- $m = 2$ ：所得的微分方程称为 Fokker-Planck 方程。
- $m = \infty$ ，即展开式无法截断。

证明。 回想一下，Kramer's-Moyal 系数定义为

$$D^{(m)}(x, t) = \frac{1}{m!} \lim_{\Delta t \rightarrow 0} \left[\frac{1}{\Delta t} \mathbb{E}[(\xi(t + \Delta t) - x)^m] \Big|_{\xi(t)=x} \right].$$

记 $x' = \xi(t + \Delta t)$ ，这里关注的是第 m 阶矩 $\mathbb{E}[(x' - x)^m]$ 。

我们应用 Cauchy-Schwarz 不等式，该不等式指出对于任何函数 f 和 g ，以及随机变量 X 和 Y ，有

$$\mathbb{E}[f(X)g(Y)]^2 \leq \mathbb{E}[f(X)^2] \mathbb{E}[g(Y)^2].$$

我们考虑两种可能性：

- 假设 $m \geq 3$ 且 m 为奇数，则

$$\mathbb{E}[(x' - x)^m]^2 = \mathbb{E} \left[(x' - x)^{\frac{m-1}{2}} (x' - x)^{\frac{m+1}{2}} \right]^2 \leq \mathbb{E}[(x' - x)^{m-1}] \mathbb{E}[(x' - x)^{m+1}].$$

- 假设 $m \geq 4$ 且 m 为偶数，则

$$\mathbb{E}[(x' - x)^m]^2 = \mathbb{E} \left[(x' - x)^{\frac{m-2}{2}} (x' - x)^{\frac{m+2}{2}} \right]^2 \leq \mathbb{E}[(x' - x)^{m-2}] \mathbb{E}[(x' - x)^{m+2}].$$

注意，我们不能对 $m = 0, 1, 2$ 应用上述论证，因为它们会给出平凡的等式。

从这两个关系出发，并假设我们记 $D_m = D^{(m)}(x, t)$ ，则上述两种情况可以写成

$$\begin{aligned} D_m^2 &\leq D_{m-1} D_{m+1}, & m \text{ odd and } m \geq 3, \\ D_m^2 &\leq D_{m-2} D_{m+2}, & m \text{ even and } m \geq 4. \end{aligned}$$

我们的目标是证明这个递推关系将导致对于任何 $m \geq 3$, $D_m = 0$ 。

首先假设 $D_4 = 0$ 。那么 $D_6 \leq D_4 D_8$ 意味着 $D_6 = 0$ 。但如果 $D_6 = 0$, 则 $D_8 \leq D_6 D_{10}$ 意味着 $D_8 = 0$ 。重复此过程将得到 $m = 4, 6, 8, 10, \dots$ 时 $D_m = 0$ 。类似地, 假设 $D_6 = 0$ 。那么 $D_4 \leq D_2 D_6$ 意味着 $D_4 = 0$ 。但如果 $D_4 = 0$, 我们可以回到第一种情况并证明 $m = 4, 6, 8, 10, \dots$ 时 $D_m = 0$ 。一般来说, 如果任何一个 $m \geq 4$ 的偶数为零, 则所有 $m \geq 4$ 的偶数都应为零。对于奇数 m : 如果 $D_4 = 0$, 则 $D_3 \leq D_2 D_4$ 意味着 $D_3 = 0$ 。类似地, 如果 $D_6 = 0$, 我们将有 $D_5 = 0$ 。因此, 如果 $D_4 = D_6 = D_8 = \dots = 0$, 则 $D_3 = D_5 = D_7 = \dots = 0$ 。因此, 如果对于任何 $m \geq 4$ 的偶数 $D_m = 0$, 则对于所有 $m \geq 3$ 的整数 $D_m = 0$ 。

上述分析表明, 如果 Kramers-Moyal 展开截断到 $m = 3$, 使得 $D_3 \neq 0$ 且 $D_4 = D_5 = \dots = 0$, 则 $D_4 = 0$ 将迫使 $D_3 = 0$ 。因此, 我们将有对于所有 $m \geq 3$, $D_m = 0$ 。类似地, 如果 Kramers-Moyal 展开截断到 $m = 4$, 使得 $D_4 \neq 0$ 且 $D_5 = D_6 = \dots = 0$, 则 $D_6 = 0$ 将迫使 $D_4 = 0$ 。因此, 我们将再次有对于所有 $m \geq 3$, $D_m = 0$ 。

通过对其他 $m \geq 3$ 重复上述论证, 我们看到不可能对任何 $m \geq 3$ 截断 Kramers-Moyal 展开。换句话说, 我们只能在 $m = 1$ 、 $m = 2$ 处截断展开, 或者永远不截断它。

Pawula 定理并没有说 Fokker-Planck 方程 (将 Kramers-Moyal 展开截断到 $m = 2$) 是基础 Masters 方程的良好近似。它只是说我们可以使用 $m = 1$ 或 $m = 2$ 精确近似 Masters 方程, 或者根本无法近似。

5.4 Fokker-Planck 方程

我们现在可以讨论 Fokker-Planck 方程。Fokker-Planck 方程是 Kramers-Moyal 展开在 $m = 2$ 时的截断。

Definition 5.4. Fokker-Planck 方程是通过将 Kramers-Moyal 展开截断至 $m = 2$ 得到的。也就是说, 对于任何马尔可夫过程 $\xi(t)$, $\xi(t) = x$ 在时间 t 的概率分布 $p(x, t)$ 将满足以下偏微分方程:

$$\frac{\partial}{\partial t} p(x, t) = -\frac{\partial}{\partial x} D^{(1)}(x, t) p(x, t) + \frac{\partial^2}{\partial x^2} D^{(2)}(x, t) p(x, t). \quad (5.35)$$

Fokker-Planck 方程是任何马尔可夫随机过程的普遍结果, 因为它是 Chapman-Kolmogorov 方程和主方程的结果。我们在本教程中研究的过程, 例如 Langevin 方程, 是这一大类随机过程的特例。因此, 如果我们有一个 Langevin 方程, 那么解 $\xi(t)$ 的概率分布必然满足 Fokker-Planck 方程。

非线性 Langevin 方程。如果我们关注非线性 Langevin 方程

$$\dot{\xi} = h(\xi, t) + g(\xi, t)\Gamma(t),$$

我们可以评估 Kramers-Moyal 系数 $D^{(m)}(x, t)p(x, t)$ 。以下定理总结了这些系数。我们注意到, 在证明这个定理的过程中, 将清楚地说明为什么 $D^{(m)}(x, t)p(x, t)$ 仅限于 $m = 1$ 和 $m = 2$ 。

Theorem 5.9. 非线性 Langevin 方程的 Fokker-Planck 方程。考虑非线性 Langevin 方程

$$\dot{\xi} = h(\xi, t) + g(\xi, t)\Gamma(t),$$

对于函数 $h(\xi, t)$ 和 $g(\xi, t)$ 。这个非线性 Langevin 方程的 Fokker-Planck 方程将具有 Kramers-Moyal 系数:

$$(\text{漂移}) \quad D^{(1)}(x, t) = h(x, t) + g'(x, t)g(x, t) \quad (5.36)$$

$$(\text{扩散}) \quad D^{(2)}(x, t) = g^2(x, t). \quad (5.37)$$

证明。回顾 Kramers-Moyal 系数的定义:

$$D^{(m)}(x, t) = \frac{1}{m!} \lim_{\tau \rightarrow 0} \frac{\mathbb{E}[(\xi(t + \tau) - x)^m]}{\tau} \Big|_{\xi(t)=x}.$$

困难的部分是如何评估矩 $\mathbb{E}[(\xi(t + \tau) - x)^m]$ 。

我们从非线性 Langevin 方程开始：

$$\dot{\xi} = h(\xi, t) + g(\xi, t)\Gamma(t).$$

对于小的 τ ，表达 $\xi(t + \tau) - \xi(t) = \int_t^{t+\tau} \dot{\xi}(t') dt'$ 并令 $\xi(t) = x$ ，我们可以写出

$$\xi(t + \tau) - x = \int_t^{t+\tau} \left[h(\xi(t'), t') + g(\xi(t'), t')\Gamma(t') \right] dt'.$$

我们假设 h 和 g 可以展开为

$$\begin{aligned} h(\xi(t'), t') &= h(x, t') + h'(x, t')(\xi(t') - x) + \dots \\ g(\xi(t'), t') &= g(x, t') + g'(x, t')(\xi(t') - x) + \dots \end{aligned}$$

这将给我们

$$\begin{aligned} \xi(t + \tau) - x &= \int_t^{t+\tau} \left[h(x, t') + h'(x, t')(\xi(t') - x) + \dots \right] dt' \\ &\quad + \int_t^{t+\tau} \left[g(x, t') + g'(x, t')(\xi(t') - x) + \dots \right] \Gamma(t') dt' \\ &= \int_t^{t+\tau} h(x, t') dt' + \int_t^{t+\tau} h'(x, t')(\xi(t') - x) dt' + \dots \\ &\quad + \int_t^{t+\tau} g(x, t') \Gamma(t') dt' + \int_t^{t+\tau} g'(x, t')(\xi(t') - x) \Gamma(t') dt' + \dots \end{aligned}$$

现在，我们迭代上述方程并用积分替换 $\xi(t') - x$ 。这将给我们

$$\begin{aligned} \xi(t + \tau) - x &= \int_t^{t+\tau} h(x, t') dt' + \int_t^{t+\tau} h'(x, t') \left[\int_t^{t'} h(x, t'') dt'' \right] dt' + \\ &\quad + \int_t^{t+\tau} h'(x, t') \left[\int_t^{t'} g(x, t'') \Gamma(t'') dt'' \right] dt' + \dots \\ &\quad + \int_t^{t+\tau} g(x, t') \Gamma(t') dt' + \int_t^{t+\tau} g'(x, t') \left[\int_t^{t'} h(x, t'') dt'' \right] \Gamma(t') dt' \\ &\quad + \int_t^{t+\tau} g'(x, t') \left[\int_t^{t'} g(x, t'') \Gamma(t'') dt'' \right] \Gamma(t') dt' + \dots \end{aligned} \quad (5.38)$$

其中我们只写出涉及 h 、 g 和 Γ 的项。涉及 $\xi(t'') - x$ 的项未被丢弃。

取期望，并注意到 $\mathbb{E}[\Gamma(t)] = 0$ ，我们可以证明只有 Eqn (5.38) 中的前两项和最后一项会保留。因此，我们有

$$\begin{aligned} \mathbb{E}[\xi(t + \tau) - x] &= \int_t^{t+\tau} h(x, t') dt' + \int_t^{t+\tau} \int_t^{t'} h'(x, t') h(x, t'') dt'' dt' + \dots \\ &\quad + \underbrace{\int_t^{t+\tau} g'(x, t') \int_t^{t'} g(x, t'') 2\delta(t'' - t') dt'' dt'}_{=g(x, t')} + \dots \end{aligned} \quad (5.39)$$

其中我们遵循 Risken 的定义，即 $\int_t^{t'} 2\delta(t'' - t') dt'' = 1$ [33]。当 $\tau \rightarrow 0$ 时，Eqn (5.39) 的第一项和第三

项为

$$\begin{aligned}\lim_{\tau \rightarrow 0} \int_t^{t+\tau} h(x, t') dt' &= h(x, t), \\ \lim_{\tau \rightarrow 0} \int_t^{t+\tau} g'(x, t') g(x, t') dt' &= g'(x, t) g(x, t).\end{aligned}$$

对于 Eqn (5.39) 中的第二项，我们可以证明

$$\begin{aligned}\lim_{\tau \rightarrow 0} \int_t^{t+\tau} \int_t^{t'} h'(x, t') h(x, t'') dt'' dt' &= \lim_{\tau \rightarrow 0} \int_t^{t+\tau} h'(x, t') (H(x, t') - H(x, t)) dt' \\ &= h'(x, t) (H(x, t) - H(x, t)) = 0,\end{aligned}$$

其中我们假设 $h(x, t)$ 在 t 上可积，因此我们可以定义 $H(x, t) = \int_0^t h(x, t') dt'$ 。因此，我们得到

$$D^{(1)}(x, t) = h(x, t) + g'(x, t) g(x, t).$$

$D^{(2)}(x, t)$ 的推导基本上遵循相同的论点。这里需要注意的是，当我们在 $\mathbb{E}[(\xi(t+\tau) - x)^2]$ 中取平方时，Eqn (5.39) 中的积分将给我们与 τ^2 成正比的贡献。当 $\tau \rightarrow 0$ 时，所有这些项都会消失，因为在 $D^{(2)}(x, t)$ 的定义中只有一个 $1/\tau$ 。因此，唯一可以保留的项是

$$\begin{aligned}D^{(2)}(x, t) &= \frac{1}{2} \lim_{\tau \rightarrow 0} \frac{1}{\tau} \int_t^{t+\tau} \int_t^{t'} g(x, t') g(x, t'') 2\delta(t' - t'') dt' dt'' \\ &= g^2(x, t),\end{aligned}$$

这完成了证明。

Example 5.4. 考虑以下 Langevin 方程

$$\dot{\xi} = A(\xi)\xi + \sigma\Gamma(t).$$

那么，解 $\xi(t)$ 的概率分布 $p(x, t)$ 将满足以下 Fokker-Planck 方程

$$\begin{aligned}\frac{\partial}{\partial t} p(x, t) &= -\frac{\partial}{\partial x} [h(x, t) + g'(x, t) g(x, t)] p(x, t) + \frac{\partial^2}{\partial x^2} [g^2(x, t) p(x, t)] \\ &= -\frac{\partial}{\partial x} [(A(x) + 0 \cdot \sigma) p(x, t)] + \frac{\partial^2}{\partial x^2} [\sigma^2 p(x, t)] \\ &= -\frac{\partial}{\partial x} [A(x) p(x, t)] + \sigma^2 \frac{\partial^2}{\partial x^2} [p(x, t)].\end{aligned}$$

Example 5.5. 对于特殊情况 $A(x) = 0$ ，朗之万方程简化为维纳过程：

$$\dot{\xi} = \sigma\Gamma(t).$$

相应的福克-普朗克方程为

$$\frac{\partial}{\partial t} p(x, t) = \sigma^2 \frac{\partial^2}{\partial x^2} p(x, t).$$

该方程被称为**热方程**或**扩散方程**。如果初始条件是 $p(x, 0) = \delta(x)$ ，则解为（见下文推导）

$$p(x, t) = \frac{1}{\sqrt{4\pi\sigma^2 t}} e^{-\frac{x^2}{4\sigma^2 t}}.$$

热方程的解。热方程可以通过傅里叶变换求解。为了符号简洁，我们记 $u_t = \frac{\partial u}{\partial t}$ 和 $u_{xx} = \frac{\partial^2 u}{\partial x^2}$ 。考虑一般的热方程：

$$u_t(x, t) = k u_{xx}(x, t), \quad x \in \mathbb{R}, t > 0,$$

初始条件为 $u(x, 0) = \phi(x)$ 。我们可以通过定义

$$\begin{aligned}\hat{u}_t(\omega, t) &= \mathcal{F}\{u_t(x, t)\} = \int_{-\infty}^{\infty} u_t(x, t) e^{j\omega x} dx \\ \hat{u}_{xx}(\omega, t) &= \mathcal{F}\{u_{xx}(x, t)\} = \int_{-\infty}^{\infty} u_{xx}(x, t) e^{j\omega x} dx.\end{aligned}$$

对两边进行傅里叶变换（在 $x \leftrightarrow \omega$ 之间映射）。这将给出

$$\hat{u}_t(\omega, t) = k \hat{u}_{xx}(\omega, t).$$

利用傅里叶变换的微分性质，我们可以将方程的右边写为

$$k \hat{u}_{xx}(\omega, t) = k(j\omega)^2 \hat{u}(\omega, t) = -k\omega^2 \hat{u}(\omega, t),$$

这将给出一个常微分方程

$$\hat{u}_t(\omega, t) = -k\omega^2 \hat{u}(\omega, t). \quad (5.40)$$

该微分方程（关于 t ）的解为

$$\hat{u}(\omega, t) = \hat{\phi}(\omega) e^{-k\omega^2 t}. \quad (5.41)$$

（注：Eqn (5.40) 只是一个简单的微分方程 $f'(t) = af(t)$ ，其解可以通过积分找到。）因此，如果我们对 $\hat{u}(\omega, t)$ 进行逆傅里叶变换（关于 $\omega \leftrightarrow x$ ），我们将得到

$$u(x, t) = \mathcal{F}^{-1}\{\hat{u}(\omega, t)\} = \mathcal{F}^{-1}\{\hat{\phi}(\omega) e^{-k\omega^2 t}\}$$

这是 $\hat{\phi}(\omega)$ 和 $\hat{f}(\omega) \stackrel{\text{def}}{=} e^{-k\omega^2 t}$ 乘积的逆傅里叶变换。由于傅里叶域中的乘法对应于空间域中的卷积，因此 $u(x, t)$ 是 $\phi(x)$ 和 $f(x) = \mathcal{F}^{-1}(e^{-k\omega^2 t})$ 的卷积。但 $\mathcal{F}^{-1}(e^{-k\omega^2 t}) = \frac{1}{\sqrt{2kt}} e^{-x^2/(4kt)}$ 。因此，我们可以证明解为

$$\begin{aligned}u(x, t) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \phi(x - x') f(x') dx' \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \phi(x - x') \frac{1}{\sqrt{2kt}} e^{-(x')^2/(4kt)} dx'.\end{aligned}$$

所以，如果 $\phi(x) = \delta(x)$ ，使得 $\phi(x - x') = \delta(x - x')$ ，则

$$u(x, t) = \frac{1}{\sqrt{4k\pi t}} e^{-\frac{x^2}{4kt}}. \quad (5.42)$$

概率流。福克-普朗克方程有一些有趣的物理解释。回想一下，福克-普朗克方程为

$$\frac{\partial}{\partial t} p(x, t) = -\frac{\partial}{\partial x} D^{(1)}(x, t) p(x, t) + \frac{\partial^2}{\partial x^2} D^{(2)}(x, t) p(x, t). \quad (5.43)$$

我们定义一个量

$$S(x, t) = \left[D^{(1)}(x, t) - \frac{\partial}{\partial x} D^{(2)}(x, t) \right] p(x, t). \quad (5.44)$$

那么，福克-普朗克方程可以写为

$$\frac{\partial p}{\partial t} + \frac{\partial S}{\partial x} = 0. \quad (5.45)$$

Eqn (5.45) 的一种解释是它是**概率流**。

Eqn (5.45) 的直观推导。 能量守恒告诉我们，如果某个空间区域内的某种量增加或减少（例如粒子或电荷），其量的变化应等于其表面的变化。因此，如果 $p(x, t)$ 表示某种密度，那么 $p(x, t)dx$ 将是时间 t 时位于 $(x, x + dx)$ 之间的粒子量。这里， $S(x, t)$ 可以看作是单位时间内流过 x 的粒子流。对于时间间隔 $(t, t + dt)$ 和空间间隔 $(x, x + dx)$ ，粒子量的变化为

$$\text{number of particles increased/decreased} = [p(x, t + dt) - p(x, t)]dx.$$

由于能量守恒，为了使这种变化发生，必须有某种电流流动。该间隔内的电流为

$$\text{number of particles flowing in/out} = [S(x, t) - S(x + dx, t)]dt.$$

通过将两者相等，我们将得到

$$[p(x, t + dt) - p(x, t)]dx = [S(x, t) - S(x + dx, t)]dt.$$

一阶泰勒近似将给出 $p(x, t + dt) - p(x, t) = \frac{\partial p}{\partial t} dt$ 和 $S(x, t) - S(x + dx, t) = -\frac{\partial S}{\partial x} dx$ 。这将给出

$$\frac{\partial p}{\partial t} + \frac{\partial S}{\partial x} = 0. \quad (5.46)$$

因此，福克-普朗克方程可以被视为能量守恒的一种形式，其中 p 的变化（随时间）应等于 S 的变化（随空间）。

平衡解。 在平衡状态下，电流消失，因此我们有 $S = 0$ 。因此，我们可以证明以下内容。

Theorem 5.10. 在平衡状态下，由于概率流消失，概率分布 $p(x)$ 满足

$$D^{(1)}(x, t)p(x) = \frac{\partial}{\partial x} [D^{(2)}(x, t)p(x)].$$

Example 5.6. 例如，如果 $D^{(1)} = -\gamma x$ 且 $D^{(2)} = \frac{\gamma kT}{m}$ ，那么 $S = 0$ 将给出

$$\left(-\gamma x - \frac{\gamma kT}{m} \frac{\partial}{\partial x}\right)p(x) = 0.$$

然后 $-\gamma xp(x) = \frac{\gamma kT}{m} \frac{\partial}{\partial x} p(x)$ 。解这个微分方程将得到

$$p(x) = \sqrt{\frac{m}{2\pi kT}} e^{-\frac{mx^2}{2kT}}.$$

Example 5.7. 与 SMLD 的联系 让我们尝试将我们的结果与定义 3.1 中定义的 Eqn (3.1) 进行映射。我们将考虑一维情况。考虑以下朗之万方程

$$\underbrace{\frac{\partial x}{\partial t}}_{\xi} = \tau \underbrace{\frac{\partial}{\partial x} \log p(x)}_{h(\xi, t)} + \underbrace{\sigma}_{g(\xi, t)} \Gamma(t).$$

为了避免符号混淆，我们设 $W(x, t)$ 为该朗之万方程的解 $x(t)$ 的概率分布。该朗之万方程的 Kramers-Moyal 系数为

$$D^{(1)}(x, t) = h(x, t) + g'(x, t)g(x, t) = \tau \frac{\partial}{\partial x} \log p(x) \stackrel{\text{def}}{=} A(x)$$

$$D^{(2)}(x, t) = g(x, t)^2 = \sigma^2.$$

因此，相应的福克-普朗克方程为

$$\begin{aligned}\frac{\partial}{\partial t}W(x,t) &= -\frac{\partial}{\partial x} \left[D^{(1)}(x,t)W(x,t) \right] + \frac{\partial^2}{\partial x^2} \left[D^{(2)}(x,t)W(x,t) \right] \\ &= -\frac{\partial}{\partial x} [A(x)W(x,t)] + \sigma^2 \frac{\partial^2}{\partial x^2} W(x,t).\end{aligned}$$

在平衡状态下，当 $t \rightarrow \infty$ 时，概率分布 $W(x,t)$ 可以写成 $W(x)$ 。由于概率流消失，因此有

$$A(x)W(x) = \sigma^2 \frac{\partial}{\partial x} W(x).$$

回想 $A(x) = \tau \frac{\partial}{\partial x} \log p(x)$ ，因此有

$$\tau \frac{\partial}{\partial x} \log p(x) = \sigma^2 \frac{\partial}{\partial x} W(x).$$

由于我们可以自由选择 σ ，我们将其设为 $\sigma = \sqrt{\tau}$ 。然后上述方程简化为 $\frac{\partial}{\partial x} \log p(x) = \frac{\partial}{\partial x} W(x)$ 。对两边关于 x 积分将得到

$$\log p(x) = W(x) + C, \quad (5.47)$$

其中 C 为常数。设 $U(x) = e^{W(x)}$ 为概率分布，使得 $W(x) = \log U(x)$ 为对数似然，Eqn (5.47) 将给出 $p(x) = U(x)e^C$ 。由于 $p(x)$ 和 $U(x)$ 是概率分布，我们必须有 $\int p(x)dx = 1$ 和 $\int U(x)dx = 1$ 。因此，我们可以证明 $C = 0$ 。

因此，我们得出结论，如果我们运行朗之万方程直到收敛，解的概率分布 $W(x)$ 正是真实分布 $p(x)$ 。此外，噪声水平 σ 和步长 τ 的关系为 $\sigma = \sqrt{\tau}$ 。

5.5 结论性评述

本节我们探讨了布朗运动、朗之万方程以及福克-普朗克方程背后的物理学原理，并展示了统计物理学文献中的几个经典定理。我们的许多结果具有普遍性，因为它们适用于任何马尔可夫随机过程。超越马尔可夫过程的方法可以通过将空间/时间相关性限制在一个小范围内来实现。

关于这一主题的参考文献众多，其中许多源自物理学。Risken 的教科书 [33] 是该领域的经典参考，几乎涵盖了所有要素。对于寻求稍广泛内容的读者，Reichl 的统计物理学书籍 [31] 将能满足需求。

6 结论

本教程涵盖了近期文献中基于扩散的生成模型的一些基本概念。我们发现深入这些基本原理比停留在 Python 编程的表面更为重要。

在撰写本教程的过程中，我们学到了一些值得分享的经验。DDPM 的发展在许多方面是对 VAE 的扩展，无论是在结构上、证据下界的使用上，还是重参数化技巧上。尽管 DDPM 仍是最先进的方法之一，但如果未来的模型能够避免任何迭代，那将更为理想。最近的一些论文开始探索使用知识蒸馏来减少迭代次数的可行性。还有一些研究通过借鉴微分方程文献中的思想来研究加速方法。

对于对成像感兴趣的读者，得分匹配 Langevin 动力学很可能继续在解决逆问题中发挥基础作用。得分匹配函数的训练几乎与训练图像去噪器相同，而得分匹配步骤的应用与去噪步骤相同。因此，一旦我们知道如何将逆问题分解为前向模型和先验分布，我们就能够利用得分匹配进行后验采样。最近的方法也开始探索不同形式的贝叶斯扩散模型，以连接物理模型和数据驱动模型。

SDE 和 Fokker-Planck 方程提供了关于为什么 SMLD 方程以某种方式推导出来的重要理论直觉。从历史上看，SMLD 的发展似乎并不是从 SDE 开始的，但今天的认识帮助我们理解解统计的行为。

展望未来，扩散模型的最大挑战是与物理世界的一致性，更不用说它们的高计算复杂性。特定类别的学习将继续具有影响力。例如，可以使用手机上的图库图像训练定制的扩散模型。时间一致性将需要更大的模型和更多的内存来存储帧。需要新的架构来利用越来越多的时间输入。另一个开放的问题是如何将语言和语义引入图像生成。图像是否应该继续表示为像素数组（或特征像素），还是有新的方法可以用几句话描述场景而不丢失信息？最后，信息取证将是未来几十年最大的挑战，直到我们能够开发出有效的对策（或政策）。

致谢

本工作部分由美国国家科学基金会资助，奖项编号为 2030570、2134209 和 2133032，以及 SRC JUMP 2.0 中心和三星美国研究院的研究奖项支持。自 2024 年 3 月本草案发布在互联网上以来，我们收到了来自世界各地读者的许多建设性反馈。感谢大家的意见。还要感谢普渡大学的许多研究生，他们分享了关于本教程内容的好想法。我们要特别感谢 William Chi-Kin Yau，他在关于 Langevin 和 Fokker-Planck 方程的部分与我们不懈合作。

References

- [1] Michael S. Albergo, Nicholas M. Boffi, and Eric Vanden-Eijnden. Stochastic interpolants: A unifying framework for flows and diffusions. <https://arxiv.org/abs/2303.08797>.
- [2] Brian Anderson. Reverse-time diffusion equation models. *Stochastic Process. Appl.*, 12(3):313–326, May 1982. <https://www.sciencedirect.com/science/article/pii/0304414982900515>.
- [3] Kendall Atkinson, Weimin Han, and David Stewart. *Numerical solution of ordinary differential equations*. Wiley, 2009. https://homepage.math.uiowa.edu/~atkinson/papers/NAODE_Book.pdf.
- [4] Christopher Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [5] Charles A. Bouman and Gregory T. Buzzard. Generative plug and play: Posterior sampling for inverse problems. In *2023 59th Annual Allerton Conference on Communication, Control, and Computing (Allerton)*, pages 1–7, 2023. <https://arxiv.org/abs/2306.07233>.
- [6] Robert Brown. A brief account of microscopical observations on the particles contained in the pollen of plants and the general existence of active molecules in organic and inorganic bodies. *Edinburgh New Philosophical Journal*, pages 358–371, 1828.
- [7] Stanley H. Chan. *Introduction to Probability for Data Science*. Michigan Publishing, 2021. <https://probability4datascience.com/>.
- [8] Stanley H. Chan, Xiran Wang, and Omar Elgendy. Plug-and-Play ADMM for image restoration: Fixed point convergence and applications. *IEEE Trans. Computational Imaging*, 3(5):84–98, Mar 2017. <https://arxiv.org/abs/1605.01710>.
- [9] Hyungjin Chung and Jong Chul Ye. Score-based diffusion models for accelerated mri. *Medical Image Analysis*, 80:102479, 2022. <https://arxiv.org/abs/2110.05243>.
- [10] Peter Dayan, Geoffrey E. Hinton, Radford M. Neal, and Richard S. Zemel. The Helmholtz machine. *Neural Computation*, 7(5):889–904, 1995.
- [11] Mauricio Delbracio and Peyman Milanfar. Inversion by direct iteration: An alternative to denoising diffusion for image restoration. *Transactions on Machine Learning Research (TMLR)*, 2023. <https://openreview.net/forum?id=VmyFF51L3F>.
- [12] Carl Doersch. Tutorial on variational autoencoders, 2016. <https://arxiv.org/abs/1606.05908>.
- [13] Luca Donati. From Chapman-Kolmogorov equation to Master equation and Fokker-Planck equation. https://www.zib.de/userpage/donati/stochastics2023/03/lecture_notes/L03_dCKeq.pdf.
- [14] Albert Einstein. On the movement of small particles suspended in stationary liquids required by the molecular-kinetic theory of heat. *Annalen der Physik*, pages 549–560, 1905.
- [15] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 27, 2014. <https://arxiv.org/abs/1406.2661>.
- [16] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. <https://arxiv.org/abs/2006.11239>.
- [17] Jason Hu, Bowen Song, Xiaojian Xu, Liye Shen, and Jeffrey A. Fessler. Learning image priors through patch-based diffusion models for solving inverse problems, 2024. <https://arxiv.org/abs/2406.02462>.
- [18] Aapo Hyvärinen. Estimation of non-normalized statistical models by score matching. *Journal of Machine Learning Research (JMLR)*, 6(24):695–709, 2005. <https://jmlr.org/papers/volume6/hyvarinen05a/hyvarinen05a.pdf>.

- [19] Zahra Kadkhodaie and Eero P. Simoncelli. Solving linear inverse problems using the prior implicit in a denoiser, 2020. <https://arxiv.org/abs/2007.13640>.
- [20] Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. <https://arxiv.org/abs/2206.00364>.
- [21] Bahjat Kavar, Michael Elad, Stefano Ermon, and Jiaming Song. Denoising diffusion restoration models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. <https://arxiv.org/abs/2201.11793>.
- [22] Diederik P. Kingma, Tim Salimans, Ben Poole, and Jonathan Ho. Variational diffusion models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. <https://arxiv.org/abs/2107.00630>.
- [23] Diederik P Kingma and Max Welling. Auto-encoding variational Bayes. In *International Conference on Learning Representations (ICLR)*, 2014. <https://openreview.net/forum?id=33X9fd2-9FyZd>.
- [24] Diederik P. Kingma and Max Welling. An introduction to variational autoencoders. *Foundations and Trends in Machine Learning*, 12(4):307–392, 2019. <https://arxiv.org/abs/1906.02691>.
- [25] Andrey Kolmogorov. *Foundations of the Theory of Probability*. Dover, 2018. The original version was published in 1933 in German. <https://dn790007.ca.archive.org/0/items/foundationsofthe00kolm/foundationsofthe00kolm.pdf>.
- [26] Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. DPM-Solver: A fast ODE solver for diffusion probabilistic model sampling in around 10 steps. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. <https://arxiv.org/abs/2206.00927>.
- [27] Calvin Luo. Understanding diffusion models: A unified perspective, 2022. <https://arxiv.org/abs/2208.11970>.
- [28] Chenlin Meng, Robin Rombach, Ruiqi Gao, Diederik Kingma, Stefano Ermon, Jonathan Ho, and Tim Salimans. On distillation of guided diffusion models. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14297–14306, 2023. <https://arxiv.org/abs/2210.03142>.
- [29] Gabriel Nagy. MTH 235 differential equations, 2024. <https://users.math.msu.edu/users/gnagy/teaching/ade.pdf>.
- [30] R. Pawula. Generalizations and extensions of the Fokker-Planck-Kolmogorov equations. *IEEE Transactions on Information Theory*, 13(1):33–41, 1967.
- [31] L. E. Reichl. *A Modern Course in Statistical Physics*. John Wiley and Sons, Inc, 2 edition, 1998.
- [32] Danilo Rezende and Shakir Mohamed. Variational inference with normalizing flows. In *Proceedings of International Conference on Machine Learning (ICML)*, pages 1530–1538, 2015. <https://arxiv.org/abs/1505.05770>.
- [33] Hannes Risken. *The Fokker-Planck Equations: Methods of solutions and applications*. Springer, 2 edition, 1989.
- [34] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10684–10695, 2022. <https://arxiv.org/abs/2112.10752>.
- [35] Chitwan Saharia, William Chan, Saurabh Saxena, Lala Li, Jay Whang, Emily L Denton, Kamyar Ghasemipour, Raphael Gontijo Lopes, Burcu Karagol Ayan, Tim Salimans, Jonathan Ho, David J Fleet, and Mohammad Norouzi. Photorealistic text-to-image diffusion models with deep language understanding. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 35, pages 36479–36494, 2022. <https://arxiv.org/abs/2205.11487>.

- [36] Tim Salimans and Jonathan Ho. Progressive distillation for fast sampling of diffusion models. In *International Conference on Learning Representations (ICLR)*, 2022. <https://arxiv.org/abs/2202.00512>.
- [37] Yash Sanghvi, Yiheng Chi, and Stanley H. Chan. Kernel diffusion: An alternate approach to blind deconvolution. In *European Conference on Computer Vision (ECCV)*, 2024. <https://arxiv.org/abs/2312.02319>.
- [38] Jascha Sohl-Dickstein, Eric Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *Proceedings of International Conference on Machine Learning (ICML)*, volume 37, pages 2256–2265, 2015. <https://arxiv.org/abs/1503.03585>.
- [39] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations (ICLR)*, 2023. <https://openreview.net/forum?id=St1giarCHLP>.
- [40] Yang Song and Stefano Ermon. Generative modeling by estimating gradients of the data distribution. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. <https://arxiv.org/abs/1907.05600>.
- [41] Yang Song and Stefano Ermon. Improved techniques for training score-based generative models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020. <https://arxiv.org/abs/2006.09011>.
- [42] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations (ICLR)*, 2021. <https://openreview.net/forum?id=PXTIG12RRHS>.
- [43] Pascal Vincent. A connection between score matching and denoising autoencoders. *Neural Computation*, 23(7):1661–1674, 2011. https://www.iro.umontreal.ca/~vincentp/Publications/smdae_techreport.pdf.
- [44] M. von Smoluchowski. Zur kinetischen theorie der brownschen molekularbewegung und der suspensionen. *Annalen der Physik*, pages 756–780, 1906.
- [45] Martin J. Wainwright and Michael I. Jordan. Graphical models, exponential families, and variational inference. *Foundations and Trends in Machine Learning*, 1(1-2):1–305, 2008. <https://cba.mit.edu/events/03.11.ASE/docs/Wainwright.1.pdf>.
- [46] Max Welling and Yee Whye Teh. Bayesian learning via stochastic gradient Langevin dynamics. In *Proceedings of International Conference on Machine Learning (ICML)*, pages 681–686, 6 2011. <https://www.stats.ox.ac.uk/~teh/research/compstats/WelTeh2011a.pdf>.