

Machine Learning Principles

机器学习原理

Zhihao Li

Homepage: <https://lzhms.github.io/>

Email: zhihaoli25@stu.pku.edu.cn

1	The Math of Machine Learning	2
1.1	Basic Concepts and Notation	2
1.2	Basic Operations	7
1.3	Eigendecomposition	9
1.4	Singular Value Decomposition	9

课程导论

- 从生活中发现问题，收集数据、设计机器学习的算法模型，解决生活中的问题，例如房价预测问题；
- 确定研究目标，希望解决什么问题，是研究成功的一大半，不用担心目前没有找到解决方法的问题；

1 The Math of Machine Learning

1.1 Basic Concepts and Notation

矩阵表示具有 m 行 n 列的二维数组，记作 $A \in \mathbb{R}^{m \times n}$ ，其中 $\mathbb{R}$ 表示矩阵元素是实数域上的数值。

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}. \quad (1)$$

向量表示具有 n 个元素的一维数组，向量 $\mathbf{a} \in \mathbb{R}^n$ 默认指的是列向量：

$$\mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{bmatrix}. \quad (2)$$

在一个矩阵中，行向量表示为 $\mathbf{a}_i = A_{i,:}$ ，列向量表示为 $\mathbf{a}_j = A_{:,j}$ ，而矩阵也可以被紧凑地表达为

$$A = [\mathbf{a}_1, \cdots, \mathbf{a}_j, \cdots, \mathbf{a}_n]. \quad (3)$$

张量是标量、向量、矩阵等概念的一般化推广，可以认为向量是一阶张量，是张量的一般形式。




Figure 1: Tensor 的概念对比

Vector Space n 维向量空间是由一组包含有 n 个正交基张成的空间， n 维向量可以表示为空间中的一个坐标。
向量空间需要满足加法（Addition）和标量乘法（又称为数乘，scalar multiplication）两种运算。




Figure 2: 加法和数乘运算

Theorem 1 (Vector Space Definition)

设 x, y, z 均是 n 维向量, a, b 是标量, 则满足以下性质的向量集合称为向量空间。

闭包性质 (Closure) $x + y$ 和 ax 仍然在该向量空间中。

加法性质

$$x + y = y + x$$

$$(x + y) + z = x + (y + z)$$

$$\exists \mathbf{0}, \text{ s.t. } x + \mathbf{0} = x$$

$$\forall x, \exists -x, \text{ s.t. } x + (-x) = \mathbf{0}$$

数乘性质

$$a(bx) = (ab)x$$

$$\forall x, 1x = x$$

$$a(x + y) = ax + ay$$

$$(a + b)x = ax + bx$$

Theorem 2 (Vector Subspace Definition)

子空间 $W \in \mathbb{R}^n$ 是向量空间 $\mathbb{R}^n$ 的一个子空间, 当且仅当满足以下条件:

$$\mathbf{0} \in W$$

$$\forall x, y \in W, x + y \in W$$

$$\forall x \in W, a \in \mathbb{R}, ax \in W$$

Matrix Multiplication

$$C = AB, A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times p}, C \in \mathbb{R}^{m \times p} \quad (4)$$

其中，矩阵元素的表达式为

$$C_{ij} = \sum_{k=1}^n A_{ik} B_{kj}. \quad (5)$$

Remark 3 (Useful Skills)

对于矩阵 $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$, 有以下几种常用的矩阵乘法技巧:

$$\begin{aligned} AB &= [Ab_1, Ab_2, \dots, Ab_p] \\ &= [a_{1,:}B, a_{2,:}B, \dots, a_{m,:}B]^T \end{aligned}$$

Identity Matrix 单位矩阵记作 $I \in \mathbb{R}^{m \times n}$ 是一个方阵，其对角线元素为 1 其余元素均为 0.

$$AI = IA = A. \quad (6)$$

Diagonal Matrix 对角矩阵是一种特殊矩阵，其除了对角线元素以外，其余元素均为 0，因此是 $\mathbb{R}^{n \times n}$ 的方阵。

$$D = \text{diag}(d_1, d_2, \dots, d_n) \quad (7)$$

$$D_{ij} = \begin{cases} d_i & i = j \\ 0 & i \neq j \end{cases}. \quad (8)$$

Matrix Transpose

$$(A^T)_{ij} = A_{ji}$$

$$(A^T)^T = A$$

$$(A + B)^T = A^T + B^T$$

$$(AB)^T = B^T A^T$$

Symmetric Matrix 如果 $A = A^T$ ，则称矩阵 A 为对称矩阵；如果 $A = -A^T$ ，则称矩阵 A 为反对称矩阵。

对于任意的方阵 $A \in \mathbb{R}^{n \times n}$ ， $(A + A^T)$ 是对称矩阵， $(A - A^T)$ 是反对称矩阵。

对于任意的方阵 $A \in \mathbb{R}^{n \times n}$ ， A 可以唯一地表示为一个对称矩阵和一个反对称矩阵之和：

$$A = \frac{1}{2}(A + A^T) + \frac{1}{2}(A - A^T). \quad (9)$$

Trace of Matrix 对于一个方阵 $A \in \mathbb{R}^{n \times n}$ ，矩阵的迹是指其对角线元素之和，记作 $\text{tr}(A) = \sum_{i=1}^n A_{ii}$.

Remark 4 (Properties)

方阵的迹满足以下性质：

- If $A \in \mathbb{R}^{n \times n}$, then $\text{tr} A = \text{tr} A^T$

- If $A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times m}$, then $\text{tr}AB = \text{tr}BA$
- If $A, B \in \mathbb{R}^{n \times n}$, then $\text{tr}(A + B) = \text{tr}A + \text{tr}B$
- If $A \in \mathbb{R}^{n \times n}, t \in \mathbb{R}$, then $\text{tr}(tA) = t\text{tr}A$

Norm of Vector 对于一个实数而言，可以测定其绝对值表示其大小，而对于一个向量而言，采用向量范数来表征其长度，记为 $\|\mathbf{x}\|$ 。

欧拉范数或 L2 范数是最常用的向量范数，表示为：

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2}. \quad (10)$$

为了简要形式，可以对其平方后得到向量积形式：

$$\|\mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{x} = \langle \mathbf{x}, \mathbf{x} \rangle, \quad \text{where } \mathbf{x} \in \mathbb{R}^n. \quad (11)$$

Theorem 5 (Norm Definition of Vector)

通常使用的向量范数有：

1. l_1 Norm

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$$

2. l_2 Norm

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n x_i^2} = \sqrt{\mathbf{x}^T \mathbf{x}}$$

3. l_∞ Norm(极大模/最大范数)

$$\|\mathbf{x}\|_\infty = \max_i |x_i|$$

4. l_p Norm

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, p \geq 1$$

Norm of Matrix 对于矩阵 $A \in \mathbb{R}^{m \times n}$ ，矩阵范数可以看作是矩阵元素的向量化形式的范数。例如，列和范数和行和范数都是选出一个长度最大的向量代表矩阵的大小。

Theorem 6 (Norm Definition of Matrix)

通常使用的矩阵范数有：

1. l_1 Norm(列和范数)：所有矩阵列向量绝对值之和的最大值

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |A_{ij}|$$

2. l_2 Norm(谱范数)： $A^T A$ 矩阵的最大特征值的开平方

$$\|A\|_2 = \max_{X \in \mathbb{R}^n, \|X\| \neq 0} \frac{\|AX\|_2}{\|X\|_2} = \sqrt{\lambda_{\max}(A^T A)} = \sigma_{\max}(A)$$

3. l_∞ Norm(行和范数)：所有矩阵行向量绝对值之和的最大值

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |A_{ij}|$$

4. F Norm(F 范数, Frobenius 范数)：矩阵元素平方和的开平方

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n A_{ij}^2} = \sqrt{\text{tr}(A^T A)} = \sqrt{\sum_{i=1}^{\min\{m,n\}} \sigma_i^2}$$

Rank of Matrix 矩阵的列秩 (Column Rank) 是指矩阵中线性无关的列向量的最大数量, 记作 $\text{colrank}(A)$; 矩阵的行秩 (Row Rank) 是指矩阵中线性无关的行向量的最大数量, 记作 $\text{rowrank}(A)$; 矩阵的秩 (Rank) 是指矩阵中线性无关的行或列向量的最大数量, 记作 $\text{rank}(A) = \text{colrank}(A) = \text{rowrank}(A)$.

Theorem 7 (Properties of Rank)

对于矩阵 $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{n \times p}$, 矩阵的秩满足以下性质：

1. $\text{rank}(A) \leq \min\{m, n\}$
2. $\text{rank}(A + B) \leq \text{rank}(A) + \text{rank}(B)$
3. $\text{rank}(AB) \leq \min\{\text{rank}(A), \text{rank}(B)\}$
4. $\text{rank}(A) = \text{rank}(A^T)$
5. $\text{rank}(A) = \min\{m, n\}$, 则 A 为满秩矩阵
6. $\text{rank}(A) < \min\{m, n\}$, 则 A 为秩亏矩阵

Orthogonal Matrices 正交矩阵是满足 $Q^T Q = Q Q^T = I$ 的方阵 $Q \in \mathbb{R}^{n \times n}$, 即 $Q^T = Q^{-1}$, 因此只有方阵才可能为正交矩阵。

向量正交是指两个向量的点积为 0, 即 $\mathbf{x}^T \mathbf{y} = 0$, 归一化向量是指向量的范数为 1, 即 $\|\mathbf{x}\| = 1$.

标准正交矩阵是指一个方阵 $Q \in \mathbb{R}^{n \times n}$ 的列向量 (或行向量) 两两正交且均为单位/归一化/标准化向量, 即 $\mathbf{q}_i^T \mathbf{q}_j = 0$ 当 $i \neq j$, 且 $\|\mathbf{q}_i\| = 1$.

1.2 Basic Operations

1.2.1 Vector-Vector Products

Inner/Dot/Scalar Product 两个同维度的向量 $\mathbf{x} \in \mathbb{R}^n, \mathbf{y} \in \mathbb{R}^n$, 其内积 (inner product)、点积 (dot product) 或标量积 (scalar product) 仍然为一个标量。

$$c = \langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y} = \mathbf{y}^T \mathbf{x} = \sum_{i=1}^n x_i y_i \in \mathbb{R}. \quad (12)$$

Remark 8 (Properties)

点积具有的一些基本运算性质:

1. $\langle \mathbf{x}, \mathbf{y} \rangle \leq 0$
2. $\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle$
3. $\langle a\mathbf{x}, \mathbf{y} \rangle = a\langle \mathbf{x}, \mathbf{y} \rangle$
4. $\langle \mathbf{x}, \mathbf{y} + \mathbf{w} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{x}, \mathbf{w} \rangle$

向量积的物理/几何意义:

1. 表征或计算两个向量之间的夹角;
2. 计算 $\mathbf{y}$ 向量在 $\mathbf{x}$ 向量方向上的投影。

Cosine Similarity $c = \langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y} = \mathbf{y}^T \mathbf{x} = \sum_{i=1}^n x_i y_i = |\mathbf{x}| |\mathbf{y}| \cos \theta$

Exterior/Cross Product 解析几何中向量的外积 (Exterior Product) 或叉乘 (Cross Product) $\mathbf{x} \times \mathbf{y}$ 是一个向量, 其长度等于 $|\mathbf{x} \times \mathbf{y}| = |\mathbf{x}| |\mathbf{y}| \sin \angle(\mathbf{x}, \mathbf{y})$, 其方向正交于 $\mathbf{x}, \mathbf{y}$, 并且 $(\mathbf{x}, \mathbf{y}, \mathbf{x} \times \mathbf{y})$ 构成右手系。

在三维几何中, 向量叉乘得到的新的向量又被称为法向量, 垂直于两个向量构成的平面, 在 3D 图形学中常被用来构造 X, Y, Z 坐标系。

Outer Product 线性代数中向量的外积 (Outer Product) 生成的是一个矩阵, 也被称为张量积, 即两个向量 $x \in \mathbb{R}^m$ 与 $y \in \mathbb{R}^n$ 运算得到:

$$C = xy^T \in \mathbb{R}^{m \times n} = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \dots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \dots & x_2 y_n \\ \vdots & \vdots & \ddots & \vdots \\ x_m y_1 & x_m y_2 & \dots & x_m y_n \end{bmatrix}. \quad (13)$$

1.2.2 Matrix-Vector Products

矩阵向量积是指一个给定的矩阵和一个向量相乘, 结果仍然是一个向量:

$$A \in \mathbb{R}^{m \times n}, x \in \mathbb{R}^n, y = Ax \in \mathbb{R}^m. \quad (14)$$

将 A 写作列向量的形式, 矩阵向量积又可以看作是线性组合, A 的列向量行程坐标系, x 的各个元素是相应的坐标。

$$y = Ax = [a_1, a_2, \dots, a_n] \begin{bmatrix} x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix} = x_1 a_1 + x_2 a_2 + \dots + x_n a_n. \quad (15)$$

1.2.3 Matrix-Matrix Products

矩阵积有不同的表示形式, 可以视为不同形式的向量积或向量矩阵积。

Vector-Vector Products

$$C = AB = [a_1, a_2, \dots, a_n] \begin{bmatrix} b_1^T \\ b_2^T \\ \dots \\ b_n^T \end{bmatrix} = \sum_{i=1}^n a_i b_i^T. \quad (16)$$

Vector-Matrix Products

$$C = AB = A [b_1, b_2, \dots, b_n] = [Ab_1, Ab_2, \dots, Ab_n]. \quad (17)$$

$$C = AB = \begin{bmatrix} a_1^T \\ a_2^T \\ \dots \\ a_m^T \end{bmatrix} B = \begin{bmatrix} a_1^T B \\ a_2^T B \\ \dots \\ a_m^T B \end{bmatrix}. \quad (18)$$

Remark 9 (Properties)

一些有用的矩阵积的性质：

1. 结合律： $(AB)C = A(BC)$
2. 分配律： $A(B + C) = AB + AC$
3. 非交换律： $AB \neq BA$

1.3 Eigendecomposition

特征值分解 (Eigendecomposition) 是将一个方阵分解为其特征向量和特征值的形式。

$$Av = \lambda v. \quad (19)$$

其中， $A \in \mathbb{R}^{n \times n}$ 是一个方阵， $v \in \mathbb{R}^n$ 是 A 的特征向量， $\lambda \in \mathbb{R}$ 是对应的特征值。

几何意义表示， v 在 A 作用下以比例为 λ 进行拉伸或压缩，而不改变方向。

$$\begin{array}{c}
 \mathbf{A} \\
 \left[\begin{array}{|c|c|c|} \hline & & \\ \hline & & \\ \hline & & \\ \hline \end{array} \right] = \underbrace{\left[\begin{array}{|c|c|c|} \hline v_1 & v_2 & v_3 \\ \hline \end{array} \right]}_{\text{Eigen vectors of } \mathbf{A}} \underbrace{\left[\begin{array}{ccc} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{array} \right]}_{\text{Eigen values of } \mathbf{A}} \underbrace{\left[\begin{array}{|c|c|c|} \hline v_1 & v_2 & v_3 \\ \hline \end{array} \right]^{-1}}_{\text{Eigen vectors of } \mathbf{A}}
 \end{array}$$

Figure 3: 特征值分解

$$\mathbf{A} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^{-1}. \quad (20)$$

其中， $\mathbf{P} = [v_1, v_2, \dots, v_n]$ 是由 A 的特征向量组成的矩阵， $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ 是由对应的特征值组成的对角矩阵。

矩阵 A 是实对称矩阵时，对应的特征向量矩阵 P 的各个特征向量是单位向量且正交，即可以作为一个线性空间的一组基向量，在特征向量张成的线性空间中，矩阵 A 的坐标值就是特征值。

1.4 Singular Value Decomposition

只有方阵才能进行特征值分解，而奇异值分解 (Singular Value Decomposition, SVD) 可以对任意形状的矩阵进行分解。




Figure 4: 奇异值分解

对于矩阵 $A \in \mathbb{R}^{m \times n}$, 其奇异值分解为:

$$A = U \Sigma V^T. \quad (21)$$

为了求解 U 和 V , 可以通过计算 $A^T A$ 和 AA^T 的特征值和特征向量来实现。

$$(A^T A)v_i = \lambda_i v_i, \quad i = 1, 2, \dots, n \quad (22)$$

$$(AA^T)u_i = \mu_i u_i, \quad i = 1, 2, \dots, m. \quad (23)$$

其中, v_i 称为右奇异向量, u_i 称为左奇异向量。

$$AV = U \Sigma V^T V$$

$$AV = U \Sigma$$

$$Av_i = \sigma_i u_i$$

$$\Rightarrow \sigma_i = Av_i / u_i$$