




Zhihao Li's
Pocket Book

From 2024
to 2025

Professional Intuitions

Zhihao Li

Computer Science and Technology, Xidian University

zhihaoli@stu.xidian.edu.cn

CONTENTS

CHAPTER 1

PROFESSION & LEARNING

PAGE 5

1.1	Mathematical Principles	5
1.1.1	仿射变换 (Affine Transformation)	5
1.1.2	非线性频率压缩	5
1.1.3	离散 Bucket 设计	5
1.1.4	哈达玛积 (Hadamard product)	6
1.2	Computer Graphics	6
1.2.1	Camera Theory	6
	相机成像	6
	相机内参	6
	视场角 (FoV)	7
	球谐函数 (Spherical Harmonics)	8
	关键帧	9
	UV 坐标系统	9
1.3	Digital Human	9
1.3.1	Model Learning	9
	FLAME	9

CHAPTER 2

PHILOSOPHY & INSIGHT

PAGE 11

2.1	Research Guidelines	11
2.1.1	Research Purpose	11
2.1.2	Global Stages	11
2.1.3	Early Stage	11
2.1.4	Research Survey	12
	Purpose	12
	Roadmap	12
	Survey Stage	12
2.2	Research Habits	13
2.2.1	Paper Reading	13
	跟进前沿	13
	论文略读	13
	论文精读	13
	论文总结	13
2.2.2	Experiment Exploration	14
2.2.3	Balanced Life	14
2.2.4	Future Planning	14

CHAPTER 3	VIEWS & INSPIRATION	PAGE 15
3.1	Scene Reconstruction	15
3.1.1	Solid Work	15
	<i>[Surface-Splatting-Based] [TOG 2023 3DGS] 3D Gaussian Splatting for Real-Time Radiance Field Rendering</i>	15
3.2	3D Facial Reconstruction	16
3.2.1	Classic Work	16
	<i>[3DGS-Based] [CVPR 2024 GaussianAvatars] Photorealistic Head Avatars with Rigged 3D Gaussians</i>	16
3.3	Co-speech Gesture Generation	17
3.4	Audio-driven Talking Head Generation	17
3.4.1	Conference	18
3.4.2	Keywords	18
3.4.3	Goals	18
3.4.4	Challenges	19
	<i>Audio-motion Correlation</i>	19
	<i>Mean Face</i>	19
3.4.5	Preliminaries	19
	<i>3D Morphable Model</i>	19
	<i>Audio Extractor</i>	19
	<i>Video Extractor</i>	19
	<i>Modalities Fusion</i>	20
3.4.6	Benchmarks	20
3.4.7	Baseline	20
3.4.8	Backbones	20
3.4.9	Metrics	20
	<i>PSNR</i>	20
	<i>SSIM</i>	20
3.4.10	SOTA	21
3.4.11	Video-Editing	21
	<i>[Implicit-Keypoint-Based] [CVPR 2024 LivePortrait] Efficient Portrait Animation with Stitching and Retargeting Control</i>	21
3.4.12	Single-Image	22
	<i>[Diffusion-Based] [CVPR 2024 EMO] Emote Portrait Alive - Generating Expressive Portrait Videos with Audio2Video Diffusion Model under Weak Conditions</i>	22
	<i>[3DGS-Based] [ECCV 2024 TalkingGaussian] Structure-Persistent 3D Talking Head Synthesis via Gaussian Splatting</i>	24
	<i>[3DMM-Based] [CVPR 2023 VividTalk] One-Shot Audio-Driven Talking Head Generation Based on 3D Hybrid Prior</i>	25
	<i>[GAN-Based] [CVPR 2018 LMG] Lip Movements Generation at a Glance</i>	26
	<i>[GAN-Based] [CVPR 2019 FacialAnimation] Realistic Speech-Driven Facial Animation with GANs</i>	27
	<i>[GAN-Based] [CVPR 2017 Speech2Vid] You said that?</i>	27
3.5	Audio-driven Human Video Generation	27
3.5.1	Single-Image	27
	<i>[Diffusion-Based] [CVPR 2025 EMO2] End-Effector Guided Audio-Driven Avatar Video Generation</i>	27
CHAPTER 4	CODING & SKILLS	PAGE 29
4.1	Environment Configuration	29
4.1.1	Miniconda Installation On Linux	29

4.1.2	<i>Pytorch3d</i> Installation on Windows	29
4.1.3	<i>Ninja</i> Installation on Linux	30
4.2	Python Debugging	30
4.2.1	<i>Visual Studio Code</i> Debugging Configuration	30
4.3	Bugs with Solution	32
4.3.1	Version Conflict	32
4.4	Coding Tricks	32
4.4.1	Python	32
4.4.2	Cmd On Windows	38

CHAPTER 5

GRAMMAR & WRITINGS

PAGE 39

5.1	Mathematical Symbols in LaTeX	39
5.1.1	集合及向量空间的表示	39
5.1.2	运算符号	39
5.1.3	多行公式	39
5.2	Extended Markdown	40
5.3	Elaborating Ideas	41

CHAPTER 6

TEMPLATES & TOOLS

PAGE 42

6.1	Templates	42
6.1.1	Loss Calculation	42
	<i>L1 Loss</i>	42
	<i>L2 范数</i>	42
	<i>L3 范数</i>	43
	<i>Scaling Loss</i>	43
	<i>Cosine Similarity Loss</i>	43
	<i>Pixel-level Reconstruction Loss</i>	44
	<i>Perceptual Loss</i>	44
6.1.2	Computer Graphics	45

Chapter 1

Profession & Learning

1.1 Mathematical Principles

1.1.1 仿射变换 (Affine Transformation)

$$price = w_{area} \cdot area + w_{age} \cdot age + b \quad (1.1)$$

仿射变换的特点是通过加权和对特征进行线性变换，并通过偏置项进行平移。

1.1.2 非线性频率压缩

在滤波器设计中将整个模拟频率轴压缩到 π/T 之间，使得 $H_a(s), s = j\Omega$ 压缩为 $\widehat{H}_a(s_1), s_1 = j\Omega_1$ ，可以利用正切变换实现频率压缩模型：

$$\Omega = \frac{2}{T} \tan\left(\frac{1}{2}\Omega_1 T\right) \quad (1.2)$$

这个设计思想实质上利用了正切函数定义域有限、值域无限以及奇函数的性质；推而广之，这种设计可以实现特定的单值压缩方法，也可以实现值域的延展。

1.1.3 离散 Bucket 设计

一些类似的函数特性，对数函数，指数函数分别适合于定义域、值域取值 $0 \sim 1$ 之间的情况，但是对目标域都有所限制，因此这些函数往往没有正切函数具有优良的特性。

对于一个连续角速度变量 w ，将其序列范围划分为 d 个大小不同的离散速度 buckets。每一个 bucket 都有一个中心 $c_i \in \{c_1, \dots, c_d\}$ 以及一个半径 $r_i \in \{r_1, \dots, r_d\}$ ，为了表示不同 bucket 的重要性，可以将角速度变量 w 转换为向量 $\vec{s} \in \mathcal{R}^d$ 表示，其中第 i 个值记为，

$$s_i = \tanh\left(\frac{w - c_i}{r_i} * 3\right) \quad (1.3)$$

其中， $\tanh(x)$ 函数是双曲正切函数 (hyperbolic tangent function)，值域是 $(-1, 1)$ 且单调递增，常用作激活函数，其定义为，

$$\tanh(x) = \frac{\sinh(x)}{\cosh(x)} = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (1.4)$$

这种 bucket 方式用于将一个连续变量转换为特征向量表示，并且对于 $(w - c_i)/r_i$ 考虑了 w 距离 bucket c_i 的相对距离，而非绝对距离以保证对不同 bucket 具有一致的衡量标准。

1.1.4 哈达玛积 (Hadamard product)

Hadamard 乘积是矩阵的一类运算，对形状相同的矩阵进行运算，并产生相同维度的第三个矩阵。在数学中，Hadamard 乘积（也称为 Schur 乘积或逐元素乘积）是一种二元运算，它用两个具有相同维数的矩阵产生另一个具有相同维数的矩阵，其中每个元素 (i, j) 是原始两个矩阵的元素 (i, j) 的乘积。它是由法国数学家雅克·哈达玛 (Jacques Hadamard) 或德国数学家 Issai Schur 命名的。

$$C = (A \odot B)_{ij} = a_{ij} * b_{ij} \quad (1.5)$$

1.2 Computer Graphics

1.2.1 Camera Theory

相机成像

相机成像过程涉及到四个坐标系的变换，世界坐标系经过刚体变换（缩放、旋转、平移）后变成了相机坐标系，再次经过透视投影变成图像坐标系，最后经过仿射变换变成像素坐标系。

$$Z \begin{pmatrix} u \\ v \\ 1 \end{pmatrix} = \underbrace{\begin{pmatrix} \frac{1}{dX} & -\frac{\cot\theta}{dX} & u_0 \\ 0 & \frac{1}{dY\sin\theta} & v_0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} f & 0 & 0 & 0 \\ 0 & f & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}}_{\text{内参矩阵}} \underbrace{\begin{pmatrix} R & T \\ 0 & 1 \end{pmatrix} \begin{pmatrix} U \\ V \\ W \\ 1 \end{pmatrix}}_{\text{外参矩阵}}$$

仿射变换 透视投影 刚体变换

↓ ↓ ↓

内参矩阵 外参矩阵

CSDN @思妙想多财·杰

Figure 1.1: 坐标系变换过程

为了简洁表示，一般都通过内参矩阵和外参矩阵来实现坐标系的转换，内参矩阵就是相机的内参，外参矩阵就是相机的外参。

相机内参

相机内参包括相机的焦距 (Focal Length) 以及主点 (Principal Point)，焦距指的是成像元件的光学中心到成像平面的距离，单位通常是像素；主点是相机图像平面上的主点坐标，也就是图像坐标系的原点，通常是相机的光学中心在图像平面上的投影。主点是相机图像中理想情况下图像中心的位置，通常接近图像的几何中心，但在实际相机中，由于制造偏差，可能不完全重合。

针孔相机模型




Figure 1.2: 相机内参计算

根据图 1.2 可以计算出对应的内参矩阵，一般来说， f_x 和 f_y 在一个理想的相机中应该是相同的，但是由于像素的非方形（长宽比不一致）或者相机的几何畸变，这两个值通常是不同的。它们反映了每个像素在水平方向和垂直方向上对应的实际焦距，如公式 1.6 所示。

$$K = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \quad (1.6)$$

- f_x 和 f_y 分别是相机的横向和纵向焦距，在像素单位下的水平和垂直方向上的投影比例系数，表示了相机成像的缩放效果，通常以像素单位进行测量；当像素单元是正方形时， $f_x = f_y$ ，是长方形时， $f_x \neq f_y$ 。
- c_x 和 c_y 是相机光心在像素坐标系下的水平和垂直方向上的位置，表示了相机成像中心在图像上的位置。

视场角 (FoV)

视场角是以光学仪器的镜头为顶点，以被测目标的物像可通过镜头看到的最大范围的两条边缘构成的夹角，称为视场角 (Field of View, FoV)。FoV 指的是相机视场张角，用来描述拍摄的范围。

最常用的是水平视场角 (VFoV) 和垂直视场角 (HFoV)，其与焦距的转换关系如下公式所示。

$$\begin{cases} \tan \frac{VFoV}{2} = \frac{w/2}{f_x} \Rightarrow f_x = \frac{w}{2 \tan \frac{VFoV}{2}} \\ \tan \frac{HFoV}{2} = \frac{h/2}{f_y} \Rightarrow f_y = \frac{h}{2 \tan \frac{HFoV}{2}} \end{cases} \quad (1.7)$$




Figure 1.3: FoV 视角分布

球谐函数 (Spherical Harmonics)

球谐函数 (SH) 是一种用于近似球面函数的数学工具，在计算机图形学中广泛用于光照和渲染。

1. 基本概念

球谐函数的阶数 (Degree)

- 0 阶：常数项，表示均匀光照；
- 1 阶：线性变化，可以表示主要方向的光照；
- 2 阶：二次变化，可以表示更复杂的光照；
- 3 阶：更高次变化，可以表示更细致的光照细节。

2. 系数数量

对于 degree 为 L 的球谐函数，总系数数量为 $(L+1)^2$ ，例如当 $L=3$ 时：总系数 = 16 个，包含 0 阶：1 个系数，1 阶：3 个系数，2 阶：5 个系数，3 阶：7 个系数。

3. 光照表示

- 用于表示每个高斯点的方向性光照响应；
- 较高的 degree 可以表示更精细的光照变化；
- 默认值 3 提供了良好的视觉质量和计算效率的平衡。

4. 性能影响

- degree 越高，需要存储的系数越多；
- 计算复杂度随 degree 增加而增加；
- 内存占用也随 degree 增加而增加。

5. 质量与效率权衡

- 较低 degree(0-1)：基础光照，效果简单；
- 中等 degree(2-3)：较好的视觉效果，适中的计算量；
- 高 degree(4+)：更精细的光照细节，但计算成本高。

关键帧

关键帧（代表帧，Key frame）是视频中一个镜头的关键图像帧，可以反映一个镜头的主要内容。关键帧间隔指的是两个关键帧之间间隔的中间帧数量，+ 较小的间隔 = 更细腻动画 + 较大的间隔 = 更粗糙但效率更高


UV 坐标系统

UV 坐标是 3D 模型的二维纹理坐标系统，用于定义如何将 2D 纹理图像映射到 3D 模型表面。

1. 基本概念

- U: 横向坐标 (类似 X 轴);
- V: 纵向坐标 (类似 Y 轴);
- 范围: 通常在 [0,1] 或 [-1,1] 之间.

2. UV 映射原理



3. UV 坐标系统特点

- 二维性: 将 3D 表面”展开”到 2D 平面;
- 连续性: 保证纹理在模型表面连续;
- 无缝性: 避免纹理接缝和扭曲.

1.3 Digital Human

1.3.1 Model Learning

FLAME

```

1 flame_param = {
2     'shape': tensor,          # 形状参数
3     'expr': tensor,          # 表情参数
4     'rotation': tensor,      # 旋转参数
5     'neck_pose': tensor,     # 颈部姿态
6     'jaw_pose': tensor,      # 下巴姿态
7     'eyes_pose': tensor,     # 眼睛姿态
8     'translation': tensor,   # 平移参数
9     'static_offset': tensor, # 静态偏移

```

```
10     'dynamic_offset': tensor # 动态偏移
11 }
```

Chapter 2

Philosophy & Insight

2.1 Research Guidelines

2.1.1 Research Purpose

“大道至简”，追求 *simple and effective* 研究。学习姚期智院士的选题三问，

1. 你的研究选题真的很重要吗？
2. 有多少人在做？
3. 为什么轮到了你来做？

关于学术品味，姚期智院士曾讲，“一个好的问题应该是漂亮的，即简洁、新颖、令人惊讶；也应该是重要的，即人们关心其答案；并且应该具有普遍吸引力，能够超越学术界限，引起广泛关注”。

- Attractive (漂亮的): Simplicity; Novelty; Surprise;
- Importance (重要的): People care what the answer is;
- Universe (普遍的): Transcends academic boundaries.

2.1.2 Global Stages

1. 不要被工程化的思维所束缚，做 A+B 的工作，着重分析本质，从源头创新。

2.1.3 Early Stage

1. 前期注重多看研究论文，精度并总结，打牢基础，做研究综述。
2. **研究综述**：有多少途径能够实现研究目的，各自是从哪些地方出发的，本质的区别是什么。
3. 对研究的议题有深入且广泛的了解，目前领域中的研究进展如何，明确 SOTA 是什么；
4. 明确有哪些子议题及技术已经被探讨，可以知道哪些还可以开发以及哪些技术可以被自己的研究议题拿来应用；

2.1.4 Research Survey

Purpose

1. 对研究的议题有深入且广泛的了解，目前领域中的研究进展如何，明确 SOTA 是什么；
2. 明确有哪些子议题及技术已经被探讨，可以知道哪些还可以开发以及哪些技术可以被自己的研究议题拿来应用；

Roadmap

1. 在该领域中主要的国际会议是什么；
2. 对这些会议近几年来（至少三年）所发表过的论文的 title 以及 abstract 浏览一次，寻找跟研究议题比较相关的论文（十来篇到二、三十篇或者更多）；
3. 阅读论文的 Introduction，做个初步的浏览，然后将这些论文依照它们与自己的研究议题的相关性做个大致的排序；
4. 依序对这些论文仔细地研读，每篇论文的重点是什么、关键的技术又是什么；
5. 文献追溯，研读的每篇论文，需要关注于它们探讨过哪些相关的文献，并且就其中与自己研究议题最相关的论文，也需要仔细地研读（追溯大概三、四代）。

Survey Stage

在这一部分，主要介绍在 survey 的过程中，分为几个阶段以及每个阶段应当把握的原则（检测 Roadmap 的指南）是什么。

1. Stage 1: 第一阶段的任务是 survey 与研究议题相关的主要国际会议，通常不超过 3 到 5 个。将与研究议题相关的最近几篇论文拿出来，看看这些论文所引用的文献有没有所不知道的，如果没有，那么比这些论文早的文献你大概都没遗漏了。如果有，就把它找出来仔细地研读。
2. Stage 2: 第二阶段的任务是 survey 更多的国际会议或 workshop，注意每篇文章的发表位置，从而找到有哪些可能相关的国际会议。仔细研读这些论文有什么突破，同时注意这些论文引用的参考文献有没有尚未读过的，没有的话表示前阶段的 survey 做的很仔细，有的话就需要把这些遗漏的论文找出来研读，并且用前面提到的方法再去追溯这篇论文三、四代以内的参考文献。

通常而言，在第二阶段找到的论文不会太多，大多数的论文在 survey 的第一阶段都会看到。

这些过程一定会收敛的，而当你发现没有新的论文被你找出来之后，你的 survey 工作大概已经做的差不多了，可以准备收工全心投入研究议题上。

进入研究阶段的时机，当你发现拿到一篇新论文时只要看完它的 Introduction 之后，你就知道这篇论文的重点及猜出它用的主要技术之后，你的功力已经提升到可以进入研究议题的阶段了。在这个阶段，如果论文的研读够深入及广泛，你往往也可以发现新的研究议题。

整个 survey 的阶段会看完几篇论文？三十篇以上是至少的，如果部分只浏览 Introduction 的部分，那可能能在五、六十篇以上。

2.2 Research Habits

2.2.1 Paper Reading

跟进前沿

关注领域内发展，要跟进最新研究成果，及时搜集最新研究论文。

- 统一的渠道：X-MOL 学术平台并保持邮件推送。
- 分散的渠道：各个期刊会议的官网。

论文略读

1. 阅读题目和整体流程图；
 2. 阅读摘要和 Introduction；
 3. 选择性阅读 Method 模块。
- 阅读原则：明确研究目标、研究问题、解决方案以及方法流程。
 - 总结原则：一段话总结 + 贡献点 + 启发思路。

论文精读

1. 先阅读题目、摘要、Introduction 和 Method；
 2. 再阅读 Related Work；
 3. 选择性阅读实验部分。
- 阅读原则：明确研究目标、研究问题、解决方案以及方法流程。
 - 总结原则：一段话总结 + 手推思路。

论文总结

1. 论文阅读后及时总结，多发掘创新点、启发点；
 2. 积累论文写作经验，可以在阅读论文中总结；
 3. 集中在一个地方整理笔记，形成研究发展体系。
- 略读选择的平台：TexStudio 汇总笔记。
 - 精读选择的平台：TexStudio 汇总笔记 + 纸质笔记。

2.2.2 Experiment Exploration

1. 积累代码实现，技巧、工具库以及模板等；
 2. 多进行代码阅读，关注核心代码的编写；
 3. 关注重要的实验细节，积累调参技巧。
- 积累选择的平台：TexStudio 汇总笔记。

2.2.3 Balanced Life

1. 调控健康的生活节奏，尽量不要熬夜、不要懒觉；
2. 安排适量的运动，保证每周都能有三到五次的运动锻炼；
3. 注重健康饮食，忌高油高盐，保持均衡的营养摄入。

2.2.4 Future Planning

1. 提起规划未来半年到一年的安排；
2. 半年内的计划需清晰具象；
3. 一年内的计划可模糊笼统。

Chapter 3

Views & Inspiration

3.1 Scene Reconstruction

3.1.1 Solid Work

[Surface-Splatting-Based] [TOG 2023 3DGS] 3D Gaussian Splatting for Real-Time Radiance Field Rendering




Figure 3.1: 3DGS

1. Goals: novel-view synthesis
2. Problem: 解决对无边界和完整场景的 1080p 分辨率实时渲染。
3. Solution: 作者提出了一种新颖的场景表示方法，即采用 3D Gaussian 进行场景表示，同时执行交错式的对 3D Gaussians 的优化和密度控制（核心部分），实现对场景的精确表示。
4. Contribution: 提出了一个快速渲染算法支持各向异性泼溅、加速训练和实时渲染。
5. Inspiration: 从一组稀疏的没有法线的 SfM 点集中优化一个场景表示并允许高质量的新颖视图合成，需要一种能够继承可微体积表示的体素，同时是非结构化的以及允许快速渲染。3D Gaussians 是一个可微分的体积表示，易于投影到 2D 平面进行高效地光栅化并应用标准 α 混合进行渲染。之前采用 2D 点的方法假定每个点都是一个具有法线的小平面圆，但由于 SfM 点的稀疏性，非难估计出法线，即便能够估计出这样的法线，也会含有较大噪声。而优化这些较大的噪声法线是非常困难的。因此采用 3D Gaussians 建模几何是不需要法线的，这样就规避了这个问题。
6. Details: 3D Gaussians 是通过在世界空间中定义的 3D 协方差矩阵表示的，源于 2001 年的 Surface Splatting.

3.2 3D Facial Reconstruction

3.2.1 Classic Work

[3DGS-Based] [CVPR 2024 GaussianAvatars] Photorealistic Head Avatars with Rigged 3D Gaussians

1. Views: GaussianAvatars 一种新颖的方法能够生成表情、姿势和视角完全可控的逼真的头像，核心的思想是将基于 3DGS 的动态 3D 表示与参数化可形变人脸模型进行绑定。这种结合实现逼真渲染的同时能够允许高精度肖像控制，通过内在的参数模型，例如来自驱动序列的表情迁移以及调节形变模型的参数。
2. Contributions:
 - 提出了 GaussianAvatars，一种新的结合 3DGS 与参数化人脸模型的人头肖像生成方法。
 - 设计了一个约束性继承策略，能够支持添加和移除 3D 高斯以实现自适应控制。
3. Reproducition:
 - 原始数据：

一个 subject 在一种表情/姿态下，对应 16 个相机 views 拍摄的视频序列，每一个视频序列均 73 FPS 持续 5s，包含 365 帧图像，分辨率为 2200×3208。
 - 数据处理：
 - 从视频序列中提取帧数据，施加下采样的缩放比例 2.4 并移除图像的背景。
 - 针对下采样比例为 4 的图像数据，利用 LandmarkDetectorSTAR 进行关键点检测。然后再所有帧数据上随机采样进行序列跟踪，优化每一帧人脸的姿势和表情参数。初始化参数在第一帧图像上，然后对第一帧图像的刚性形变、全局的关键点以及 RGB 纹理和全局参数以及静态位移都进行 500 步的优化迭代。然后在剩余的全部帧图像上进行序列跟踪。最后通过随机选择一帧图像就行全局跟踪，优化所有的参数。
 - 以 NeRF 格式导出序列跟踪的结果。
 - 模型准备：

首先初始化 Gaussian 模型的各个高斯球属性，球谐函数阶数、位置、不透明度、缩放以及旋转等参数。然后根据形状和表情参数初始化 FLAME 模型，包括牙齿参数。最后初始化绑定参数，包括绑定关系以及三角形面元中心位置、缩放以及朝向。
 - 场景准备：

首先加载每帧图像的信息，以及相机参数，然后加载预先获取的 FLAME 参数，统一构造出场景信息。然后高斯模型加载场景的 Mesh 网格信息，然后从 PCD 中创建高斯点云。
 - 模型训练：

初始化优化参数（FLAME 和 Gaussian 属性）后，从数据集中随机选择一帧图像，根据时间步选择对应帧的 FLAME 参数，通过 FLAME 模型 forward 得到顶点属性，并更新现有的网格属性。然后通过高斯微分光栅化器进行场景渲染，得到渲染的图像和可见性滤波器等属性。接着计算各个损失项，并判断是否需要进行致密和裁剪操作。最后计算梯度，进行参数的更新。




Figure 3.2: GaussianAvatars

3.3 Co-speech Gesture Generation

3.4 Audio-driven Talking Head Generation

Audio-driven Talking Head Generation 涉及了 Audio, Frame(Image) 以及它们的混合, 这是一个 Cross-modality generation 的问题, 旨在基于一种模态的数据合成另一种不同模态的数据。

Audio-driven 的方法中, 肖像的面部运动是直接从音频输入预测的, 确保真实和自然性是一个关键点。

通用视频生成是生成领域的研究问题, 具体在数字人领域聚焦以人为中心的视频生成, 研究领域包括 portrait video generation 和 human animation。而 talking head generation 是这个 field 中最显著的 area, 旨在合成一个能够匹配上输入音频的人头说话视频, 并捕获人脸表情、人头运动和嘴唇运动。

Lip Movements Generation 是这个 area 的 sub-problem, 旨在根据音频生成一致且平滑的 Lip Motion 序列, 其理论基础是 speech 是与 lip movements 高度相关的, 由此也兴起了概念——唇读 Lip Reading。最早的研究方法, 采用 LSTM 主要是从目标身份的大量视频帧中检索图像而不是生成图像, 随着 GAN 的兴起, 一些方法开始转向直接生成 Lip Motion。

研究方法总体上可以分为两类, 一类是 video-based methods 和另一类是 single-image。video-based talking head generation 允许直接在输入视频片段上进行编辑, 例如在输入视频上生成与音频匹配的嘴唇运动 [Live-Portrait]。这类方法的缺点是, 依赖于一个基本的视频, 导致保持固定的头部运动而只生成嘴部运动, 致使限制真实性。single-image talking head generation 利用一张输入的参考图像生成一个与图像外观一样的视频 [EMO]。

由于模糊性和一对多映射的关系, 将音频转换到人头动画是非常具有挑战性的。在 talking head 研究上, 最多的技术路线就是将头部运动和面部表情分开处理。他们认为, talking head 的面部运动主要来自于非刚性表情形变和刚性头部运动两个部分。

- 对于头部运动，由于与音频的弱相关性是非常难建模的，一些研究方法利用一个视频提供头部姿势或者在说话的过程中保持头部静止，另一些研究方法提出直接从音频中学习头部姿势，但会生成不连续以及不自然的结果。
- 对于表情形变，大多数现有的研究方法都采用多阶段的框架，将音频特征映射到一个中间表示，例如人脸关键点以及 3DMM 系数来指导生成，但是人脸关键点太稀疏而不能详细地建模丰富且富有表现力的面部表情。3DMM 被认为是具有能够表示各种表情人脸的潜力，但是被观测到 blendshape 在相同表情上分布差异较大，会加剧音频到面部运动一对多的映射问题，且缺乏细粒度运动。

这些方法的缺点，倾向于限制生成内容的整体表情以及自然性，例如会在转换的过程中丢失自发手势的微妙之处或与语音的情感语气相关的细微表情。解决该问题的关键是摆脱强先验的限制并充分利用生成模型的潜力。

3.4.1 Conference

相关的国际会议主要包括，SIGGRAPH, SIGGRAPH Asia, CVPR, ICLR, ICCV, ECCV, AAAI, NeurIPS, ACM-MM. 论文查找工具：[Paper Copilot™ - Research Toolbox](#)

3.4.2 Keywords

- talking head/face
- audio-driven
- speech-driven
- co-speech
- facial animation
- portrait animation
- avatar animation
- 3D Face Generator and Animation

3.4.3 Goals

Audio-driven talking head generation 研究目标主要包括，

1. lib-sync 嘴唇同步
2. expressive facial expression 高表现力的面部表情
3. natural head pose generation 自然的头部姿势
4. high video quality 高质量视频

3.4.4 Challenges

Audio-motion Correlation

一个 audio 与 mouth motion 最相关, 但是很难建模 non-mouth motion, 因为弱相关性。

1. [VividTalk](#) 中通过引入 blendshape 和 vertex offset 作为中间表示, blendshape 提供全局的 coarse facial expression motion 而 lib-related vertex offset 提供局部的 fine-grained lib motion.

Mean Face

Audio 到 facial expression motions 有一对多的映射关系, 意味着同一个 audio 会对应不止一种正确 motion pattern, 致使出现没有个性化特点的平均脸现象。

1. [VividTalk](#) 中提出多分支 transformer-based generator 单独建模每一部分的 motion 并加入 subject-specific style 维持个性化特征。

3.4.5 Preliminaries

3D Morphable Model

在 3DMM 中, 3D face shape 表示为,

$$S = \bar{S} + \alpha U_{id} + \beta U_{exp} \quad (3.1)$$

其中, $\bar{S}$ 表示平均人脸形状, U_{id} 和 U_{exp} 分别是表示 identity 和 expression 的 PCA 主成分。 α, β 是生成一个 3D 人脸的身份和表情系数。

Audio Extractor

1. Preprocessing: Audio stream 音频流 S_{raw} , 即 audio waveform(音频波形), 被转换为 log-mel spectrogram (log-mel 频谱图) S_{lms} ;
2. Extractor: 利用 Audio Encoder 将 S_{lms} 提取音频特征 $f_s \in \mathcal{R}^{T \times F \times C_1}$, 其中 T, F 分别表示时间帧数以及频率通道。
3. Variation: 可以对提取出的特征在时间维度上求导数, 即 $f'_s = \mathcal{R}^{(T-1) \times F \times C_1}$.

Video Extractor

1. Preprocessing: Identity Image 记为 p_r ;
2. Extractor: 利用 Identity Encoder 将 p_r 提取图像特征 $f_p \in \mathcal{R}^{H \times W \times C_2}$.
3. Variation: 光流估计算法 (optical flow algorithm) 来表示连续帧的 optical flow, 用于衡量 video feature 的变化。

Modalities Fusion

Audio 与 Image 是两种模态，提取出的特征也首先在不同的特征空间中，其中最大的挑战在于如何将这两种模态信息相互融合。

1. LMG 中采用基于复制和拼接的方法，将 Audio Feature 沿着频率维度进行复制，即 $f'_s \in \mathcal{R}^{T \times F \times F \times C_1}$ 。而 Image Feature 当作 Video 的一帧图像，扩展为 $f'_p \in \mathcal{R}^{T \times H \times W \times C_2}$ 。当设定 $H = W = F$ 时，两者可以通过特征维度拼接起来，即 $f_v \in \mathcal{R}^{T \times F \times F \times (C_1 + C_2)}$ 。

Semantic Segmentation

1. BiSeNet：用于实时语义分割的双边分割网络

3.4.6 Benchmarks

3.4.7 Baseline

3.4.8 Backbones

3.4.9 Metrics

PSNR

PSNR (Peak Signal-to-Noise Ratio)，即峰值信噪比，是衡量图像质量的指标之一。基于均方误差 (MSE) 计算，通过量化像素级误差并将其转换为分贝 (dB) 单位。

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} (I(i, j) - K(i, j))^2 \quad (3.2)$$

其中， I 为原始图像， K 为是帧图像，图像尺寸为 $m \times n$ 。基于 MSE 可以进一步地计算出 PSNR 指标。

$$PSNR = 10 \times \log_{10} \left(\frac{MAX^2}{MSE} \right) \quad (3.3)$$

对于 8 位图像（每个像素值的编码范围为 0 ~ 255）， $MAX=255$ 。PSNR 值越高，表示图像质量越好，失真越小。

1. 高于 40dB：说明图像质量极好 (即非常接近原始图像);
2. 30—40dB：通常表示图像质量是好的 (即失真可以察觉但可以接受);
3. 20—30dB：说明图像质量差;
4. 低于 20dB：图像质量不可接受。

指标优势在于计算简单，适用于多种图像处理场景的横向对比。但与人眼感知不一致，PSNR 基于像素级误差，可能无法反映人眼对纹理、结构变化的敏感度。例如，模糊图像可能与噪声图像 PSNR 相近，但人眼感知差异显著。而且受限于色彩空间，默认计算基于亮度分量（如 YUV 的 Y 通道），对颜色失真不敏感。

SSIM

SSIM (Structural Similarity Index Measure, 结构相似性指数) 是一种用于衡量两幅图像相似度的全参考客观评价指标, 其核心思想是通过模拟人类视觉系统 (HVS) 对亮度、对比度和结构信息的敏感度进行综合评估。

SSIM 的计算基于滑动窗口实现, 即每次计算均从图片上取一个尺寸为 $N \times N$ 的窗口, 基于窗口计算 SSIM 指标, 遍历整张图像后再将所有窗口的数值取平均值, 作为整张图像的 SSIM 指标。假设 x 表示第一张图像窗口中的数据, y 表示第二张图像窗口中的数据, 通过以下三个维度计算原始图像与失真图像的相似度。

- 亮度 (Luminance)

基于图像局部均值计算, 反映亮度差异:

$$l(x, y) = \frac{2\mu_x\mu_y + c_1}{\mu_x^2 + \mu_y^2 + c_1} \quad (3.4)$$

其中, μ_x 和 μ_y 分别表示 x 和 y 的均值, $c_1 = (k_1L)^2$ 避免分母为 0, L 为像素动态范围 (如 8 位图像 $L = 255$), k_1 为小常数 (默认 0.01)。

- 对比度相似性 (Contrast)

基于标准差计算, 衡量纹理强度差异:

$$c(x, y) = \frac{2\sigma_x\sigma_y + c_2}{\sigma_x^2 + \sigma_y^2 + c_2} \quad (3.5)$$

其中, σ_x 和 σ_y 表示 x 和 y 图像块的标准差, $c_2 = (k_2L)^2$ 避免分母为 0, L 为像素动态范围 (如 8 位图像 $L = 255$), k_2 为小常数 (默认 0.03)。

- 结构相似性 (Structure)

通过协方差衡量像素间关系, 反映边缘和纹理的位置一致性:

$$s(x, y) = \frac{\sigma_{xy} + c_3}{\sigma_x\sigma_y + c_3} \quad (3.6)$$

其中, σ_{xy} 表示 x 和 y 之间的协方差, 且 $c_3 = c_2/2$ 。

最终, 综合以上三项得到最后的计算指标,

$$SSIM(x, y) = l(x, y)^\alpha \cdot c(x, y)^\beta \cdot s(x, y)^\gamma \quad (3.7)$$

如果, $\alpha = \beta = \gamma = 1$, 则常用的 SSIM 公式为,

$$SSIM(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)} \quad (3.8)$$

3.4.10 SOTA

3.4.11 Video-Editing

[Implicit-Keypoint-Based] [CVPR 2024 LivePortrait] Efficient Portrait Animation with Stitching and Retargeting Control

1. Views: 作者不同于主流基于扩散模型的方法, 提出了基于隐式关键点的视频驱动肖像动画框架, 能够明显地增强生成质量和泛化性能, 并利用小型 MLP 设计了一个先进的缝接模块和两个重定向模块实现平衡计算效率和可控性的目的。

2. Roadmap: 基于 Face vid2vid, 核心模块是构建的形变场。
3. Inspiration: 采用隐式关键点以及小型 MLP 给模型计算效率带来新的突破。




Figure 3. Pipeline of the second stage: stitching and retargeting modules training. After training the base model in the first stage, we freeze the appearance and motion extractor, warping module and decoder. Only the stitching module and the retargeting modules are optimized in the second stage. Please refer to Sec. 3.3 for details.

Figure 3.3: LivePortrait

3.4.12 Single-Image

[Diffusion-Based] [CVPR 2024 EMO] Emote Portrait Alive - Generating Expressive Portrait Videos with Audio2Video Diffusion Model under Weak Conditions

1. Goals: talking head video generation
2. Problem: 解决生成视频中表情的细微变化和自然性，能够捕获人脸的全部表情和独特风格。
3. Idea: 持有观点，摆脱强先验的限制并充分利用生成模型的潜力是创造高表现力人头说话视频的关键。
4. Solution: EMO 利用 Diffusion Model 的生成潜能直接捕获复杂的音频-视觉相关性，而没有依赖中间 3D 表示或预定义的运动模板，并引入弱监督条件稳定生成过程。
5. View:
 - 构造了一个庞大而多样的数据集,长达 250 小时的素材,涉及 speeches,file, television clips and singing performances. 并认为丰富多样的 videos 捕获了人类表情的声音样式的全部特点,是模型能够表现出所有人类表情和声音风格的原因。
 - 提出了一个新的评估指标, E-FID 用于评估生成视频的表现力。




Fig. 2: Overview of the proposed method. Our framework is mainly constituted with two stages. In the initial stage, termed Frames Encoding, the ReferenceNet is deployed to extract features from the reference image and motion frames. Subsequently, during the Diffusion Process stage, a pretrained audio encoder processes the audio embedding. The facial region mask is integrated with multi-frame noise to govern the generation of facial imagery. This is followed by the employment of the Backbone Network to facilitate the denoising operation. Within the Backbone Network, two forms of attention mechanisms are applied: Reference-Attention and Audio-Attention. These mechanisms are essential for preserving the character’s identity and modulating the character’s movements, respectively. Additionally, Temporal Modules are utilized to manipulate the temporal dimension, and adjust the velocity of motion.

Figure 3.4: EMO

[3DGS-Based] [ECCV 2024 TalkingGaussian] Structure-Persistent 3D Talking Head Synthesis via Gaussian Splatting




Fig. 2: Overview of TalkingGaussian. Learning from the speech video with training frames I , TalkingGaussian builds two separate branches to represent the dynamic face and inside mouth areas. Queried by the primitives in Persistent Gaussian Fields with parameters θ_C , a point-wise deformation can be predicted from Grid-based Motion Fields conditioned with audio feature a and upper-face expression e . After that, the 3DGS rasterizer renders the deformed 3D Gaussian primitives into 2D images observed from the given camera, which are then fused to synthesize the entire talking head.

Figure 3.5: TalkingGaussian

1. 研究目标: talking head synthesis

2. 研究问题:

解决对迅速变化外观的不准确预测带来的固有的面部扭曲问题。

3. 解决方案:

作者采用基于形变的网络，对姿势一致性的人头结构施加预测的形变位移，而不是直接预测形变后的人头，并提出了一个 Face-Mouth 分解模块，采用两个相互独立的网络分别学习人脸和嘴唇的形变。

4. 启发思路:

施加预测的形变位移，模块的分解能够提供更加准确的控制而且易于学习。

5. 技术路线:

基于 3DGS 构造高斯球面，首先学习一个基本的粗略平均场，然后通过 MLP 预测对应的位移以获得形变后的形变场，优化每个高斯球的属性实现最佳效果，再利用 3DGS 的光栅化器，计算逐像素的颜色，最终渲染出图像。

[3DMM-Based] [CVPR 2023 VividTalk] One-Shot Audio-Driven Talking Head Generation Based on 3D Hybrid Prior




Figure 2. Overview of the proposed VividTalk. Our framework is constituted by two cascaded stages. The Audio-To-Mesh stage maps the audio to non-rigid facial expression motion and rigid head pose, respectively, which results in the driven meshes. The Mesh-To-Video stage transforms the driven meshes into 2D dense motion and synthesizes high-visual quality and realistic talking head videos.

Figure 3.6: VividTalk




Figure 3. The structure of the proposed BlendShape and Vertex Offset Generator. The blendshape $\{\beta_{lip}, \beta_{other}\}$ provide the coarse facial expression motion with personal style, and the lip-related vertex offset $\tilde{O}_{lip}$ supplement the lip motion at a fine-grained level.




Figure 4. The two-phase training mechanism of the Learnable Head Pose Codebook. Note that we train the two phases separately, the decoder $\mathcal{D}$ and codebook $\mathcal{Z}$ are frozen during the training of the mapping phase.




Figure 4. The two-phase training mechanism of the Learnable Head Pose Codebook. Note that we train the two phases separately, the decoder $\mathcal{D}$ and codebook $\mathcal{Z}$ are frozen during the training of the mapping phase.

(a)

(b)

(c)

Figure 3.7: VividTalk Components

- Goals: talking head video generation
- Problem: 解决 talking head 中表情形变的细粒度控制以及头部姿势的自然性。
- Idea: 认为 3DMM 是具有能够表示各种表情人脸的潜力。
- Solution: 提出了一个 Audio-To-Mesh 和 Mesh-To-Video 两阶段的框架，第一阶段同时利用 blendshape 和 3D vertex 作为中间表示，并认为 blendshape 提供一个粗粒度运动，vertex 位移提供一个细粒度的唇部运动，以解决 facial motion 和 blendshape 分布的一对多映射问题。并采用一个多分支的 transformer 网络利用长期的音频语境建模与中间表示的相关性。对于刚性形变，将从音频中学习刚性头部运动转换为在离散且有限空间中的代码查询任务。将学习到的 motion 应用到 reference identity 以形成 driven meshes。第二阶段基于 driven meshes 和 reference image 渲染内外脸的投影纹理，以全面建模 motion。一个双分支 motion-vae 设计建模 dense motion，将作为生成器的输入以合成最终的 video。

5. View:

- 将 long-term audio context 映射到 blendshape 和 vertex 认为可以最大化模型的代表能力, 对于之前基于 3DMM coefficients 和 facial landmarks 的方法中间表示能力受限而难以生成嘴唇同步和逼真的 talking head.
- 认为 blendshape 和 vertex 同时作为中间表示可以分别建模 coarse motion 和 fine-grained motion。


[GAN-Based] [CVPR 2018 LMG] Lip Movements Generation at a Glance

Fig. 2: Full model illustration. Audio encoder and identity encoder extracts and fuses audio and visual embeddings. Audio-Identity fusion network fuses features from two modalities. Decoder expands fused feature to synthesized video. Correlation Networks are in charge of strengthening the audio-visual mapping. Three-Stream discriminator is responsible for distinguishing generated video and real video.

Figure 3.8: LMG




Fig. 3: Audio-Identity fusion. Transfer audio time-frequency features and image spatial features to video spatial-temporal features.

(a)




Fig. 5: Three-stream GAN discriminator illustration.

(b)

Figure 3.9: LMG Components

1. Goals: Lip Movements Generation
2. Problem: 首次考虑 Lip movements 和 audio 之间的相关性, 来解决单样本的 Lip movements generation。
3. Idea: 广泛探索了 audio-visual 相关性, 提出了一个基于复制和拼接的融合 audio 和 image embedding 的方法, 在利用单个 identity 的 image 可以生成多个 lip images, 并提出了一个新的相关性损失, 考虑 lip

movements feature 与 audio feature 变化规律之间的相关性。整体的模型是一个基于 GAN 的生成结构, 具有 end-to-end fashion, 先构建 Lip movements generator 然后通过设计的 discriminator 判别生成的 lip image.

4. View:

- Lip movements 经常在 audio signal 生成之前.
- Acoustic information 声学信息在不同 identities 之间也是与 lip movements 相关的, 因为共享 high-level 表示, 但是两种模态在时间维度上的变化规律是更相关的, 即 acoustic feature with visual feature of lip shape 相关性小于 variation of audio feature with variation of visual feature.
- 而这种特征的变化, 作者采取在时间维度上求导来实现。

[GAN-Based] [CVPR 2019 FacialAnimation] Realistic Speech-Driven Facial Animation with GANs

[GAN-Based] [CVPR 2017 Speech2Vid] You said that?

3.5 Audio-driven Human Video Generation

Audio-driven 的 Human Video Generation 旨在从音频中利用参考图像生成具有同步的面部表情和身体姿势的视频, full-body or half-body。实际上, 大部分在 Human Video Generation 领域的研究工作主要关注于 talking head generation, 而在此 Human Video Generation 代表那些具有手势或其它部位姿势的研究, 最近相关的工作通常存在不能够生成丰富的身体运动姿势以及缺乏对多样性场景泛化能力的问题。

这一研究方向中最基本性的挑战在于人体结构作为一个多关节铰接系统的复杂性, 使得预测与音频同步的丰富手势特别困难。

3.5.1 Single-Image

[Diffusion-Based] [CVPR 2025 EMO2] End-Effector Guided Audio-Driven Avatar Video Generation

1. Goals: human video generation
2. Problem: 解决协同语音手势视频的生成, 识别出音频特征和全身手势的弱对应性。
3. Contribution: 识别出音频和手部运动的强相关性, 基于此提出了一个新颖的两阶段音频驱动的 talking head 方法, 能够同步生成高表现力的面部表情和手势。
4. Solution: EMO2 分为两个阶段, 第一个阶段利用音频信号和手部姿势的强相关性 (Co-speech gesture generation), 直接从音频中生成手部姿势。在第二阶段中, 利用 Diffusion 模型, 结合生成的手部姿势生成具有逼真面部表情和身体动作的视频帧。




Figure 2. Overview of the stage 1 hand motion generation framework. The framework includes serveral DiT blocks as backbone. Audio embeddings are injected via cross-attention, style and speed embeddings are added on timestep, previous motion latent sequence is concatenated on current noisy motion latent sequence for smooth transition. Hand masks that mask out invisible hands frames are directly added on noisy motion latent.

Figure 3.10: EMO2: Stage 1




Figure 3. The overview of the Stage 2 video generation pipeline, which is based on the Parallel Reference Network structure. The ReferenceNet extracts visual features from both the reference image and motion frames. The MANO maps and keypoint maps generated in Stage 1 are passed through the denoising Backbone Network to guide the character's motion. Additionally, trainable hand confidence embeddings enhance the quality of the generated hands. The audio embeddings are injected to ensure synchronization between audio and visual elements.

Figure 3.11: EMO2: Stage 2

Chapter 4

Coding & Skills

4.1 Environment Configuration

4.1.1 Miniconda Installation On Linux

```
# Fetch the miniconda script
export HOME=$PWD
wget -q https://repo.anaconda.com/miniconda/ \
Miniconda3-py37_4.12.0-Linux-x86_64.sh -O miniconda.sh
sh miniconda.sh -b -p $HOME/miniconda3
rm miniconda.sh
export PATH=$HOME/miniconda3/bin:$PATH

# Initialize conda
source $HOME/miniconda3/etc/profile.d/conda.sh
hash -r
conda config --set always_yes yes --set changeps1 yes

# Create new environment
conda create -n my_env python=3.8
conda activate my_env
```

4.1.2 Pytorch3d Installation on Windows

Windows 下 3D Vision 环境配置 (GaussianAvatars)

4.1.3 Ninja Installation on Linux

```
1 apt install ninja-build
```

4.2 Python Debugging

4.2.1 Visual Studio Code Debugging Configuration

为了能够在 Visual Studio Code 中调试 Python 项目，首先需要安装 Python 和 Python Debugger 扩展。然后如图4.1所示，点击左侧的调试按钮，添加 launch.json 文件，并根据代码的配置示例创建项目配置。




Figure 4.1: Python 项目调试配置

```
1 {
2     "version": "0.2.0",
3     "configurations": [
4         {
5             // 配置名称，将在调试配置下拉列表中显示
6             "name": "Python: Run My Module",
7             "type": "python", // 调试类型，这里是 Python
8             "request": "launch", // 请求类型，这里选择 "launch" 表示启动调试
9             "program": "${file}",
10            "cwd": "${workspaceFolder}", // 当前工作目录设置为项目文件夹
11            // 使用 VSCode 的集成终端显示输出
12            "console": "integratedTerminal",
13            "args": [
14                "--batch", "64",
15                "--epoches", "30",
16            ], // 如果需要传递命令行参数，可以在这个列表中添加
17            // 指定 Python 解释器的路径
```

```

18 "pythonPath": "D:/anaconda3/envs/d2l/python.exe",
19 "env": {}, // 环境变量字典，可以在这里添加自定义环境变量
20 // 如果需要从文件加载环境变量，可以指定.env 文件的路径
21 "envFile": "${workspaceFolder}/.env",
22 // 是否在程序启动时立即暂停，以便在第一行代码之前设置断点
23 "stopOnEntry": false,
24 "showReturnValue": true, // 是否在调试过程中显示函数的返回值
25 "redirectOutput": true // 是否将程序输出重定向到调试控制台，而不是终端
26 }
27 }
28 }

```

在完成以上准备工作后，设置程序断点，然后直接点击调试三角形按钮，即可开始调试，如图 4.2 所示。




Figure 4.2: Python 程序调试示例

【内嵌调试终端找不到环境变量解决办法】




Figure 4.3: 弹出的外部终端

在一些情况下, VS Code 中调试程序无法找到环境变量, 但在 CMD 终端中可以成功运行。这样的情况, 解决办法也很简单, 将调试的终端更改为外部终端即可, 即配置 "console": "externalTerminal" 参数。配置完成后, 重新调试程序, 会调用外部的终端作为调试终端, 如图4.3所示。

4.3 Bugs with Solution

4.3.1 Version Conflict

1. • Q: Numpy 版本和 Pytorch 版本不兼容。
- A: 尝试更换 Numpy 版本。

```
1      assert (self.faces==torch.from_numpy(flame_model.f.astype( \
2      'int64'))).all()
3      RuntimeError: Numpy is not available
```

2. • Q: PIL 版本更新问题。
- A: 在 pillow 的 10.0.0 版本中, ANTIALIAS 方法被删除了, 通过命令 `pip install Pillow==9.5.0` 安装旧版本即可。

```
1      AttributeError: module 'PIL.Image' has no attribute 'ANTIALIAS'
```

3. • Q: PyAudio 安装问题。
- A: PyAudio 官方仅支持部分的 Python 版本, 如果需要安装对应 Python=3.9 的版本, 需要从非官方安装包进行安装——[清华镜像网站](#)。

```
1  LibMambaUnsatisfiableError: Encountered problems while solving:
2      - package pyaudio-0.2.11-py27h0c8e037_1 requires python >=2.7, \
3      <2.8.0a0, but none of the providers can be installed
4
5  Could not solve for environment specs
6  The following packages are incompatible
7  └─ pin-1 is installable and it requires
8  ☒   └─ python 3.9.* , which can be installed;
9  └─ pyaudio is not installable because there are no viable options
```

4.4 Coding Tricks

4.4.1 Python

1. 路径管理库 pathlib

- 类型指定: `input: Path`
- 路径赋值: `'../../dir'`
- 判断路径是否存在: `Path.exists()`
- 获取父目录: `Path.parent`
- 通配符匹配: `Path.glob()`

2. 数字可读性 8_000: Python 中数字表示含有下划线时, 仅用于提高大数字的可读性, 对数值没有影响。

3. 解析指定命令行参数 parser

```
1 args = parser.parse_args(sys.argv[1:])
```

其中, `sys.argv[0]` 是 Python 脚本名称, `sys.argv[1]` 包含所有实际的命令行参数。例如, 启动命令为 `python train.py --batch-size 32 --learning-rate 0.001` 对应, `sys.argv[0]` 表示 `train.py`, `sys.argv[1]` 表示 `['--batch-size', '32', '--learning-rate', '0.0']`。

4. with 同时打开多个文件

```
1 with open(scene_info.ply_path, 'rb') as src_file, \
2     open(os.path.join(self.model_path, "input.ply"), 'wb') \
3     as dest_file:
4     dest_file.write(src_file.read())
```

5. `tensor.scatter_add_` 函数用法

`scatter_add_` 是 PyTorch 中的一个张量操作函数, 用于将一个张量中的值按照指定的索引累加到另一个张量中。

```
1 torch.Tensor.scatter_add_(dim, index, src) -> Tensor
```

`scatter_add_` 会根据 `index` 中的索引, 将 `src` 中的值累加到目标张量 (即调用该方法的张量) 的指定位置。

下面代码实现了绑定计数的功能, 根据绑定关系 (下标索引) 将全 1 向量统计到每个面中。

```
1 # 创建计数器和绑定关系
2 counter = torch.zeros(5, device="cuda") # 假设有 5 个面
3 # 4 个点绑定到不同的面
4 binding = torch.tensor([0, 2, 2, 1], device="cuda")
5 # 使用 scatter_add_ 统计每个面绑定的点数
6 counter.scatter_add_(0, binding,
7     torch.ones_like(binding, dtype=counter.dtype, device="cuda"))
8
9 print(counter) # 输出: tensor([1, 1, 2, 0, 0])
```

6. register_buffer 作用

register_buffer 是 PyTorch 中 nn.Module 的一个方法，用于注册不需要计算梯度的张量。

```
1 def register_buffer(self, name: str, tensor: Optional[Tensor],\
2                       persistent: bool = True)
```

register_buffer 的这些数据是模型状态的一部分，但不需要梯度；在模型移动到 GPU 时会自动转移，会被保存在模型的 state_dict 中。

通过注册缓冲变量后，可以当作属性直接访问使用：

```
1 self.register_buffer(
2     "v_template",
3     to_tensor(to_np(flame_model.v_template), dtype=self.dtype)
4 )
5 # 1. 直接访问
6 vertices = self.v_template
7
8 # 2. 获取所有 buffers
9 for name, buffer in self.named_buffers():
10     print(f"Buffer {name}: {buffer.shape}")
```

最后总结一下，torch.nn 库中 Parameter 和 Buffer 的区别：

- Parameter: 需要梯度计算，会被优化器更新，用于模型权重。
- Buffer: 不需要梯度，不会被优化器更新，用于常量或中间状态。

7. @dataclass 装饰器使用

@dataclass 是 Python 3.7 引入的一个装饰器，用于自动生成数据类的特殊方法，比如 __init__、__repr__、__eq__ 等，常用作配置类、数据传输对象以及不可变数据结构。

```
1 from dataclasses import dataclass
2
3 # 不使用 @dataclass
4 class PersonWithoutDecorator:
5     def __init__(self, name: str, age: int):
6         self.name = name
7         self.age = age
8
9     def __repr__(self):
10         """
11         用于生成字符串表示，主要控制输出格式。
12         """
```

```
13         return f"Person(name='{self.name}', age={self.age})"
14
15     def __eq__(self, other):
16         """
17         实现相等比较，重载 == 运算符。
18         """
19         return self.name == other.name and self.age == other.age
20
21 # 使用 @dataclass - 自动生成上述所有方法
22 @dataclass
23 class Person:
24     name: str
25     age: int
26
27 @dataclass(frozen=True) # frozen=True 使对象不可变
28 class Point3D:
29     x: float
30     y: float
31     z: float
32
33 PWD = PersonWithoutDecorator("Zhihao Li", 22)
34 PWDold = PersonWithoutDecorator("Zhihao Li", 23)
35 Per = Person("Zhihao Li", 22)
36 point = Point3D(1, 2, 3)
37
38 # 判断比较以及装饰器
39 print(PWD)
40 print(PWD == PWDold)
41 print(Per)
42
43 # 判断不可变数据结构
44 print(point)
45 try:
46     point.x = 3
47     print("successfully modified the data")
48     print(point)
49 except:
50     print("not support modifying the data")
51     print(point)
52
53 # results
```

```

54 Person(name='Zhihao Li', age=22)
55 False
56 Person(name='Zhihao Li', age=22)
57 Point3D(x=1, y=2, z=3)
58 not support modifying the data
59 Point3D(x=1, y=2, z=3)

```

8. field 函数用法

```

1 class Config(Mini3DViewerConfig):
2     pipeline: PipelineConfig = field(default_factory=PipelineConfig)

```

从上面可以分析得出，PipelineConfig 是一个类，每个 Config 实例都需要一个独立的 PipelineConfig 实例，如果直接写 pipeline: PipelineConfig = PipelineConfig()，所有 Config 实例会共享同一个 PipelineConfig 实例。

因此 field 函数主要用于在初始化中生成动态的实例或数据，常见于类初始化中。

```

1 from dataclasses import field
2
3 field(
4     default_factory=PipelineConfig, # 用于生成默认值的工厂函数
5     init=True,                      # 是否作为 __init__ 参数
6     repr=True,                      # 是否包含在 repr 中
7     compare=True,                   # 是否参与比较
8     hash=None,                      # 是否参与哈希计算
9     metadata=None                   # 字段元数据
10 )

```

```

1 from dataclasses import dataclass, field
2
3 # 可变默认值
4 @dataclass
5 class Example:
6     list_field: list = field(default_factory=list)
7     dict_field: dict = field(default_factory=dict)
8
9 exp1 = Example([1,2], {"1":3})
10 exp2 = Example([2,2], {"1":3, "2":3})
11 print(exp1)

```

```

12 print(exp2)
13
14 exp1.list_field.append(3)
15 print(exp1)
16
17 # 定义对象实例
18 class Number:
19     def __init__(self):
20         self.number = 0
21
22 @dataclass
23 class Config:
24     number: Number = field(default_factory=Number)
25
26 cfg1 = Config()
27 cfg2 = Config()
28 cfg1.number.number = 1
29 cfg2.number.number = 2
30 print(cfg1.number.number)
31 print(cfg2.number.number)
32
33 # results
34 Example(list_field=[1, 2], dict_field={'1': 3})
35 Example(list_field=[2, 2], dict_field={'1': 3, '2': 3})
36 Example(list_field=[1, 2, 3], dict_field={'1': 3})
37 1
38 2

```

9. tyro.cli 函数用法

tyro.cli() 是一个用于将 dataclass 转换为命令行参数的工具。

预先定义的 dataclass 后，通过语句 `cfg = tyro.cli(Config)` 将其转换为支持命令行参数的配置，之后便可以在命令后中指定对应的参数，作用等同于 `argparse`。

```

1 @dataclass
2 class Config(Mini3DViewerConfig):
3     pipeline: PipelineConfig = field(default_factory=PipelineConfig)
4     cam_convention: Literal["opengl", "opencv"] = "opencv"
5     point_path: Optional[Path] = None
6
7 python local_viewer.py \
8     --point_path path/to/point_cloud.ply \

```

```

9      --cam_convention opencv \
10     --sh_degree 3 \
11     --fps 25

```

10. setattr 函数用法

setattr 主要用于设置对象的实例属性。

```

1  class Struct(object):
2      def __init__(self, **kwargs):
3          for key, val in kwargs.items():
4              setattr(self, key, val)
5
6  # 创建实例并设置属性
7  config = Struct(name="FLAME", version="1.0", features=["shape", \
8                "expression"])
9
10 # 访问属性
11 print(config.name)      # 输出: "FLAME"
12 print(config.version)   # 输出: "1.0"
13 print(config.features)  # 输出: ["shape", "expression"]
14
15 # 单独使用该方法设置对象 config 的属性
16 setattr(config, "test", "val")
17 print(config.test)
18
19 # results
20 FLAME
21 1.0
22 ['shape', 'expression']
23 val

```

4.4.2 Cmd On Windows

1. 打印当前目录路径 pwd

```

1  PS D:\ZHaoLi\02.Hobbies\01.Blog> pwd
2
3  Path
4  ----
5  D:\ZHaoLi\02.Hobbies\01.Blog

```

Chapter 5

Grammar & Writings

5.1 Mathematical Symbols in LaTeX

5.1.1 集合及向量空间的表示

Rendered Symbol	Source Code	Rendered Symbol	Source Code
S	<code>$\mathcal{S}$</code>	$\mathbb{R}$	<code>$\mathbb{R}$</code>

Table 5.1: LaTeX Symbols and Their Source Code

5.1.2 运算符号

Rendered Symbol	Source Code	Rendered Symbol	Source Code
$\ll$	<code>$\ll$</code>	$\mathbb{R}$	<code>$\mathbb{R}$</code>

Table 5.2: LaTeX Symbols and Their Source Code

5.1.3 多行公式

在 Latex 中编写多行公式, 一般采用 `\begin{cases} \dots \end{cases}` 和 `\begin{dcases} \dots \end{dcases}` 表示分段函数, 并且它们的主要区别在于公式的排版方式:

1. `{cases}`: 采用普通的数学样式 (textstyle), 适用于行内或小型公式。生成的分段函数会比较紧凑, 分式等数学表达式会缩小。

```
1 \begin{align}
2   l_0(x) =
3   \begin{cases}
4     \frac{(x - x_1)}{x_0 - x_1} , x \in [x_0, x_1] \\
5   \end{cases}
```

```

6      l_i(x)=
7      \begin{cases}
8          \frac{x-x_{i-1}}{x_0-x_1}, x \in [x_0, x_1], \\
9          0, \text{ 其他}
10     \end{cases}
11 \end{align}

```

$$l_0(x) = \begin{cases} \frac{x-x_1}{x_0-x_1}, x \in [x_0, x_1] \\ 0, \text{ 其他} \end{cases} \quad l_i(x) = \begin{cases} \frac{x-x_{i-1}}{x_i-x_{i+1}}, x \in [x_i, x_{i+1}] \\ 0, \end{cases} \quad (5.1)$$

2. {dcases}: 采用 display 数学样式 (displaystyle), 适用于更清晰的公式排版。适用于较大的数学符号 (如分式、求和符号等), 使其在每一行都保持较大的尺寸。

```

1 \begin{align}
2   & l_0(x) = \begin{dcases}
3       \frac{(x - x_1)}{x_0 - x_1}, & x \in [x_0, x_1] \\
4       0, & \text{其他},
5   \end{dcases} \\
6   & l_i(x) = \begin{dcases}
7       \frac{x-x_{i-1}}{x_i-x_{i+1}}, & x \in [x_{i-1}, x_i], \\
8       \frac{x-x_{i+1}}{x_i-x_{i+1}}, & x \in [x_i, x_{i+1}] \\
9       0, & \text{其他}
10  \end{dcases} \quad \& i = 1, 2, \dots, n-1,
11 \end{align}

```

$$l_0(x) = \begin{cases} \frac{(x-x_1)}{x_0-x_1}, & x \in [x_0, x_1] \\ 0, & \text{其他}, \end{cases} \quad (5.2)$$

$$l_i(x) = \begin{cases} \frac{x-x_{i-1}}{x_i-x_{i+1}}, & x \in [x_{i-1}, x_i], \\ \frac{x-x_{i+1}}{x_i-x_{i+1}}, & x \in [x_i, x_{i+1}] \\ 0, & \text{其他} \end{cases} \quad i = 1, 2, \dots, n-1, \quad (5.3)$$

5.2 Extended Markdown

在 Markdown 文件中实现下拉式列表, 可以通过 'html' 语言实现, 具体语法如下:

```

1 <details>
2   <summary> Dependencies (click to expand) </summary>
3

```



```
4      ## Dependencies
5      - PyTorch 1.4
6      - matplotlib
7      - numpy
8      - imageio
9      - imageio-ffmpeg
10     - configargparse
11
12     The LLFF data loader requires ImageMagick.
13 </details>
```

5.3 Elaborating Ideas

1. 首先阐述问题的必要性，然后引出自己的方法。

Chapter 6

Templates & Tools

6.1 Templates

6.1.1 Loss Calculation

L1 Loss

L1 损失也称为平均绝对误差 (MAE)，计算公式如6.1。对异常值不敏感，适合希望减少大误差影响的场景；在零点不可导，优化时需使用次梯度（如符号函数）。

$$L1_{loss} = \frac{1}{N} \sum_{i=1}^N |y_{pred}^i - y_{true}^i| \quad (6.1)$$

```
1 def l1_loss(pred, gt):  
2     return torch.abs((pred - gt)).mean()
```

在 Pytorch 中，一般通过 `torch.nn` 实现。

```
1 import torch  
2 import torch.nn as nn  
3  
4 # 默认是 'mean'（平均），也可设为 'sum'（求和）或 'none'（保留逐元素误差）  
5 criterion = nn.L1Loss(reduction='mean')  
6 loss = criterion(y_pred, y_true)
```

L2 范数

L2 范数是数学和机器学习中广泛使用的一种“向量长度”或“距离度量”工具，本质上是计算向量元素的平方和的平方根。对于一个向量而言，其 L2 范数表示为公式6.2所示。

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2} \quad (6.2)$$

对于论文中的公式6.3，对于向量范数加入了阈值截断，其中 μ 表示高斯球的中心坐标， ϵ 表示设定的阈值。

$$L_{pos} = \max(\|\mu\|_2 - \epsilon_{pos}, 0) \quad (6.3)$$

在代码实现中，对于最值阶段的操作选取了 F.relu 激活函数实现，为了约束高四点在局部坐标系的位置不能偏差坐标系原点太大，先计算局部高斯点坐标的范数，然后减去阈值，并通过激活函数判断是否超过阈值，保证在阈值范围内的高斯点是合理的。

```
1 F.relu(gaussians._xyz[visibility_filter].norm(dim=1) - \
2      opt.threshold_xyz).mean()
```

L3 范数

L3 范数是 Lp 范数的一种 (p=3)，表示向量元素绝对值的三次方之和的三次方根。它在数学上有明确的定义，但在实际应用（如机器学习、优化）中并不常见。对于一个向量而言，其 L3 范数表示为公式6.4所示。

$$\|x\|_3 = (x_1^3 + x_2^3 + \cdots + x_n^3)^{1/3} \quad (6.4)$$

Scaling Loss

在控制高斯球在 x, y, z 三个方向上的缩放时，应当调整 L2 Norm 的顺序，如公式6.5所示。

$$L_{scaling} = \|\max(s - \epsilon_{scaling}, 0)\|_2 \quad (6.5)$$

在代码中实现如下，通过指数函数将缩放系数进一步放大，然后对于三个方向的缩放先进行阈值判断，通过激活函数滤除阈值范围内的情况，最后再计算 L2 范数作为损失项。

```
1 F.relu(torch.exp(gaussians._scaling[visibility_filter]) - \
2      opt.threshold_scale).norm(dim=1).mean()
```

Cosine Similarity Loss

给定两个向量 $\vec{u}, \vec{v}$ ，希望计算两个向量的夹角余弦值以此衡量之间的相似度，只关注向量的方向而忽视向量的大小关系，对长度不敏感，适合高维稀疏数据。

$$\text{Cos} \langle \vec{u}, \vec{v} \rangle = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\| \|\vec{v}\|} \quad (6.6)$$

```
1 class CosineSimiLoss(nn.Module):
2     def __init__(self, batch_size):
3         super(CosineSimiLoss, self).__init__()
4         self.ones = Variable(torch.ones(batch_size)).cuda(async=True)
5         self.l1_loss = nn.L1Loss()
```

```

6
7     def forward(self, input1, input2):
8         cos_simi = F.cosine_similarity(input1, input2, eps=1e-5)
9         return self.l1_loss(cos_simi, self.ones)

```

Pixel-level Reconstruction Loss

Pixel-level Reconstruction Loss（像素级重建损失）用于衡量生成图像与原始图像在像素级别上的差异，确保生成图像在像素级别上尽可能接近原始输入，推动模型学习细节特征，常见的方式有 MSE 和 MAE。

优点是计算简单高效，直接约束像素匹配。缺点是可能导致生成结果过于平滑（丢失高频细节），例如合成的视频帧流畅度较低，需配合其他损失（如 SSIM、感知损失）提升视觉效果。

1. 均方误差（MSE, Mean Squared Error）

$$MSE = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2 \quad (6.7)$$

N 表示像素总数，通过图像通道、高度与宽度的乘积计算。

2. 平均绝对误差（MAE, Mean Absolute Error）

$$MAE = \frac{1}{N} \sum_{i=1}^N |x_i - \hat{x}_i| \quad (6.8)$$

```

1  def pixel_mse_loss_np(original: np.ndarray, reconstructed: np.ndarray):
2      """MSE"""
3      return np.mean((original - reconstructed) ** 2)
4
5  def pixel_mae_loss_np(original: np.ndarray, reconstructed: np.ndarray):
6      """MAE"""
7      return np.mean(np.abs(original - reconstructed))

```

Perceptual Loss

Perceptual Loss 的核心思想是通过预训练的卷积神经网络（如 VGG19）提取图像的中间层特征，比较生成图像与真实图像在特征空间的差异。损失函数通常是各层特征的 均方误差（MSE）的加权和。

优点具有感知一致性：确保生成图像在结构、纹理等高层特征上与真实图像接近，而非仅像素级相似。提升生成质量：常用于 GANs、图像修复（如 Inpainting）、风格迁移等任务，减少生成模糊或失真。缺点是，权重调节困难，且忽略底层细节。

$$L_{perceptual} = \sum_i w_i \cdot \|F_i(G) - F_i(R)\|^2 \quad (6.9)$$

其中， F_i 表示 VGG19 中第 i 层的输出特征， w_i 表示可调节的权重，而 G, R 分别表示生成和真实图像。


```

1 import torch
2 import torch.nn as nn
3 import torchvision.models as models
4 from torchvision import transforms
5
6 class PerceptualLoss(nn.Module):
7     def __init__(self, weights=None):
8         super().__init__()
9         # 加载 VGG19 的特征提取层（去掉全连接层）
10        self.vgg = models.vgg19(pretrained=True).features.eval()
11        self.weights = weights or [1.0, 1e-4, 1e-9, 1e-13, 1e-16]
12
13        # 输入归一化参数（与 VGG 预训练一致）
14        self.mean = [0.485, 0.456, 0.406]
15        self.std = [0.229, 0.224, 0.225]
16        self.transform = transforms.Compose([
17            transforms.Resize((224, 224)),
18            transforms.Normalize(mean=self.mean, std=self.std)
19        ])
20
21    def forward(self, generated, real):
22        gen = self.transform(generated)
23        real = self.transform(real)
24        loss = 0.0
25        for layer, w in zip(self.vgg, self.weights):
26            gen_feat = layer(gen)
27            real_feat = layer(real)
28            loss += w * nn.functional.mse_loss(gen_feat, real_feat)
29        return loss

```

6.1.2 Computer Graphics

1. OpenGL/Blender camera axes(Y up, Z back) to COLMAP(Y down, z forward)



```

8           /
9         ↙
10        Z (视线方向)

```

```

1  # NeRF 'transform_matrix' is a camera-to-world transform
2  c2w = np.array(frame["transform_matrix"])
3  c2w[:3, 1:3] *= -1
4
5  # get the world-to-camera transform and set R, T
6  w2c = np.linalg.inv(c2w)
7  # R is stored transposed due to 'glm' in CUDA code
8  R = np.transpose(w2c[:3, :3])
9  T = w2c[:3, 3]

```

2. 视场角与焦距的转换

根据前面推导出的公式1.7，即可推导出相互转换关系。

```

1  def fov2focal(fov, pixels):
2      return pixels / (2 * math.tan(fov / 2))
3
4  def focal2fov(focal, pixels):
5      return 2 * math.atan(pixels / (2 * focal))

```