

Motivation

随着面向视觉语言模型的提示学习的迅速发展，解决标签噪声的鲁棒性提示学习也因此被提出，以往的研究方法旨在解决伪标签的翻新问题，并没有关注于伪标签的质量性。然而，低质量的伪标签不仅对模型学习没有帮助，而且会造成更严重的学习误导。旨在解决这个问题，我们提出了一个用于伪标签翻新和质量评估的新框架。具体来讲，整体框架主要包含两个阶段：

1) 噪声感知的伪标签翻新：我们基于噪声感知的自适应阈值分别翻新 clean, noisy and confused 子集以获得适应于高低水平噪声不同情形的伪标签；2) BLIPEvaluator，为了降低模型自我确认偏差，我们采用BLIP视觉语言模型作为质量评估器，对细致化翻新的伪标签构建文本特征提示以获得高低质量伪标签子集，通过改进的 MixMatch 操作进一步提升模型学习效果。

MixDivide：噪声感知的伪标签翻新

由于下游任务的多样以及复杂性，所获得的数据集很可能包含从低到高的一系列噪声水平，并且具有复杂且严峻的噪声类型。这不仅对伪标签翻新造成了极大的困扰，而且会引起模型对样本判断的波动性，我们认为，当面对这种更加复杂严峻的任务时，仅仅通过划分为 clean 和 noisy 子集难以兼顾到所有不同难度的情形。例如，在低水平的噪声情形下，模型判断为 clean 的样本数会较多，此使应该尽最大程度保留原始的样本标签以进行翻新，相反，在高噪声水平下，模型判断为 noisy 的样本数会较多，此使应该尽最大程度依赖于模型的预测以进行翻新。因此我们将提出了基于噪声感知的自适应阈值将数据集划分为 clean, noisy and confused 子集的划分机制，以获得适应于高低水平噪声不同情形。

对于模型预测存在的波动性，我们利用共识约束机制以最大化模型预测共识，同时这也有利于解决 confused 子集，这部分是模型难以准确处理的“棘手”样本。

Quality Evaluation：基于BLIP的伪标签质量评估

对于翻新的伪标签，在线学习的模型往往会陷入自我确认的误差，结合学习模型的预测会在一定程度上使得伪标签的翻新偏离正确的方向。这种情况的出现，我们认为是缺乏伪标签质量评估机制的缘故，对于涉及自我学习、自我确认的机制，一个客观且准确的评估器是非常必要的。

鉴于大规模数据训练的视觉语言模型所具有的强大表现力，VisionQuestionAnswer 的研究也具有极大的进步，因此结合鲁棒性提示学习的特点，我们利用预训练的BLIP模型对翻新的伪标签重构文本提示特征，并挖掘well-learned的上游知识能力对伪标签的质量进行评估，以获得低质量和高质量伪标签组。

在少样本学习中，任何一个学习样本都是极其珍贵的，因此我们通过扩展的 MixMatch机制以充分利用高低质量伪标签组：对于低质量伪标签组，通过引入高质量标签组进行简单的 MixMatch以进行质量提升，并保留高质量伪标签组作为学习样本，以获得鲁棒且更高质量的监督学习。

算法伪代码

Algorithm Pseudo Labels Generation and Evaluation for Robust Prompt Learning

Input: Training dataset $\mathcal{D} = (X, Y)$, Prompt Learner $\Theta^{(1)}$, Featured Prompt Learner $\Theta^{(2)}$, Pretrained BLIP, GMM, consensus regularization parameter λ , sharpen parameter $\mathcal{T}$, confidence threshold θ , epoch E

Procedure:

$\Theta^{(1)}, \Theta^{(2)} = \text{WarmUp}(\Theta^{(1)}, \Theta^{(2)}, \mathcal{D})$ // only for 1 epoch

while $e < E$ **do**

 // Pseudo Labels Generation and Evaluation

if $e \bmod 2 = 0$ **then**

 // step 1: eval the dataset and calculate the two thresholds

$P^{(1)}, P^{(2)} = \text{CLIP}(\Theta^{(1)}, X), \text{CLIP}(\Theta^{(2)}, X)$

$\mathcal{L} = \text{CE}(P^{(1)}, Y) + \text{CE}(P^{(2)}, Y) + \lambda * \text{KL}(P^{(1)}, P^{(2)})$

$\mu_c, \sigma_c, \mu_n, \sigma_n, W = \text{GMM}(\mathcal{L})$

$\alpha_1, \alpha_2 = \text{MixDivide}(\mu_c, \sigma_c, \mu_n, \sigma_n, \theta)$

$\mathcal{L}_L, \mathcal{L}_R = \min(\alpha_1, \alpha_2), \max(\alpha_1, \alpha_2)$

 // step 2: divide the training dataset by the two thresholds

$X^* \leftarrow \{(x_i, y_i) | \mathcal{L}_i \leq \mathcal{L}_L, (x_i, y_i) \in (X, Y)\}$ // clean

$C^* \leftarrow \{(x_i, y_i, w_i, p_i^{(1)}, p_i^{(2)}) | \mathcal{L}_L < \mathcal{L}_i < \mathcal{L}_R, (x_i, y_i, w_i, p_i^{(1)}, p_i^{(2)}) \in (X, Y, W, P^{(1)}, P^{(2)})\}$

 // confused

$U^* \leftarrow \{(x_i, p_i^{(1)}, p_i^{(2)}) | \mathcal{L}_i \geq \mathcal{L}_R, (x_i, p_i^{(1)}, p_i^{(2)}) \in (X, P^{(1)}, P^{(2)})\}$ // noisy

 // step 3: refurbish the pseudo label of confused and noisy sub-dataset

for $(x_i, y_i, w_i, p_i^{(1)}, p_i^{(2)})$ in C^* **do**

$\hat{y}_i = w_i * y_i + (1 - w_i) * (p_i^{(1)} + p_i^{(2)})/2$

end for

for $(x_i, p_i^{(1)}, p_i^{(2)})$ in U^* **do**

$\hat{y}_i = (p_i^{(1)} + p_i^{(2)})/2$

end for

$\mathcal{D}^* = [X^*, C^*, U^*] = (X, \hat{Y})$

 // step 4: quality evaluation for the generated pseudo labels

$S = \text{BLIP}(\mathcal{D}^*)$

$P^S = \text{GMM}(S)$

$\mathcal{D}_H^* \leftarrow \{(x_i, \hat{y}_i) | P_i^S \geq \tau, (x_i, \hat{y}_i) \in (X, \hat{Y})\}$ // high quality set

$\mathcal{D}_L^* \leftarrow \{(x_i, \hat{y}_i) | P_i^S < \tau, (x_i, \hat{y}_i) \in (X, \hat{Y})\}$ // low quality set

end if

for $i = 1$ to I **do**

 Fetch the batch B_H^*, B_L^* from $\mathcal{D}_H^*, \mathcal{D}_L^*$

$\mathcal{D}_{\text{MixMatch}}^* = \text{MixMatch}(\mathcal{D}_L^*)$

$\mathcal{D}_{\text{Learning}}^* = [\mathcal{D}_H^*, \mathcal{D}_{\text{MixMatch}}^*] = (X_L, Y_L)$

$L_1, L_2 = \text{CE}(\text{CLIP}(\Theta^{(1)}, X_L), Y_L), \text{CE}(\text{CLIP}(\Theta^{(2)}, X_L), Y_L)$

$\Theta^{(1)}, \Theta^{(2)} = \text{SGD}(L_1, \Theta^{(1)}), \text{SGD}(L_2, \Theta^{(2)})$

end for

end while
